

# Selezione Dinamica della Dimensione del Campione

in Metodi di Ottimizzazione per il Machine Learning

---

La tesi presenta la selezione dinamica della dimensione del campione negli algoritmi di ottimizzazione per il machine learning su larga scala, fondandosi sul lavoro di Byrd, Chin, Nocedal e Wu (2012). L'idea centrale: invece di fissare a priori la dimensione del batch, si decide durante l'algoritmo se e quando aumentarla, guidandosi da stime statistiche della varianza del gradiente stocastico. Il lavoro offre un'analisi teorica completa della convergenza, il miglioramento di alcuni risultati mediante disuguaglianze più strette e un'implementazione Python dei quattro algoritmi principali: Dynamic GD, Newton-CG, estensione  $L_1$  e BB-CCV, con un'applicazione web interattiva per la sperimentazione.

# Struttura dell'esposizione

- Contesto: il costo del gradiente su larga scala e il mini-batch
- Stato dell'arte: SGD e metodi a varianza ridotta (SVRG, SAGA)
- L'idea: batch grandi solo quando servono, con la Condizione di Controllo della Varianza (CCV)
- I quattro algoritmi a campionamento dinamico e i loro schemi
- Risultati teorici di convergenza e complessità
- Esperimenti numerici: app web, problemi sintetici, riuso del mini-batch
- Conclusioni e lavoro futuro

## Contesto: ottimizzazione su larga scala

- Obiettivo: minimizzare la perdita empirica

$$J(w) = \frac{1}{N} \sum_{i=1}^N \ell(w; i), \quad w \in \mathbb{R}^m$$

con  $N \approx 10^6$ – $10^9$  esempi e  $m$  grande: il gradiente completo  $\nabla J(w)$  costa  $O(Nm)$  per iterazione, proibitivo.

- Mini-batch  $\mathcal{S}_k$  di dimensione  $n_k$ : stima  $g_k = \nabla J_{\mathcal{S}_k}(w_k)$ , costo  $O(n_k m)$ . Se  $n_k \ll N$  le iterazioni sono economiche.
- Compromesso classico (Bottou–Bousquet, 2008): batch piccolo = stima rumorosa; batch grande = stima accurata ma costo proporzionale alla dimensione.
- Nei metodi classici  $n_k$  è **fissata a priori**; questa tesi analizza la proposta di renderla **dinamica** durante le iterazioni (Byrd, Chin, Nocedal e Wu, 2012).

## Stato dell'arte: SGD e il problema della varianza

- SGD (Robbins–Monro, 1951): aggiornamento su un singolo esempio (o un piccolo batch),  $w_{k+1} = w_k - \alpha_k \nabla \ell(w_k; i_k)$ , con  $\mathbb{E}[\nabla \ell(w_k; i)] = \nabla J(w_k)$ : stimatore *non distorto*, costo per iterazione indipendente da  $N$ .
- Ma la varianza  $\text{Var}[\nabla \ell(w; i)]$  **non** tende a zero vicino all'ottimo: quando  $\nabla J(w) \rightarrow 0$  il rumore domina e limita la precisione raggiungibile.
- Conseguenze pratiche: a passo fisso si resta in un intorno dell'ottimo (precisione limitata); a passo  $\alpha_k \rightarrow 0$  la convergenza rallenta.
- Su larga scala conta il **costo totale** (costo per iterazione  $\times$  numero di iterazioni), non solo il numero di iterazioni.
- Due strade per uscirne: aumentare il campione (costo) oppure ridurre la varianza con stimatori migliori.

## Metodi a varianza ridotta: l'idea comune

- SVRG (*Stochastic Variance Reduced Gradient*; Johnson–Zhang, 2013) e SAGA (metodo di riduzione della varianza di Defazio–Bach–Lacoste-Julien, 2014): SGD + *correzione* costruita su quantità globali.
- Forma generale dello stimatore corretto:

$$g_k = \nabla \ell(w_k; i_k) - c_k + \mathbb{E}[c_k],$$

che resta non distorto:  $\mathbb{E}[g_k] = \nabla J(w_k)$ .

- Se  $c_k$  “specchia” il gradiente campionato (stesso esempio  $i_k$ , valutato in un punto vicino a  $w_k$ ), sottrarla riduce la varianza di  $g_k$ , fino a zero vicino all’ottimo: *variance reduction*. Meccanismo e forma di  $c_k$  per SVRG e SAGA: prossima slide.
- Differenza chiave tra i due metodi:
  - **SVRG**: ricalcola periodicamente un gradiente esatto su un punto di ancoraggio;
  - **SAGA**: mantiene una tavola dei gradienti per-esempio, aggiornata a ogni iterazione.

Dalla tesi — Sez. 4.1 (Lavori Correlati) e Appendice D (Schemi dei metodi a varianza ridotta)

## Perché la correzione riduce la varianza

- Per  $w_k$  fissato,  $\mathbb{E}[c_k]$  è noto: non aggiunge rumore. La parte aleatoria di  $g_k = \nabla \ell(w_k; i_k) - c_k + \mathbb{E}[c_k]$  è  $\nabla \ell(w_k; i_k) - c_k$ , quindi

$$\text{Var}(g_k) = \text{Var}(\nabla \ell(w_k; i_k)) + \text{Var}(c_k) - 2 \text{Cov}(\nabla \ell(w_k; i_k), c_k).$$

- $c_k$  è costruita usando lo stesso esempio  $i_k$  del gradiente: se lo “specchia” ( $\text{Cov} > 0$ ), il termine  $-2 \text{Cov}$  cancella parte del rumore e  $\text{Var}(g_k)$  scende. Se  $c_k$  fosse indipendente non ci sarebbe guadagno; se anti-correlata la varianza *aumenterebbe*.
- **SVRG**:  $c_k = \nabla \ell(\bar{w}; i_k)$  con  $\mathbb{E}[c_k] = \nabla J(\bar{w})$ . Quando  $w_k \approx \bar{w}$ , per la regolarità dei gradienti  $c_k \approx \nabla \ell(w_k; i_k)$ : la covarianza è quasi massima e  $\text{Var}(g_k) \rightarrow 0$ .
- **SAGA**:  $c_k = g^{(i_k)}$  (gradiente dell'esempio  $i_k$  memorizzato alla sua ultima occorrenza) con  $\mathbb{E}[c_k] = \bar{g}$ ; a convergenza ( $w_k \rightarrow w_*$ , minimo) ogni voce tende a  $\nabla \ell(w_*; i)$  e la cancellazione è la stessa di SVRG, senza ricalcoli globali.

Dalla tesi — Appendice D (Schemi dei metodi a varianza ridotta)

# SVRG: l'ancora e il ricampionamento ogni $m$ iterazioni


- Punto di ancoraggio  $\bar{w}$  con gradiente esatto  $\nabla J(\bar{w})$ , ricalcolato ogni  $m$  iterazioni.

- Stimatore non distorto:

$$g_k = \nabla \ell(w_k; i_k) - \nabla \ell(\bar{w}; i_k) + \nabla J(\bar{w})$$

- **Idea:** finché  $w_k \approx \bar{w}$ , per la regolarità dei gradienti  $\nabla \ell(w_k; i_k) \approx \nabla \ell(\bar{w}; i_k)$ : i due termini stocastici si elidono e resta  $g_k \approx \nabla J(\bar{w})$ : poca varianza.
- Quando  $w_k$  si allontana da  $\bar{w}$  la correzione “invecchia”: il rumore non è più eliso e la varianza ricresce  $\rightarrow$  si aggiorna l'ancora e si ricampiona l'intero dataset.

Dalla tesi — Appendice D, Schema SVRG




# SAGA: la tavola dei gradienti, nessun ricalcolo globale

- Tavola  $g^{(i)}$ : l'ultimo gradiente calcolato per ogni esempio  $i$ ; media  $\bar{g} = \frac{1}{N} \sum_i g^{(i)}$  (solo memoria  $O(Nm)$ , nessuna passata completa periodica).
- Stimatore:

$$g_k = \nabla \ell(w_k; i_k) - g^{(i_k)} + \bar{g}$$

- A ogni iterazione si aggiorna *solo* la voce estratta:  $g^{(i_k)} \leftarrow \nabla \ell(w_k; i_k)$  e  $\bar{g}$  di conseguenza.
- Stesso schema di riduzione della varianza di SVRG, ma la correzione è sempre “fresca” per l'esempio appena campionato.

Dalla tesi — Appendice D, Schema SAGA (fig. saga)





## Limiti di SVRG/SAGA e lezione per la tesi

- **SVRG**: una passata completa sui dati ogni  $m$  iterazioni; se  $N$  è enorme il costo dei ricalcoli periodici si fa sentire.
- **SAGA**: memoria  $O(Nm)$  per la tavola dei gradienti (un gradiente per ogni esempio): improponibile quando  $N \cdot m$  è molto grande.
- In entrambi la dimensione del campione è **fissata a priori** (tipicamente un esempio per iterazione): non è mai adattata alle necessità di accuratezza del momento.
- Le garanzie di convergenza lineare valgono sotto convessità forte.
- **Lezione**: rendere *dinamica* la dimensione del campione, aumentandola (e ricampionando) quando la stima corrente non è abbastanza accurata: è l'approccio di Byrd, Chin, Nocedal e Wu (2012), al centro della tesi.

## Campionamento dinamico: la Condizione di Controllo della Varianza

- Si parte da un batch piccolo: iterazioni economiche; il batch cresce solo quando la stima del gradiente non è abbastanza accurata.
- Criterio (CCV): la varianza campionaria del gradiente deve essere piccola rispetto alla norma del gradiente stimato:

$$\frac{\|\hat{\mathcal{V}}\|_1}{n_k} \leq \theta^2 \|g_k\|_2^2, \quad g_k = \nabla J_{S_k}(w_k), \quad \theta \in (0, 1)$$

- Se la CCV è violata si ricampiona con un batch più grande:

$$n_k^{\text{new}} = \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|g_k\|_2^2} \right\rceil$$

- Profilo a “scalini”;  $\theta$  piccolo  $\rightarrow$  si aumenta presto (batch accurati),  $\theta$  grande  $\rightarrow$  batch piccolo più a lungo.
- Nessuna stima di  $\kappa$  né regola geometrica a priori: la crescita è guidata dai dati.

Dalla tesi — Sez. 5.1 (Byrd, Chin, Nocedal e Wu, 2012)

## La CCV garantisce una direzione di discesa

- $-g_k$  è di discesa per  $J$  se l'errore relativo della stima è piccolo:  $\|e_k\|_2 \leq \theta \|g_k\|_2$  con  $e_k = g_k - \nabla J(w_k)$ . Infatti, per Cauchy-Schwarz,

$$\nabla J(w_k)^\top g_k = \|g_k\|_2^2 + e_k^\top g_k \geq \|g_k\|_2^2 - \|e_k\|_2 \|g_k\|_2 \geq (1 - \theta) \|g_k\|_2^2 > 0.$$

- In aspettativa l'errore è la varianza dello stimatore:

$$\mathbb{E}[\|e_k\|_2^2] = \mathbb{E}[\|g_k - \mathbb{E}[g_k]\|_2^2] = \|\text{Var}(g_k)\|_1,$$

stimata dalla CCV con  $\|\hat{\mathcal{V}}\|_1/n_k$ .


- Sotto la CCV la direzione resta di discesa: è la base per la convergenza dei metodi presentati.

Dalla tesi — Sez. 5.1: condizione di discesa e Lemma di accuratezza

## I quattro algoritmi a campionamento dinamico


- **Dynamic GD**: gradiente su campione dinamico con CCV e line search di Wolfe (base del metodo).
- **Newton-CG**: Hessiana sottocampionata ( $|\mathcal{H}| = R |\mathcal{S}|$ ) e criterio di arresto adattivo del CG interno, basato sulla varianza dei prodotti Hessiana-vettore: niente iterazioni interne sprecate quando l'Hessiana è limitata dal sottocampionamento.
- **Newton-CG  $L_1$** : gradiente generalizzato, identificazione dell'active set e line search proiettata (soluzioni sparse).
- **BB-CCV**: passo di Barzilai–Borwein con campionamento dinamico (line search di Armijo).
- Tutti implementati in Python (Appendice B) e nell'app web interattiva; per ognuno, lo schema seguente mostra il flusso con la CCV come decisione centrale.

# Schema: Dynamic GD (Fig. 5.1)




Flusso CCV: se la varianza campionaria è troppo grande rispetto a  $\theta^2 \|g_k\|^2$ ,  $n_k$  cresce e si ricampiona; altrimenti line search di Wolfe e aggiornamento.

# Schema: Newton-CG (Fig. 5.2)




Hessiana sottocampionata con  $|\mathcal{H}| = R |\mathcal{S}|$ ; il CG interno è Hessian-free e si ferma con un criterio adattivo basato sulla varianza dei prodotti Hessiana-vettore.

# Schema: Newton-CG $L_1$ (Fig. 5.5)



Gradiente generalizzato per la  $L_1$ : identificazione dell'active set e line search proiettata mantengono a zero le variabili giuste, producendo soluzioni sparse.

# Schema: BB-CCV (Fig. 5.6)



Gradiente dinamico con passo Barzilai–Borwein (line search di Armijo): la CCV regola la dimensione del campione mentre il passo adatta la lunghezza dello spostamento.



## Risultati teorici: convergenza e complessità

- Sotto la CCV la direzione di ricerca è di discesa e il metodo converge *linearmente*: sia in forma deterministica sia in aspettativa.
- Complessità totale  $\mathcal{O}(mL/(\lambda\varepsilon))$  (con  $m$  parametri,  $L$  costante di Lipschitz di  $\nabla J$ ,  $\lambda$  convessità forte): competitiva con SGD.
- Su problemi mal condizionati il fattore  $\kappa^2$  tipico di SGD diventa  $\kappa$  per il campionamento dinamico.
- **Contributo della tesi**: fattore di contrazione migliorato, da  $1 - \frac{(1-\theta)\lambda}{2L}$  a  $1 - \frac{(1-\theta)\lambda}{L}$ , usando la disuguaglianza di Polyak–Łojasiewicz in forma forte.
- Per Newton-CG: arresto adattivo del CG basato sulla varianza dei prodotti Hessiana-vettore, nessuna iterazione interna sprecata.

Dalla tesi — Cap. 5 (convergenza) e Sez. 6.3 (Risultati Numerici)

## App web interattiva: esperimenti nel browser

- `visualizzazione.html`: singolo file, Pyodide + Plotly, nessuna installazione o server.
- Codice Python dei quattro algoritmi visibile e modificabile nel browser; preset quadratici + dataset sintetico “centrato” ( $\hat{J}_N = J$ ).
- Percorso 3D/2D su  $J(w)$ , metriche in tempo reale, pannelli “Analisi” e “Test batch” (per riprodurre le tabelle della tesi).
- Permette di osservare la dinamica del batch ( $n_k$  vs  $k$ ) e l’effetto del parametro  $\theta$  sulla soglia CCV.
- Implementazione Python standalone equivalente (`simulazione_batch.py`) per la rigenerazione di figure e tabelle della tesi.

## Setup e risultati numerici

- Setup:  $N = 200$ , seed 42,  $w_0 = (2, -3)$ ,  $\alpha = 0.1$ ,  $\theta = 0.5$ ,  $n_0 = 5$ , 30 iterazioni, tolleranza  $\|\nabla J\| < 10^{-6}$ .
- Preset: ben condizionato ( $\kappa \approx 1.1$ ), mal condizionato ( $\kappa \approx 20$ ), molto mal condizionato ( $\kappa \approx 100$ ), incrociato.
- Profilo a “scalini” di  $n_k$  confermato dagli esperimenti: il batch cresce solo quando la CCV lo richiede.
- BB-CCV raggiunge la precisione macchina ( $\approx 1.1 \times 10^{-14}$ ) su  $\kappa \approx 100$ ; l'analisi teorica ( $\kappa$  al posto di  $\kappa^2$ ) è confermata dai dati.





Fig. 5.3 — dimensione del campione  $n_k$  vs iterazioni  $k$

## Riuso del mini-batch (Sez. 6.5)

- Variante studiata nella tesi: riusare lo stesso campione per  $M$  iterazioni consecutive (ricalcolando però il gradiente al punto corrente, non riusando i gradienti vecchi).
- La CCV fa da segnale di “esaurimento” del campione: quando non è più soddisfatta,  $n_k$  cresce e si ricampiona.
- $M = \infty$ : si tiene il campione finché la CCV vale; il costo per iterazione scende, ma il campione “invecchia”.
- Effetti dipendenti dal metodo e dal condizionamento del problema: quantificati con le tabelle del Cap. 6.



Traiettorie con riuso del batch

# Conclusioni

- Quadro completo: dalla varianza del gradiente stocastico (SGD) e dai metodi a varianza ridotta (SVRG/SAGA) si arriva a una regola *dinamica e basata sui dati* per la dimensione del campione.
- Analisi teorica: convergenza lineare (deterministica e in aspettativa) e complessità sotto la CCV.
- Contributi propri: fattore di contrazione migliorato (PL forte), arresto adattivo del CG per Newton-CG.
- Implementazione Python dei quattro algoritmi + app web interattiva per ripetere gli esperimenti.
- Esperimenti sui problemi quadratici sintetici (da  $\kappa \approx 1.1$  a  $\kappa \approx 100$ ) coerenti con la teoria; analizzato anche il riuso del mini-batch.

## Limiti e lavoro futuro

- Limiti attuali: ipotesi di convessità forte, varianza limitata, esperimenti su dataset sintetici (quadratici, centrati).
- Futuro: assumere direttamente la condizione di Polyak–Łojasiewicz (copre funzioni non convesse).
- Futuro: rapporto di sottocampionamento  $R$  dell'Hessiana dinamico (oltre alla sola  $n_k$  del gradiente).
- Futuro: validazione su dataset reali e problemi non convessi, confronto sistematico con SVRG/SAGA su larga scala.