

Selezione Dinamica della Dimensione del Campione

in Metodi di Ottimizzazione per il Machine Learning

La tesi presenta la selezione dinamica della dimensione del campione negli algoritmi di ottimizzazione per il machine learning su larga scala, fondandosi sul lavoro di Byrd, Chin, Nocedal e Wu (2012). L'idea centrale: invece di fissare a priori la dimensione del batch, si decide durante l'algoritmo se e quando aumentarla, guidandosi da stime statistiche della varianza del gradiente stocastico. Il lavoro offre un'analisi teorica completa della convergenza, il miglioramento di alcuni risultati mediante disuguaglianze più strette e un'implementazione Python dei quattro algoritmi principali: Dynamic GD, Newton-CG, estensione L_1 e BB-CCV, con un'applicazione web interattiva per la sperimentazione.

Contesto: ottimizzazione su larga scala

- Obiettivo: minimizzare la perdita empirica

$$J(w) = \frac{1}{N} \sum_{i=1}^N \ell(w; i), \quad w \in \mathbb{R}^m$$

con $N \approx 10^6$ – 10^9 esempi e m grande: il gradiente completo $\nabla J(w)$ costa $O(Nm)$ per iterazione, proibitivo.

- Mini-batch $\mathcal{S}_k$ di dimensione n_k : stima $g_k = \nabla J_{\mathcal{S}_k}(w_k)$, costo $O(n_k m)$. Se $n_k \ll N$ le iterazioni sono economiche.
- Compromesso classico (Bottou–Bousquet, 2008): batch piccolo = stima rumorosa; batch grande = stima accurata ma costo proporzionale alla dimensione.
- Nei metodi classici n_k è **fissata a priori**; questa tesi analizza la proposta di renderla **dinamica** durante le iterazioni (Byrd, Chin, Nocedal e Wu, 2012).

Stato dell'arte: SGD e il problema della varianza

- SGD (Robbins–Monro, 1951): aggiornamento su un singolo esempio (o un piccolo batch), $w_{k+1} = w_k - \alpha_k \nabla \ell(w_k; i_k)$, con $\mathbb{E}[\nabla \ell(w_k; i)] = \nabla J(w_k)$: stimatore *non distorto*, costo per iterazione indipendente da N .
- Ma la varianza $\text{Var}[\nabla \ell(w; i)]$ **non** tende a zero vicino all'ottimo: quando $\nabla J(w) \rightarrow 0$ il rumore domina e limita la precisione raggiungibile.
- Conseguenze pratiche: a passo fisso si resta in un intorno dell'ottimo (precisione limitata); a passo $\alpha_k \rightarrow 0$ la convergenza rallenta.
- Su larga scala conta il **costo totale** (costo per iterazione $\times$ numero di iterazioni), non solo il numero di iterazioni.
- Due strade per uscirne: aumentare il campione (costo) oppure ridurre la varianza con stimatori migliori.

Metodi a varianza ridotta: l'idea comune

- SVRG (*Stochastic Variance Reduced Gradient*; Johnson–Zhang, 2013) e SAGA (metodo di riduzione della varianza di Defazio–Bach–Lacoste-Julien, 2014): SGD + *correzione* costruita su quantità globali.
- Forma generale dello stimatore corretto:

$$g_k = \nabla \ell(w_k; i_k) - c_k + \mathbb{E}[c_k],$$

che resta non distorto: $\mathbb{E}[g_k] = \nabla J(w_k)$.

- Se la correzione c_k è correlata al rumore del gradiente stocastico, la varianza di g_k si riduce (idealmente tende a zero vicino all'ottimo): *variance reduction*.
- Differenza chiave tra i due metodi:
 - **SVRG**: ricalcola periodicamente un gradiente esatto su un punto di ancoraggio;
 - **SAGA**: mantiene una tavola dei gradienti per-esempio, aggiornata a ogni iterazione.

Dalla tesi — Sez. 4.1 (Lavori Correlati) e Appendice D (Schemi dei metodi a varianza ridotta)

SVRG: l'ancora e il ricampionamento ogni t iterazioni


- Punto di ancoraggio $\bar{w}$ con gradiente esatto $\nabla J(\bar{w})$, ricalcolato ogni t iterazioni.

- Stimatore non distorto:

$$g_k = \nabla \ell(w_k; i_k) - \nabla \ell(\bar{w}; i_k) + \nabla J(\bar{w})$$

- Idea:** finché $w_k \approx \bar{w}$, per la regolarità dei gradienti $\nabla \ell(w_k; i_k) \approx \nabla \ell(\bar{w}; i_k)$: i due termini stocastici si elidono e resta $g_k \approx \nabla J(\bar{w})$: poca varianza.
- Quando w_k si allontana da $\bar{w}$ la correzione “invecchia”: il rumore non è più eliso e la varianza ricresce $\rightarrow$ si aggiorna l'ancora e si ricampiona l'intero dataset.

Dalla tesi — Appendice D, Schema SVRG




SAGA: la tavola dei gradienti, nessun ricalcolo globale

- Tavola $g^{(i)}$: l'ultimo gradiente calcolato per ogni esempio i ; media $\bar{g} = \frac{1}{N} \sum_i g^{(i)}$ (solo memoria $O(Nm)$, nessuna passata completa periodica).
- Stimatore:

$$g_k = \nabla \ell(w_k; i_k) - g^{(i_k)} + \bar{g}$$

- A ogni iterazione si aggiorna *solo* la voce estratta: $g^{(i_k)} \leftarrow \nabla \ell(w_k; i_k)$ e $\bar{g}$ di conseguenza.
- Stesso schema di riduzione della varianza di SVRG, ma la correzione è sempre “fresca” per l'esempio appena campionato.

Dalla tesi — Appendice D, Schema SAGA (fig. saga)



Limiti di SVRG/SAGA e conseguenze per la tesi

- **SVRG**: memoria extra minima (solo l'ancora e il suo gradiente, $O(m)$); ma ogni t iterazioni va ricalcolato il gradiente esatto $\nabla J(\bar{w})$ con una passata completa sul dataset: costo *temporale* $O(Nm)$ per passata, che per N molto grande può dominare il costo complessivo.
- **SAGA**: nessuna passata completa periodica, ma *memoria* $O(Nm)$ per la tavola dei gradienti (un gradiente per ogni esempio): improponibile quando $N \cdot m$ è molto grande.
- In entrambi la dimensione del campione è **fissata a priori** (un esempio per iterazione): non è mai adattata alle necessità di accuratezza del momento.
- Le garanzie di convergenza lineare valgono sotto convessità forte.
- **Conclusione**: rendere *dinamica* la dimensione del campione, aumentandola (e ricampionando) quando la stima corrente non è abbastanza accurata: è l'approccio di Byrd, Chin, Nocedal e Wu (2012), al centro della tesi.

La varianza del gradiente stimato: definizioni

- Il gradiente sul batch è la *media* dei gradienti per-esempio,
 $g_k = \nabla J_{S_k}(w_k) = \frac{1}{n_k} \sum_{i \in S_k} \nabla \ell(w_k; i)$, con $\mathbb{E}[g_k] = \nabla J(w_k)$ (stimatore non distorto).
L'errore $e_k = g_k - \nabla J(w_k)$ non è calcolabile; si controlla la *varianza dello stimatore*:
 $\mathbb{E}[\|e_k\|_2^2] = \|\text{Var}(g_k)\|_1$ (somma delle varianze, componente per componente).
- Definizioni: $\mathcal{V}$ è la *varianza della popolazione* del gradiente della loss (non calcolabile: servirebbe $\nabla J(w_k)$); $\widehat{\mathcal{V}}$ (“v-hat”) è la sua stima *campionaria* sul batch corrente, centrata sulla media campionaria g_k :

$$\mathcal{V} := \frac{1}{N} \sum_{i=1}^N (\nabla \ell(w_k; i) - \nabla J(w_k))^2, \quad \widehat{\mathcal{V}} := \frac{1}{n_k - 1} \sum_{i \in S_k} (\nabla \ell(w_k; i) - g_k)^2,$$

quadrati e divisioni sempre componente per componente ($\in \mathbb{R}^m$).

Dalla tesi — Sez. 5.1

Varianza dello stimatore: decomposizione

- $\widehat{\mathcal{V}}$ (denominatore $n_k - 1$) è non distorta, $\mathbb{E}[\widehat{\mathcal{V}}] = \mathcal{V}$: stima la *dispersione dei singoli gradienti* del batch. Ma g_k è la loro *media*; la varianza della media si ricava da quella dei singoli con la *decomposizione* (con reinserimento, indipendenza):

$$\text{Var}(g_k) = \text{Var}\left(\frac{1}{n_k} \sum_{i \in S_k} \nabla \ell(w_k; i)\right) = \frac{1}{n_k^2} \sum_{i \in S_k} \text{Var}(\nabla \ell(w_k; i)) = \frac{\mathcal{V}}{n_k}.$$

- Senza reinserimento (i batch reali) si aggiunge il *fattore di correzione per popolazione finita*:

$$\text{Var}(g_k) = \frac{\mathcal{V}}{n_k} \cdot \frac{N - n_k}{N - 1}.$$

La sua dimostrazione è in Appendice (tesi). Per $N \gg n_k$ (condizione tipica nel machine learning) il fattore è ≈ 1 , quindi vale la forma pratica $\text{Var}(g_k) \approx \mathcal{V}/n_k$.

Dalla tesi — Sez. 5.1; dimostrazione del fattore di correzione per popolazione finita in Appendice

Campionamento dinamico: la Condizione di Controllo della Varianza

- Si parte da un batch piccolo: iterazioni economiche; il batch cresce solo quando la stima del gradiente non è abbastanza accurata.
- Criterio (CCV): la varianza stimata dello stimatore del gradiente deve essere piccola rispetto alla norma del gradiente stimato:

$$\frac{\|\widehat{\mathcal{V}}\|_1}{n_k} \leq \theta^2 \|g_k\|_2^2, \quad \theta \in (0, 1)$$

- Se la CCV è violata si ricampiona con un batch più grande:

$$n_k^{\text{new}} = \left\lceil \frac{\|\widehat{\mathcal{V}}\|_1}{\theta^2 \|g_k\|_2^2} \right\rceil$$

- Profilo a “scalini”; θ piccolo $\rightarrow$ si aumenta presto (batch accurati), θ grande $\rightarrow$ batch piccolo più a lungo.
- Nessuna stima di κ né regola geometrica a priori: la crescita è guidata dai dati.

Dalla tesi — Sez. 5.1 (Byrd, Chin, Nocedal e Wu, 2012)

Direzione di discesa: livello puntuale e garanzia in media

- **Livello puntuale (deterministico).** Se per il batch corrente vale la condizione di accuratezza $\|e_k\|_2 \leq \theta \|g_k\|_2$ ($e_k = g_k - \nabla J(w_k)$), allora $-g_k$ è di discesa per J : per Cauchy–Schwarz,

$$\nabla J(w_k)^\top g_k = \|g_k\|_2^2 - e_k^\top g_k \geq \|g_k\|_2^2 - \|e_k\|_2 \|g_k\|_2 \geq (1 - \theta) \|g_k\|_2^2 > 0.$$

È una condizione *sufficiente e puntuale*: ipotesi dell'analisi deterministica, non una conseguenza della CCV.

- **Livello CCV (in aspettativa).** La CCV controlla la *varianza* dello stimatore ($\|\widehat{\mathcal{V}}\|_1/n_k \leq \theta^2 \|g_k\|_2^2$), non l'errore del singolo mini-batch: non garantisce la discesa a ogni iterazione.
- **Garanzia in media.** g_k è non distorto, $\mathbb{E}[g_k] = \nabla J(w_k)$, quindi

$$\mathbb{E}[\nabla J(w_k)^\top g_k] = \nabla J(w_k)^\top \mathbb{E}[g_k] = \|\nabla J(w_k)\|_2^2 > 0,$$

e la CCV tiene sotto controllo le fluttuazioni (base dell'analisi di convergenza in media).

Dalla tesi — Sez. 5.1: condizione puntuale (deterministica), CCV (in aspettativa) e garanzia in media

I quattro algoritmi a campionamento dinamico

- **Dynamic GD**: gradiente su campione dinamico con CCV e line search di Wolfe (base del metodo).
- **Newton-CG**: Hessiana sottocampionata ($|\mathcal{H}| = R |\mathcal{S}|$) e criterio di arresto adattivo del CG interno, basato sulla varianza dei prodotti Hessiana-vettore: niente iterazioni interne sprecate quando l'Hessiana è limitata dal sottocampionamento.
- **Newton-CG L_1** : gradiente generalizzato, identificazione dell'active set e line search proiettata (soluzioni sparse).
- **BB-CCV**: passo di Barzilai–Borwein con campionamento dinamico (line search di Armijo).
- Tutti implementati in Python (Appendice B) e nell'app web interattiva; per ognuno, lo schema seguente mostra il flusso con la CCV come decisione centrale.

Condizioni di Wolfe (con $h = \alpha d$)

- $h = \alpha d$ è lo spostamento lungo una direzione di discesa: $\nabla f(x)^T h < 0$, quindi nelle formule i due membri sono negativi.
- **Armijo** (prima condizione di Wolfe): la caduta deve essere “sufficiente”,

$$f(x + h) - f(x) \leq c_1 \nabla f(x)^T h, \quad 0 < c_1 < 1.$$

Moltiplicando per -1 : la *caduta effettiva* deve essere almeno la frazione c_1 della caduta lineare prevista dal gradiente. Impedisce passi troppo corti o scarsi.

- **Curvatura di Wolfe**: la pendenza finale non deve essere troppo ripida,


$$\nabla f(x + h)^T h \geq c_2 \nabla f(x)^T h, \quad c_1 < c_2 < 1.$$

Moltiplicando per -1 : la *pendenza residua* (in valore assoluto) deve essere al più la frazione c_2 di quella iniziale. Se è ancora molto negativa, f continua a scendere: si può allungare il passo. Impedisce di fermarsi troppo presto.

$$\begin{cases} f(x + h) - f(x) \leq c_1 \nabla f(x)^T h & \text{(caduta sufficiente)} \\ \nabla f(x + h)^T h \geq c_2 \nabla f(x)^T h & \text{(curvatura)} \end{cases}$$

Insieme rendono il passo *bilanciato*: si scende abbastanza senza fermarsi troppo presto. (Dalla tesi — Appendice A; Wolfe $c_1=10^{-4}$, $c_2=0.9$ nei codici.)

Schema: Dynamic GD (Fig. 5.1)



Flusso CCV: se la varianza campionaria è troppo grande rispetto a $\theta^2 \|g_k\|^2$, n_k cresce e si ricampiona; altrimenti line search di Wolfe e aggiornamento.

Newton-CG: struttura del metodo (eq. 5.31–5.32)

- Due campioni a ogni iterazione: $\mathcal{S}_k$ per il **gradiente** (campionamento dinamico con CCV) e $\mathcal{H}_k \subset \mathcal{S}_k$ per l'**Hessiana**, con $|\mathcal{H}_k| \ll |\mathcal{S}_k|$ (prodotti Hessiana-vettore economici).
- La direzione di ricerca d_k è la soluzione approssimata del sistema (Hessian-free: la matrice non è mai costruita)

$$\nabla^2 J_{\mathcal{H}_k}(w_k) d = -\nabla J_{\mathcal{S}_k}(w_k).$$

- Rapporto di sottocampionamento fissato a priori e costante; quando $\mathcal{S}_k$ cresce (CCV) cresce in proporzione anche $\mathcal{H}_k$:

$$R = \frac{|\mathcal{H}_k|}{|\mathcal{S}_k|} < 1, \quad |\mathcal{H}_k| = \lceil R |\mathcal{S}_k| \rceil.$$

Linea guida: il costo dei prodotti Hessiana-vettore nel CG non deve superare quello di $\nabla J_{\mathcal{S}_k}(w_k)$.

Dalla tesi — Sez. 5.2, eq. 5.31–5.32

Newton-CG: non serve un residuo più piccolo dell'errore di Hessiana

- Il CG risolve in modo **approssimato** il sistema di Newton (eq. 5.31), gradiente su $\mathcal{S}_k$ e Hessiana su $\mathcal{H}_k$; il suo **residuo** è (eq. 5.33):

$$r_k = \nabla^2 J_{\mathcal{H}_k}(w_k) d + \nabla J_{\mathcal{S}_k}(w_k),$$

- L'Hessiana è quindi **approssimata**: il residuo del sistema che userebbe il campione grande $\mathcal{S}_k$ per gradiente ed Hessiana si scompone in

$$\nabla^2 J_{\mathcal{S}_k}(w_k) d + \nabla J_{\mathcal{S}_k}(w_k) = \underbrace{r_k}_{\text{residuo del CG}} + \underbrace{\Delta_{\mathcal{H}_k}(w_k; d)}_{\text{errore di Hessiana}},$$

dove $\Delta_{\mathcal{H}_k}(w_k; d) = [\nabla^2 J_{\mathcal{S}_k}(w_k) - \nabla^2 J_{\mathcal{H}_k}(w_k)]d$ è **costante durante il CG** e **non eliminabile** (il campione $\mathcal{H}_k$ è fissato).

- Poiché $\Delta_{\mathcal{H}_k}$ non si può eliminare, *non serve* ridurre r_k fino a zero: **basta fermarlo quando è confrontabile con $\Delta_{\mathcal{H}_k}$** ; oltre, le iterazioni del CG sono *tempo sprecato*.
- Perché non è calcolabile?** $\Delta_{\mathcal{H}_k}$ contiene il prodotto Hessiana–vettore $\nabla^2 J_{\mathcal{S}_k}(w_k)d$, la media su *tutto* $\mathcal{S}_k$ dei prodotti $\nabla^2 \ell(w_k; i)d$: calcolarlo costerebbe quanto l'Hessiana piena e **vanificherebbe** il sottocampionamento di $\mathcal{H}_k$. Come per l'errore e_k del gradiente: stima con la **varianza campionaria** dei prodotti Hessiana–vettore su $\mathcal{H}_k$ (prossima slide).

Dalla tesi — Sez. 5.2, eq. 5.31 e 5.33–5.34 e discussione del criterio

Newton-CG: come si stima l'errore di Hessiana (eq. 5.35)

- $\Delta_{\mathcal{H}_k}(w_k; d)$ **non è calcolabile** (servirebbe il prodotto Hessiana–vettore su tutto $\mathcal{S}_k$): come per l'errore del gradiente, se ne stima il valore atteso con la **varianza campionaria dei prodotti Hessiana–vettore** su $\mathcal{H}_k$ (campionamento senza reinserimento: fattore $(|\mathcal{S}_k| - |\mathcal{H}_k|)/(|\mathcal{S}_k| - 1) \approx 1$ perché $|\mathcal{H}_k| \ll |\mathcal{S}_k|$):

$$\mathbb{E}[\|\Delta_{\mathcal{H}_k}(w_k; d)\|_2^2] \approx \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d)\|_1}{|\mathcal{H}_k|}.$$

Come per il gradiente: è la varianza della *media* su $\mathcal{H}_k$ (la dispersione dei singoli prodotti divisa per $|\mathcal{H}_k|$).

- La stima vale per una direzione generica d : nel CG andrebbe rivalutata a ogni iterazione interna j , sulla direzione corrente d_j . Ricalcolare la varianza campionaria a ogni passo è però costoso: la prossima slide mostra come si evita.

Dalla tesi — Sez. 5.2, eq. 5.35

Newton-CG: omogeneità di grado 2 e un solo calcolo (eq. 5.36–5.38)

- Su un campione fissato, la varianza dei prodotti Hessiana–vettore è una **forma quadratica** in d :
 $\text{Var}(\nabla^2 \ell(w_k; i) d) = d^T \Sigma_{\mathcal{H}_k} d$ ($\Sigma_{\mathcal{H}_k}$ covarianza campionaria sdp; la relazione vale componente per componente). Vale quindi l'**omogeneità di grado 2**

$$\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i)(\lambda d)) = \lambda^2 \text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d).$$

- Un solo calcolo.** Per non ricalcolare la varianza a ogni iterazione del CG (costo elevato), la si calcola **una sola volta** sulla prima direzione $p_0 = -g_k$,

$$\alpha := \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{\|p_0\|_2^2} = \frac{\|p_0^T \Sigma_{\mathcal{H}_k} p_0\|_1}{\|p_0\|_2^2},$$

e per ogni d_j si usa $\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d_j)\|_1 \approx \alpha \|d_j\|_2^2$.

- Approssimazione.** La varianza effettiva di d_j è $\|d_j^T \Sigma_{\mathcal{H}_k} d_j\|_1$, non $\alpha \|d_j\|^2$: α è la media pesata degli autovalori di $\Sigma_{\mathcal{H}_k}$ ($\lambda_{\min} \leq \alpha \leq \lambda_{\max}$) e usarla su tutte le direzioni è lecito se la forma quadratica è sufficientemente *ben condizionata* (dipendenza angolare trascurabile).
- Dalla (5.35), la soglia per il test di arresto del CG è $\gamma := \alpha/|\mathcal{H}_k|$ e $\Psi(d) := \gamma \|d\|_2^2$: per ogni d_j ,
 $\Psi(d_j) \approx \mathbb{E} \|\Delta_{\mathcal{H}_k}(w_k; d_j)\|_2^2$ **cresce con** $\|d_j\|^2$ (prossima slide: criterio di arresto).

Dalla tesi — Sez. 5.2, eq. 5.36–5.38

Newton-CG: criterio di arresto adattivo del CG (eq. 5.39)

- A ogni iterazione interna j del CG si confronta il residuo r_{j+1} con la stima $\Psi(d_j)$ dell'errore di Hessiana:


$$\|r_{j+1}\|_2^2 \leq \Psi(d_j) = \gamma \|d_j\|_2^2.$$

Se la condizione è verificata il CG **termina** e si accetta la direzione d_{j+1} ; altrimenti si prosegue con l'iterazione successiva.

- È un criterio *automatico*: γ è fissata dai dati all'inizio del CG e la soglia $\Psi(d_j)$ si aggiorna a ogni iterazione con la sola $\|d_j\|_2^2$ e nessuna tolleranza da scegliere a priori.
- **Perché è adattivo.**
 - evita calcoli inutili quando l'approssimazione dell'Hessiana è limitata dal campione $\mathcal{H}_k$;
 - $\Psi \propto \|r_0\|^2$: la soglia segue la *distanza dal minimo*;
 - Ψ cresce con $\|d_j\|^2$: ferma il CG prima che la direzione diventi eccessivamente grande (stabilità numerica).

Dalla tesi — Sez. 5.2, eq. 5.39 e discussione del criterio

Schema: Newton-CG (Fig. 5.2)



Hessiana sottocampionata con $|\mathcal{H}| = R |\mathcal{S}|$; il CG interno è Hessian-free e si ferma con un criterio adattivo basato sulla varianza dei prodotti Hessiana-vettore.

Newton-CG L_1 : il gradiente generalizzato di $F = J + \nu \|w\|_1$

- $F(w) = J(w) + \nu \sum_{i=1}^m |w_i|$: parte liscia J + parte non liscia $\nu \sum_i |w_i|$. La somma si decompone per componente $\Rightarrow$ il gradiente generalizzato si calcola coordinata per coordinata: per la i -esima servono
 1. la derivata parziale della parte liscia: $\partial J(w)/\partial w_i$;
 2. il subgradiente di $\nu |w_i|$: $\partial(\nu |w_i|) = \{+\nu\}$ se $w_i > 0$, $\{-\nu\}$ se $w_i < 0$, $[-\nu, +\nu]$ se $w_i = 0$.
- Quindi, per ogni componente,

$$[\tilde{\nabla} F(w)]_i = \underbrace{\frac{\partial J(w)}{\partial w_i}}_{\text{gradiente di } J} + \underbrace{g_i}_{\text{subgradiente di } \nu |w_i|}, \quad g_i \in \begin{cases} \{+\nu\}, & w_i > 0, \\ \{-\nu\}, & w_i < 0, \\ [-\nu, +\nu], & w_i = 0. \end{cases}$$

- Quando $w_i = 0$ c'è libertà su $g_i \in [-\nu, +\nu]$; la scelta è fatta in modo che in w^* valga $\tilde{\nabla} F(w^*) = 0$. Posto $d_i := \partial J(w)/\partial w_i$ (così $[\tilde{\nabla} F]_i = d_i + g_i$), si prende $g_i = \arg \min_{g \in [-\nu, \nu]} |d_i + g|$: il subgradiente che rende $d_i + g_i$ il più vicino possibile a zero (zero se possibile), così $w_i = 0$ è riconosciuto come vero minimo quando lo è. Ne derivano i tre casi:

- $d_i < -\nu \Rightarrow g_i = +\nu \Rightarrow [\tilde{\nabla} F]_i < 0$ (w_i cresce);
- $-\nu \leq d_i \leq +\nu \Rightarrow g_i = -d_i \Rightarrow [\tilde{\nabla} F]_i = 0$ ($w_i = 0$ stazionario);
- $d_i > +\nu \Rightarrow g_i = -\nu \Rightarrow [\tilde{\nabla} F]_i > 0$ (w_i decresce).

Dalla tesi — Sez. 5.3, “Il gradiente generalizzato” (eq. 5.43)

Newton-CG L_1 : z_k , active set e faccia ortante

- $F = J + \nu \|w\|_1$ non è differenziabile dove $w_i = 0$: lì si sceglie g_i (slide precedente) e la decisione se liberare w_i o attivarla (tenerla a zero, per la sparsità) è codificata da $z_k \in \{-1, 0, +1\}^m$ (eq. 5.44):

$$z_k^i = \begin{cases} +1 & w_k^i > 0 \text{ oppure } (w_k^i = 0 \text{ e } \partial J_{S_k} / \partial w_i < -\nu) \\ -1 & w_k^i < 0 \text{ oppure } (w_k^i = 0 \text{ e } \partial J_{S_k} / \partial w_i > \nu) \\ 0 & \text{altrimenti} \end{cases}$$

- **Active set** (eq. 5.46): $\mathcal{A}_k = \{i : z_k^i = 0\}$ sono le variabili tenute a zero durante la minimizzazione; le altre sono *libere*.
- z_k definisce la **faccia ortante** (eq. 5.45) $\Omega_k = \{d : \text{sign}(d^i) = \text{sign}(z_k^i)\}$, dove $\|w\|_1$ è lineare e il gradiente generalizzato è $\widetilde{\nabla} F_{S_k}(w_k) = \nabla J_{S_k}(w_k) + \nu z_k$ (eq. 5.43); su Ω_k si minimizza il modello quadratico ristretto alle variabili libere.

Dalla tesi — Sez. 5.3, eq. 5.43–5.47

Newton-CG L_1 : la ricerca lineare proiettata

- Il candidato $w_k + \alpha_k d_k$ può **uscire dalla faccia** Ω_k : una variabile attiva lascerebbe lo zero, una libera attraverserebbe l'angolo della L_1 . Si proietta su Ω_k (eq. 5.49):

$$P(w_i) = \begin{cases} w_i & \text{sign}(w_i) = \text{sign}(z_k^i) \\ 0 & \text{altrimenti} \end{cases}$$

La proiezione $P(\cdot)$ azzera le componenti con segno non coerente con z_k .


- Il passo è scelto con **Armijo su F** (eq. 5.50): α_k è il più grande valore in $\{1, \frac{1}{2}, \frac{1}{4}, \dots\}$ tale che

$$F_{S_k}(P[w_k + \alpha_k d_k]) \leq F_{S_k}(w_k) + \sigma \tilde{\nabla} F_{S_k}(w_k)^T (P[w_k + \alpha_k d_k] - w_k), \quad \sigma \in (0, 1).$$

- Aggiornamento: $w_{k+1} = P[w_k + \alpha_k d_k]$; le variabili attive restano a zero $\Rightarrow$ soluzione sparsa.

Dalla tesi — Sez. 5.3, eq. 5.49–5.50

Schema: Newton-CG L_1 (Fig. 5.5)



Gradiente generalizzato per la L_1 : identificazione dell'active set e line search proiettata mantengono a zero le variabili giuste, producendo soluzioni sparse.

Il passo di Barzilai–Borwein (1/2) — relazione secante (eq. 5.52–5.54)

- BB-CCV sostituisce il passo *fisso* del Dynamic GD con un passo **adattivo** che stima la curvatura di J lungo la direzione percorsa usando **solo gradienti già calcolati**: nessuna Hessiana.
- Tra due iterate consecutive, $w_{k+1} = w_k + \Delta w_k$, lo sviluppo al primo ordine del gradiente $g = \nabla J$ attorno a w_k è

$$g(w_{k+1}) \approx g(w_k) + \nabla^2 J(w_k) \Delta w_k.$$

- Posto $s_k := w_{k+1} - w_k$ (spostamento) e $y_k := g(w_{k+1}) - g(w_k)$ (variazione del gradiente), si ha la **relazione secante**

$$y_k \approx \nabla^2 J(w_k) s_k.$$

- I metodi quasi-Newton approssimano l'Hessiana con B_{k+1} imponendo $B_{k+1} s_k = y_k$: è il punto di partenza del passo BB (prossima slide).

Dalla tesi — Sez. 5.4, eq. 5.52–5.54

Il passo di Barzilai–Borwein (2/2) — minimi quadrati e salvaguardia (eq. 5.55–5.56)


- BB spinge il quasi-Newton all'estremo: $B_{k+1} = \alpha^{-1} I$ (passo **scalare**); la secante diventa $\alpha^{-1} s \approx y$, un sistema di n equazioni in un'incognita risolto **ai minimi quadrati**. Le due formule classiche:

$$\alpha_k^{(1)} = \frac{s_k^\top y_k}{y_k^\top y_k} \quad (\min \|\alpha y - s\|^2), \quad \alpha_k^{(2)} = \frac{s_k^\top s_k}{s_k^\top y_k} \quad (\min \|\alpha^{-1} s - y\|^2).$$

- BB-CCV usa la **seconda**, più *aggressiva*: passi più grandi dove il gradiente cambia poco (direzione piatta), più piccoli dove cambia molto.
- Rischio**: se $s^\top y \approx 0$ (spostamento e variazione del gradiente quasi perpendicolari) il passo esplode; la **salvaguardia** $\text{clip}(s^\top s / s^\top y, \alpha/20, 5\alpha)$ lo tiene in $[\alpha/20, 5\alpha]$.
- Su J quadratiche ($y = As$ esatta, A definita positiva) il passo è **ottimale**: poche iterazioni. Su J generali la secante è solo locale e $s^\top y$ può diventare ≤ 0 : stabilizzano salvaguardia e line search di Armijo.

Dalla tesi — Sez. 5.4, eq. 5.55–5.56 e salvaguardia clip

Schema: BB-CCV (Fig. 5.6)



Gradiente dinamico con passo Barzilai–Borwein (line search di Armijo): la CCV regola la dimensione del campione mentre il passo adatta la lunghezza dello spostamento.

App web interattiva: esperimenti nel browser

- `visualizzazione.html`: singolo file, Pyodide + Plotly, nessuna installazione o server.
- Codice Python dei quattro algoritmi visibile e modificabile nel browser; preset quadratici + dataset sintetico “centrato” ($\widehat{J}_N = J$).
- Percorso 3D/2D su $J(w)$, metriche in tempo reale, pannelli “Analisi” e “Test batch” (per riprodurre le tabelle della tesi).
- Permette di osservare la dinamica del batch (n_k vs k) e l’effetto del parametro θ sulla soglia CCV.
- Implementazione Python standalone equivalente (`simulazione_batch.py`) per la rigenerazione di figure e tabelle della tesi.

Le funzioni test: espressioni usate negli esperimenti

- **Ben condizionata** ($\kappa \approx 1.1$): $J(w) = (w_1 - 1)^2 + (w_2 + 2)^2 + 0.1 w_1 w_2$
- **Mal condizionata** ($\kappa \approx 20$): $J(w) = 20 (w_1 - 1)^2 + (w_2 + 2)^2$
- **Molto mal condizionata** ($\kappa \approx 100$): $J(w) = 100 (w_1 - 1)^2 + (w_2 + 2)^2$
- **Termine incrociato** ($\kappa \approx 1.67$): $J(w) = (w_1 - 1)^2 + (w_2 + 2)^2 + 0.5 (w_1 - 1)(w_2 + 2)$
- **Funzione di Rosenbrock** (non quadratica, $c=100$):

$$J(w) = \frac{1}{N} \sum_{i=1}^N \left[(w_1 - a_i)^2 + 100((w_2 - b_i) - (w_1 - a_i))^2 \right],$$

con a_i, b_i stocastici centrati ($\sigma = 0.2$, medie 1 e -2), $N = 200$, seed 42: $w_* \approx (1.06, -1.96)$.

- Minimo comune dei quattro problemi quadratici: $w_* = (1, -2)$ (dataset centrato, $\hat{J}_N = J$).

Dalla tesi — Sez. 6.1 (Setup Sperimentale)

Il dataset sintetico “centrato”: $J(w)$ vs $\hat{J}_N(w)$

- Nel codice la **superficie plottata** è la funzione obiettivo teorica $J(w)$ (preset della loss): serve per disegnare il grafico, calcolare il percorso e mostrare le metriche $J(w_k)$ e $\|\nabla J(w_k)\|$.
- L'algoritmo però **non minimizza** $J(w)$: usa un dataset sintetico di N funzioni di perdita individuali $\ell(w; i)$, $i = 1, \dots, N$, costruito *perturbando i coefficienti* di $J(w)$; ogni $\ell(w; i)$ è il contributo del singolo esempio i .
- A ogni iterazione si estrae un batch $\mathcal{S}_k$ di dimensione n_k e si calcola il **gradiente del batch**
 $g_k = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i)$; la line search di Armijo usa la **loss del batch**
 $J_{\mathcal{S}_k}(w) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \ell(w; i)$. La media su tutti gli N dati è $\hat{J}_N(w) = \frac{1}{N} \sum_{i=1}^N \ell(w; i)$.
- **Dataset “centrato”**: le medie campionarie dei coefficienti delle perturbazioni coincidono esattamente con i coefficienti di $J(w) \Rightarrow \hat{J}_N(w) = J(w)$ e $\nabla \hat{J}_N(w) = \nabla J(w)$ per ogni w , *indipendentemente da N* (si sottrae a ogni perturbazione la propria media campionaria).
- Quindi $J(w)$ è la funzione plottata, ma l'algoritmo minimizza $\hat{J}_N(w)$ (o sue approssimazioni su batch); la loss campionaria totale $\hat{J}_N(w)$ è usata per la **condizione di arresto**. Nel codice la coincidenza $\hat{J}_N = J$ vale per ogni N *esattamente*; in un problema reale solo nel limite $N \rightarrow \infty$.

Dalla tesi — Sez. 6.2 (Architettura Software), “Costruzione del dataset sintetico centrato”

Setup e risultati numerici


- Setup: $N = 200$, seed 42,
 $w_0 = (2, -3)$, $\alpha = 0.1$, $\theta = 0.5$,
 $n_0 = 5$, 30 iterazioni, $\|\nabla J\|_2 < 10^{-6}$
(Wolfe; Armijo per BB-CCV).
- Funzioni test (5): ben condizionata ($\kappa \approx 1.1$), mal ($\kappa \approx 20$), molto mal ($\kappa \approx 100$), incrociato ($\kappa \approx 1.67$) e **Funzione di Rosenbrock** (non quadratica, $c=100$); formule a slide 28.
- n_k a “scalini”: il batch cresce solo se la CCV è violata (Fig. 5.3).
- BB-CCV su $\kappa \approx 100$:
 1.0991×10^{-14} (precisione macchina, cella verde in tabella).

Problema	Dynamic GD	BB-CCV	Newton-CG	Newton-CG L_1
$\kappa \approx 1.1$	1.1895×10^{-1}	1.1662×10^{-1}	4.0264×10^{-1}	1.0167×10^{-1}
$\kappa \approx 20$	4.9050×10^{-2}	9.7195×10^{-5}	2.3463×10^{-1}	4.8802×10^{-1}
$\kappa \approx 100$	4.6668×10^{-1}	1.0991×10^{-14}	2.0969×10^{-1}	9.6954×10^{-1}
incrociato ($\kappa \approx 1.67$)	9.4161×10^{-3}	6.1644×10^{-4}	3.5167×10^{-1}	2.0877×10^{-2}
Rosenbrock ($c=100$)	6.1354×10^{-4}	1.0645×10^{-1}	2.0625×10^{-1}	1.2525×10^{-1}

e_{30} = errore finale (base, seed 42), come in tesi_finale (Tab. riuso_sintesi):
sfondo su scala log, verde = minimo, rosso = massimo.

Riuso del mini-batch (Sez. 6.5)

- Variante studiata nella tesi: riusare lo stesso campione per M iterazioni consecutive (ricalcolando però il gradiente al punto corrente, non riusando i gradienti vecchi).
- La CCV fa da segnale di “esaurimento” del campione: quando non è più soddisfatta, n_k cresce e si ricampiona.
- $M = \infty$: si tiene il campione finché la CCV vale; il costo per iterazione scende, ma il campione “invecchia”.
- Effetti dipendenti dal metodo e dal condizionamento del problema: quantificati con le tabelle del Cap. 6.



Traiettorie con riuso del batch

Cosa significa riusare il batch

- Riusare il batch = tenere **fissa solo la lista di indici** S_k per M iterazioni; il gradiente è **ricalcolato al punto corrente** w_k a ogni iterazione (non si riusa il gradiente né una “direzione vecchia”).
- Sui *ben condizionati* la traiettoria sembra “dritta” perché w_S^* è vicino a w^* in ogni direzione: i gradienti successivi puntano quasi allo stesso bersaglio.
- Sui *mal condizionati* il minimo campionario w_S^* è spostato lungo la direzione quasi piatta: il batch fisso “tira” verso un bersaglio sbagliato (**bias sistematico**, Sez. 6.5.2), che la CCV **non** vede (misura la varianza interna, non il bias).
- **Primo ordine** (Dynamic GD, BB-CCV): $d_k = -g_k$ è sempre opposto al gradiente fresco (angolo 180°), la discesa sul batch è garantita: il rischio è solo la lenta *deriva* verso w_S^* .
- **Secondo ordine** (Newton-CG): con $\mathcal{H}_k$ fisso la curvatura “invecchia” mentre w_k avanza; $d_k = -H_k^{-1}g_k$ può finire a $\approx 90^\circ$ dalla vera discesa e la line search taglia il passo $\Rightarrow$ per questo serve lo stop adattivo (slide seguenti).

Dalla tesi — Sez. 6.5.2, “Meccanismo: vantaggi e limiti del riuso”

Perché il riuso è critico sui mal condizionati: l'esempio κ

Modello (Sez. 6.5.2): $J(w) = \kappa w_1^2 + w_2^2$ con $w^* = (0, 0)$, $\ell(w; i) = \kappa(w_1 + \varepsilon_1^{(i)})^2 + (w_2 + \varepsilon_2^{(i)})^2$ con $\varepsilon^{(i)} \sim \mathcal{N}(0, 0.04 I)$. La media sugli N esempi è $J(w)$, ma ogni loss è centrata in un punto diverso.

- **Primo ordine** ($d_k = -g_k$): **deriva permanente**. Il gradiente sul batch punta al *minimo* *campionario* $w_{\mathcal{S}}^* = (-\bar{\varepsilon}_1, -\bar{\varepsilon}_2) \neq w^*$:

$$g_k = \nabla J_{\mathcal{S}_k}(w_k) = [2\kappa(w_1 + \bar{\varepsilon}_1), 2(w_2 + \bar{\varepsilon}_2)]^\top, \quad \bar{\varepsilon}_j = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \varepsilon_j^{(i)}.$$

Nella direzione quasi piatta w_2 il gradiente di J è debolissimo: anche un piccolo $\bar{\varepsilon}_2 \approx 0.09$ ($n_k = 5$) sposta di molto $w_{\mathcal{S}}^*$. Riusare lo stesso batch significa smettere di mediare il rumore: l'iterato *deriva* verso $w_{\mathcal{S}}^*$, e la CCV non lo vede (misura la varianza interna, non il bias sistematico).

- **Secondo ordine** ($d_k = -H_k^{-1} g_k$): **Hessiana obsoleta**. H_k compensa il condizionamento: se è stata calcolata dove il batch è stato estratto ma w_k si è spostato, applica una curvatura *vecchia* (allunga il passo dove la funzione è diventata ripida, lo accorcia dove è diventata piatta). Con κ grande d_k può formare $\approx 90^\circ$ con la vera discesa: la line search taglia il passo e il metodo si *blocca* lontano dal minimo ($e_{30} \approx 1.28$ con $M=\infty$ su $\kappa \approx 100$).

Dalla tesi — Sez. 6.5.2, “Meccanismo: vantaggi e limiti del riuso”

Riuso del mini-batch: sintesi dei risultati (Tab. 6.1)

- **Aiuta:** ben condizionato ($\kappa \approx 1.1$), termine incrociato, BB-CCV su $\kappa \approx 20$ (fino a $\sim 10^{-10}$).
- **Peggiora:** BB-CCV su $\kappa \approx 100$ (base già alla precisione macchina, $\sim 10^{-14}$) e Dynamic GD/Newton-CG sui mal condizionati con $M=\infty$ (direzioni che invecchiano).

Metodo	base	$M=\infty$	$M=10$	$M=5$	$M=3$	$M=2$	$M=1$
$\kappa \approx 1.1$ - Dynamic GD	1.1895×10^{-1}	$1.1739 \times 10^{-1} \blacktriangle$	$1.1739 \times 10^{-1} \blacktriangle$	$1.1920 \times 10^{-1} \blacktriangledown$	$1.1903 \times 10^{-1} \blacktriangledown$	$1.1777 \times 10^{-1} \blacktriangle$	$1.1895 \times 10^{-1} =$
$\kappa \approx 1.1$ - BB-CCV	1.1662×10^{-1}	1.1662×10^{-1}	1.1662×10^{-1}	1.1662×10^{-1}	1.1662×10^{-1}	$1.1662 \times 10^{-1} \blacktriangle$	$1.1662 \times 10^{-1} =$
$\kappa \approx 1.1$ - Newton-CG	4.0264×10^{-1}	2.2230×10^{-1}	$3.7373 \times 10^{-1} \blacktriangle$	$4.1553 \times 10^{-1} \blacktriangledown$	3.2913×10^{-1}	2.6069×10^{-1}	$3.0560 \times 10^{-1} \blacktriangle$
$\kappa \approx 1.1$ - Newton-CG L_1	1.0167×10^{-1}	8.1750×10^{-2}	$9.2407 \times 10^{-2} \blacktriangle$	$1.0010 \times 10^{-1} \blacktriangle$	$1.0624 \times 10^{-1} \blacktriangledown$	9.4078×10^{-2}	$1.0028 \times 10^{-1} \blacktriangle$
$\kappa \approx 20$ - Dynamic GD	4.9050×10^{-2}	$1.0103 \times 10^{-1} \blacktriangledown$	$7.6020 \times 10^{-2} \blacktriangledown$	$4.7211 \times 10^{-2} \blacktriangle$	$1.1746 \times 10^{-1} \blacktriangledown$	4.2898×10^{-2}	$4.9050 \times 10^{-2} =$
$\kappa \approx 20$ - BB-CCV	9.7195×10^{-5}	9.5364×10^{-10}	9.5364×10^{-10}	$2.6835 \times 10^{-3} \blacktriangledown$	3.8422×10^{-8}	1.5436×10^{-10}	$9.7195 \times 10^{-5} =$
$\kappa \approx 20$ - Newton-CG	2.3463×10^{-1}	1.2807×10^{-1}	$9.4933 \times 10^{-1} \blacktriangledown$	$4.1051 \times 10^{-1} \blacktriangledown$	$3.3396 \times 10^{-1} \blacktriangledown$	$4.0617 \times 10^{-1} \blacktriangledown$	$1.6683 \times 10^{-1} \blacktriangle$
$\kappa \approx 20$ - Newton-CG L_1	4.8802×10^{-1}	7.6221×10^{-1}	5.5687×10^{-1}	$6.2190 \times 10^{-1} \blacktriangledown$	4.5512×10^{-1}	4.3392×10^{-1}	$5.4573 \times 10^{-1} \blacktriangledown$
$\kappa \approx 100$ - Dynamic GD	4.6668×10^{-1}	3.7060×10^{-1}	3.7060×10^{-1}	3.7060×10^{-1}	3.7060×10^{-1}	3.7060×10^{-1}	$4.6668 \times 10^{-1} =$
$\kappa \approx 100$ - BB-CCV	1.0991×10^{-14}	7.4538×10^{-3}	7.4538×10^{-3}	7.4538×10^{-3}	7.4538×10^{-3}	$7.4538 \times 10^{-3} \blacktriangledown$	$1.0991 \times 10^{-14} =$
$\kappa \approx 100$ - Newton-CG	2.0969×10^{-1}	1.2807×10^{-1}	6.4441×10^{-1}	3.3452×10^{-1}	3.7338×10^{-1}	4.4283×10^{-1}	$2.3041 \times 10^{-1} \blacktriangledown$
$\kappa \approx 100$ - Newton-CG L_1	9.6954×10^{-1}	9.7065×10^{-1}	8.6360×10^{-1}	$9.6997 \times 10^{-1} \blacktriangledown$	8.7711×10^{-1}	9.6944×10^{-1}	$8.6562 \times 10^{-1} \blacktriangle$
incrociato ($\kappa \approx 1.67$) - Dynamic GD	9.4161×10^{-3}	5.5315×10^{-3}	$9.9566 \times 10^{-3} \blacktriangledown$	5.9490×10^{-3}	$7.5801 \times 10^{-3} \blacktriangle$	$8.7213 \times 10^{-3} \blacktriangle$	$9.4161 \times 10^{-3} =$
incrociato ($\kappa \approx 1.67$) - BB-CCV	6.1644×10^{-4}	6.1689×10^{-4}	6.1689×10^{-4}	6.1689×10^{-4}	$6.1610 \times 10^{-4} \blacktriangle$	6.1685×10^{-4}	$6.1644 \times 10^{-4} =$
incrociato ($\kappa \approx 1.67$) - Newton-CG	3.5167×10^{-1}	4.1026×10^{-2}	1.0511×10^{-1}	$3.3540 \times 10^{-1} \blacktriangle$	2.3364×10^{-1}	2.1820×10^{-1}	$2.6381 \times 10^{-1} \blacktriangle$
incrociato ($\kappa \approx 1.67$) - Newton-CG L_1	2.0877×10^{-2}	3.8938×10^{-2}	$3.9410 \times 10^{-2} \blacktriangledown$	$2.9304 \times 10^{-2} \blacktriangledown$	2.3645×10^{-2}	3.8543×10^{-2}	$2.5154 \times 10^{-2} \blacktriangledown$
Funzione di Rosenbrock ($c=100$) - Dynamic GD	6.1354×10^{-4}	2.5435×10^0	2.5435×10^0	2.5435×10^0	2.0803×10^0	1.4213×10^0	$6.1354 \times 10^{-4} =$
Funzione di Rosenbrock ($c=100$) - BB-CCV	1.0645×10^{-1}	1.6648×10^{-1}	1.6648×10^{-1}	1.6648×10^{-1}	1.6648×10^{-1}	3.6984×10^{-1}	$1.0645 \times 10^{-1} =$
Funzione di Rosenbrock ($c=100$) - Newton-CG	2.0625×10^{-1}	1.0605×10^0	1.1367×10^0	1.2475×10^0	1.1893×10^0	1.2292×10^0	$9.3953 \times 10^{-1} \blacktriangledown$
Funzione di Rosenbrock ($c=100$) - Newton-CG L_1	1.2525×10^{-1}	3.8199×10^{-1}	2.4883×10^{-1}	$3.0766 \times 10^{-1} \blacktriangledown$	$3.1242 \times 10^{-1} \blacktriangledown$	2.7111×10^{-1}	$2.0207 \times 10^{-1} \blacktriangledown$

Dalla tesi — Sez. 6.5.5 e Tab. 6.1: errore finale e_{30} (seed 42) per tutti i valori di M ; $\blacktriangle/\blacktriangledown/=$ rispetto alla *base*.

Robustezza del riuso su 5 seed indipendenti (Tab. 6.2)

- Su $\kappa \approx 1.1$ il riuso regge su quasi tutti i seed (Dynamic GD e BB-CCV 5/5).
- Sui mal condizionati il segno dipende dal metodo; Newton-CG non migliora mai (0/5) $\Rightarrow$ serve un criterio automatico di stop.

Problema	Algoritmo	$M=\infty$			$M=10$		
		Migl.	Pegg.	Uguale	Migl.	Pegg.	Uguale
$\kappa \approx 1.1$	Dynamic GD	5	0	0	5	0	0
	BB-CCV	5	0	0	5	0	0
	Newton-CG	4	1	0	3	2	0
	Newton-CG L_1	4	1	0	5	0	0
$\kappa \approx 20$	Dynamic GD	2	3	0	1	4	0
	BB-CCV	3	2	0	3	2	0
	Newton-CG	0	5	0	0	5	0
	Newton-CG L_1	1	4	0	2	3	0
$\kappa \approx 100$	Dynamic GD	3	2	0	3	2	0
	BB-CCV	1	3	1	1	3	1
	Newton-CG	0	5	0	0	5	0
	Newton-CG L_1	3	2	0	4	1	0
incrociato ($\kappa \approx 1.67$)	Dynamic GD	4	1	0	3	2	0
	BB-CCV	2	3	0	2	3	0
	Newton-CG	4	1	0	3	2	0
	Newton-CG L_1	2	3	0	1	4	0
Funzione di Rosenbrock ($c=100$)	Dynamic GD	2	3	0	2	3	0
	BB-CCV	1	4	0	1	4	0
	Newton-CG	1	4	0	2	3	0
	Newton-CG L_1	1	4	0	2	3	0

Dalla tesi — Sez. 6.5.5 e Tab. 6.2: numero di seed (su 5, {42, 7, 123, 2024, 999}) in cui e_{30} è minore/maggiore/uguale rispetto alla *base*.

Stop adattivo con validation set: come funziona

- Il riuso richiede di fissare M (iterazioni sullo stesso batch), ma il valore ottimo cambia con problema e algoritmo e $M=\infty$ può far collassare i metodi di Newton. Lo stop adattivo **decide da solo quando ricampionare**, senza scegliere M a priori.
- Si riserva una frazione p del dataset come *validation set*: il mini-batch è campionato dal solo training set (CCV con tetto $|\mathcal{T}|$ invece di N) e l'Hessiana segue il batch (modalità legata).

Pseudocodice (iterazione esterna k , batch in riuso):

1. $S_k \leftarrow$ mini-batch dal training set; $g_k = \nabla J_{S_k}(w_k)$; aggiorna w_{k+1} con la line search.
2. Ogni f iterazioni (dopo l'aggiornamento) valuta $J_{\text{val}}(w_{k+1})$, la loss media sul validation set.
3. *Progresso* se $J_{\text{val}} \leq J_{\text{val}}^{\text{best}}(1 - \tau) - \epsilon_{\text{abs}}$: aggiorna il best e azzera il contatore.
4. Se per P valutazioni consecutive *non* c'è progresso $\Rightarrow$ **ricampiona** all'iterazione successiva (risplit se la strategia è *dinamica*).

Dalla tesi — Sez. 6.5.6. Iperparametri: $P, f, p, \tau, \epsilon_{\text{abs}}$, strategia di split (fissa o dinamica).

Stop adattivo con validation set (Tab. 6.3)

- Ricampiona quando la loss su un *validation set* smette di migliorare per P valutazioni; evita il collasso di $M=\infty$ sui metodi di Newton.
- Calibrato con ricerca a griglia (Sez. 6.5.8): $P=1$, $p=10\%$, split dinamico; scende sotto la *base* su 5 seed: 2.04×10^{-1} vs 2.16×10^{-1} (12/20).

Metodo	base	$M=\infty$	def.	$P=1, p=0.1, \text{dyn}$	$P=3, p=0.1, \text{dyn}$
$\kappa \approx 1.1$ - Dynamic GD	1.2412×10^{-1} (29)	$1.2347 \times 10^{-1} \blacktriangle (19)$	$1.2347 \times 10^{-1} \blacktriangle (19)$	$1.1704 \times 10^{-1} \blacktriangle (19)$	$1.1441 \times 10^{-1} \blacktriangle (18)$
$\kappa \approx 1.1$ - BB-CCV	1.2268×10^{-1} (29)	$1.2268 \times 10^{-1} \blacktriangledown (8)$	$1.2268 \times 10^{-1} \blacktriangledown (8)$	$1.1629 \times 10^{-1} \blacktriangle (26)$	$1.1629 \times 10^{-1} \blacktriangle (26)$
$\kappa \approx 1.1$ - Newton-CG	3.7346×10^{-1} (29)	$1.4142 \times 10^{-1} \blacktriangledown (6)$	$2.9780 \times 10^{-1} \blacktriangledown (3)$	$1.7763 \times 10^{-1} \blacktriangle (5)$	$1.6879 \times 10^{-1} \blacktriangle (6)$
$\kappa \approx 1.1$ - Newton-CG L_1	1.1114×10^{-1} (29)	$7.7838 \times 10^{-2} \blacktriangle (6)$	$7.7838 \times 10^{-2} \blacktriangle (6)$	$8.7102 \times 10^{-2} \blacktriangle (13)$	$8.7102 \times 10^{-2} \blacktriangle (13)$
$\kappa \approx 20$ - Dynamic GD	5.6422×10^{-2} (29)	$6.1835 \times 10^{-2} \blacktriangledown (1)$	$6.1835 \times 10^{-2} \blacktriangledown (1)$	$1.5675 \times 10^{-1} \blacktriangledown (27)$	$1.2093 \times 10^{-2} \blacktriangle (8)$
$\kappa \approx 20$ - BB-CCV	1.7173×10^{-3} (29)	$1.7173 \times 10^{-3} \blacktriangle (10)$	$1.7173 \times 10^{-3} \blacktriangle (13)$	$3.7758 \times 10^{-2} \blacktriangledown (26)$	$1.6199 \times 10^{-2} \blacktriangledown (20)$
$\kappa \approx 20$ - Newton-CG	1.7217×10^{-1} (29)	$6.4637 \times 10^{-1} \blacktriangledown (0)$	$3.6965 \times 10^{-1} \blacktriangledown (6)$	$1.8698 \times 10^{-1} \blacktriangledown (11)$	$4.0726 \times 10^{-1} \blacktriangledown (5)$
$\kappa \approx 20$ - Newton-CG L_1	4.8708×10^{-1} (29)	$5.9759 \times 10^{-1} \blacktriangledown (4)$	$5.9759 \times 10^{-1} \blacktriangledown (4)$	$6.6464 \times 10^{-1} \blacktriangledown (7)$	$6.7171 \times 10^{-1} \blacktriangledown (5)$
$\kappa \approx 100$ - Dynamic GD	4.5401×10^{-1} (29)	$4.7131 \times 10^{-1} \blacktriangledown (26)$	$4.7131 \times 10^{-1} \blacktriangledown (26)$	$5.4144 \times 10^{-1} \blacktriangledown (27)$	$4.0066 \times 10^{-1} \blacktriangle (26)$
$\kappa \approx 100$ - BB-CCV	1.7173×10^{-3} (29)	$1.4573 \times 10^{-3} \blacktriangle (26)$	$1.4573 \times 10^{-3} \blacktriangle (26)$	$3.4910 \times 10^{-3} \blacktriangledown (27)$	$2.2569 \times 10^{-1} \blacktriangledown (25)$
$\kappa \approx 100$ - Newton-CG	1.8251×10^{-1} (29)	$1.4142 \times 10^{-1} \blacktriangledown (0)$	$8.2559 \times 10^{-1} \blacktriangledown (8)$	$1.9718 \times 10^{-1} \blacktriangledown (12)$	$3.9508 \times 10^{-1} \blacktriangledown (5)$
$\kappa \approx 100$ - Newton-CG L_1	8.6698×10^{-1} (29)	$9.7009 \times 10^{-1} \blacktriangledown (3)$	$9.6923 \times 10^{-1} \blacktriangledown (4)$	$9.6870 \times 10^{-1} \blacktriangledown (9)$	$9.6870 \times 10^{-1} \blacktriangledown (4)$
incrociato ($\kappa \approx 1.67$) - Dynamic GD	1.8709×10^{-3} (29)	$1.7261 \times 10^{-2} \blacktriangle (16)$	$1.7261 \times 10^{-2} \blacktriangle (16)$	$6.1465 \times 10^{-3} \blacktriangle (16)$	$6.2449 \times 10^{-3} \blacktriangle (15)$
incrociato ($\kappa \approx 1.67$) - BB-CCV	9.5580×10^{-3} (29)	$9.5580 \times 10^{-3} \blacktriangle (19)$	$9.5580 \times 10^{-3} \blacktriangle (21)$	$5.3768 \times 10^{-4} \blacktriangle (27)$	$5.3768 \times 10^{-4} \blacktriangle (27)$
incrociato ($\kappa \approx 1.67$) - Newton-CG	2.8717×10^{-1} (29)	$1.4142 \times 10^{-1} \blacktriangledown (6)$	$7.8791 \times 10^{-2} \blacktriangledown (5)$	$9.2824 \times 10^{-2} \blacktriangledown (11)$	$1.7781 \times 10^{-1} \blacktriangle (8)$
incrociato ($\kappa \approx 1.67$) - Newton-CG L_1	1.0628×10^{-2} (29)	$2.2289 \times 10^{-2} \blacktriangledown (11)$	$2.2289 \times 10^{-2} \blacktriangledown (11)$	$2.7610 \times 10^{-2} \blacktriangledown (17)$	$2.7754 \times 10^{-2} \blacktriangledown (14)$
Funzione di Rosenbrock ($c=100$) - Dynamic GD	5.3698×10^{-3} (29)	$5.3845 \times 10^{-3} \blacktriangledown (22)$	$5.3845 \times 10^{-3} \blacktriangledown (22)$	$1.4065 \times 10^{-2} \blacktriangledown (24)$	$4.7963 \times 10^{-3} \blacktriangle (23)$
Funzione di Rosenbrock ($c=100$) - BB-CCV	5.3653×10^{-3} (29)	$5.3653 \times 10^{-3} \blacktriangledown (26)$	$5.3653 \times 10^{-3} \blacktriangledown (26)$	$5.0034 \times 10^{-3} \blacktriangledown (27)$	$5.0034 \times 10^{-3} \blacktriangle (27)$
Funzione di Rosenbrock ($c=100$) - Newton-CG	4.2039×10^{-1} (29)	$5.6994 \times 10^{-1} \blacktriangledown (2)$	$4.8797 \times 10^{-1} \blacktriangledown (3)$	$7.2464 \times 10^{-2} \blacktriangle (10)$	$9.7980 \times 10^{-2} \blacktriangle (7)$
Funzione di Rosenbrock ($c=100$) - Newton-CG L_1	2.0116×10^{-1} (29)	$1.2973 \times 10^{-1} \blacktriangle (2)$	$1.2973 \times 10^{-1} \blacktriangle (2)$	$1.1021 \times 10^{-1} \blacktriangle (3)$	$1.0884 \times 10^{-1} \blacktriangle (3)$
Media (20 casi)	1.9562×10^{-1}	$4.0383 \times 10^{-1} \blacktriangledown$	$2.3383 \times 10^{-1} \blacktriangledown$	$1.7919 \times 10^{-1} \blacktriangle$	$2.0065 \times 10^{-1} \blacktriangledown$

Dalla tesi — Sez. 6.5.6 e Tab. 6.3 (seed 42): tra parentesi il numero di ricampionamenti su 30 iterazioni. *def.* = valori di default ($P=3$, $p=20\%$, split fisso).

Validation set: perché evita il collasso di $M=\infty$

- **Perché $M=\infty$ collassa (Newton).** H_k è calcolata nel punto in cui il batch è stato estratto e “invecchia” mentre w_k si muove: curvatura vecchia su gradiente fresco $\Rightarrow d_k$ quasi $\perp$ alla discesa (fino a $\approx 90^\circ$), la line search dimezza α_k e l’iterato si blocca (e_{30} fino a 1.41). La CCV non lo vede: controlla solo la varianza interna dei gradienti del batch.
- **La validation è un giudice esterno** (i suoi dati non entrano in gradiente/Hessiana): finché il batch è utile J_{val} scende; quando H_k invecchia o si deriva verso $w_{\mathcal{S}}^*$, J_{val} smette di scendere (anche se J_{batch} scende ancora) $\Rightarrow$ dopo P controlli si ricampiona $\mathcal{S}_k$ (e H_k legata) al punto corrente: curvatura “rinfrescata”.
- **seed 42 (Tab. 6.3).** Newton-CG su $\kappa \approx 1.1$: $M=\infty$ 1.41 $\rightarrow$ default $2.98 \times 10^{-1} \rightarrow$ calib. $P=1, p=10\%, \text{dyn}$ 1.78×10^{-1} , migliore della base (3.73×10^{-1}). Con i default la media (20 casi) resta sopra la base: 2.34×10^{-1} vs 1.96×10^{-1} .
- **5 seed.** Default 2.67×10^{-1} (7/20), peggiore della base (2.16×10^{-1}); calib. $P=1, p=10\%, \text{dyn}$ 2.04×10^{-1} (12/20), sotto base e molto sotto $M=\infty$ (3.84×10^{-1}).
- **Perché $P=1, p=10\%, \text{dyn}$.** Pazienza bassa = criterio reattivo (in 30 iterazioni i passi persi contano); $p=10\%$ lascia più training di $p=20\%$; split dinamico riparte da zero la validation a ogni cambio di batch. Contano pazienza e p ; τ e strategia di split hanno effetti marginali.

Dalla tesi — Sez. 6.5.6, Tab. 6.3 (seed 42) e robustezza su 5 seed

Riuso per discesa della loss sul batch: come funziona

- Stesso obiettivo dello stop adattivo: capire quando il batch non porta più miglioramenti. Qui però **senza riservare dati**: si osserva solo la loss sul mini-batch corrente, campionato dall'intero dataset (CCV con tetto N).
- Le line search garantiscono già J_{batch} decrescente a ogni passo accettato: il criterio non scatta se la loss *cresce*, ma se *decresce troppo poco* (riduzione relativa sotto soglia), tipico in prossimità del minimo campionario del batch.

Pseudocodice (iterazione esterna k , batch in riuso):

1. $S_k \leftarrow$ mini-batch dall'intero dataset; $g_k = \nabla J_{S_k}(w_k)$; aggiorna w_{k+1} con la line search.
2. Ogni f iterazioni valuta $J_{\text{batch}}(w_k)$ e la confronta con la valutazione precedente *sullo stesso batch* (il confronto riparte da zero dopo ogni ricampionamento).
3. *Progresso* se $J_{\text{batch}}(w_{k-1}) - J_{\text{batch}}(w_k) \geq \tau |J_{\text{batch}}(w_{k-1})| + \epsilon_{\text{abs}}$.
4. Se per P valutazioni consecutive *non* c'è progresso $\Rightarrow$ **ricampiona** (il batch non porta più miglioramenti); una τ più alta (es. 10^{-3}) fa scattare il ricampionamento prima.

Dalla tesi — Sez. 6.5.7. Per Newton-CG L_1 si monitora $F_{\text{batch}} = J_{\text{batch}} + \nu \|w\|_1$ sul batch.

In alternativa: riuso per discesa della loss sul batch (Tab. 6.5)

- Alternativa *senza* validation set: si osserva la sola loss sul batch corrente (il batch non porta più miglioramenti quando la riduzione relativa è sotto soglia).
- Per i metodi di Newton evita il collasso di $M=\infty$ ($\kappa \approx 20$: da 1.28 a 2.48×10^{-1}); per Dynamic GD/BB-CCV quasi come $M=\infty$.

Metodo	base	$M=\infty$	def.	$P=1, \tau=10^{-3}, f=1$	$P=1, \tau=10^{-5}, f=1$
$\kappa \approx 1.1$ - Dynamic GD	1.1895×10^{-1} (29)	1.1739×10^{-1} $\blacktriangle$ (18)	1.1739×10^{-1} $\blacktriangle$ (18)	1.1739×10^{-1} $\blacktriangle$ (18)	1.1739×10^{-1} $\blacktriangle$ (18)
$\kappa \approx 1.1$ - BB-CCV	1.1662×10^{-1} (11)	1.1662×10^{-1} $\blacktriangle$ (5)	1.1662×10^{-1} $\blacktriangle$ (5)	1.1662×10^{-1} $\blacktriangle$ (5)	1.1662×10^{-1} $\blacktriangle$ (5)
$\kappa \approx 1.1$ - Newton-CG	3.0560×10^{-1} (29)	2.2230×10^{-1} $\blacktriangle$ (2)	1.6534×10^{-1} $\blacktriangle$ (4)	1.6534×10^{-1} $\blacktriangle$ (4)	1.6534×10^{-1} $\blacktriangle$ (4)
$\kappa \approx 1.1$ - Newton-CG L_1	1.0028×10^{-1} (29)	8.1750×10^{-2} $\blacktriangle$ (8)	8.1750×10^{-2} $\blacktriangle$ (8)	8.1750×10^{-2} $\blacktriangle$ (8)	8.1750×10^{-2} $\blacktriangle$ (8)
$\kappa \approx 20$ - Dynamic GD	4.9050×10^{-2} (29)	1.0103×10^{-1} $\blacktriangledown$ (1)	1.0103×10^{-1} $\blacktriangledown$ (1)	4.8866×10^{-2} $\blacktriangle$ (14)	1.0103×10^{-1} $\blacktriangledown$ (1)
$\kappa \approx 20$ - BB-CCV	9.7195×10^{-3} (29)	9.5364×10^{-10} $\blacktriangle$ (14)	9.5364×10^{-10} $\blacktriangle$ (14)	9.5364×10^{-10} $\blacktriangle$ (14)	9.5364×10^{-10} $\blacktriangle$ (14)
$\kappa \approx 20$ - Newton-CG	1.6683×10^{-1} (29)	1.2807×10^0 $\blacktriangledown$ (0)	2.4844×10^{-1} $\blacktriangledown$ (8)	2.4844×10^{-1} $\blacktriangledown$ (8)	2.4844×10^{-1} $\blacktriangledown$ (8)
$\kappa \approx 20$ - Newton-CG L_1	5.4573×10^{-1} (29)	7.6221×10^{-1} $\blacktriangledown$ (5)	7.6221×10^{-1} $\blacktriangledown$ (5)	7.6221×10^{-1} $\blacktriangledown$ (5)	7.6221×10^{-1} $\blacktriangledown$ (5)
$\kappa \approx 100$ - Dynamic GD	4.6668×10^{-1} (29)	3.7060×10^{-1} $\blacktriangle$ (27)	3.7060×10^{-1} $\blacktriangle$ (27)	3.7060×10^{-1} $\blacktriangle$ (27)	3.7060×10^{-1} $\blacktriangle$ (27)
$\kappa \approx 100$ - BB-CCV	1.0991×10^{-14} (10)	7.4538×10^{-3} $\blacktriangledown$ (24)	7.4538×10^{-3} $\blacktriangledown$ (24)	7.4538×10^{-3} $\blacktriangledown$ (24)	7.4538×10^{-3} $\blacktriangledown$ (24)
$\kappa \approx 100$ - Newton-CG	2.3041×10^{-1} (29)	1.2807×10^0 $\blacktriangledown$ (0)	4.2582×10^{-1} $\blacktriangledown$ (11)	4.2582×10^{-1} $\blacktriangledown$ (11)	4.2582×10^{-1} $\blacktriangledown$ (11)
$\kappa \approx 100$ - Newton-CG L_1	8.6562×10^{-1} (29)	9.7065×10^{-1} $\blacktriangledown$ (5)	9.7065×10^{-1} $\blacktriangledown$ (5)	9.7065×10^{-1} $\blacktriangledown$ (5)	9.7065×10^{-1} $\blacktriangledown$ (5)
incrociato ($\kappa \approx 1.67$) - Dynamic GD	9.4161×10^{-3} (29)	5.5315×10^{-3} $\blacktriangle$ (16)	5.5315×10^{-3} $\blacktriangle$ (16)	5.5315×10^{-3} $\blacktriangle$ (16)	5.5315×10^{-3} $\blacktriangle$ (16)
incrociato ($\kappa \approx 1.67$) - BB-CCV	6.1644×10^{-4} (15)	6.1689×10^{-4} $\blacktriangledown$ (9)	6.1689×10^{-4} $\blacktriangledown$ (9)	6.1689×10^{-4} $\blacktriangledown$ (9)	6.1689×10^{-4} $\blacktriangledown$ (9)
incrociato ($\kappa \approx 1.67$) - Newton-CG	2.6381×10^{-1} (29)	4.1026×10^{-2} $\blacktriangle$ (5)	4.1026×10^{-2} $\blacktriangle$ (5)	4.1026×10^{-2} $\blacktriangle$ (5)	4.1026×10^{-2} $\blacktriangle$ (5)
incrociato ($\kappa \approx 1.67$) - Newton-CG L_1	2.5154×10^{-2} (29)	3.8938×10^{-2} $\blacktriangledown$ (10)	3.8938×10^{-2} $\blacktriangledown$ (10)	3.8938×10^{-2} $\blacktriangledown$ (10)	3.8938×10^{-2} $\blacktriangledown$ (10)
Funzione di Rosenbrock ($c=100$) - Dynamic GD	6.1354×10^{-4} (29)	2.5435×10^0 $\blacktriangledown$ (25)	2.5435×10^0 $\blacktriangledown$ (25)	2.5435×10^0 $\blacktriangledown$ (25)	2.5435×10^0 $\blacktriangledown$ (25)
Funzione di Rosenbrock ($c=100$) - BB-CCV	1.0645×10^{-1} (29)	1.6648×10^{-1} $\blacktriangledown$ (10)	1.6648×10^{-1} $\blacktriangledown$ (10)	1.6648×10^{-1} $\blacktriangledown$ (10)	1.6648×10^{-1} $\blacktriangledown$ (10)
Funzione di Rosenbrock ($c=100$) - Newton-CG	9.3953×10^{-1} (29)	1.0605×10^0 $\blacktriangledown$ (0)	1.0247×10^0 $\blacktriangledown$ (4)	1.0247×10^0 $\blacktriangledown$ (4)	1.0247×10^0 $\blacktriangledown$ (4)
Funzione di Rosenbrock ($c=100$) - Newton-CG L_1	2.0207×10^{-1} (29)	3.8199×10^{-1} $\blacktriangledown$ (0)	3.8199×10^{-1} $\blacktriangledown$ (0)	3.8199×10^{-1} $\blacktriangledown$ (0)	3.8199×10^{-1} $\blacktriangledown$ (0)

Dalla tesi — Sez. 6.5.7 e Tab. 6.5 (seed 42): tra parentesi il numero di ricampionamenti su 30 iterazioni. *def.* = valori di default ($\tau=10^{-4}$, $P=1$, $f=1$).

Discesa della loss sul batch: lettura dei risultati

- **Meccanismo (ricorda).** Nessun dato riservato: si campiona dall'intero dataset (tetto N); la decisione usa solo J_{batch} sul batch corrente. La line search fa scendere sempre J_{batch} : il criterio scatta quando la discesa è *troppo lenta* (vicino al minimo campionario), non quando la loss sale.
- **seed 42 (Tab. 6.5).** Primo ordine $\approx M=\infty$: pochi ricampionamenti (BB-CCV su $\kappa \approx 20$ fino a $\sim 9.5 \times 10^{-10}$); τ più alto (10^{-3}) $\Rightarrow$ più ricampionamenti: Dynamic GD su $\kappa \approx 20$ torna vicino alla base ($\approx 4.9 \times 10^{-2}$).
- **Newton protetto.** Newton-CG su $\kappa \approx 20$: da 1.28 ($M=\infty$) a 2.48×10^{-1} ; evita il collasso anche per Newton-CG L_1 (si monitora F_{batch}).
- **Punto debole: Rosenbrock.** Sul batch locale la loss scende sempre: nessun segnale di “deriva”; il criterio trattiene troppo il batch e peggiora tutti i metodi (su Rosenbrock: 1.97×10^{-1} base $\rightarrow 3.84 \times 10^{-1}$ con la discesa).
- **5 seed (Tab. 6.7).** Discesa calib. ($\tau=10^{-3}$, $P=1$, $f=1$): vince 11/20 ma media 2.38×10^{-1} sopra la base (2.09×10^{-1}); la validation calib. resta migliore in media (2.04×10^{-1} , 12/20) ma “costa” il 10% dei dati.
- **In sintesi.** È l'alternativa alla validation *senza riservare dati* e protegge i metodi di Newton dal collasso; non risolve Rosenbrock. Per Dynamic GD/BB-CCV resta consigliata la *base*; per Newton-CG la validation $P=1$, $p=10\%$.

Dalla tesi — Sez. 6.5.7–6.5.8, Tab. 6.5 (seed 42) e Tab. 6.7 (5 seed)

Confronto finale su 5 seed: base, $M=\infty$, validation e discesa (Tab. 6.7)

- $\bar{e}_{30}$ = media su 20 combinazioni problema×algoritmo e 5 seed; *vitt.* = caselle (su 20) in cui la strategia batte la *base*.
- $M=\infty$ è la peggiore in media (3.73×10^{-1}); validation calib. 2.04×10^{-1} (12/20), discesa calib. 2.38×10^{-1} (11/20).
- La discesa usa l'intero dataset; la validation tiene fuori il 10% dei dati.

Strategia	$\bar{e}_{30}$	<i>vitt.</i>	$\kappa \approx 1.1$	$\kappa \approx 20$	$\kappa \approx 100$	incr. ($\kappa \approx 1.67$)	Funzione di Rosenbrock ($c=100$)
<i>base</i>	2.0909×10^{-1}		1.7930×10^{-1}	1.7595×10^{-1}	4.1162×10^{-1}	8.1419×10^{-2}	1.9719×10^{-1}
$M=\infty$	3.7299×10^{-1}		1.9159×10^{-1}	5.0123×10^{-1}	6.6432×10^{-1}	9.8773×10^{-2}	4.0901×10^{-1}
Validation calib. ($P=1, p=0.1, \text{dyn}$)	2.0375×10^{-1}		1.4045×10^{-1}	2.1065×10^{-1}	4.5437×10^{-1}	3.9223×10^{-2}	1.7407×10^{-1}
Discesa calib. ($\tau=10^{-3}, P=1, f=1$)	2.3817×10^{-1}		1.1855×10^{-1}	2.3416×10^{-1}	4.2013×10^{-1}	3.4413×10^{-2}	3.8362×10^{-1}

Dalla tesi — Sez. 6.5.6–6.5.7 e Tab. 6.7: confronto dei due criteri automatici su 5 seed. “*calib.*” = parametri del criterio scelti con una ricerca a griglia (Sez. 6.5.8), non i default: validation $P=1$, $p=10\%$, split dinamico (default $P=3$, $p=20\%$, split fisso); discesa $\tau=10^{-3}$, $P=1$, $f=1$ (default $\tau=10^{-4}$).

Conclusioni

- Quadro completo: dalla varianza del gradiente stocastico (SGD) e dai metodi a varianza ridotta (SVRG/SAGA) si arriva a una regola *dinamica e basata sui dati* per la dimensione del campione.
- Arresto adattivo del CG per Newton-CG: criterio automatico basato sulla varianza dei prodotti Hessiana–vettore.
- Implementazione Python dei quattro algoritmi + app web interattiva per ripetere gli esperimenti.
- Esperimenti sui problemi quadratici sintetici (da $\kappa \approx 1.1$ a $\kappa \approx 100$) e sulla Funzione di Rosenbrock; analizzato anche il riuso del mini-batch con stop adattivo.

Limiti e lavoro futuro

- Limite attuale: esperimenti solo su problemi sintetici (quadratici centrati, $\kappa \approx 1.1, 20, 100$, termine incrociato, Funzione di Rosenbrock).
- Limite attuale: nessun confronto sistematico con SVRG/SAGA sulle stesse batterie di test.
- Futuro: rapporto di sottocampionamento R dell'Hessiana dinamico (oggi R è fisso: si adatta solo n_k del gradiente).
- Futuro: validazione su dataset reali e problemi non convessi, confronto sistematico con SVRG/SAGA su larga scala.