

Teorema

Teorema 3.1 (Convergenza in aspettativa). Posto $\alpha := 1 - \frac{\lambda}{L}$ e $\beta := \frac{\omega}{2L}$, per ogni $k \geq 0$ vale

$$\mathbb{E}[J(w_k) - J(w_*)] \leq \alpha^k \varepsilon_0 + \beta a \frac{\alpha^k - a^{-k}}{\alpha a - 1},$$

dove il rapporto va inteso nel senso dei limiti se $\alpha a = 1$. Di conseguenza, posto $\rho := \max\{\alpha, 1/a\}$, se $a > 1$ si ha $\rho < 1$ ed esiste una costante $C = C(\varepsilon_0, \omega, \lambda, L, a)$ tale che

$$\mathbb{E}[J(w_k) - J(w_*)] \leq C \rho^k \quad \forall k \geq 0.$$

Ipotesi del Teorema 3.1

- **Struttura di J .** J è λ -fortemente convessa ($\nabla^2 J(w) \succeq \lambda I$, $\lambda > 0$, con minimo unico w_*) e L -liscia ($\nabla^2 J(w) \preceq L I$). Ne seguono la maggiorazione di Taylor e la disuguaglianza di Polyak–Łojasiewicz in forma forte $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$ (con $J(w_*) = 0$).
- **Campionamento e stimatore.** Dataset finito, $J(w) = \frac{1}{N} \sum_{i=1}^N \ell(w; i)$ con indice I uniforme su $\{1, \dots, N\}$; lo stimatore $g_k = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i)$ è non distorto: $\mathbb{E}[g_k | w_k] = \nabla J(w_k)$.
- **Varianza limitata** (uniformemente in w_k): $\|\text{Var}(\nabla \ell(w_k; I))\|_1 \leq \omega$ con $\omega > 0$; di conseguenza $\|\text{Var}(g_k)\|_1 \leq \omega/n_k$.
- **Algoritmo.** Passo fisso $1/L$: $w_{k+1} = w_k - \frac{1}{L} g_k$; dimensione del batch geometrica $n_k = \lceil a^k \rceil$ con $a > 1$ (è quanto basta perché $\rho = \max\{1 - \lambda/L, 1/a\} < 1$).
- **Ipotesi ausiliarie** (non nell'enunciato). Condizione di accuratezza $\|g_k - \nabla J(w_k)\| \leq \theta \|g_k\|$, $\theta \in [0, 1)$, usata solo per giustificare la crescita geometrica del batch; per la complessità totale $a \leq (1 - \lambda/L)^{-1}$.

La tolleranza θ non compare nell'enunciato: nel caso in aspettativa il controllo puntuale dell'errore è sostituito dall'ipotesi di varianza limitata. La costante ω è un parametro dell'analisi; in pratica è ignota e viene stimata dalla varianza campionaria.

Teorema 3.1 vs. Nocedal et al. (2012)

Simboli: J obiettivo, J_* minimo, ∇J gradiente; λ convessità forte, L lisciatezza; θ tolleranza; ω bound di varianza; $n_k = |\mathcal{S}_k|$ batch, $n_k = \lceil a^k \rceil$; ε accuratezza richiesta.

Aspetto	Nocedal et al. (2012)	Questa tesi (Teor. 3.1)
Stima del gradiente	$\ \nabla J\ ^2 \geq \lambda (J - J_*)$ (perde un fattore 2)	$\ \nabla J\ ^2 \geq 2\lambda (J - J_*)$ (convessità forte)
Convergenza deterministica	$1 - (1 - \theta)\lambda/(2L)$	$1 - (1 - \theta)\lambda/L$
Ricorrenza in aspettativa	$\varepsilon_{k+1} \leq (1 - \lambda/2L)\varepsilon_k + \omega/(2Ln_k)$	$\varepsilon_{k+1} \leq (1 - \lambda/L)\varepsilon_k + \omega/(2Ln_k)$
Metodo	induzione (maggiorazioni)	soluzione esatta (forma chiusa)
Tasso di convergenza ρ	$1 - \lambda/(4L)$	$1 - \lambda/L$
Intervallo per a	$1 < a \leq (1 - \lambda/4L)^{-1}$	$1 < a \leq (1 - \lambda/L)^{-1}$ (più ampio)
Costante C	$C = M_N$	$C = C(\varepsilon_0, \omega, \lambda, L, a)$, esplicita
Complessità per ε	gradienti $O(L/\lambda\varepsilon)$; lavoro $O(Lm/(\lambda\varepsilon) M_N)$	stesso ordine; lavoro $O(Lm/(\lambda\varepsilon) M_T)$, $M_T < M_N$

Note: $\Delta_0 = J(w_0) - J(w_*)$; $M_N = \max\{\Delta_0, 2\omega/\lambda\}$; $M_T = \max\{\Delta_0, \omega/\lambda\}$. Esito: tasso λ/L vs. $\lambda/(4L)$; complessità invariata.

Convergenza deterministica vs. Nocedal et al. (2012)

Teorema

Teorema (Convergenza deterministica). Sia $J : \mathbb{R}^m \rightarrow \mathbb{R}$ λ -fortemente convessa ($\nabla^2 J(w) \succeq \lambda I$) e con gradiente L -Lipschitz ($\nabla^2 J(w) \preceq LI$). Se a ogni iterazione vale la condizione di accuratezza e il passo è $\alpha = (1 - \theta)/L$, allora

$$\varepsilon_{k+1} \leq \left(1 - \frac{(1 - \theta)\lambda}{L}\right) \varepsilon_k, \quad \varepsilon_k := J(w_k) - J(w_*).$$

Di conseguenza il fattore di riduzione per iterazione è $\rho = 1 - \frac{(1 - \theta)\lambda}{L}$, e il numero di iterazioni per ottenere $J(w_k) - J(w_*) \leq \varepsilon$ è

$$k \leq \frac{L}{(1 - \theta)\lambda} \log\left(\frac{J(w_0) - J(w_*)}{\varepsilon}\right) = O\left(\frac{L}{\lambda} \log \frac{1}{\varepsilon}\right).$$

Aspetto	Nocedal et al. (2012)	Questa tesi
Disuguaglianza usata	$\ \nabla J\ ^2 \geq \lambda(J - J_*)$ (debole)	$\ \nabla J\ ^2 \geq 2\lambda(J - J_*)$ (forma forte)
Effetto: contrazione per iterazione	$1 - (1 - \theta)\lambda/(2L)$	$1 - (1 - \theta)\lambda/L$
Effetto: iterazioni per ε	$k \leq \frac{2L}{(1 - \theta)\lambda} \log\left(\frac{\Delta_0}{\varepsilon}\right)$	$k \leq \frac{L}{(1 - \theta)\lambda} \log\left(\frac{\Delta_0}{\varepsilon}\right)$

Con $\Delta_0 = J(w_0) - J(w_*)$. *Unica differenza di partenza:* la disuguaglianza più forte (Polyak–Łojasiewicz in forma forte); contrazione e bound su k (fattore 2 sul coefficiente) ne sono la conseguenza.