



SAPIENZA
UNIVERSITÀ DI ROMA

Selezione Dinamica della Dimensione del Campione in Algoritmi di Ottimizzazione per il Machine Learning su Larga Scala

Metodi adattivi con campionamento dinamico dell'Hessiana
per problemi di ottimizzazione convessa

Facoltà di Scienze Matematiche Fisiche e Naturali
Scienze Matematiche per l'Intelligenza Artificiale

Alessandro Lo Curcio

Matricola 2107367

Relatore

Prof. Marco Sciandrone

Anno Accademico 2025/2026

Ringraziamenti

Ringrazio tutte le persone con cui ho studiato, i miei insegnanti e la mia famiglia per il supporto; in particolare, ringrazio:

Giovanni Adelfio, Alessandro Pisarra, Lorenzo Salis, Alessandro Cattaneo,
Alessio Progetti, Alberto Floris, Alessandro Centomini, Federico Carattoli,
Elena Mannoni, Alessandra Melchionna,
Azzurra Giordano, Rosamaria Graziosi, Natalia Pasquetto,
Marco Galletti, Francesco Mondelli, Luca Montefusco,
Cristina Pesci, Emmanuel Nsia, Ilenia Filippi, Giada Manfredi,
Gaia Facioni, Gabriele Cirillo, Mario Prignano, Michele Aliffi,
Luca Veneri, Matteo Pinato,
Mariagiusti Nicodemo, Aurora Di Giovanna, Sofia De Angelis,
Giovanni Gigante, Rita Grifo, Alessandro Pirisinu, Francesco Terracciano, Marco
dell'Oste,
Luigi Capini, Luca Massimo Andrea Martinazzi, Claudia Malvenuto,
Giulio D'Agostini,
Grant Sanderson, Steve Chow, Navdeep Singh, Francesco Zamponi, Emanuele
Caglioti,
Gabriella Puppo, Antonella Poggi, Federica Baccini, Marco Sciandrone,
Fabrizio Silvestri, Marco Isopi, Elena Agliari, Davide Torlo, Emanuele Rodolà,
Maria Antonietta Palladino

Inoltre, ringrazio ogni artista che, indirettamente, mi ha motivato ad andare avanti nei momenti difficili, in particolare:

Eminem, Chris Webby, Token, NF, Dope D.O.D.,
Mostro, Hopsin, Snak The Ripper, Ensi,
JZAC

Abstract

Questa tesi presenta, in forma rigorosa ma accessibile, la metodologia per la selezione dinamica della dimensione del campione negli algoritmi di ottimizzazione per il machine learning su larga scala, basandosi sul lavoro seminale di Byrd, Chin, Nocedal e Wu [1]. L'idea centrale è la seguente: anziché scegliere a priori una dimensione fissa del batch (il sottoinsieme di dati usato ad ogni iterazione), è possibile decidere durante l'algoritmo se e quando aumentarla, guidandosi da stime statistiche della varianza del gradiente stocastico. I contributi di questo lavoro sono un'analisi teorica completa dei metodi a campione dinamico (convergenza lineare deterministica e in aspettativa, stima della complessità totale), il miglioramento di alcuni risultati di convergenza mediante disuguaglianze più strette, e un'implementazione Python dei quattro algoritmi (gradiente a campione dinamico, Newton-CG con Hessiana sotto-campionata, estensione ai problemi con regolarizzazione L_1 e BB-CCV, il gradiente dinamico con passo di Barzilai–Borwein) con un'applicazione web interattiva per la sperimentazione. Il documento è organizzato in sette capitoli: dopo l'introduzione e il background necessario, si formula il problema di ottimizzazione, si passano in rassegna i lavori correlati, si descrivono gli algoritmi studiati, se ne discute l'implementazione interattiva con i risultati sperimentali e si traggono le conclusioni con le prospettive di lavoro futuro. I dettagli dimostrativi e i codici Python completi sono raccolti in appendice.

Indice

1	Introduzione	5
1.1	Contesto	5
1.2	Il problema: la dimensione del mini batch	5
1.3	La soluzione proposta: il campionamento dinamico	5
1.4	Contributi del lavoro	5
1.5	Struttura della tesi	6
2	Background e Notazione	6
2.1	Glossario dei simboli ricorrenti	6
2.2	Collegamento con la formulazione del problema	7
3	Formulazione del Problema	8
3.1	Apprendimento supervisionato su larga scala	8
3.2	La sfida computazionale	8
3.3	Il trade off	9
3.4	Formulazione del problema	9
3.5	Ipotesi su J	9
4	Lavori Correlati	11
4.1	Metodi di ottimizzazione stocastica	11
4.2	Campionamento dinamico	11
4.3	Metodi di secondo ordine stocastici	12
4.4	Regolarizzazione L_1 in ottimizzazione	12
5	Algoritmi Proposti	13
5.1	Metodo del Gradiente a Campione Dinamico	13
5.1.1	Formulazione della dinamica del batch	14
5.1.2	Formulazione matematica della condizione di accettazione	14
5.1.3	Regola di aggiornamento del batch	17
5.1.4	Pseudocodice (Algoritmo)	18
5.1.5	Convergenza deterministica	19
5.1.6	Analisi Stocastica e Complessità del Metodo	23
5.2	Metodo di Newton-CG con Campionamento Dinamico	31
5.2.1	Struttura del metodo	31
5.2.2	Criterio di terminazione del gradiente coniugato	32
5.2.3	Pseudocodice (Algoritmo Newton-CG)	35
5.3	Metodo Newton-CG per Modelli con Regolarizzazione L_1	39
5.3.1	Formulazione del Problema	39
5.3.2	Il gradiente generalizzato	39
5.3.3	Identificazione dell'Active Set e della Faccia Ortante	41
5.3.4	Fase di Minimizzazione nel Sottospazio	42
5.3.5	Ricerca Lineare Proiettata	43
5.3.6	Algoritmo Completo	44
5.4	Metodo BB-CCV (Barzilai–Borwein con campionamento dinamico)	46
5.4.1	Il metodo di Barzilai–Borwein	46
5.4.2	Schema dell'algoritmo BB-CCV	48

6	Esperimenti e Visualizzazione Interattiva	49
6.1	Setup Sperimentale	49
6.2	Architettura Software	51
6.3	Risultati Numerici	52
6.4	Visualizzazione Interattiva	53
6.5	Riuso del mini-batch: iterazioni consecutive sullo stesso campione . .	54
6.5.1	Descrizione della variante	54
6.5.2	Meccanismo: vantaggi e limiti del riuso	55
6.5.3	Setup sperimentale	57
6.5.4	Risultati numerici	58
6.5.5	Sintesi: quando il riuso aiuta e quando no	59
6.5.6	Stop adattivo con validation set	62
6.5.7	Riuso per discesa della loss sul batch	64
6.5.8	Iperparametri consigliati per ciascun metodo	67
7	Conclusioni e Lavoro Futuro	69
7.1	Riassunto dei risultati	69
7.2	Limiti dello studio	69
7.3	Direzioni per lavoro futuro	70
A	Dimostrazioni	71
A.1	Dimostrazione delle disuguaglianze di Polyak–Łojasiewicz	71
A.2	Dimostrazione del fattore di correzione per popolazione finita	74
A.3	Dimostrazione delle formule per α_k e β_k nel Metodo del Gradiente Coniugato	77
A.4	Spiegazione delle condizioni sul passo α_k	80
B	Codici Python completi	80
B.1	Metodo del gradiente a campione dinamico	81
B.2	Newton-CG con campionamento dinamico	84
B.3	Newton-CG per problemi L_1 -regolarizzati	88
B.4	Barzilai–Borwein con campionamento dinamico	93
C	Istruzioni per l'esecuzione	96
C.1	Dipendenze	96
C.2	Installazione	96
C.3	Esecuzione degli esperimenti numerici	96
C.4	Esecuzione dei singoli algoritmi	97
C.5	Avvio dell'applicazione web	97
C.6	Requisiti di sistema	97
D	Schemi dei metodi a varianza ridotta	97

1 Introduzione

1.1 Contesto

Nel machine learning su larga scala si dispone di un dataset di N esempi (spesso dell'ordine di 10^6 – 10^9) e si cerca il vettore di parametri w che minimizza la perdita media $J(w)$. Il calcolo del gradiente completo $\nabla J(w)$ richiede di valutare la perdita su tutti gli esempi, con costo $O(Nm)$ ad iterazione, proibitivo se ripetuto su larga scala.

Per questo motivo gli algoritmi di ottimizzazione stocastica, che usano ad ogni passo soltanto un sottoinsieme dei dati (batch), sono diventati lo standard: la letteratura offre un ampio spettro di metodi, dal gradiente stocastico classico (SGD) [6, 2] ai metodi a varianza ridotta [10, 9].

1.2 Il problema: la dimensione del mini batch

La scelta della dimensione del mini batch è un compromesso fondamentale. Un batch piccolo rende ogni iterazione economica ma il gradiente stimato è rumoroso, e il rumore limita la precisione raggiungibile. Un batch grande fornisce una stima più accurata, ma il costo per iterazione cresce proporzionalmente alla sua dimensione. Nei metodi classici la dimensione del batch è fissa e scelta euristicamente all'inizio dell'ottimizzazione, senza alcun adattamento alla difficoltà del problema: se il batch è troppo piccolo si rischia di non convergere alla precisione desiderata; se è troppo grande si spreca risorse computazionali nelle prime iterazioni, dove una stima grossolana sarebbe più che sufficiente.

1.3 La soluzione proposta: il campionamento dinamico

La soluzione studiata in questa tesi consiste nel rendere dinamica la dimensione del batch: si parte da un campione piccolo per fare progressi rapidi ed economici e lo si aumenta progressivamente quando serve precisione. La decisione su quando e di quanto aumentare il batch è guidata da una condizione di controllo della varianza (CCV): finché la varianza campionaria del gradiente stocastico è piccola rispetto alla norma del gradiente corrente, il batch corrente è adeguato; quando il gradiente si avvicina a zero, il rumore relativo cresce e la CCV impone un batch più grande. In questo modo la risorsa computazionale viene concentrata dove è realmente necessaria, con un adattamento automatico alla difficoltà del problema.

Questa idea, introdotta da Byrd, Chin, Nocedal e Wu [1], è qui approfondita sotto tre aspetti: un'analisi teorica completa del metodo del gradiente a campione dinamico e della sua variante Newton-CG con Hessiana sottocampionata (convergenza lineare deterministica e in aspettativa, complessità totale); il raffinamento di alcuni risultati di convergenza mediante disuguaglianze più strette; e l'implementazione degli algoritmi in Python, accompagnata da un'applicazione web interattiva che ne permette la sperimentazione diretta.

1.4 Contributi del lavoro

I metodi qui analizzati, gradiente a campione dinamico, Newton-CG con Hessiana sottocampionata ed estensione ai problemi con regolarizzazione L_1 , sono stati in-

trodotto da Byrd, Chin, Nocedal e Wu [1]. I contributi di questa tesi riguardano l'analisi, il miglioramento di alcuni risultati di convergenza e l'implementazione:

1. **Analisi teorica.** Viene fornita una trattazione completa della dinamica del batch basata sul controllo della varianza: si dimostra la convergenza lineare del metodo del gradiente a campione dinamico, in forma deterministica e in aspettativa, e si ricava una stima della complessità totale competitiva con quella di SGD e migliore sui problemi mal condizionati.
2. **Miglioramento dei teoremi di convergenza.** I risultati di convergenza dei metodi a campione dinamico sono raffinati rispetto al lavoro originale [1] e a Nocedal e Wright [3], e il contributo non è solo l'impiego della disuguaglianza di Polyak–Łojasiewicz nella forma forte $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$: la ricorrenza di convergenza in aspettativa è anche risolta in forma chiusa, senza il fattore $1/2$ che l'argomento induttivo del lavoro originale introduce. In particolare, il fattore di contrazione del metodo del gradiente a campione dinamico passa da $1 - \frac{(1-\theta)\lambda}{2L}$ a $1 - \frac{(1-\theta)\lambda}{L}$, con il dimezzamento delle iterazioni necessarie per raggiungere l'accuratezza ε (Sezione 5.1.5); il tasso di convergenza in aspettativa diventa $\rho = \max\{1 - \lambda/L, 1/a\}$ (da $\max\{1 - \lambda/(4L), 1/a\}$), con costante C esplicita; di conseguenza l'intervallo di ammissibilità per la crescita geometrica del batch è più ampio e il bound di complessità totale ha una costante migliore (Corollario 5.2).
3. **Implementazioni.** I quattro algoritmi (Dynamic GD, Newton-CG, Newton-CG L_1 e BB-CCV) sono implementati in Python e disponibili nell'applicazione web interattiva, con esperimenti numerici (Capitolo 6) e codici completi (Appendice B).

1.5 Struttura della tesi

Il resto del lavoro è organizzato come segue. Il Capitolo 2 richiama la notazione usata nel resto del lavoro; il Capitolo 3 formalizza il problema dell'ottimizzazione empirica su larga scala e le ipotesi strutturali su J ; il Capitolo 4 passa in rassegna i lavori correlati; il Capitolo 5 descrive gli algoritmi proposti con i risultati di convergenza e complessità; il Capitolo 6 illustra l'implementazione e i risultati numerici; il Capitolo 7 riassume i risultati e delinea le direzioni di lavoro futuro. Le dimostrazioni, i codici Python, le istruzioni di esecuzione e gli schemi degli algoritmi aggiuntivi sono raccolti nelle Appendici A–D.

2 Background e Notazione

Questo capitolo richiama la notazione usata nel resto del lavoro.

2.1 Glossario dei simboli ricorrenti

Per facilitare la lettura, raccogliamo qui i simboli matematici che appariranno più frequentemente.

Simbolo	Significato
$w \in \mathbb{R}^m$	parametri del modello
N	numero di esempi del dataset
n_k	dimensione del batch all'iterazione k
$\mathcal{S}_k \subseteq \{1, \dots, N\}$	campione di indici all'iterazione k
$\ell(w; i)$	perdita sull'esempio i
$J(w)$	perdita media sul dataset
$J_{\mathcal{S}}(w)$	perdita media sul campione $\mathcal{S}$
λ, L	costanti di convessità forte e di Lipschitz del gradiente
$\kappa = L/\lambda$	sovrastima del numero di condizionamento (che, in norma 2 e per matrici simmetriche, è $\lambda_{\max}/\lambda_{\min}$; cfr. Sez. 3)
$\theta \in (0, 1)$	tolleranza sull'errore relativo del gradiente stimato
α_k	passo all'iterazione k
$\mathcal{V}$	varianza della popolazione del gradiente della loss, componente per componente
$\hat{\mathcal{V}}$	stima campionaria di $\mathcal{V}$ sul batch

Nota

Il significato di $\mathcal{V}$ (varianza della popolazione). Al passo k , con pesi correnti w_k , il vettore $\mathcal{V}$ misura quanto i singoli gradienti $\nabla \ell(w_k; i)$ differiscono dalla loro media $\nabla J(w_k)$:

$$\mathcal{V} := \frac{1}{N} \sum_{i=1}^N (\nabla \ell(w_k; i) - \nabla J(w_k))^2 \in \mathbb{R}^m,$$

dove il quadrato è inteso componente per componente. Se i gradienti individuali sono tra loro coerenti (bassa varianza), la media campionaria è un buon stimatore di $\nabla J(w_k)$; se invece sono molto dispersi, il batch deve essere grande perché la stima sia affidabile. Questa osservazione è il punto di partenza della Condizione di Controllo della Varianza (CCV) introdotta nella Sezione 5.

2.2 Collegamento con la formulazione del problema

La notazione introdotta in questo capitolo è usata nel prossimo per formalizzare il problema di ottimizzazione empirica su larga scala. In particolare, la varianza della popolazione $\mathcal{V}$ e la sua stima campionaria forniranno il criterio per decidere, dinamicamente, quanti dati usare a ogni iterazione.

3 Formulazione del Problema

3.1 Apprendimento supervisionato su larga scala

Nell'apprendimento supervisionato, si dispone di un insieme di esempi etichettati $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, dove:

- $x_i \in \mathbb{R}^m$ è il vettore delle feature (caratteristiche) dell' i -esimo esempio,
- $y_i \in \mathcal{Y}$ è la corrispondente etichetta (valore da predire),
- $N \in \mathbb{N}$ è il numero totale di esempi, potenzialmente dell'ordine di 10^6 – 10^9 .

Si assume che le coppie (x_i, y_i) siano realizzazioni i.i.d. di una variabile casuale con distribuzione di probabilità congiunta P su $\mathcal{X} \times \mathcal{Y}$. L'obiettivo ideale è minimizzare il rischio ovvero l'attesa della loss sullo spazio $\mathcal{X} \times \mathcal{Y}$:

$$\min_{w \in \mathbb{R}^m} R(w) = \mathbb{E}_{(x,y) \sim P} \ell(f(w, x), y) = \int_{\mathcal{X} \times \mathcal{Y}} \ell(f(w; x), y) dP(x, y)$$

dove:

- $f(w; x) = w^T x$ è il predittore lineare parametrizzato da w ,
- $\ell : \mathbb{R} \times \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}$ è la funzione di perdita convessa.

Poiché P è ignota, si minimizza invece il rischio empirico:

Definizione

Funzione Obiettivo Empirica.

$$\min_{w \in \mathbb{R}^m} J(w) = \min_{w \in \mathbb{R}^m} \frac{1}{N} \sum_{i=1}^N \ell(w; i), \quad (3.1)$$

dove abbiamo usato la notazione abbreviata $\ell(w; i) \triangleq \ell(f(w; x_i), y_i)$

- $w \in \mathbb{R}^m$: parametri del modello (variabile di ottimizzazione),
- N : dimensione del dataset,
- $\ell(w; i)$: perdita del modello w sull'esempio i -esimo.

3.2 La sfida computazionale

Il gradiente esatto di J richiede la somma su tutti gli N esempi:

$$\nabla J(w) = \frac{1}{N} \sum_{i=1}^N \nabla \ell(w; i).$$

Il costo di ogni $\nabla \ell(w; i)$ è $O(m)$, siccome deve essere valutato N volte, ogni valutazione del gradiente di J in un punto w costa $O(Nm)$ operazioni. Per $N = 10^8$ e $m = 10^4$ si tratta di 10^{12} operazioni per singola iterazione ovvero un costo che non è praticabile.

3.3 Il trade off

Il problema è che per minimizzare J dobbiamo calcolare $\nabla J(w)$ in tanti punti w , una volta per ogni iterazione, finché non troviamo il minimo; in particolare un singolo gradiente di J costa $O(Nm)$. Se N è enorme, una iterazione è già costosissima, e di iterazioni ne servono tante. Le strade possibili sono le seguenti: il metodo stocastico (SGD) usa un solo esempio per iterazione: il costo è basso, ma il gradiente è rumoroso, quindi servono tante iterazioni e la convergenza è lenta. Il batch completo usa tutti i dati: il gradiente è esatto, quindi servono poche iterazioni, ma ogni iterazione costa $O(Nm)$ ed è impraticabile. Il mini batch fisso è un compromesso: usa un numero intermedio di esempi, bilanciando costo e accuratezza, ma la dimensione del batch è arbitraria e fissa.

La soluzione proposta è il metodo del gradiente a campione dinamico: si parte con un batch piccolo per fare progressi veloci, e lo si aumenta gradualmente quando serve precisione, in questo modo il costo computazionale si concentra solo dove serve.

3.4 Formulazione del problema

Definizione

Perdita media sul campione $\mathcal{S}_k$: ad ogni iterazione k si seleziona un sottoinsieme $\mathcal{S}_k \subseteq \{1, \dots, N\}$ di dimensione $n_k = |\mathcal{S}_k|$ e si definisce la funzione

$$J_{\mathcal{S}_k}(w) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \ell(w; i).$$

- $\mathcal{S}_k$: campione casuale di indici all'iterazione k ,
- $n_k = |\mathcal{S}_k|$: dimensione del batch, variabile con k ,
- $J_{\mathcal{S}_k}(w)$: approssimazione stocastica dell'obiettivo reale $J(w)$.

L'algoritmo definisce una regola per aggiornare w_k e per scegliere n_{k+1} in funzione delle informazioni disponibili all'iterazione k .

3.5 Ipotesi su J

Per garantire le proprietà teoriche degli algoritmi, si assumono le seguenti condizioni.

Definizione

Convessità forte e liscezza: la funzione $J : \mathbb{R}^m \rightarrow \mathbb{R}$ è uniformemente convessa e ha gradiente Lipschitz continuo: esistono costanti $0 < \lambda \leq L$ tali che, per ogni $w, d \in \mathbb{R}^m$,

$$\lambda \|d\|_2^2 \leq d^T \nabla^2 J(w) d \leq L \|d\|_2^2.$$

- $\lambda > 0$: costante di convessità forte. Impone che $\nabla^2 J(w) \succeq \lambda I$ per ogni w , il che garantisce che J abbia un unico minimizzatore w^* .
- L : costante di Lipschitz del gradiente. Impone che $\|\nabla J(x) - \nabla J(y)\|_2 \leq L\|x - y\|_2$ per ogni x, y , il che equivale a $\nabla^2 J(w) \preceq LI$ per ogni w .

- $\kappa = L/\lambda$: numero di condizionamento (stima superiore). Per una data Hessiana $\nabla^2 J(w)$ (matrice simmetrica), il numero di condizionamento in norma 2 sarebbe $\lambda_{\max}(\nabla^2 J(w))/\lambda_{\min}(\nabla^2 J(w))$. Dato che gli autovallori sono ovunque compresi tra λ e L , si ha $\kappa \leq L/\lambda$, $\kappa = L/\lambda$ viene usato come stima superiore uniforme. Se $\kappa \gg 1$, il problema è mal condizionato e più difficile da ottimizzare.

Nota

In pratica, la convessità forte non è sempre verificata (ad esempio, la perdita logistica non è fortemente convessa). Tuttavia, è sufficiente aggiungere un termine di regolarizzazione $\frac{\gamma}{2} \|w\|^2$ alla funzione obiettivo J se è convessa, per indurre convessità forte con $\lambda = \gamma$.

Nota

Disuguaglianze fondamentali (si veda l'Appendice A.1 per la dimostrazione completa). Sia w_* l'unico minimo di J e, per semplificare le notazioni, poniamo $J(w_*) = 0$. Allora con le ipotesi strutturali esplicitate sopra valgono le seguenti disuguaglianze:

$$\|\nabla J(w)\|_2^2 \geq 2\lambda J(w), \quad J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|_2^2.$$

4 Lavori Correlati

Questo capitolo passa in rassegna la letteratura pertinente, organizzata per temi: metodi di ottimizzazione stocastica, metodi con campionamento dinamico, metodi di secondo ordine stocastici e regolarizzazione L_1 .

4.1 Metodi di ottimizzazione stocastica

Il punto di partenza di tutti i metodi stocastici è il lavoro pionieristico di Robbins e Monro [6], che ha introdotto il metodo del gradiente stocastico (SGD): ad ogni iterazione si stima il gradiente su un singolo esempio (o un piccolo batch) e si aggiorna w con un passo decrescente. Il costo per iterazione è indipendente da N , ma la varianza dello stimatore limita la velocità di convergenza e la precisione raggiungibile, come analizzato in dettaglio da Bottou e Bousquet [2] e nella rassegna più recente di Bottou, Curtis e Nocedal [5], che hanno formalizzato il compromesso tra costo per iterazione e velocità di convergenza su larga scala.

Per ridurre la varianza dello stimatore sono state proposte diverse famiglie di metodi. I metodi a varianza ridotta combinano la stima stocastica con una correzione periodica basata su un gradiente (quasi) esatto: SVRG di Johnson e Zhang [9] mantiene una copia dei parametri su cui ricalcola un gradiente completo a intervalli regolari (Schema D.1 in Appendice D), mentre SAGA di Defazio et al. [10] mantiene una tavola dei gradienti individuali e corregge la stima a ogni iterazione (Schema D.2 in Appendice D). Questi metodi ottengono una convergenza lineare per problemi fortemente convessi, ma richiedono di memorizzare o ricalcolare quantità globali e la dimensione del batch rimane comunque fissata a priori.

Tutti questi metodi condividono una caratteristica: la dimensione del batch è fissa o comunque determinata da una regola prestabilita, non da una condizione di accuratezza verificata durante l'esecuzione. È proprio questo il punto che il campionamento dinamico intende superare.

4.2 Campionamento dinamico

L'idea di far crescere la dimensione del batch durante l'ottimizzazione non è nuova, ma è stata formalizzata in modo sistematico da Byrd, Chin, Nocedal e Wu [1], il lavoro di riferimento di questa tesi. Gli autori propongono di adattare la dimensione del campione alla varianza stimata del gradiente: il batch viene aumentato quando tale varianza è troppo grande rispetto alla norma del gradiente stesso, ottenendo così un compromesso controllato tra costo per iterazione e accuratezza della direzione di discesa.

Approcci correlati adottano regole di crescita della dimensione del batch basate su criteri diversi. Ad esempio, una strategia semplice e diffusa è la crescita geometrica $n_k = \lceil a^k \rceil$, che però richiede la conoscenza (o una stima) del numero di condizionamento κ . Alcuni metodi propongono invece di adattare la dimensione del batch in modo euristico in base all'andamento della funzione obiettivo o della perdita di validazione, senza una garanzia teorica. Il vantaggio dell'approccio basato sulla varianza è duplice: da un lato fornisce una giustificazione statistica alla regola di aggiornamento, dall'altro si adatta automaticamente alla difficoltà locale del problema, senza richiedere la stima di κ .

4.3 Metodi di secondo ordine stocastici

I metodi del primo ordine convergono lentamente su problemi mal condizionati, poiché il numero di condizionamento κ del problema entra nel tasso di convergenza. I metodi di Newton incorporano l'informazione di curvatura dell'Hessiana e raggiungono un tasso di convergenza locale quadratico (o superlineare), a costo di risolvere ad ogni iterazione un sistema lineare $H_k d = -g_k$; si veda il testo di Nocedal e Wright [3] per una trattazione completa.

Su larga scala la costruzione esplicita dell'Hessiana è impraticabile, e sono stati sviluppati metodi che ne usano soltanto approssimazioni. I metodi inexact Newton [11] risolvono il sistema di Newton in modo approssimato, controllando il residuo del risolutore interno tramite un parametro di forcing; il metodo del gradiente coniugato (CG) applicato al sistema di Newton, in forma Hessian free, permette di calcolare i prodotti Hessiana-vettore senza costruire la matrice [12, 3]. In ambito stocastico, Byrd et al. [4] hanno proposto un metodo che sottocampiona sia il gradiente sia l'Hessiana, mostrando che un numero di iterazioni del CG che cresce con la precisione desiderata mantiene la convergenza. Il metodo Newton-CG presentato in questa tesi si colloca in questa linea di ricerca, con due innovazioni rispetto ai lavori precedenti: la dimensione del campione per il gradiente è regolata dinamicamente dalla CCV, e il criterio di arresto del CG interno è adattivo, basato sulla varianza campionaria dei prodotti Hessiana-vettore, in modo da non sprecare iterazioni interne quando l'approssimazione dell'Hessiana è limitata dal sottocampionamento.

4.4 Regolarizzazione L_1 in ottimizzazione

La regolarizzazione L_1 consiste nell'aggiungere alla funzione obiettivo un termine di penalità proporzionale alla norma L_1 dei parametri,

$$\nu \|w\|_1 = \nu \sum_{i=1}^m |w_i|,$$

dove $\nu > 0$ è un coefficiente che ne controlla l'intensità. L'effetto è duplice: da un lato i coefficienti grandi vengono penalizzati, scoraggiando l'adattamento eccessivo ai dati; dall'altro, ed è la proprietà più importante, la soluzione risulta *sparsa*, cioè con molti coefficienti esattamente nulli. L'intuizione è la seguente: a differenza della norma L_2 , il cui costo marginale tende a zero per coefficienti piccoli, la norma L_1 “costa” sempre ν per ogni unità di coefficiente, anche vicino a zero. Conviene quindi azzerare le variabili il cui contributo alla perdita non supera tale costo, ed è per questo che la L_1 è uno strumento fondamentale per l'interpretabilità dei modelli ad alta dimensionalità (è il principio alla base del LASSO).

La non differenziabilità della norma L_1 nei punti in cui un coefficiente si annulla richiede però di adattare i metodi classici del primo ordine. In questa tesi si segue la strategia dell'*active set* (o delle facce ortanti): si identifica l'insieme delle variabili che all'ottimo saranno nulle e si minimizza la funzione obiettivo solo sulle variabili libere, dove la L_1 è differenziabile, mantenendo le altre esattamente a zero tramite una ricerca lineare proiettata.

Le variabili da tenere a zero sono individuate tramite il gradiente generalizzato (Sezione 5.3): quando $w_i = 0$, tra tutti i subgradienti possibili in $[-\nu, +\nu]$ viene selezionato quello che rende minima la componente del gradiente generalizzato, zero

se possibile. Così $w_i = 0$ viene riconosciuto come un vero minimo del problema ogni volta che lo è, e l'algoritmo non rischia di allontanarsene. È la strategia adottata dal metodo Newton-CG- L_1 descritto nel Capitolo 5.

5 Algoritmi Proposti

5.1 Metodo del Gradiente a Campione Dinamico



Figura 5.1: Schema dell'algoritmo con controllo della varianza campionaria (CCV): il flusso principale segue inizializzazione $\rightarrow$ estrazione batch $\rightarrow$ calcolo di gradiente e varianza $\rightarrow$ verifica della CCV $\rightarrow$ line search $\rightarrow$ aggiornamento; quando la CCV è violata la dimensione del batch viene aumentata e si ripete l'estrazione.

5.1.1 Formulazione della dinamica del batch

Il metodo del gradiente (o steepest descent) è l'algoritmo di ottimizzazione più semplice: a ogni passo, si scende nella direzione opposta al gradiente. La variante proposta non usa il gradiente esatto $\nabla J(w_k)$ (troppo costoso), ma un'approssimazione basata su un campione:

$$g_k = \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i).$$

Vogliamo sapere quando il campione $\mathcal{S}_k$ è abbastanza grande da garantire che $-g_k$ sia davvero una direzione di discesa per J .

La direzione $-g_k$ è di discesa per J se l'errore del gradiente $\|g_k - \nabla J(w_k)\|$ è piccolo rispetto a $\|g_k\|$ (dimostrazione sotto). Questo errore non è calcolabile esattamente, ma può essere stimato dalla varianza campionaria di $\{\nabla \ell(w_k; i)\}_{i \in \mathcal{S}_k}$: se i gradienti dei singoli esempi nel batch sono coerenti tra loro (bassa varianza), allora la loro media è un buon estimatore di $\nabla J(w_k)$.

Nel metodo del gradiente classico, si richiede che la direzione di discesa d_k soddisfi $\nabla J(w_k)^T d_k < 0$. Qui, poiché g_k è la direzione di discesa, che approssima $\nabla J(w_k)$, abbiamo $\nabla J(w_k)^T (-g_k) = -\nabla J(w_k)^T g_k$. Se g_k è sufficientemente vicino a $\nabla J(w_k)$ in norma relativa, allora $-g_k$ è effettivamente una direzione di discesa.

5.1.2 Formulazione matematica della condizione di accettazione

La direzione $d_k = -g_k$ è di discesa per J se l'errore del gradiente stimato rispetto a quello reale è sufficientemente piccolo in norma relativa:

$$\|g_k - \nabla J(w_k)\|_2 \leq \theta \|g_k\|_2, \quad \theta \in [0, 1).$$

Per capire perché questo garantisce la discesa, poniamo $e_k = g_k - \nabla J(w_k)$, cioè $g_k = \nabla J(w_k) + e_k$. Allora

$$\nabla J(w_k)^T g_k = \nabla J(w_k)^T (\nabla J(w_k) + e_k) = \|\nabla J(w_k)\|^2 + \nabla J(w_k)^T e_k.$$

Poiché $\nabla J(w_k) = g_k - e_k$, si ha anche

$$\nabla J(w_k)^T g_k = (g_k - e_k)^T g_k = \|g_k\|^2 - e_k^T g_k.$$

Per ogni numero reale x vale $x \geq -|x|$; quindi $e_k^T g_k \geq -|e_k^T g_k|$. Usando Cauchy-Schwarz, $|e_k^T g_k| \leq \|e_k\| \|g_k\|$, da cui $e_k^T g_k \geq -\|e_k\| \|g_k\|$. Sostituendo,

$$\nabla J(w_k)^T g_k \geq \|g_k\|^2 - \|e_k\| \|g_k\| = \|g_k\| (\|g_k\| - \|e_k\|).$$

Affinché $\nabla J(w_k)^T g_k > 0$ (cioè $-g_k$ sia di discesa) è sufficiente che $\|g_k\| - \|e_k\| > 0$, ovvero $\|e_k\| < \|g_k\|$. La condizione $\|e_k\| \leq \theta \|g_k\|$ con $\theta < 1$ implica $\|e_k\| < \|g_k\|$, dunque, quando è verificata per il batch corrente, garantisce la discesa in quell'iterazione. È la *condizione puntuale di accuratezza*: una condizione sufficiente, non necessaria, assunta come ipotesi nel Teorema di Convergenza Deterministica (Sezione 5.1.5). Nel caso stocastico g_k è però una variabile aleatoria e la condizione non è verificabile né garantita a ogni iterazione: la CCV, introdotta tra poco, opera invece in aspettativa.



Figura 5.2: Rappresentazione geometrica della condizione di discesa: se il gradiente stimato g_k giace nel cono di tolleranza attorno al gradiente esatto $\nabla J(w_k)$, con errore $\|e_k\| = \|g_k - \nabla J(w_k)\| \leq \theta \|g_k\|$, allora $-g_k$ è una direzione di discesa per J .

Dimostrazione: Per dimostrare che g_k deve essere in norma vicino al gradiente esatto, si riprendono le disuguaglianze del Lemma 1, dimostrato nella Sezione 5.1.5. Per quanto riguarda l'angolo, si usa la disuguaglianza sul doppio prodotto scalare tra $\nabla J(w_k)$ e g_k ricavata nella dimostrazione dello stesso lemma: sostituendo la definizione di prodotto scalare e isolando il coseno si ottiene un quoziente con una somma di quadrati al numeratore. Tale somma si può minorare con $2AB$ (grazie a $A^2 + B^2 \geq 2AB$), indebolendo il termine; infine, dall'identità fondamentale $\sin^2 \varphi + \cos^2 \varphi = 1$, si esprime il seno in funzione del coseno, $\sin \varphi = \sqrt{1 - \cos^2 \varphi}$, e si conclude $\sin \varphi \leq \theta$.

Poiché il gradiente della popolazione totale $\nabla J(w_k)$ è ignoto, non è possibile valutare questa condizione in modo deterministico a ogni iterazione. È importante distinguere due livelli: la condizione puntuale $\|g_k - \nabla J(w_k)\| \leq \theta \|g_k\|$ è quella usata nel Teorema deterministico per garantire la discesa a ogni passo; la Condizione di Controllo della Varianza (CCV) che introdurremo tra poco è invece una condizione in aspettativa, sufficiente per l'analisi di convergenza in media ma non una garanzia puntuale. Il mini batch $\mathcal{S}_k$ viene estratto casualmente dal dataset, rendendo g_k una variabile aleatoria con $\mathbb{E}_{\mathcal{S}_k}[g_k] = \nabla J(w_k)$. Passare dal controllo dell'errore puntuale $\|g_k - \nabla J(w_k)\|$ al controllo del suo valore atteso permette di aggirare l'ignoranza su $\nabla J(w_k)$:

$$\begin{aligned}
 \mathbb{E}_{\mathcal{S}_k} [\|g_k - \mathbb{E}_{\mathcal{S}_k}[g_k]\|_2^2] &= \mathbb{E}_{\mathcal{S}_k} \left[\sum_{j=1}^m \left(g_k^{(j)} - \mathbb{E}_{\mathcal{S}_k}[g_k^{(j)}] \right)^2 \right] \\
 &= \sum_{j=1}^m \mathbb{E}_{\mathcal{S}_k} \left[\left(g_k^{(j)} - \mathbb{E}_{\mathcal{S}_k}[g_k^{(j)}] \right)^2 \right] \\
 &= \sum_{j=1}^m \text{Var}_{\mathcal{S}_k} \left(g_k^{(j)} \right) = \|\text{Var}_{\mathcal{S}_k}(g_k)\|_1.
 \end{aligned}$$

Decomposizione della varianza dello stimatore. Definiamo la varianza della popolazione (vettore):

$$\begin{aligned}\mathcal{V} &:= \mathbb{E}_I [(\nabla \ell(w_k; I) - \mathbb{E}_I[\nabla \ell(w_k; I)])^2] \\ &= \text{Var}_I(\nabla \ell(w_k; I)) = \frac{1}{N} \sum_{i=1}^N (\nabla \ell(w_k; i) - \nabla J(w_k))^2 \in \mathbb{R}^m,\end{aligned}$$

dove il quadrato è inteso componente per componente, e distinguiamo I variabile aleatoria distribuita uniformemente in $\{1, \dots, N\}$ con i realizzazione di tale variabile.

Caso con reinserimento (indipendenza):

$$\begin{aligned}\text{Var}(g_k) &= \text{Var}\left(\frac{1}{n_k} \sum_{i \in S_k} \nabla \ell(w_k; i)\right) = \frac{1}{n_k^2} \sum_{i \in S_k} \text{Var}(\nabla \ell(w_k; i)) \\ &= \frac{1}{n_k^2} \underbrace{\text{Var}(\nabla \ell(w_k; i)) + \dots + \text{Var}(\nabla \ell(w_k; i))}_{n_k \text{ volte}} = \frac{\mathcal{V}}{n_k}.\end{aligned}$$

Anche qui la divisione va fatta componente per componente, siccome $\mathcal{V}$ è un vettore.

Caso senza reinserimento (dipendenza):

$$\text{Var}(\nabla J_{S_k}(w_k)) = \frac{\mathcal{V}}{n_k} \cdot \frac{N - n_k}{N - 1}.$$

La dimostrazione del fattore che si aggiunge qui è riportata nell'appendice. Per $N \gg n_k$ (condizione tipica nel Machine Learning), il fattore di correzione $\frac{N-n_k}{N-1}$ è circa 1, quindi $\text{Var}(g_k) \approx \mathcal{V}/n_k$: la condizione esatta si semplifica nella forma pratica riportata sotto.

Poiché $\mathcal{V}$ è ignoto, lo sostituiamo con la sua stima campionaria sul batch corrente:

$$\hat{\mathcal{V}} := \text{Var}_{i \in S_k}(\nabla \ell(w_k; i)) = \frac{1}{n_k - 1} \sum_{i \in S_k} (\nabla \ell(w_k; i) - \nabla J_{S_k}(w_k))^2.$$

Otteniamo così la Condizione di Controllo della Varianza (CCV):

Teorema

$$\frac{\|\hat{\mathcal{V}}\|_1}{n_k} \leq \theta^2 \|\nabla J_{S_k}(w_k)\|_2^2,$$

dove:

- $\|\cdot\|_1$ somma le varianze componente per componente,
- $\theta \in (0, 1)$ è la tolleranza impostata dall'utente,
- n_k è la dimensione del batch corrente.

Questa è la forma pratica per $N \gg n_k$ (corrispondente al limite $N \rightarrow \infty$ della condizione esatta che include il fattore $\frac{N-n_k}{N-1}$ derivata sopra). La condizione verifica che la varianza stimata dello stimatore sia sufficientemente piccola rispetto al gradiente corrente. Se non è soddisfatta, si aumenta n_k .

Nota

Dalla condizione di discesa (5.1) sappiamo che, per garantire che $-g_k$ sia una direzione di discesa, dobbiamo avere $\|e_k\|_2 \leq \theta \|g_k\|_2$, con $e_k := g_k - \nabla J(w_k)$. Elevando al quadrato:

$$\|e_k\|_2^2 \leq \theta^2 \|g_k\|_2^2.$$

Poiché $\nabla J(w_k)$ è ignoto, non possiamo calcolare $\|e_k\|_2^2$ esattamente. Tuttavia, poiché $\mathbb{E}[g_k] = \nabla J(w_k)$, si ha:

$$\mathbb{E} [\|e_k\|_2^2] = \mathbb{E} [\|g_k - \mathbb{E}[g_k]\|_2^2] = \|\text{Var}(g_k)\|_1.$$

Stimando $\|\text{Var}(g_k)\|_1 \approx \frac{\|\hat{\mathcal{V}}\|_1}{n_k}$, la disuguaglianza in valore atteso diventa esattamente la CCV:

$$\frac{\|\hat{\mathcal{V}}\|_1}{n_k} \leq \theta^2 \|g_k\|_2^2.$$

Il parametro θ controlla la tolleranza sull'errore relativo $\|e_k\|/\|g_k\|$; elevandolo al quadrato si preserva la coerenza dimensionale con la varianza (che è un errore quadratico medio).

Va sottolineato che la CCV è una condizione *in aspettativa*: controlla l'errore quadratico medio dello stimatore del gradiente, non l'errore del singolo mini-batch, e quindi non garantisce la condizione puntuale (5.1) a ogni iterazione (quella resta un'ipotesi dell'analisi deterministica). Poiché g_k è non distorto, $\mathbb{E}_{\mathcal{S}_k}[g_k] = \nabla J(w_k)$, la discesa è però garantita *in valore atteso* a ogni iterazione in cui $\nabla J(w_k) \neq 0$:

$$\mathbb{E}_{\mathcal{S}_k} [\nabla J(w_k)^\top g_k] = \nabla J(w_k)^\top \mathbb{E}_{\mathcal{S}_k}[g_k] = \|\nabla J(w_k)\|_2^2 > 0,$$

e la CCV mantiene piccolo $\|\text{Var}(g_k)\|_1$, facendo crescere n_k quando serve: su questo si basa l'analisi di convergenza in media sviluppata più avanti.

5.1.3 Regola di aggiornamento del batch

Se la condizione CCV non è soddisfatta, si stima la nuova dimensione minima del batch. Supponendo che, per aumenti gradualmente, la varianza campionaria e la norma del gradiente non cambino significativamente (la stima della varianza per predire la dimensione del batch k viene fatta con la varianza del batch $k-1$) si ottiene:¹

Definizione

Regola di Aggiornamento del Batch.

$$n_k^{\text{new}} = \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|\nabla J_{\mathcal{S}_k}(w_k)\|_2^2} \right\rceil$$

dove $\hat{\mathcal{V}} := \text{Var}_{i \in \mathcal{S}_k}(\nabla \ell(w_k; i))$ è la varianza campionaria.

¹Nell'implementazione si aggiunge 1 per evitare che, quando il rapporto è esattamente intero, il batch non cresca, causando ripetute violazioni della CCV per fluttuazioni numeriche.

Nota

Quando siamo lontani dal minimo, $\|\nabla J_{\mathcal{S}_k}(w_k)\|_2^2$ è grande: la formula di aggiornamento del batch dà un n piccolo, quindi il batch resta piccolo. Avvicinandoci al minimo, il gradiente si azzerava e il denominatore diventa piccolo: la formula impone un batch grande. *Il batch cresce automaticamente dove serve precisione.*



Figura 5.3: Andamento della dimensione del batch n_k in funzione dell'iterazione k per il metodo a campione dinamico (linea blu, con gradini in corrispondenza delle violazioni della CCV), confrontato con la funzione esponenziale a^k (curva oro). Il parametro $a > 1$ è stimato per minimi quadrati in scala logaritmica: minimizza $\sum_k (\ln n_k - k \ln a)^2$, da cui $\ln a = \frac{\sum_k k \ln n_k}{\sum_k k^2}$. La crescita di n_k segue quindi una legge quasi geometrica $n_k \approx a^k$, concentrando la risorsa computazionale nelle iterazioni finali, dove il gradiente è piccolo e serve precisione.

5.1.4 Pseudocodice (Algoritmo)

Algoritmo

Gradiente a Campione Dinamico

Input: w_0 (punto iniziale), $\mathcal{S}_0$ (batch iniziale), $\theta \in (0, 1)$ (tolleranza).

Ripeti per ogni $k \in \mathbb{N}$ fino a convergenza:

1. $g_k = \nabla J_{\mathcal{S}_k}(w_k)$.
2. $\hat{\mathcal{V}} = \text{Var}_{i \in \mathcal{S}_k}(\nabla \ell(w_k; i)) = \frac{1}{n_k - 1} \sum_{i \in \mathcal{S}_k} (\nabla \ell_i(w_k) - g_k)^2$.
3. Se $\frac{\|\hat{\mathcal{V}}\|_1}{n_k} > \theta^2 \|g_k\|_2^2$ aumenta il batch: $n_k \leftarrow \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|g_k\|_2^2} \right\rceil$.
4. Esegui una line search: trova $\alpha_k > 0$ tale che $J_{\mathcal{S}_k}(w_k - \alpha_k g_k) < J_{\mathcal{S}_k}(w_k)$.
5. Aggiorna: $w_{k+1} = w_k - \alpha_k g_k$.
6. Seleziona un nuovo campione $\mathcal{S}_{k+1}$ di dimensione n_k (la nuova dimensione, eventualmente aumentata).

5.1.5 Convergenza deterministica

Consideriamo l'iterazione a passo fisso

$$w_{k+1} = w_k - \alpha g_k, \quad \alpha = \frac{1 - \theta}{L},$$

dove g_k è un'approssimazione di $\nabla J(w_k)$ che soddisfa la condizione di accuratezza

$$\|g_k - \nabla J(w_k)\|_2 \leq \theta \|g_k\|_2, \quad \theta \in [0, 1).$$

Lemma 1. *Sotto la condizione di accuratezza si hanno le seguenti disuguaglianze:*

$$\|\nabla J(w_k)\| \leq (1 + \theta)\|g_k\|, \quad \|\nabla J(w_k)\| \geq (1 - \theta)\|g_k\|.$$

Inoltre,

$$\nabla J(w_k)^T g_k \geq (1 - \theta)\|g_k\|^2.$$

Dimostrazione. Poniamo $e_k = g_k - \nabla J(w_k)$. Allora per definizione $\nabla J(w_k) = g_k - e_k$. Prima dimostrazione: $\|\nabla J(w_k)\| \leq (1 + \theta)\|g_k\|$. Applicando la disuguaglianza triangolare $\|x + y\| \leq \|x\| + \|y\|$ con $x = g_k$ e $y = -e_k$:

$$\|\nabla J(w_k)\| = \|g_k + (-e_k)\| \leq \|g_k\| + \|-e_k\| = \|g_k\| + \|e_k\|.$$

Dalla condizione di accuratezza, $\|e_k\| \leq \theta\|g_k\|$. Sostituendo:

$$\|\nabla J(w_k)\| \leq \|g_k\| + \theta\|g_k\| = (1 + \theta)\|g_k\|.$$

Seconda dimostrazione: $\|\nabla J(w_k)\| \geq (1 - \theta)\|g_k\|$. Partiamo dalla disuguaglianza triangolare standard $\|a\| = \|a - b + b\| \leq \|a - b\| + \|b\|$, valida per ogni a, b . Ponendo $a = g_k$ e $b = e_k$:

$$\|g_k\| \leq \|g_k - e_k\| + \|e_k\| = \|\nabla J(w_k)\| + \|e_k\|.$$

Quindi $\|\nabla J(w_k)\| \geq \|g_k\| - \|e_k\|$. Sostituendo $\|e_k\| \leq \theta\|g_k\|$:

$$\|\nabla J(w_k)\| \geq \|g_k\| - \theta\|g_k\| = (1 - \theta)\|g_k\|.$$

Dimostrazione di $\nabla J(w_k)^T g_k \geq (1 - \theta)\|g_k\|^2$. Eleviamo al quadrato la condizione di accuratezza:

$$\|g_k - \nabla J(w_k)\|^2 \leq \theta^2 \|g_k\|^2.$$

Sviluppando il quadrato del binomio:

$$\|g_k\|^2 - 2\nabla J(w_k)^T g_k + \|\nabla J(w_k)\|^2 \leq \theta^2 \|g_k\|^2.$$

Isoliamo il termine con il prodotto scalare portando gli altri termini a destra:

$$-2\nabla J(w_k)^T g_k \leq \theta^2 \|g_k\|^2 - \|g_k\|^2 - \|\nabla J(w_k)\|^2 = (\theta^2 - 1)\|g_k\|^2 - \|\nabla J(w_k)\|^2.$$

Moltiplichiamo entrambi i membri per -1 :

$$2\nabla J(w_k)^T g_k \geq (1 - \theta^2)\|g_k\|^2 + \|\nabla J(w_k)\|^2.$$

Utilizziamo ora la disuguaglianza $\|\nabla J(w_k)\| \geq (1-\theta)\|g_k\|$ dimostrata in precedenza, elevandola al quadrato:

$$\|\nabla J(w_k)\|^2 \geq (1-\theta)^2\|g_k\|^2.$$

Sostituiamo questa stima nella disuguaglianza del Lemma:

$$2\nabla J(w_k)^T g_k \geq (1-\theta^2)\|g_k\|^2 + (1-\theta)^2\|g_k\|^2.$$

Raccogliamo $\|g_k\|^2$ e semplifichiamo i coefficienti:

$$\begin{aligned} 2\nabla J(w_k)^T g_k &\geq [(1-\theta^2) + (1-2\theta+\theta^2)]\|g_k\|^2 \\ &= [1-\theta^2 + 1-2\theta+\theta^2]\|g_k\|^2 = 2(1-\theta)\|g_k\|^2. \end{aligned}$$

Dividendo entrambi i membri per 2 si ottiene la tesi:

$$\nabla J(w_k)^T g_k \geq (1-\theta)\|g_k\|^2.$$

□

Teorema

Teorema di Convergenza Deterministica. Sia $J : \mathbb{R}^m \rightarrow \mathbb{R}$ una funzione λ -fortemente convessa ($\nabla^2 J(w) \succeq \lambda I$ per ogni w) e con gradiente L -Lipschitz ($\nabla^2 J(w) \preceq LI$ per ogni w). Si assuma che a ogni iterazione valga la condizione di accuratezza e si scelga il passo $\alpha = \frac{1-\theta}{L}$. Allora

$$\underbrace{J(w_{k+1}) - J(w^*)}_{=:\varepsilon_{k+1}} \leq \left(1 - \frac{(1-\theta)\lambda}{L}\right) \underbrace{(J(w_k) - J(w^*))}_{=:\varepsilon_k}.$$

Di conseguenza:

- Il fattore di riduzione per iterazione è $\rho = 1 - \frac{(1-\theta)\lambda}{L} \in (0, 1)$;
- Il numero di iterazioni per ottenere $J(w_k) - J(w^*) \leq \varepsilon$ è al più

$$k \geq \frac{L}{(1-\theta)\lambda} \log\left(\frac{J(w_0) - J(w^*)}{\varepsilon}\right) = O\left(\frac{L}{\lambda} \log \frac{1}{\varepsilon}\right).$$

Nota

Confronto con il risultato di Nocedal e Wright [3]. Il fattore di contrazione qui ottenuto è $1 - \frac{(1-\theta)\lambda}{L}$, mentre Nocedal e Wright [3] dimostrano $1 - \frac{(1-\theta)\lambda}{2L}$ (eq. 4.9). Ora $1 - \frac{(1-\theta)\lambda}{L} < 1 - \frac{(1-\theta)\lambda}{2L}$, cioè abbiamo un fattore di contrazione più piccolo (convergenza più rapida). Esso è dovuto all'uso della disuguaglianza di Polyak–Lojasiewicz nella forma forte $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$ (dimostrata nell'appendice A.1), invece della forma più debole $\|\nabla J(w)\|^2 \geq \lambda(J(w) - J(w_*))$ (eq. 4.4–4.5) utilizzata da Nocedal e Wright [3]. La forma più forte è resa possibile dall'ipotesi di convessità forte ($\nabla^2 J \succeq \lambda I$), che implica direttamente $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$ quando $J(w_*) = 0$.

Dimostrazione. Per semplificare poniamo $J(w^*) = 0$ (altrimenti si definisce $\tilde{J}(w) = J(w) - J(w^*)$, che soddisfa le stesse ipotesi di convessità e ha minimo nullo).

Per la L -lipschitzianità del gradiente, vale la seguente maggiorazione (conseguenza del teorema di Taylor con resto di Lagrange):

$$J(w_{k+1}) \leq J(w_k) + \nabla J(w_k)^T (w_{k+1} - w_k) + \frac{L}{2} \|w_{k+1} - w_k\|^2.$$

Sostituendo $\alpha = \frac{1-\theta}{L}$ e $w_{k+1} = w_k - \alpha g_k \Rightarrow w_{k+1} - w_k = -\alpha g_k$:

$$J(w_{k+1}) \leq J(w_k) - \frac{1-\theta}{L} \nabla J(w_k)^T g_k + \frac{L}{2} \left(\frac{1-\theta}{L}\right)^2 \|g_k\|^2.$$

Semplifichiamo il coefficiente del termine quadratico:

$$\frac{L}{2} \left(\frac{1-\theta}{L}\right)^2 = \frac{L}{2} \cdot \frac{(1-\theta)^2}{L^2} = \frac{(1-\theta)^2}{2L}.$$

Quindi:

$$J(w_{k+1}) \leq J(w_k) - \underbrace{\frac{1-\theta}{L} \nabla J(w_k)^T g_k + \frac{(1-\theta)^2}{2L} \|g_k\|^2}_{:=S}.$$

Moltiplichiamo la disuguaglianza del Lemma per $\frac{1-\theta}{2L}$:

$$\frac{1-\theta}{2L} \cdot 2 \nabla J(w_k)^T g_k \geq \frac{1-\theta}{2L} \left[(1-\theta^2) \|g_k\|^2 + \|\nabla J(w_k)\|^2 \right].$$

Semplificando il membro sinistro:

$$\frac{1-\theta}{L} \nabla J(w_k)^T g_k \geq \frac{(1-\theta)(1-\theta^2)}{2L} \|g_k\|^2 + \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Riorganizziamo la disuguaglianza appena scritta per isolare $-\frac{1-\theta}{L} \nabla J(w_k)^T g_k$, che compare nella definizione di S :

$$-\frac{1-\theta}{L} \nabla J(w_k)^T g_k \leq -\frac{(1-\theta)(1-\theta^2)}{2L} \|g_k\|^2 - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Inseriamo questa disuguaglianza nella definizione di S :

$$J(w_{k+1}) \leq J(w_k) - \frac{(1-\theta)(1-\theta^2)}{2L} \|g_k\|^2 - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2 + \frac{(1-\theta)^2}{2L} \|g_k\|^2.$$

Raccogliamo i coefficienti di $\|g_k\|^2$:

$$-\frac{(1-\theta)(1-\theta^2)}{2L} + \frac{(1-\theta)^2}{2L} = -\frac{1-\theta}{2L} \left[(1-\theta^2) - (1-\theta) \right].$$

Calcoliamo la differenza tra parentesi:

$$(1-\theta^2) - (1-\theta) = 1-\theta^2-1+\theta = \theta-\theta^2 = \theta(1-\theta).$$

Quindi:

$$-\frac{1-\theta}{2L} \cdot \theta(1-\theta) = -\frac{\theta(1-\theta)^2}{2L}.$$

La disuguaglianza diventa:

$$J(w_{k+1}) \leq J(w_k) - \frac{\theta(1-\theta)^2}{2L} \|g_k\|^2 - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Poiché $\frac{\theta(1-\theta)^2}{2L} \|g_k\|^2 \geq 0$, il termine $-\frac{\theta(1-\theta)^2}{2L} \|g_k\|^2$ è minore o uguale a zero, trascurarlo può solo aumentare il membro destro e la disuguaglianza rimane valida:

$$J(w_{k+1}) \leq J(w_k) - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Infine, dalla disuguaglianza di convessità forte dimostrata nell'Appendice A.1,

$$\|\nabla J(w_k)\|^2 \geq 2\lambda J(w_k) \quad (\text{valida con } J(w_*) = 0),$$

si ottiene:

$$S \leq -\frac{1-\theta}{2L} \cdot 2\lambda J(w_k) = -\frac{\lambda(1-\theta)}{L} J(w_k).$$

Sostituendo nella disuguaglianza che definisce S :

$$J(w_{k+1}) \leq J(w_k) - \frac{\lambda(1-\theta)}{L} J(w_k) = \left(1 - \frac{\lambda(1-\theta)}{L}\right) J(w_k).$$

Applicando la disuguaglianza appena dimostrata ricorsivamente:

$$J(w_k) \leq \rho^k J(w_0), \quad \text{dove } \rho = 1 - \frac{\lambda(1-\theta)}{L}.$$

Poiché $\theta \in [0, 1)$, $\lambda > 0$ e $L > 0$, si ha $\rho \in (0, 1)$.

Imponiamo $J(w_k) \leq \varepsilon$:

$$\rho^k J(w_0) \leq \varepsilon \implies k \geq \frac{\log(J(w_0)/\varepsilon)}{\log(1/\rho)}.$$

Usando $\log(1/\rho) \geq 1 - \rho$:

$$1 - \rho = \frac{\lambda(1-\theta)}{L},$$

quindi:

$$k \geq \frac{L}{\lambda(1-\theta)} \log\left(\frac{J(w_0)}{\varepsilon}\right).$$

Questa è la stima del numero di iterazioni necessarie per ridurre l'errore al di sotto di ε . $\square$

5.1.6 Analisi Stocastica e Complessità del Metodo

Nell'analisi deterministica abbiamo assunto la condizione di accuratezza

$$\|g_k - \nabla J(w_k)\|_2 \leq \theta \|g_k\|_2, \quad \theta \in [0, 1), \quad (5.1)$$

garantendo che $-g_k$ sia una direzione di discesa per J e stabilendo la convergenza lineare (Teorema di Convergenza Deterministica).

Nel caso stocastico, $g_k = \nabla J_{\mathcal{S}_k}(w_k)$ è calcolato su un campione casuale $\mathcal{S}_k$ di dimensione n_k , rendendo g_k una variabile aleatoria. La condizione (5.1) non può essere garantita con probabilità 1 per ogni iterazione. Dobbiamo quindi sviluppare un'analisi in aspettativa, tenendo conto che n_k può variare nel corso delle iterazioni.

Impostazione del problema stocastico Definiamo

$$g_k := \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i), \quad n_k := |\mathcal{S}_k|. \quad (5.2)$$

Per ogni w_k fissato, g_k è uno stimatore non distorto:

$$\mathbb{E}[g_k \mid w_k] = \nabla J(w_k). \quad (5.3)$$

Introduciamo l'ipotesi fondamentale di limitatezza della varianza dei gradienti individuali. Si noti che questa è un'ipotesi forte, necessaria per l'analisi di complessità teorica; in pratica può essere rilassata, ad esempio richiedendo la limitatezza solo in un intorno del minimo o utilizzando stime locali della varianza.

Nota

Ipotesi di limitatezza della varianza. $\exists \omega \in \mathbb{R}, \omega > 0$ tale che $\forall w_k$,

$$\|\text{Var}(\nabla \ell(w_k; I))\|_1 \leq \omega, \quad (5.4)$$

dove $\text{Var}(\nabla \ell(w_k; I)) := \mathbb{E}_I[(\nabla \ell(w_k; I) - \nabla J(w_k))^2]$ è inteso componente per componente.

Dal Lemma 1 abbiamo $\|\nabla J(w_k)\| \geq (1 - \theta)\|g_k\|$, da cui

$$\|g_k\|^2 \leq \frac{1}{(1 - \theta)^2} \|\nabla J(w_k)\|^2.$$

Dall'Appendice A.1 (disuguaglianza $J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|^2$) otteniamo $\|\nabla J(w_k)\|^2 \leq \frac{2L^2}{\lambda} J(w_k)$. Combinando con la convergenza lineare del Teorema di Convergenza Deterministica, $J(w_k) \leq (1 - \frac{(1-\theta)\lambda}{L})^k J(w_0)$, segue

$$\|g_k\|^2 \leq \frac{1}{(1 - \theta)^2} \frac{2L^2}{\lambda} J(w_k) \leq \frac{1}{(1 - \theta)^2} \frac{2L^2 J(w_0)}{\lambda} \left(1 - \frac{(1 - \theta)\lambda}{L}\right)^k. \quad (5.5)$$

Va osservato che questo bound ha natura circolare: la convergenza lineare del Teorema di Convergenza Deterministica, usata nella (5.5), richiede a sua volta che la CCV sia soddisfatta a ogni iterazione, ed è proprio questo che si intende garantire con la scelta di n_k . La (5.5) va quindi intesa come una stima guida/euristica per la scelta di n_k , non come una derivazione rigorosa, in analogia con quanto fatto nel lavoro originale [1]. Questo bound adotta il tasso deterministico $\rho = 1 - \frac{(1-\theta)\lambda}{L}$ usato nel teorema precedente. Si noti che questo tasso è più favorevole (più rapido) rispetto a quello ottenuto da Byrd et al. [1], che presentano un fattore 1/2 aggiuntivo a denominatore a causa dell'uso di una disuguaglianza più debole. Dalla Condizione di Controllo della Varianza (CCV):

$$\frac{\|\overbrace{\text{Var}_{i \in \mathcal{S}_k}(\nabla \ell(w_k; i))}^{\hat{v}}\|_1}{n_k} \leq \theta^2 \|g_k\|^2. \quad (5.6)$$

Per garantire la (5.6) in media, dobbiamo scegliere n_k sufficientemente grande. Usando l'ipotesi (5.4), la condizione (5.6) è sicuramente soddisfatta se

$$\frac{\omega}{n_k} \leq \theta^2 \|g_k\|^2,$$

ovvero se

$$n_k \geq \frac{\omega}{\theta^2 \|g_k\|^2}. \quad (5.7)$$

Osserviamo che la (5.5) fornisce un bound superiore su $\|g_k\|^2$ che decresce geometricamente con tasso $\rho = 1 - (1 - \theta)\lambda/L$. Poiché nella (5.7) la dimensione del batch è inversamente proporzionale a $\|g_k\|^2$, al restringersi del gradiente n_k deve crescere per evitare che il rumore domini la discesa. Per stimare la velocità di crescita necessaria, usiamo il bound (5.5) per valutare il tasso massimo con cui il denominatore di (5.7)

può restringersi: sostituendo la (5.5) nella (5.7) si ottiene una condizione guida sulla crescita di n_k ,

$$n_k \geq \frac{\omega}{\theta^2 \cdot \frac{1}{(1-\theta)^2} \frac{2L^2 J(w_0)}{\lambda} \left(1 - \frac{(1-\theta)\lambda}{L}\right)^k} = \frac{\omega(1-\theta)^2 \lambda}{\theta^2 2L^2 J(w_0)} \left(1 - \frac{(1-\theta)\lambda}{L}\right)^{-k}. \quad (5.8)$$

Pertanto, per far decadere il rumore almeno alla stessa velocità con cui l'errore deterministico si riduce, n_k deve crescere geometricamente come

$$n_k \geq O\left(\left(1 - \frac{(1-\theta)\lambda}{L}\right)^{-k}\right).$$

Nell'analisi stocastica imponiamo quindi:

$$n_k = \lceil a^k \rceil, \quad a > 1. \quad (5.9)$$

Le ipotesi si dividono in due categorie complementari:

- Ipotesi strutturali su J ($\lambda I \preceq \nabla^2 J(w) \preceq LI$): garantiscono la convergenza lineare se la direzione di discesa è accurata (Teorema di Convergenza Deterministica), e forniscono la maggiorazione di Taylor (A.12), che sarà usata per derivare la disuguaglianza di convergenza in aspettativa.
- Ipotesi stocastica (5.4): garantisce che la varianza dello stimatore g_k decada come $\|\text{Var}(g_k)\|_1 \leq \omega/n_k$, rendendo il rumore controllabile aumentando il batch.

Iterazione stocastica a passo fisso Consideriamo l'iterazione

$$w_{k+1} = w_k - \frac{1}{L} g_k. \quad (5.10)$$

Nell'analisi stocastica si adotta il passo $1/L$, più lungo del passo deterministico $(1-\theta)/L$ poiché il fattore $(1-\theta)$ non è necessario quando il controllo dell'errore è affidato alla crescita del batch. Questo produce un tasso di contrazione deterministico $\alpha = 1 - \lambda/L$ più piccolo rispetto a $1 - (1-\theta)\lambda/L$, e quindi un reciproco $(1 - \lambda/L)^{-1}$ più grande: il vincolo su a ammette un bound superiore più alto.

Usando la (A.12) con $y = w_{k+1}$ e $w = w_k$:

$$J(w_{k+1}) \leq J(w_k) + \nabla J(w_k)^T (w_{k+1} - w_k) + \frac{L}{2} \|w_{k+1} - w_k\|^2. \quad (5.11)$$

Sostituendo $w_{k+1} - w_k = -\frac{1}{L} g_k$:

$$J(w_{k+1}) \leq J(w_k) - \frac{1}{L} \nabla J(w_k)^T g_k + \frac{1}{2L} \|g_k\|^2. \quad (5.12)$$

Passando al valore atteso condizionato a w_k :

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{L} \nabla J(w_k)^T \mathbb{E}[g_k \mid w_k] + \frac{1}{2L} \mathbb{E}[\|g_k\|^2 \mid w_k].$$

Usando (5.3):

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{L} \|\nabla J(w_k)\|^2 + \frac{1}{2L} \mathbb{E}[\|g_k\|^2 \mid w_k]. \quad (5.13)$$

Per esprimere $\mathbb{E}[\|g_k\|^2 \mid w_k]$, utilizziamo l'identità $\mathbb{E}[\|X\|^2] = \|\text{Var}(X)\|_1 + \|\mathbb{E}[X]\|^2$ (valida componente per componente). Applicandola a $X = g_k$:

$$\mathbb{E}[\|g_k\|^2 \mid w_k] = \|\text{Var}(g_k)\|_1 + \|\nabla J(w_k)\|^2. \quad (5.14)$$

Sostituendo in (5.13):

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{2L} \|\nabla J(w_k)\|^2 + \frac{1}{2L} \|\text{Var}(g_k)\|_1. \quad (5.15)$$

Dalla formula per la varianza di una media campionaria (derivata in precedenza) e dall'ipotesi (5.4):

$$\|\text{Var}(g_k)\|_1 \leq \frac{\|\text{Var}(\nabla \ell(w_k; i))\|_1}{n_k} \leq \frac{\omega}{n_k}. \quad (5.16)$$

Sostituendo in (5.15):

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{2L} \|\nabla J(w_k)\|^2 + \frac{\omega}{2Ln_k}. \quad (5.17)$$

Dalla λ -convessità forte di J (disuguaglianza di PL dimostrata nell'Appendice A.1):

$$\|\nabla J(w_k)\|^2 \geq 2\lambda(J(w_k) - J(w_*)). \quad (5.18)$$

Sostituendo in (5.17):

$$\mathbb{E}[J(w_{k+1}) - J(w_*) \mid w_k] \leq \left(1 - \frac{\lambda}{L}\right) (J(w_k) - J(w_*)) + \frac{\omega}{2Ln_k}. \quad (5.19)$$

Prendendo il valore atteso totale e ponendo $\varepsilon_k := \mathbb{E}[J(w_k) - J(w_*)]$:

$$\varepsilon_{k+1} \leq \left(1 - \frac{\lambda}{L}\right) \varepsilon_k + \frac{\omega}{2Ln_k}. \quad (5.20)$$

Questa è l'equazione fondamentale che governa la convergenza in aspettativa.

Possiamo ora enunciare il teorema di convergenza in aspettativa.

Teorema

Teorema 5.1 (Convergenza in aspettativa). Posto $\alpha := 1 - \frac{\lambda}{L}$ e $\beta := \frac{\omega}{2L}$, per ogni $k \geq 0$ vale

$$\mathbb{E}[J(w_k) - J(w_*)] \leq \alpha^k \varepsilon_0 + \beta a \frac{\alpha^k - a^{-k}}{\alpha a - 1}, \quad (5.21)$$

dove il rapporto va inteso nel senso dei limiti se $\alpha a = 1$. Di conseguenza, posto $\rho := \max\{\alpha, 1/a\}$, se $a > 1$ si ha $\rho < 1$ e esiste una costante $C = C(\varepsilon_0, \omega, \lambda, L, a)$ tale che

$$\mathbb{E}[J(w_k) - J(w_*)] \leq C \rho^k \quad \forall k \geq 0.$$

Nota

Differenza rispetto al lavoro originale [1] (Teorema 4.2). Il paper ottiene $\rho = \max\{1 - \lambda/(4L), 1/a\}$ e $C = \max\{J(w_0) - J(w_*), 2\omega/\lambda\}$ tramite un argomento induttivo che introduce un fattore $\frac{1}{2}$ aggiuntivo. La dimostrazione qui presentata ottiene invece $\rho = \max\{1 - \lambda/L, 1/a\}$ risolvendo esplicitamente la ricorrenza, il che dà un tasso deterministico $\alpha = 1 - \lambda/L$ più conservativo. Di conseguenza, l'intervallo ammissibile per a nel Corollario 5.2 è $(1, (1 - \lambda/L)^{-1}]$ anziché $(1, (1 - \lambda/(4L))^{-1}]$ come nel paper.

Dimostrazione. Iterazione della ricorrenza e forma chiusa

Dalla (5.20) possiamo esplicitare l'andamento di ε_k . Scriviamo i primi passi:

$$\begin{aligned} \varepsilon_1 &\leq \alpha \varepsilon_0 + \beta, \\ \varepsilon_2 &\leq \alpha \varepsilon_1 + \beta a^{-1} \leq \alpha(\alpha \varepsilon_0 + \beta) + \beta a^{-1} = \alpha^2 \varepsilon_0 + \alpha \beta + \beta a^{-1}, \\ \varepsilon_3 &\leq \alpha \varepsilon_2 + \beta a^{-2} \leq \alpha(\alpha^2 \varepsilon_0 + \alpha \beta + \beta a^{-1}) + \beta a^{-2} \\ &= \alpha^3 \varepsilon_0 + \alpha^2 \beta + \alpha \beta a^{-1} + \beta a^{-2}. \end{aligned}$$

Il pattern generale è

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \beta \sum_{j=0}^{k-1} \alpha^{k-1-j} a^{-j}. \quad (5.22)$$

Calcoliamo la somma geometrica finita:

$$S_k := \sum_{j=0}^{k-1} \alpha^{k-1-j} a^{-j}.$$

Ponendo $i = k - 1 - j$, si ha:

$$S_k = \sum_{i=0}^{k-1} \alpha^i a^{-(k-1-i)} = a^{-(k-1)} \sum_{i=0}^{k-1} (\alpha a)^i.$$

Se $\alpha a \neq 1$, la progressione geometrica dà:

$$S_k = a^{-(k-1)} \frac{1 - (\alpha a)^k}{1 - \alpha a} = \frac{a(\alpha^k - a^{-k})}{\alpha a - 1}. \quad (5.23)$$

Sostituendo (5.23) in (5.22) si ottiene la forma chiusa:

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \beta a \frac{\alpha^k - a^{-k}}{\alpha a - 1}, \quad (5.24)$$

che è la (5.24), cioè la (5.21) del teorema. Questa espressione è valida per $\alpha a \neq 1$; nel caso $\alpha a = 1$ si intende per limite e si ottiene $\varepsilon_k \leq (\varepsilon_0 + \beta k/\alpha) \rho^k$ (con $\rho = \alpha$), che porta allo stesso tasso esponenziale a meno di un fattore polinomiale.

Deduzione del tasso di convergenza Dalla (5.21) possiamo ricavare il tasso di convergenza studiando il comportamento asintotico. Si presentano tre casi.

- Caso $\alpha a > 1$: allora $\alpha > 1/a$, quindi α^k decresce più lentamente di a^{-k} ; il termine α^k domina. Trascurando a^{-k} rispetto a α^k :

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \frac{\beta a}{\alpha a - 1} \alpha^k = \left(\varepsilon_0 + \frac{\beta a}{\alpha a - 1} \right) \alpha^k.$$

Quindi $\rho = \alpha = 1 - \lambda/L$. Possiamo trascurare il fattore a^{-k} perché è un o -piccolo rispetto ad α^k : infatti $\lim_{k \rightarrow \infty} \frac{a^{-k}}{\alpha^k} = \lim_{k \rightarrow \infty} \left(\frac{1/a}{\alpha} \right)^k = \lim_{k \rightarrow \infty} \left(\frac{1}{\alpha a} \right)^k$ poiché $\alpha a > 1$, si ha $0 < \frac{1}{\alpha a} < 1 \implies \lim_{k \rightarrow \infty} \left(\frac{1}{\alpha a} \right)^k = 0 \implies \frac{a^{-k}}{\alpha^k} \rightarrow 0$

- Caso $\alpha a < 1$: allora $\alpha < 1/a$, quindi a^{-k} decresce più lentamente di α^k ; il termine a^{-k} domina. Trascurando α^k rispetto a a^{-k} :

$$\varepsilon_k \leq \frac{\beta a}{1 - \alpha a} a^{-k} = \frac{\beta a}{1 - \alpha a} \left(\frac{1}{a} \right)^k.$$

Quindi $\rho = 1/a$. Possiamo trascurare il fattore α^k perché è un o -piccolo rispetto a a^{-k} : infatti $\lim_{k \rightarrow \infty} \frac{\alpha^k}{a^{-k}} = \lim_{k \rightarrow \infty} \frac{\alpha^k}{(1/a)^k} = \lim_{k \rightarrow \infty} (\alpha a)^k$ poiché $0 < \alpha a < 1$, si ha $0 < \alpha a < 1 \implies \lim_{k \rightarrow \infty} (\alpha a)^k = 0 \implies \frac{\alpha^k}{a^{-k}} \rightarrow 0$.

- Caso $\alpha a = 1$: allora $\alpha = 1/a$. La somma geometrica si riduce a $S_k = k a^{-(k-1)}$, da cui:

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \beta k a^{-(k-1)} = (\varepsilon_0 + \beta k/\alpha) \rho^k, \quad \rho := \alpha = 1/a.$$

Poiché per ogni $\rho' \in (\rho, 1)$ esiste una costante C (indipendente da k) tale che $k \rho^k \leq C(\rho')^k$, la tesi vale con tasso ρ' .

Quindi per $\alpha a > 1$ si ottiene $\rho = \alpha$ e $C = \varepsilon_0 + \frac{\beta a}{\alpha a - 1}$; se $\alpha a < 1$ si ottiene $\rho = 1/a$ e $C = \varepsilon_0 + \frac{\beta a}{1 - \alpha a}$ (o, più strettamente, $C = \max\{\varepsilon_0, \frac{\beta a}{1 - \alpha a}\}$).

In tutti i casi si ha:

$$\varepsilon_k \leq C \rho^k, \quad \rho := \max\{\alpha, 1/a\}, \quad (5.25)$$

per una opportuna costante $C = C(\varepsilon_0, \omega, \lambda, L, a)$.

□

Corollario sulla complessità totale

Corollario

Corollario 5.2 (Complessità totale). Supponiamo $n_k = \lceil a^k \rceil$ con

$$a \in \left(1, \underbrace{\left(1 - \frac{\lambda}{L} \right)^{-1}}_{1/\alpha} \right],$$

e che (5.4) valga per tutti i w_k . Allora il numero totale di valutazioni dei gradienti $\nabla \ell(w; i)$ necessarie per ottenere $\mathbb{E}[J(w_k) - J(w_*)] \leq \varepsilon$ è

$$O\left(\frac{L}{\lambda \varepsilon}\right), \quad (5.26)$$

e il lavoro totale dell'algoritmo (5.10) con campionamento dinamico (5.9) è

$$\mathcal{T}_{\text{tot}} = O\left(\frac{Lm}{\lambda \varepsilon} \max\left\{J(w_0) - J(w_*), \frac{\omega}{\lambda}\right\}\right), \quad (5.27)$$

dove m è il numero di variabili.

Dimostrazione. Con la scelta $a \leq \alpha^{-1}$, si ha $\rho = 1/a$. Dalla (5.21), il numero di iterazioni k necessario per ottenere $\mathbb{E}[J(w_k) - J(w_*)] \leq \varepsilon$ soddisfa $a^k \geq C/\varepsilon$. Poiché $\rho = 1/a$, la condizione $C\rho^k \leq \varepsilon$ equivale a $a^k \geq C/\varepsilon$. Il numero di iterazioni necessario soddisfa quindi $a^k = \Theta(C/\varepsilon)$. Il costo in valutazioni del gradiente è:

$$\sum_{j=0}^{k-1} n_j \leq 2 \sum_{j=0}^{k-1} a^j = 2 \cdot \frac{a^k - 1}{a - 1} \leq \frac{2}{a - 1} a^k = O\left(\frac{1}{\varepsilon}\right).$$

Moltiplicando per il costo $O(m)$ di ogni gradiente si ottiene (5.27). $\square$

Scelta di a e confronto Il risultato (5.27) vale se a è scelto nell'intervallo

$$a \in \left(1, \left(1 - \frac{\lambda}{L} \right)^{-1} \right].$$

Non è necessario conoscere il numero di condizionamento $\kappa = L/\lambda$ esattamente; qualsiasi sovrastima va bene:

$$a = \left(1 - \frac{1}{\kappa'} \right)^{-1}, \quad \kappa' \geq \kappa. \quad (5.28)$$

Dalla (5.27) ignorando la dipendenza dal punto iniziale (come in [2]) e assumendo il regime $\omega/\lambda \geq J(w_0) - J(w_*)$, si ottiene $\mathcal{T}_{\text{tot}} = O(m\kappa\omega/\lambda\varepsilon)$, che è il bound riportato in tabella sotto.

Confrontiamo questo risultato con i bound di complessità noti per il metodo a gradiente a campione fisso e il metodo del gradiente stocastico (SGD), calcolati da Bottou e Bousquet [2]: nella tabella, lo scalare $\bar{\alpha} \in [1/2, 1]$ è il *tasso di stima* del metodo a campione fisso, come definito in [2].

Lettura. Confronta i bound di complessità del metodo a gradiente dinamico con quelli del campione fisso e dell'SGD: il termine κ (invece di κ^2) rende il metodo dinamico competitivo e particolarmente vantaggioso sui problemi mal condizionati (grande κ).

I metodi a campione fisso e stocastico sono definiti come:

- Metodo a campione fisso: $w_{k+1} = w_k - \frac{1}{L} \frac{\sum_{i=1}^{N_\varepsilon} \nabla \ell(w_k; i)}{N_\varepsilon},$
- Metodo del gradiente stocastico: $w_{k+1} = w_k - \frac{1}{\lambda k} \nabla \ell(w_k; i_k),$

dove N_ε specifica una dimensione del campione tale che $\mathbb{E}[|J(w_*) - J_S(w_*)|] < \varepsilon$ vale in aspettativa. I bound di complessità presentati in [2] ignorano l'effetto del punto iniziale w_0 .

Lo scalare $\bar{\alpha} \in [1/2, 1]$, chiamato *tasso di stima* [2], dipende dalle proprietà della funzione di perdita; la costante $\bar{\nu}$ è definita come

$$\bar{\nu} = \text{trace}(H^{-1}G), \quad H = \nabla^2 J(w_*), \quad G = \mathbb{E}[\nabla \ell(w_*; i) \nabla \ell(w_*; i)^T]. \quad (5.29)$$

Poiché $H \succeq \lambda I$ e ω è un bound per $\|\text{Var}(\nabla \ell(w_k; I))\|_1$, si ha $\bar{\nu} \approx \omega/\lambda$. Sostituendo nel bound per SGD:

$$O(m\bar{\nu}\kappa^2/\varepsilon) = O\left(\frac{m\omega\kappa^2}{\lambda\varepsilon}\right). \quad (5.30)$$

Il bound per il metodo dinamico (5.27) è invece $O(m\kappa\omega/(\lambda\varepsilon))$. La differenza principale è il termine κ^2 in SGD contro κ nel metodo dinamico. Concludiamo che il metodo a gradiente dinamico gode di un bound di complessità competitivo con quello del metodo del gradiente stocastico, risultando particolarmente vantaggioso per problemi mal condizionati (grande κ).

La strategia dinamica $n_k = \lceil a^k \rceil$ con a scelto in base a una stima (bound superiore) di κ garantisce un compromesso ottimale tra costo per iterazione e velocità di convergenza. In pratica, la stima di κ può essere sostituita da una regola euristica semplice (ad esempio, $a = 1.1$), e l'algoritmo si adatta automaticamente.

5.2 Metodo di Newton-CG con Campionamento Dinamico

Il metodo del gradiente (steepest descent) può convergere lentamente, specialmente su problemi mal condizionati; gli algoritmi che incorporano informazione di curvatura (secondo ordine) sulla funzione obiettivo possono essere molto più efficienti. In questa sezione descriviamo un metodo di Newton-CG (gradiente coniugato) Hessian free (non costruiamo e non memorizziamo esplicitamente la matrice Hessiana di $J(w)$, ma ne usiamo solo i prodotti per un vettore), che impiega tecniche di campionamento dinamico sia per il calcolo della funzione e del gradiente, sia per i prodotti Hessiana-vettore.

5.2.1 Struttura del metodo

Il metodo estende l'algoritmo del gradiente a campione dinamico (quello pratico, non la sua variante idealizzata con $n_k = \lceil a^k \rceil$). Rispetto ai metodi che utilizzano un campione fisso per il gradiente e un numero fisso di iterazioni del CG, questo metodo presenta due innovazioni principali:

1. Il campione $\mathcal{S}_k$ per il gradiente non è più fisso; qui si incorporano le tecniche di campionamento dinamico dell'algoritmo visto precedentemente.
2. Il numero di iterazioni del gradiente coniugato non è più fisso; si propone un criterio di terminazione automatico per il CG, che si adatta alla dimensione del campione e all'accuratezza dell'approssimazione dell'Hessiana.

Ad ogni iterazione, il metodo sceglie due campioni $\mathcal{S}_k$ e $\mathcal{H}_k$ tali che

$$|\mathcal{H}_k| \ll |\mathcal{S}_k|,$$

e definisce la direzione di ricerca d_k come soluzione approssimata del sistema lineare

$$\underbrace{\nabla^2 J_{\mathcal{H}_k}(w_k) d = -\nabla J_{\mathcal{S}_k}(w_k)}_{\text{(metodo di Newton classico)}}. \quad (5.31)$$

L'uso di due campioni distinti è cruciale:

- $\mathcal{S}_k$ per il gradiente $\nabla J_{\mathcal{S}_k}(w_k)$, per garantire una direzione di discesa affidabile.
- $\mathcal{H}_k$ per l'Hessiana $\nabla^2 J_{\mathcal{H}_k}(w_k)$, per mantenere il costo dei prodotti Hessiana-vettore sufficientemente basso.

Il sistema (5.31) viene risolto con il metodo del gradiente coniugato (CG) Hessian free: la matrice $\nabla^2 J_{\mathcal{H}_k}(w_k)$ non viene mai costruita esplicitamente; invece, si calcola direttamente il prodotto di questa Hessiana per un vettore.

Il rapporto

$$R = \frac{|\mathcal{H}_k|}{|\mathcal{S}_k|} < 1 \quad (5.32)$$

viene fissato a priori ed è mantenuto costante durante tutto l'algoritmo. Quando il campione per il gradiente $\mathcal{S}_k$ cresce (dinamicamente), la dimensione di $\mathcal{H}_k$ viene aggiornata come $|\mathcal{H}_k| = \lceil R \cdot |\mathcal{S}_k| \rceil$, in modo che $\mathcal{H}_k$ cresca proporzionalmente a $\mathcal{S}_k$. Una linea guida pratica è che il costo totale dei prodotti Hessiana-vettore nel CG non superi il costo di una valutazione del gradiente $\nabla J_{\mathcal{S}_k}$.

5.2.2 Criterio di terminazione del gradiente coniugato

Proponiamo un criterio automatico per decidere con quale accuratezza risolvere il sistema (5.31). L'idea chiave è che il residuo del CG,

$$r_k \stackrel{\text{def}}{=} \nabla^2 J_{\mathcal{H}_k}(w_k)d + \nabla J_{\mathcal{S}_k}(w_k), \quad (5.33)$$

non deve essere più piccolo dell'errore di approssimazione dell'Hessiana.

Per comprendere questo punto, scriviamo il residuo del sistema di Newton che userebbe il campione grande $\mathcal{S}_k$ sia per il gradiente che per l'Hessiana:

$$\underbrace{\nabla^2 J_{\mathcal{S}_k}(w_k)d + \nabla J_{\mathcal{S}_k}(w_k)}_{\text{Residuo del sistema}} = \underbrace{r_k}_{\text{Residuo del CG}} + \underbrace{[\nabla^2 J_{\mathcal{S}_k}(w_k) - \nabla^2 J_{\mathcal{H}_k}(w_k)] d}_{\text{Errore di Hessiana } = \Delta_{\mathcal{H}_k}(w_k; d)}. \quad (5.34)$$

Il termine $\Delta_{\mathcal{H}_k}(w_k; d)$ misura l'errore nell'approssimazione dell'Hessiana lungo la direzione d , dovuto all'uso del campione più piccolo $\mathcal{H}_k$ e questo è costante durante l'algoritmo. È chiaro dall'equazione sopra che se l'errore di Hessiana $\Delta_{\mathcal{H}_k}$ non si può eliminare, non serve ridurre r_k fino a zero. Basta ridurlo fino a quando è comparabile a $\Delta_{\mathcal{H}_k}$. Oltre quel punto, il tempo speso è sprecato.

Il nostro obiettivo è quindi bilanciare i due termini al membro destro di (5.34), terminando il CG quando il residuo r_k è dello stesso ordine dell'errore dell'hessiana.

Tuttavia, $\Delta_{\mathcal{H}_k}(w; d)$, analogamente all'errore di approssimazione del gradiente discusso precedentemente, non è direttamente calcolabile, perché richiederebbe di calcolare $\nabla^2 J_{\mathcal{S}_k}(w_k)d$ (cioè il prodotto Hessiana-vettore sul campione grande), il che vanificherebbe il vantaggio del sottocampionamento dell'Hessiana.

Seguendo la stessa strategia implementata precedentemente per il gradiente, usiamo la varianza campionaria del prodotto Hessiana-vettore per stimare l'errore.

Errore del gradiente (sez. 5.1.2)	Errore dell'Hessiana (sez. 5.2.2)
$e_k = g_k - \nabla J(w_k)$	$\Delta_{\mathcal{H}_k}(w_k; d) = [\nabla^2 J_{\mathcal{S}_k}(w_k) - \nabla^2 J_{\mathcal{H}_k}(w_k)] d$
Non calcolabile perché richiederebbe $\nabla J(w_k)$ su tutti i dati	Non calcolabile perché richiederebbe $\nabla^2 J_{\mathcal{S}_k}(w_k)d$ su tutto il campione grande
Si aggira il problema stimando $\mathbb{E}[\ e_k\ ^2]$ con la varianza campionaria dei gradienti individuali $\nabla \ell(w_k; i)$ sul batch	Si aggira il problema stimando $\mathbb{E}[\ \Delta\ ^2]$ con la varianza campionaria dei prodotti Hessiana-vettore individuali $\nabla^2 \ell(w_k; i)d$ sul sottocampione $\mathcal{H}_k$

Per comprendere la derivazione, partiamo dalla definizione di $\Delta_{\mathcal{H}_k}$.

Precedentemente avevamo definito

$$\Delta_{\mathcal{H}_k}(w_k; d) \stackrel{\text{def}}{=} [\nabla^2 J_{\mathcal{S}_k}(w_k) - \nabla^2 J_{\mathcal{H}_k}(w_k)] d.$$

Sviluppando le medie campionarie e ponendo $X_i = \nabla^2 \ell(w_k; i)d$, abbiamo

$$\nabla^2 J_{\mathcal{S}_k}(w_k)d = \frac{1}{|\mathcal{S}_k|} \sum_{i \in \mathcal{S}_k} X_i := \mu_{\mathcal{S}} \quad \text{e} \quad \nabla^2 J_{\mathcal{H}_k}(w_k)d = \frac{1}{|\mathcal{H}_k|} \sum_{i \in \mathcal{H}_k} X_i := \mu_{\mathcal{H}}.$$

Indichiamo $\Delta_{\mathcal{H}_k}(w_k; d)$ con Δ , poiché $\mathcal{H}_k$ è un sottocampione casuale estratto senza reinserimento dall'insieme $\mathcal{S}_k$, la quantità $\mu_{\mathcal{H}}$ è uno stimatore della media

della popolazione finita $\mu_{\mathcal{S}}$. L'errore di stima è $\mu_{\mathcal{H}} - \mu_{\mathcal{S}}$, il cui quadrato atteso è la varianza dello stimatore $\mu_{\mathcal{H}}$. Osserviamo che

$$\|\Delta\|^2 = \|\mu_{\mathcal{S}} - \mu_{\mathcal{H}}\|^2 = \|\mu_{\mathcal{H}} - \mu_{\mathcal{S}}\|^2 \implies \mathbb{E}[\|\Delta\|^2] = \mathbb{E}[\|\mu_{\mathcal{H}} - \mu_{\mathcal{S}}\|^2] = \text{Var}(\mu_{\mathcal{H}}).$$

A questo punto, usiamo la formula per la varianza di una media campionaria in un campionamento senza reinserimento che avevamo derivato precedentemente. Consideriamo una popolazione finita di dimensione $N = |\mathcal{S}_k|$ con elementi $X_1, \dots, X_N$, e un campione senza reinserimento di dimensione $n = |\mathcal{H}_k|$.

$$\text{Var}(\mu_{\mathcal{H}}) = \frac{\sigma^2}{n} \cdot \frac{N - n}{N - 1}.$$

Questa è la formula classica per la varianza di una media campionaria in un campionamento senza reinserimento, che include il fattore di correzione per popolazione finita $\frac{N-n}{N-1}$. Sostituendo $n = |\mathcal{H}_k|$, $N = |\mathcal{S}_k|$ e prendendo la norma $\|\cdot\|_1$ componente per componente (poiché gli X_i sono vettori), otteniamo:

$$\mathbb{E}[\|\Delta\|^2] = \frac{\overbrace{\left\| \frac{1}{|\mathcal{S}_k|} \sum_{i \in \mathcal{S}_k} (X_i - \mu_{\mathcal{S}})^2 \right\|_1}^{\sigma^2}}{|\mathcal{H}_k|} \cdot \frac{|\mathcal{S}_k| - |\mathcal{H}_k|}{|\mathcal{S}_k| - 1}.$$

Ritornando alla notazione originale, $X_i = \nabla^2 \ell(w_k; i) d$, e ricordando che σ^2 denota la varianza della popolazione $\mathcal{S}_k$ che approssimiamo con la varianza campionaria calcolata su $\mathcal{H}_k$, otteniamo la prima approssimazione:

$$\mathbb{E}[\|\Delta_{\mathcal{H}_k}(w_k; d)\|_2^2] \approx \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d)\|_1}{|\mathcal{H}_k|} \frac{(|\mathcal{S}_k| - |\mathcal{H}_k|)}{|\mathcal{S}_k| - 1}. \quad (5.35a)$$

Questo viene fatto siccome l'uso di σ^2 richiederebbe di calcolare il prodotto Hessiana-vettore su tutto il campione grande $\mathcal{S}_k$, il che vanificherebbe il vantaggio del sotto-campionamento dell'Hessiana.

Poiché nel paper si assume $|\mathcal{H}_k| \ll |\mathcal{S}_k|$ (il campione per l'Hessiana è molto più piccolo di quello per il gradiente), il rapporto $\frac{|\mathcal{S}_k| - |\mathcal{H}_k|}{|\mathcal{S}_k| - 1}$ è circa uguale a 1. Si ottiene quindi la semplificazione finale:

$$\mathbb{E}[\Delta_{\mathcal{H}_k}(w_k; d)^2] \approx \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d)\|_1}{|\mathcal{H}_k|}. \quad (5.35b)$$

Questa equazione fornisce una stima dell'errore di approssimazione dell'Hessiana per un generico vettore d . Osserviamo che la mappa $d \mapsto \nabla^2 \ell(w_k; i) d$ è lineare in d . Di conseguenza, la sua varianza (calcolata su un campione fissato) è una forma quadratica in d : esiste una matrice di covarianza campionaria $\Sigma_{\mathcal{H}_k} \in \mathbb{R}^{m \times m}$, simmetrica semidefinita positiva, tale che

$$\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d) = d^T \Sigma_{\mathcal{H}_k} d \in \mathbb{R}^m,$$

dove il membro sinistro è inteso componente per componente e la relazione vale per ogni componente $j = 1, \dots, m$ con la corrispondente matrice $\Sigma_{\mathcal{H}_k}^{(j)}$. Questa forma quadratica gode della proprietà di omogeneità

$$\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i)(\lambda d)) = \lambda^2 \text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d).$$

All'inizio dell'algoritmo, la soluzione candidata è $d_0 = 0$ e il residuo iniziale è $r_0 = \nabla J_{\mathcal{S}_k}(w_k)$. La prima direzione di ricerca del CG è quindi $p_0 = -r_0$. Per evitare di ricalcolare la varianza a ogni iterazione del CG (operazione costosa), il lavoro originale [1] propone di calcolarla una sola volta per $d = p_0$. Sfruttando l'omogeneità della forma quadratica, si definisce

$$\alpha := \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{\|p_0\|_2^2} = \frac{\|p_0^T \Sigma_{\mathcal{H}_k} p_0\|_1}{\|p_0\|_2^2}. \quad (5.36)$$

Poiché la varianza effettiva per una generica direzione d_j è $\|d_j^T \Sigma_{\mathcal{H}_k} d_j\|_1$, e non $\alpha \|d_j\|^2$, l'uso di α per tutte le direzioni costituisce un'approssimazione, α misura l'influenza media della matrice di covarianza campionaria dei prodotti Hessiana-vettore su un vettore generico, è una media pesata degli autovalori di $\Sigma_{\mathcal{H}_k}$ ed è sempre compreso tra $\lambda_{\min}(\Sigma_{\mathcal{H}_k})$ e $\lambda_{\max}(\Sigma_{\mathcal{H}_k})$. Il metodo assume che la forma quadratica sia sufficientemente ben condizionata perché la dipendenza angolare sia trascurabile ai fini del test di arresto; ciò giustifica la stima

$$\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d_j)\|_1 \approx \alpha \|d_j\|_2^2 = \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{\|p_0\|_2^2} \|d_j\|_2^2. \quad (5.37)$$

Ora, dalla (5.35b), sostituendo la varianza stimata tramite la (5.37), definiamo

$$\gamma := \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{|\mathcal{H}_k| \|p_0\|_2^2}, \quad \Psi(d) := \gamma \|d\|_2^2. \quad (5.38)$$

Test di arresto del CG. La soglia $\Psi(d_j)$ definita in (5.38) viene utilizzata per decidere quando fermare il metodo del gradiente coniugato. Ad ogni iterazione j del CG, si controlla se il residuo r_{j+1} soddisfa

$$\|r_{j+1}\|_2^2 \leq \Psi(d_j) = \gamma \|d_j\|_2^2. \quad (5.39)$$

Se la condizione è verificata, il CG termina e la soluzione corrente d_{j+1} viene accettata come direzione di Newton approssimata. In caso contrario, si prosegue con la successiva iterazione del CG. Questo criterio di arresto è particolarmente efficace perché evita calcoli inutili quando l'approssimazione dell'Hessiana è limitata dal campione $\mathcal{H}_k$; si adatta alla distanza dal minimo poiché $\Psi \propto \|r_0\|^2$; previene instabilità numeriche perché Ψ cresce con $\|d_j\|^2$, fermando il CG prima che la direzione diventi eccessivamente grande.

L'algoritmo quindi calcola γ una volta sola all'inizio del CG, e poi ad ogni iterazione aggiorna $\Psi(d_j) = \gamma \|d_j\|^2$ e verifica la condizione (5.39).

5.2.3 Pseudocodice (Algoritmo Newton-CG)

Algoritmo

Newton-CG con Campionamento Dinamico

Input: w_0 (punto iniziale), $\mathcal{S}_0$ (batch iniziale per gradiente), $\mathcal{H}_0 \subset \mathcal{S}_0$ (batch iniziale per Hessiana), $R = |\mathcal{H}_0|/|\mathcal{S}_0|$ (rapporto costante), $\theta \in (0, 1)$ (tolleranza per varianza del gradiente), $c_1, c_2 \in (0, 1)$ con $c_1 < c_2$ (parametri Wolfe).

Inizializzazione: poni $k = 0$.

Ripeti per ogni iterazione k fino a convergenza:

1. Calcola la direzione di Newton approssimata d_k mediante gradiente coniugato (CG):

- (a) $d_0 = 0, r_0 = \nabla J_{\mathcal{S}_k}(w_k), p_0 = -r_0, j = 0, \Psi = 0.$

- (b) $\gamma = \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{|\mathcal{H}_k| \|p_0\|_2^2}.$

- (c) Finchè $\|r_j\|_2^2 > \Psi$:

- i. $s_j = \nabla^2 J_{\mathcal{H}_k}(w_k) p_j$

- ii. $\alpha_j = \frac{r_j^T r_j}{p_j^T s_j}.$

- iii. $d_{j+1} = d_j + \alpha_j p_j, r_{j+1} = r_j + \alpha_j s_j.$

- iv. $\beta_{j+1} = \frac{r_{j+1}^T r_{j+1}}{r_j^T r_j}.$

- v. $p_{j+1} = -r_{j+1} + \beta_{j+1} p_j.$

- vi. $j = j + 1, \Psi = \gamma \|d_j\|_2^2.$

- (d) $d_k = d_j$

2. Line search con condizioni di Wolfe: Trova $\alpha_k > 0$ tale che:

$$J_{\mathcal{S}_k}(w_k + \alpha_k d_k) \leq J_{\mathcal{S}_k}(w_k) + c_1 \alpha_k \nabla J_{\mathcal{S}_k}(w_k)^T d_k,$$

$$\nabla J_{\mathcal{S}_k}(w_k + \alpha_k d_k)^T d_k \geq c_2 \nabla J_{\mathcal{S}_k}(w_k)^T d_k.$$

3. Aggiorna il punto: $w_{k+1} = w_k + \alpha_k d_k.$

4. Aggiornamento dinamico del batch per il gradiente:

- (a) Seleziona un nuovo campione $\mathcal{S}_{k+1}$ della stessa dimensione di $\mathcal{S}_k.$

- (b) Calcola la varianza campionaria $\hat{\mathcal{V}} = \text{Var}_{i \in \mathcal{S}_{k+1}}(\nabla \ell(w_{k+1}; i)).$

- (c) Se $\frac{\|\hat{\mathcal{V}}\|_1}{|\mathcal{S}_{k+1}|} > \theta^2 \|\nabla J_{\mathcal{S}_{k+1}}(w_{k+1})\|_2^2$, aumenta il batch:

$$|\mathcal{S}_{k+1}| \leftarrow \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|\nabla J_{\mathcal{S}_{k+1}}(w_{k+1})\|_2^2} \right\rceil.$$

5. Seleziona $\mathcal{H}_{k+1} \subseteq \mathcal{S}_{k+1}$ tale che $|\mathcal{H}_{k+1}| = R \cdot |\mathcal{S}_{k+1}|.$

6. Incrementa $k \leftarrow k + 1.$




Figura 5.4: Schema del metodo Newton-CG con campionamento dinamico: ad ogni iterazione il gradiente coniugato risolve (in modo Hessian free) il sistema di Newton con un criterio di arresto adattivo; dopo l'aggiornamento e il ricampionamento, la CCV decide se aumentare la dimensione del batch.

Nota Tecnica

L'algoritmo del gradiente coniugato serve a minimizzare l'errore di $x \approx \bar{x}$ t.c. $A\bar{x} = b$. Nel contesto del metodo di Newton, i suoi elementi vengono reinterpretati come segue:

- $A = H_k = \nabla^2 J(w_k)$ (Hessiana della funzione obiettivo, calcolata sul campione $\mathcal{H}_k$);

- $b = -g_k = -\nabla J(w_k)$ (gradiente negativo, calcolato sul campione $\mathcal{S}_k$);
- $x = d_k$ (direzione di Newton, che risolve $H_k d_k = -g_k$).

Il CG, quindi, viene usato internamente per approssimare la direzione di Newton senza costruire esplicitamente l'Hessiana.

INPUT: $A \in \mathbb{R}^{n \times n}$ (simmetrica def. pos.), $b \in \mathbb{R}^n$, $x_0 = \mathbf{1}$, $\text{tol} = 10^{-10} \|b\|_2$, $it_{\max} = 1000$

- Calcola $r = b - Ax_0$, $p = r$, residui = $\|r\|_2$
- Per $k = 1$ a $it_{\max}$:
 - $Ap = A \cdot p$
 - $\alpha = \frac{r^T p}{p^T Ap}$ (Passo ottimale)
 - $x = x + \alpha p$
 - $r' = r - \alpha Ap$
 - $\beta = \frac{r'^T r'}{r'^T r}$
 - $p = r' + \beta p$
 - $r = r'$
 - residui = $\|r\|_2$
 - Se $\|r\|_2 \leq \text{tol}$: termina

OUTPUT: x , residui

Questo metodo usa un passo α_k che si ottiene minimizzando il funzionale

$$\phi(x) = \frac{1}{2} x^T A x - b^T x$$

per $x = x_k + \alpha p_k$, annullando la derivata di tale funzionale rispetto ad α :

$$\left. \frac{d}{d\alpha} \phi(x_k + \alpha p_k) \right|_{\alpha=\alpha_k} = (Ax_k - b)^T p_k + \alpha_k p_k^T A p_k = 0.$$

Poiché $Ax_k - b = -r_k$, dove $r_k = b - Ax_k$ è il residuo, si ha:

$$-r_k^T p_k + \alpha_k p_k^T A p_k = 0 \implies \alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}. \quad (5.40)$$

Ora però si può dimostrare che la formula usata in questo metodo è equivalente a questa. La dimostrazione completa è riportata nell'Appendice A.3. In sintesi, dalla condizione di stazionarietà al passo precedente e dall'aggiornamento del residuo si ottiene $r_k^T p_{k-1} = 0$, da cui segue $r_k^T p_k = r_k^T r_k$ e quindi l'equivalenza delle due formule. La formula con $r_k^T r_k$ è preferita nelle implementazioni numeriche perché è più stabile, poiché non dipende dall'ortogonalità numerica di $r_k^T p_{k-1}$, che in presenza di errori di arrotondamento non è esattamente zero.

In sostanza l'algoritmo a ogni iterazione k estrae due campioni distinti dal dataset. Un campione S_k grande per calcolare il gradiente $g_k = \nabla J_{S_k}(w_k)$, perché deve essere una stima accurata della direzione di discesa, e un sottocampione H_k con $|H_k| = R \cdot |S_k|$ e $R \ll 1$ per calcolare l'Hessiana $H_k = \nabla^2 J_{H_k}(w_k)$, poiché i prodotti Hessiana-vettore sono costosi e una stima della curvatura basta. Per aggiornare i pesi usa la direzione di Newton che si ottiene minimizzando l'espansione di Taylor per $J(w)$ al secondo ordine attorno a w_k : $J(w_k + d) \approx \tilde{J}(d) = J(w_k) + \nabla J(w_k)^T d + \frac{1}{2} d^T \nabla^2 J(w_k) d$, dove w_k è il punto corrente e d è la direzione. Troviamo la d che minimizza questo modello quadratico annullandone il gradiente rispetto a d , ottenendo il sistema lineare $\nabla^2 J(w_k) d = -\nabla J(w_k)$, che è praticamente del tipo $Ax = b$ con $A = \nabla^2 J(w_k)$ e $b = -\nabla J(w_k)$. Per risolvere questo sistema non si inverte mai la matrice (troppo costoso), ma si usa il metodo del gradiente coniugato Hessian free, facendo solo prodotti $H_k \cdot v$ senza costruire H_k .

Ora poiché l'Hessiana è calcolata su un campione piccolo H_k e quindi è approssimata, non ha senso risolvere il sistema con precisione assoluta. Il CG si ferma quando il suo residuo è confrontabile con l'errore di approssimazione dell'Hessiana, stimato dalla varianza campionaria dei prodotti $\nabla^2 \ell(w_k; i) \cdot p_0$ su H_k . In questo modo non si spreca iterazioni del CG a ridurre un errore che è già dominato dal rumore del campionamento.

Infine si esegue una line search di Armijo lungo la direzione d_k trovata, si aggiorna $w_{k+1} = w_k + \alpha_k d_k$, e come nell'algoritmo visto precedentemente si verifica la condizione di controllo della varianza (CCV) sul gradiente: se la varianza campionaria di g_k è troppo alta rispetto a $\|g_k\|^2$, si aumenta la dimensione del batch n_k per l'iterazione successiva, in modo da avere più precisione man mano che ci si avvicina al minimo.

Ora il metodo del gradiente coniugato è un metodo numerico per trovare x che approssimi la soluzione di $Ax = b$, ovvero minimizzi il funzionale $\phi(x) = \frac{1}{2} x^T A x - b^T x$ e per farlo cerca di minimizzare $\|e^{k+1}\|_A^2$ cercando in $e^k + \text{span}(p^k, p^{k-1})$; equivalentemente pone $e^{k+1} \perp_A p^k$ ed $e^{k+1} \perp_A p^{k-1}$, dalla prima condizione troviamo α_k e dalla seconda β_k (Dimostrazione nell'Appendice A.3).

5.3 Metodo Newton-CG per Modelli con Regularizzazione L_1

5.3.1 Formulazione del Problema

Nei modelli di apprendimento statistico con un numero molto elevato di parametri, l'aggiunta di un termine di regularizzazione L_1 è particolarmente vantaggiosa perché produce soluzioni sparse: molti coefficienti vengono automaticamente portati a zero, individuando le variabili effettivamente rilevanti per la predizione e rendendo il modello risultante più semplice e più facile da interpretare.

La funzione obiettivo (3.1) viene quindi modificata aggiungendo un termine di penalità sulla norma L_1 dei parametri:

$$F(w) = \frac{1}{N} \sum_{i=1}^N \ell(f(w; x_i), y_i) + \nu \|w\|_1 = J(w) + \nu \|w\|_1, \quad (5.41)$$

dove:

- $\nu > 0$ è un parametro di penalità (fisso);
- $\|w\|_1 = \sum_{j=1}^m |w_j|$ è la norma L_1 del vettore dei parametri;
- $J(w)$ è la funzione di perdita empirica definita in (3.1).

Nel contesto mini batch, si sceglie un sottoinsieme $\mathcal{S} \subseteq \{1, \dots, N\}$ del training set e si risolve il problema approssimato:

$$\min_{w \in \mathbb{R}^m} F_{\mathcal{S}}(w) = J_{\mathcal{S}}(w) + \nu \|w\|_1, \quad (5.42)$$

dove $J_{\mathcal{S}}$ è definita come in (5.1).

5.3.2 Il gradiente generalizzato

Per comprendere come si costruisce il gradiente generalizzato di una funzione contenente un termine L_1 , è utile partire dal caso più semplice in una variabile.

Caso 1D: la funzione $\nu|x|$. Consideriamo la funzione $\phi(x) = \nu|x|$, con $x \in \mathbb{R}$, $\nu \in \mathbb{R}$, $\nu > 0$. Questa funzione presenta un punto di non derivabilità in $x = 0$:

- se $x > 0$, la derivata è $\phi'(x) = +\nu$;
- se $x < 0$, la derivata è $\phi'(x) = -\nu$;
- se $x = 0$, la derivata classica non esiste.

Siccome la derivata classica non esiste, si utilizza il concetto di subgradiente (o gradiente generalizzato). Per $\phi(x) = \nu|x|$, il subgradiente in $x = 0$ è l'intervallo:

$$\partial\phi(0) = [-\nu, +\nu].$$

Questo significa che in $x = 0$ possiamo scegliere qualsiasi valore di pendenza compreso tra $-\nu$ e $+\nu$, a seconda della direzione di discesa che vogliamo seguire.

Estensione al caso multidimensionale. Consideriamo ora:

$$F(w) = \underbrace{J(w)}_{\text{parte liscia}} + \underbrace{\nu \sum_{i=1}^m |w_i|}_{\text{parte non liscia}}.$$

La parte non liscia è una somma di termini $\nu|w_i|$, uno per ogni componente di w . Poiché la somma si decompone componente per componente, possiamo calcolare il gradiente generalizzato di F separatamente per ogni coordinata.

Per la i -esima componente, abbiamo due contributi:

1. la derivata parziale della parte liscia: $\frac{\partial J(w)}{\partial w_i}$;
2. il subgradiente di $\nu|w_i|$:

$$\partial(\nu|w_i|) = \begin{cases} +\nu & \text{se } w_i > 0, \\ -\nu & \text{se } w_i < 0, \\ [-\nu, +\nu] & \text{se } w_i = 0. \end{cases}$$

Pertanto, per ogni componente i , il gradiente generalizzato $\tilde{\nabla}F(w)$ è dato da:

$$[\tilde{\nabla}F(w)]_i = \underbrace{\frac{\partial J(w)}{\partial w_i}}_{\text{gradiente di } J} + \underbrace{g_i}_{\text{subgradiente di } \nu|w_i|} \quad g_i \in \begin{cases} \{+\nu\} & \text{se } w_i > 0, \\ \{-\nu\} & \text{se } w_i < 0, \\ [-\nu, +\nu] & \text{se } w_i = 0. \end{cases}$$

Quando $w_i = 0$, abbiamo libertà di scegliere g_i in $[-\nu, +\nu]$. La scelta viene effettuata in modo che in w^* si abbia $\tilde{\nabla}F(w^*) = 0$. Per ogni coordinata i , definiamo:

$$\begin{cases} d_i := \frac{\partial J}{\partial w_i} \\ g_i \in [-\nu, +\nu] \end{cases} \implies [\tilde{\nabla}F]_i = d_i + g_i.$$

La scelta di g_i viene effettuata risolvendo il problema di proiezione:

$$g_i = \arg \min_{g \in [-\nu, \nu]} |d_i + g|,$$

cioè si sceglie il subgradiente che rende il gradiente generalizzato $d_i + g_i$ il più vicino possibile a zero. *Con questa scelta vogliamo che, quando $w_i = 0$, tra tutti i subgradienti possibili in $[-\nu, +\nu]$ venga selezionato quello che rende minima la componente del gradiente generalizzato, zero se possibile: così $w_i = 0$ viene riconosciuto come un vero minimo del problema ogni volta che lo è, e l'algoritmo non rischia di allontanarsene.* Ne derivano i tre casi seguenti:

Condizione su $d_i = \partial J / \partial w_i$	Scelta di g_i	Risultato $[\tilde{\nabla} F]_i$	Effetto
$d_i < -\nu$	$g_i = +\nu$	$d_i + \nu < 0$	$\tilde{\nabla} F < 0$: la discesa spinge w_i verso destra (aumenta)
$d_i > +\nu$	$g_i = -\nu$	$d_i - \nu > 0$	$\tilde{\nabla} F > 0$: la discesa spinge w_i verso sinistra (diminuisce)
$-\nu \leq d_i \leq +\nu$	$g_i = -d_i$	$d_i + g_i = 0$	$\tilde{\nabla} F = 0$: $w_i = 0$ è punto stazionario (minimo)

In sintesi, la regola di proiezione $g_i = \arg \min_{g \in [-\nu, \nu]} |d_i + g|$ garantisce che, nel punto di minimo w^* , si abbia esattamente $\tilde{\nabla} F(w^*) = 0$ per tutte le coordinate in cui $|d_i| \leq \nu$, mentre per le altre coordinate il gradiente viene reso il più piccolo possibile in valore assoluto.

Mettendo insieme tutti i casi, si ottiene la seguente espressione per il gradiente generalizzato:

$$[\tilde{\nabla} F_S(w)]^i = \begin{cases} \frac{\partial J_S(w)}{\partial w_i} + \nu & \text{se } w_i > 0 \text{ oppure } \left(w_i = 0 \text{ e } \frac{\partial J_S(w)}{\partial w_i} < -\nu \right), \\ \frac{\partial J_S(w)}{\partial w_i} - \nu & \text{se } w_i < 0 \text{ oppure } \left(w_i = 0 \text{ e } \frac{\partial J_S(w)}{\partial w_i} > \nu \right), \\ 0 & \text{se } w_i = 0 \text{ e } -\nu \leq \frac{\partial J_S(w)}{\partial w_i} \leq \nu. \end{cases} \quad (5.43)$$

Nota

La formula (5.43) è la versione multidimensionale del subgradiente di $F_S(w) = J_S(w) + \nu \|w\|_1$. Essa generalizza il caso 1D: quando $w_i \neq 0$, il gradiente è semplicemente la somma del gradiente di J_S e del segno di w_i moltiplicato per ν ; quando $w_i = 0$, si sceglie il subgradiente che punta nella direzione di massima discesa.

5.3.3 Identificazione dell'Active Set e della Faccia Ortante

Poiché la funzione $\nu|w_i|$ ha un angolo (una non derivabilità) proprio in $w_i = 0$, l'algoritmo non può usare la solita regola della derivata zero per decidere se quel punto è il minimo. Deve quindi fare una scelta esplicita: se la pendenza della parte liscia J è più forte del costo ν , allora conviene 'liberare' w_i (spostarla da zero); altrimenti, conviene 'attivarla' (tenerla bloccata a zero per ottenere una soluzione sparsa).

L'obiettivo della fase di predizione è determinare quali variabili sono nulle alla soluzione e identificare la faccia ortante (parte dell'iperpiano) su cui eseguire la minimizzazione. L'idea è quella di compiere un passo infinitesimo lungo la direzione di massima discesa $-\tilde{\nabla} F_{S_k}(w_k)$ e osservare il segno di ogni componente.

Definiamo il vettore $z_k \in \{-1, 0, +1\}^m$ che caratterizza la faccia ortante:

$$z_k^i = \begin{cases} +1 & \text{se } w_k^i > 0 \text{ oppure } \left(w_k^i = 0 \text{ e } \frac{\partial J_{S_k}(w_k)}{\partial w_i} < -\nu \right), \\ -1 & \text{se } w_k^i < 0 \text{ oppure } \left(w_k^i = 0 \text{ e } \frac{\partial J_{S_k}(w_k)}{\partial w_i} > \nu \right), \\ 0 & \text{altrimenti.} \end{cases} \quad (5.44)$$

Il vettore z_k definisce l'ortante

$$\Omega_k = \{d \in \mathbb{R}^m : \text{sign}(d^i) = \text{sign}(z_k^i)\}, \quad (5.45)$$

all'interno del quale la funzione $\|w\|_1$ è differenziabile e il suo gradiente è esattamente z_k . L'algoritmo ha scelto quella posizione basandosi sulla condizione di stazionarietà:

- Se w_i è già a destra ($w_i > 0$), allora deve restare a destra.
- Se w_i è già a sinistra ($w_i < 0$), allora deve restare a sinistra.
- Se $w_i = 0$ e il gradiente tira a destra con forza maggiore di ν , allora la libera a destra.
- Se $w_i = 0$ e il gradiente tira a sinistra con forza maggiore di ν , allora la libera a sinistra.
- Se $w_i = 0$ e il gradiente è debole ($|\partial J / \partial w_i| \leq \nu$), allora la blocca a zero.

Quindi z_i è la decisione dell'algoritmo su dove la variabile deve trovarsi. Le variabili con $z_k^i = 0$ costituiscono l'active set:

$$\mathcal{A}_k \triangleq \{i \mid z_k^i = 0\}. \quad (5.46)$$

Tali variabili verranno mantenute a zero durante la fase di minimizzazione nel sottospazio; le rimanenti sono dette libere.

5.3.4 Fase di Minimizzazione nel Sottospazio

Una volta identificata la faccia ortante, si costruisce un modello quadratico della funzione obiettivo ristretto alle variabili libere. Il modello è:

$$\begin{aligned} \min_{d \in \mathbb{R}^m} m_k(d) &\stackrel{\text{def}}{=} F_{S_k}(w_k) + \tilde{\nabla} F_{S_k}(w_k)^T d + \frac{1}{2} d^T \nabla^2 J_{\mathcal{H}_k}(w_k) d \\ \text{s.t. } d^i &= 0, \quad i \in \mathcal{A}_k. \end{aligned} \quad (5.47)$$

La minimizzazione viene effettuata con il metodo del gradiente coniugato Hessian free applicato al sistema lineare ridotto. Sia Y_k la matrice $n \times (n - |\mathcal{A}_k|)$ le cui colonne sono i versori delle coordinate libere; allora il sistema da risolvere è:

$$[Y_k^T \nabla^2 J_{\mathcal{H}_k}(w_k) Y_k] d^Y = -Y_k^T \tilde{\nabla} F_{S_k}(w_k), \quad (5.48)$$

dove $d^Y \in \mathbb{R}^{n-|\mathcal{A}_k|}$ è il vettore delle componenti libere. La direzione di ricerca dell'algoritmo è quindi $d_k = Y_k d^Y$.

5.3.5 Ricerca Lineare Proiettata

Per garantire che il nuovo iterato rimanga all'interno della stessa faccia ortante Ω_k , si utilizza una proiezione ortogonale $P(\cdot)$ su Ω_k :

$$P(w_i) = \begin{cases} w_i & \text{se } \text{sign}(w_i) = \text{sign}(z_k^i), \\ 0 & \text{altrimenti.} \end{cases} \quad (5.49)$$

La ricerca lineare determina il passo α_k come il più grande valore nella sequenza $1, \frac{1}{2}, \frac{1}{4}, \dots$ tale che:

$$F_{\mathcal{S}_k}(P[w_k + \alpha_k d_k]) \leq F_{\mathcal{S}_k}(w_k) + \sigma \tilde{\nabla} F_{\mathcal{S}_k}(w_k)^T (P[w_k + \alpha_k d_k] - w_k) \quad (5.50)$$

(Armijo) dove $\sigma \in (0, 1)$ è una costante prefissata. Il nuovo iterato è $w_{k+1} = P[w_k + \alpha_k d_k]$.

5.3.6 Algoritmo Completo

Algoritmo

Newton-CG per Problemi L_1 -Regolarizzati

Input: w_0 (punto iniziale, tipicamente $w_0 = 0$), $\mathcal{H}_0, \mathcal{S}_0$ con $|\mathcal{H}_0| < |\mathcal{S}_0|$, $\nu > 0$ (parametro di regolarizzazione), $\eta, \sigma \in (0, 1)$, $\max_{cg}$ (limite iterazioni CG).

Per ogni iterazione $k = 0, 1, \dots$ fino a convergenza:

1. Calcola $\tilde{\nabla} F_{\mathcal{S}_k}(w_k)$ tramite (5.43) e determina z_k con (5.44). Definisci l'active set $\mathcal{A}_k$ con (5.46).
2. Minimizzazione nel sottospazio
 - (a) Calcola $\tilde{\nabla} F_{\mathcal{S}_k}(w_k) = \nabla J_{\mathcal{S}_k}(w_k) + \nu z_k$.
 - (b) Applica il gradiente coniugato al sistema (5.48). Termina quando il residuo r_k soddisfa

$$\|r_k\| \leq \eta \|Y_k^T \tilde{\nabla} F_{\mathcal{S}_k}(w_k)\|, \quad (5.51)$$

oppure dopo $\max_{cg}$ iterazioni.

- (c) Poni $d_k = Y_k d^Y$.
3. Ricerca lineare proiettata. Determina il più grande $\alpha_k \in \{1, \frac{1}{2}, \frac{1}{4}, \dots\}$ che soddisfi (5.50). Aggiorna

$$w_{k+1} = P[w_k + \alpha_k d_k].$$

4. Ricampionamento. Scegli $\mathcal{H}_{k+1}, \mathcal{S}_{k+1}$ con $|\mathcal{H}_{k+1}| = |\mathcal{H}_0|$ e $|\mathcal{S}_{k+1}| = |\mathcal{S}_0|$.




Figura 5.5: Schema del metodo Newton-CG per problemi con regolarizzazione L_1 : il gradiente generalizzato determina l'active set e la faccia ortante, il CG risolve il sistema ridotto sulle variabili libere e la ricerca lineare proiettata mantiene le variabili dell'active set a zero.

Nota

L'algoritmo appena descritto è particolarmente efficace nella produzione di soluzioni sparse: la fase di predizione identifica rapidamente le variabili nulle, mentre la fase di sottospazio accelera la convergenza sulle variabili libere sfruttando l'informazione di curvatura dell'Hessiana sottocampionata.

Metodo	Costo per iterazione	Memoria	Ipotesi aggiuntive	Complessità totale
Gradiente a campione dinamico	$O(m n_k)$	$O(m)$	CCV soddisfatta a ogni iterazione; varianza limitata (5.4)	$O(mL/\lambda\varepsilon)$
Newton-CG con campionamento dinamico	$O(m n_k + m n_h j_k)$	$O(m n_h)$ (sottocampione Hessiana)	Hessiana sdp sul sottospazio; criterio di arresto (5.35a)–(5.36)	$O(mL/\lambda\varepsilon)$ iterazioni esterne
Newton-CG con regolarizzazione L_1	Come Newton-CG + costo active set	$O(m)$	Identificazione corretta della faccia ortante (5.41)–(5.46)	Come Newton-CG

Tabella 5.1: Confronto dei tre metodi a campione dinamico con analisi di complessità (Dynamic GD, Newton-CG e Newton-CG con regolarizzazione L_1); il metodo BB-CCV della Sezione 5.4 è escluso perché non ha un bound di complessità totale. n_k è la dimensione del batch corrente, $n_h = R n_k$ quella del sottocampione per l'Hessiana, j_k il numero di iterazioni interne del gradiente coniugato, m il numero di variabili.

Lettura. La tabella riassume le differenze strutturali tra i tre metodi a campione dinamico (costo per iterazione, memoria, ipotesi aggiuntive e complessità totale); il BB-CCV è escluso perché non ha un bound di complessità totale.

A differenza del Newton-CG, questa volta abbiamo una funzione da ottimizzare che comprende anche un termine che penalizza la norma 1 dei parametri: $F(w) = J(w) + \nu \sum_{i=1}^m |w_i|$; dobbiamo quindi cercare il suo minimo. Vogliamo trovare ogni singola coordinata il cui costo da spostare è troppo rispetto al beneficio, ovvero quando il modulo del gradiente di J rispetto a w_i è minore di ν : in quel caso blocchiamo la variabile w_i e la mettiamo uguale a zero. Altrimenti, prendiamo la coordinata w_i e la lasciamo in un altro insieme, quello delle variabili libere. Di quest'insieme di variabili libere ci ricordiamo il segno di ognuna e vogliamo ottimizzare su di esso, quindi utilizziamo il Newton-CG per ottimizzare queste variabili, ricordandoci però il segno iniziale: facciamo in modo che, quando vogliono attraversare lo zero e cambiare ortante, vengano piuttosto azzerate.

5.4 Metodo BB-CCV (Barzilai–Borwein con campionamento dinamico)

Il metodo BB-CCV (gradiente a campione dinamico con passo di Barzilai–Borwein) è il metodo aggiuntivo usato per i test comparativi della Sezione 6.3. Ne illustriamo il passo di Barzilai–Borwein su cui si basa e riportiamo lo schema a blocchi corrispondente.

5.4.1 Il metodo di Barzilai–Borwein

Il metodo BB-CCV sostituisce il passo fisso del Dynamic GD con un passo adattivo di Barzilai–Borwein [13], che stima la curvatura di J lungo la direzione percorsa usando soltanto le quantità già disponibili, senza richiedere la Hessiana.

Consideriamo due iterazioni consecutive, w_k e $w_{k+1} = w_k + \Delta w_k$. Lo sviluppo al primo ordine del gradiente $g(w) = \nabla J(w)$ attorno a w_k è

$$g(w_{k+1}) \approx g(w_k) + \nabla^2 J(w_k) \Delta w_k. \quad (5.52)$$

Definiamo lo spostamento e la variazione del gradiente:

$$s_k \triangleq \Delta w_k = w_{k+1} - w_k, \quad y_k \triangleq g(w_{k+1}) - g(w_k). \quad (5.53)$$

Dalla (5.52) si ottiene la relazione fondamentale

$$y_k \approx \nabla^2 J(w_k) s_k. \quad (5.54)$$

I metodi quasi Newton approssimano la Hessiana con B_{k+1} imponendo l'equazione della secante $B_{k+1} s_k = y_k$. Barzilai–Borwein estremizza l'approssimazione: pone $B_{k+1} = \alpha_{k+1}^{-1} I$, riducendo la secante a

$$\alpha^{-1} s \approx y,$$

un sistema di n equazioni scalari nell'incognita α : in generale nessun singolo scalare può soddisfarle esattamente, quindi il problema si risolve ai minimi quadrati. Dalla relazione $\alpha^{-1} s \approx y$ si ottengono due formule classiche. La prima, minimizzando $\|\alpha y - s\|_2^2$, dà

$$\alpha_k^{(1)} = \frac{s_k^\top y_k}{y_k^\top y_k}; \quad (5.55)$$

la seconda, minimizzando $\|\alpha^{-1} s - y\|_2^2$, dà

$$\alpha_k^{(2)} = \frac{s_k^\top s_k}{s_k^\top y_k}. \quad (5.56)$$

La seconda formula è più aggressiva della prima: produce passi più grandi quando il gradiente cambia poco lungo la direzione percorsa (cioè quando la funzione è piatta in quella direzione), e passi più piccoli quando il gradiente cambia molto. Tuttavia, se lo spostamento s e la variazione del gradiente y sono quasi perpendicolari (cioè $s^\top y \approx 0$), il denominatore si annulla e il passo diventa enorme, facendo esplodere l'iterazione. Per questo BB-CCV introduce la salvaguardia $\text{clip}(\cdot, \alpha/20, 5\alpha)$, che mantiene il passo in un intervallo ragionevole anche in presenza di curvature anomale.

Sulle funzioni quadratiche, dove $y = As$ è esatta e A è definita positiva, il passo di Barzilai–Borwein è ottimale e il metodo converge in poche iterazioni. Sulle funzioni generali, invece, le proprietà precedenti vengono meno: la relazione secante è solo locale, l'Hessiana varia nel tempo, il denominatore $s^\top y$ può diventare negativo o nullo (curvatura negativa o Hessiana singolare), e la presenza di derivate terze rende il passo non più ottimale. BB-CCV gestisce queste difficoltà con la salvaguardia e la line search di Armijo.

Nella pratica, sui problemi della Sezione 6.3 la salvaguardia di BB-CCV è sufficiente: il metodo risulta il più veloce tra quelli testati e raggiunge la precisione macchina sui problemi mal condizionati.

4.91×10^{-2} della base); per $\kappa \approx 100$, sorprendentemente, il riuso torna ad aiutare (3.71×10^{-1} contro 4.67×10^{-1}) (Tabella 6.1), perché la base converge già così lentamente che il beneficio di un obiettivo non più fluttuante prevale sul costo del bias sistematico introdotto dal campione. BB-CCV fa eccezione: il passo di Barzilai–Borwein lo porta alla precisione macchina già senza riuso (9.72×10^{-5} su $\kappa \approx 20$, 1.10×10^{-14} su $\kappa \approx 100$), quindi il riuso non ha margine su $\kappa \approx 100$ e lo peggiora (7.45×10^{-3} con $M = \infty$) (Tabella 6.1).

- **Metodi di Newton.** La direzione di Newton dipende anche dalla Hessiana stimata sul batch. Riusandolo, la curvatura rimane quella del punto in cui il batch è stato estratto, mentre il punto corrente si è spostato, rendendo la direzione obsoleta. Newton-CG è l'algoritmo che risente più negativamente del riuso: su $\kappa \approx 20$ con $M = \infty$ l'errore rimane bloccato a 1.28×10^0 senza progressi (Tabella 6.1). Fa eccezione, oltre al caso ben condizionato dove il riuso migliora su 4 seed su 5 (Tabella 6.2), il problema con termine incrociato con $M = \infty$, dove Newton-CG raggiunge 4.10×10^{-2} contro 3.52×10^{-1} della base (Tabella 6.1). La modalità *Indipendente da S_k* rende esplicita questa dipendenza: permette di tenere H_k più a lungo del batch (colonna $M=10$, H ind. $M_H=\infty$) o di ricampionarla più spesso, controllando così quanto può diventare "vecchia" la curvatura (Sezione 6.5.4).
- **Newton-CG L_1 .** Comportamento intermedio: la penalizzazione L_1 sulla Hessiana rende la direzione più robusta, ma non abbastanza da garantire un vantaggio uniforme.

Perché il riuso danneggia i metodi di Newton sui problemi mal condizionati. La differenza è geometrica. Nel primo ordine $d_k = -g_k(w_k)$ il gradiente è ricalcolato nel punto corrente, quindi d_k è sempre esattamente opposto al gradiente (angolo 180°) e la discesa sul batch è garantita: il riuso può al più causare una lenta deriva verso il minimo campionario w_S^* . In Newton, invece, $d_k = -H_k^{-1}g_k$: l'Hessiana ruota e riscalda il gradiente secondo la curvatura, allungando il passo dove questa è debole e accorciandolo dove è forte.

Il problema nasce quando H_k invecchia: se è stata calcolata nel punto in cui il batch è stato estratto, ma w_k nel frattempo si è spostato, al gradiente fresco viene applicata una geometria vecchia. Il passo viene allora allungato dove la funzione è diventata ripida e accorciato dove è diventata piatta, cioè esattamente al contrario di ciò che servirebbe. Più κ è grande, più la curvatura cambia tra le direzioni e più il disallineamento è grave: d_k può formare un angolo vicino a 90° con la vera direzione di discesa, e la line search taglia il passo fino a bloccare il metodo lontano dal minimo ($e_{30} \approx 1.28$ con $M = \infty$ su $\kappa \approx 100$; Tabella 6.1). Per questo il riuso prolungato è deleterio per i metodi del secondo ordine, mentre per Dynamic GD e BB-CCV il rischio è solo la deriva verso il minimo campionario.

La Figura 6.1 mostra due esecuzioni di Dynamic GD sul problema quadratico ben condizionato ($\kappa \approx 1.1$), estratte dal pannello *Traiettoria 2D* dell'applicazione: in alto la versione a ricampionamento (riuso disattivato), in basso la variante con riuso illimitato dello stesso mini-batch ($M = \infty$). La Figura 6.2 ripete lo stesso confronto sul problema quadratico molto mal condizionato ($\kappa \approx 100$). I punti marcati segnalano le iterazioni in cui la condizione CCV risulta violata e il batch viene aumentato.




Figura 6.1: Traiettorie di Dynamic GD sul problema quadratico ben condizionato ($\kappa \approx 1.1$) dal pannello *Traiettorie 2D* dell'applicazione: (in alto) ricampionamento a ogni iterazione; (in basso) riuso illimitato dello stesso mini-batch ($M = \infty$). Punto iniziale $w_0 = (0.11, -1.66)$, $\alpha = 0.1$, $\theta = 0.5$, $n_0 = 5$, 30 iterazioni, seed 42; i punti marcati indicano le iterazioni in cui la condizione CCV risulta violata (batch aumentato).




Figura 6.2: Traiettorie di Dynamic GD sul problema quadratico molto mal condizionato ($\kappa \approx 100$) dal pannello *Traiettorie 2D* dell'applicazione: (in alto) ricampionamento a ogni iterazione; (in basso) riuso illimitato dello stesso mini-batch ($M = \infty$). Punto iniziale $w_0 = (2, -3)$, $\alpha = 0.1$, $\theta = 0.5$, $n_0 = 5$, 30 iterazioni, seed 42; i punti marcati indicano le iterazioni in cui la condizione CCV risulta violata (batch aumentato).

6.5.3 Setup sperimentale

Gli esperimenti usano gli stessi problemi, parametri e seed della Sezione 6.1: l'intera batteria di cinque problemi, i quattro preset quadratici ($\kappa \approx 1.1$, $\kappa \approx 20$, $\kappa \approx 100$ e termine incrociato) e la Funzione di Rosenbrock (non quadratica, $c=100$), $N = 200$ esempi sintetici, $w_0 = (2, -3)$, $\alpha = 0.1$, $\theta = 0.5$, $n_0 = 5$, 30 iterazioni, line search di Wolfe (Armijo per BB-CCV), seed 42. Per ciascuno dei quattro algoritmi, Dynamic

GD, Newton-CG, Newton-CG L_1 e BB-CCV, si confrontano la versione a ricampionamento (colonna *base*) e il riuso dello stesso mini-batch per M iterazioni consecutive ($M \in \{\infty, 10, 5, 2\}$; la Tabella 6.1 estende la sintesi a $M \in \{\infty, 10, 5, 3, 2, 1\}$).

Per i metodi di Newton l'Hessiana è stimata sul sottoinsieme $H_k \subseteq \mathcal{S}_k$ di dimensione $n_h = \min(\max(1, \lceil Rn_k \rceil), N)$ (opzione *Sottocampionamento Hessiana* dell'app, default *Subset*, coerente con la Sezione 6.1); H_k è ricampionata insieme a S_k (modalità *Legato a S_k* , default). Nella modalità *Indipendente da S_k* con $M_H = \infty$ l'Hessiana resta invece in uso finché la CCV è soddisfatta, senza seguire il contatore del batch; con $M = \infty$ le due modalità coincidono (Sezione 6.5.1) e la modalità indipendente è quindi testata solo con batch finito.

6.5.4 Risultati numerici

Il quadro emerso è coerente con l'analisi della Sezione 6.5.2 e si riassume nei punti seguenti.

- Dynamic GD e BB-CCV si comportano in modo simile solo sul problema ben condizionato: su $\kappa \approx 1.1$ il riuso migliora su 5 seed su 5 con $M = \infty$ e $M = 10$, con il vantaggio che emerge nella seconda metà delle iterazioni (Tabella 6.2). Sui mal condizionati i due metodi divergono: su $\kappa \approx 20$ il riuso illimitato peggiora Dynamic GD (1.01×10^{-1} contro 4.91×10^{-2} della base) ma aiuta BB-CCV, la cui base converge a 9.72×10^{-5} e con $M = \infty$ scende a 9.54×10^{-10} ; su $\kappa \approx 100$ il riuso aiuta Dynamic GD (3.71×10^{-1} contro 4.67×10^{-1}) ma peggiora BB-CCV, la cui base è già alla precisione macchina (1.10×10^{-14}) e con $M = \infty$ sale a 7.45×10^{-3} (Tabella 6.1). Sulla Funzione di Rosenbrock il riuso non aiuta nessuno dei due: Dynamic GD ha base 6.14×10^{-4} al seed 42 e con $M = \infty$ l'errore sale a 2.54×10^0 ; BB-CCV peggiora in 4 seed su 5 sia con $M = \infty$ sia con $M = 10$ (Tabelle 6.1 e 6.2).
- Newton-CG è penalizzato sui problemi mal condizionati (su $\kappa \approx 20$ e $\kappa \approx 100$ peggiora su tutti e 5 i seed con $M = \infty$), mentre il riuso lo aiuta sul problema ben condizionato (4 seed su 5 con $M = \infty$) e sul termine incrociato con $M = \infty$ (Tabella 6.2). Sulla Funzione di Rosenbrock Newton-CG peggiora con ogni valore di M (1 seed su 5 con $M = \infty$, 2 su 5 con $M = 10$): con $M = \infty$ l'errore al seed 42 passa da 2.06×10^{-1} a 1.06×10^0 (Tabelle 6.1 e 6.2).
- Newton-CG L_1 ha comportamento intermedio, senza una tendenza netta sui problemi quadratici. Sulla Funzione di Rosenbrock, al seed 42, ogni M (anche $M=1$) peggiora la base (1.25×10^{-1}); su 5 seed, invece, il riuso $M=3$ migliora la mediana (da 2.05×10^{-1} a 1.73×10^{-1}) pur vincendo in soli 2 seed su 5 (Sezione 6.5.8).
- La modalità *Indipendente da S_k* (colonna $M=10$, H ind. $M_H=\infty$) sposta il compromesso. Rispetto alla colonna $M=10$ legata (stessa politica di batch), tenere l'Hessiana oltre i ricampionamenti del batch migliora Newton-CG sul problema ben condizionato (3.15×10^{-1} contro 3.74×10^{-1}) e Newton-CG L_1 sul termine incrociato (2.50×10^{-2} contro 3.94×10^{-2}), mentre peggiora Newton-CG sui problemi mal condizionati ($\kappa \approx 20$: 1.15×10^0 contro 9.49×10^{-1} ;

$\kappa \approx 100$: 1.16×10^0 contro 6.44×10^{-1}), dove la direzione resta più a lungo ancorata alla Hessiana del campione iniziale.

Vale la pena notare che le curve di errore con il riuso non sono monotone rispetto alla base iterazione per iterazione: anche nei casi in cui l'errore finale è migliore, ci sono fasi intermedie in cui è temporaneamente più alto, perché la line search garantisce la discesa solo sulla loss del batch corrente, non sulla funzione intera.

6.5.5 Sintesi: quando il riuso aiuta e quando no

La Tabella 6.1 riassume l'errore finale e_{30} per tutti i valori di M ; la Tabella 6.2 riporta la robustezza su cinque seed indipendenti.

- Il riuso aiuta quando il problema è ben condizionato: il minimo campionato è vicino a w^* in tutte le direzioni, i passi coerenti riducono il rimbalzo attorno al minimo e l'iterato scende sotto il pavimento di rumore.
- Il riuso non aiuta quando il problema è mal condizionato e il metodo non ha margine di miglioramento: è il caso di Dynamic GD su $\kappa \approx 20$ e di BB-CCV su $\kappa \approx 100$, dove la base è già alla precisione macchina e il riuso introduce la deriva verso il minimo campionario, non rilevata dalla CCV; non aiuta nemmeno con i metodi del secondo ordine (Hessiana obsoleta). Sulla Funzione di Rosenbrock vale lo stesso: al seed 42 nessun valore di M migliora la base per nessun metodo (Tabella 6.1), e su 5 seed le mediane peggiorano per Dynamic GD e BB-CCV; l'unica eccezione è Newton-CG L_1 con $M=3$, che migliora la mediana su 5 seed (da 2.05×10^{-1} a 1.73×10^{-1}).
- La modalità *Indipendente da S_k* con $M_H = \infty$ non cambia il quadro qualitativo: la colonna $M=10$, H ind. $M_H=\infty$ segue l'andamento della colonna $M=10$ legata, con lievi miglioramenti sui problemi ben condizionati e sul termine incrociato e un peggioramento confermato sui mal condizionati di Newton-CG. Il suo ruolo è quello di disaccoppiare la frequenza di ricampionamento dell'Hessiana da quella del batch: con $M = \infty$ la scelta diventa ininfluente, perché entrambe le modalità ricampionano solo alla violazione della CCV.

Osservazione sul costo computazionale. Il confronto è fatto a parità di iterazioni. Il riuso è già favorito dal punto di vista del costo: Dynamic GD e BB-CCV non richiedono calcoli aggiuntivi; Newton-CG nella versione base spende un campione fresco a ogni iterazione solo per valutare la CCV. Il fatto che nonostante questo vantaggio il riuso non sia sempre vincente rende i casi negativi ancora più significativi: il problema è di qualità delle direzioni di discesa, non di costo.

Tabella 6.1: Errore finale $e_{30} = \|w_{30} - w_*\|_2$ al termine delle 30 iterazioni (seed 42) per tutti i valori del numero massimo M di iterazioni consecutive sullo stesso mini-batch. *base*: ricampionamento a ogni iterazione. Simboli relativi a *base*: $\blacktriangle$ = migliora, $\blacktriangledown$ = peggiora, $=$ = invariato. Valori arrotondati a tre cifre significative.

Metodo	<i>base</i>	$M=\infty$	$M=10$	$M=5$	$M=3$	$M=2$	$M=1$
$\kappa \approx 1.1$ - Dynamic GD	1.1895×10^{-1}	$1.1739 \times 10^{-1} \blacktriangle$	$1.1739 \times 10^{-1} \blacktriangle$	$1.1920 \times 10^{-1} \blacktriangledown$	$1.1903 \times 10^{-1} \blacktriangledown$	$1.1777 \times 10^{-1} \blacktriangle$	$1.1895 \times 10^{-1} =$
$\kappa \approx 1.1$ - BB-CCV	1.1662×10^{-1}	$1.1662 \times 10^{-1} \blacktriangle$	$1.1662 \times 10^{-1} \blacktriangle$	$1.1662 \times 10^{-1} \blacktriangle$	$1.1662 \times 10^{-1} \blacktriangle$	$1.1662 \times 10^{-1} \blacktriangle$	$1.1662 \times 10^{-1} =$
$\kappa \approx 1.1$ - Newton-CG	4.0264×10^{-1}	$2.2230 \times 10^{-1} \blacktriangle$	$3.7373 \times 10^{-1} \blacktriangle$	$4.1553 \times 10^{-1} \blacktriangledown$	$3.2913 \times 10^{-1} \blacktriangledown$	$2.6069 \times 10^{-1} \blacktriangle$	$3.0560 \times 10^{-1} \blacktriangle$
$\kappa \approx 1.1$ - Newton-CG L_1	1.0167×10^{-1}	$8.1750 \times 10^{-2} \blacktriangle$	$9.2407 \times 10^{-2} \blacktriangle$	$1.0010 \times 10^{-1} \blacktriangle$	$1.0624 \times 10^{-1} \blacktriangledown$	$9.4078 \times 10^{-2} \blacktriangle$	$1.0028 \times 10^{-1} \blacktriangle$
$\kappa \approx 20$ - Dynamic GD	4.9050×10^{-2}	$1.0103 \times 10^{-1} \blacktriangledown$	$7.6020 \times 10^{-2} \blacktriangledown$	$4.7211 \times 10^{-2} \blacktriangledown$	$1.1746 \times 10^{-1} \blacktriangledown$	$4.2898 \times 10^{-2} \blacktriangle$	$4.9050 \times 10^{-2} =$
$\kappa \approx 20$ - BB-CCV	9.7195×10^{-5}	$9.5364 \times 10^{-10} \blacktriangle$	$9.5364 \times 10^{-10} \blacktriangle$	$2.6835 \times 10^{-3} \blacktriangledown$	$3.8422 \times 10^{-8} \blacktriangledown$	$1.5436 \times 10^{-10} \blacktriangle$	$9.7195 \times 10^{-5} =$
$\kappa \approx 20$ - Newton-CG	2.3463×10^{-1}	$1.2807 \times 10^0 \blacktriangledown$	$9.4933 \times 10^{-1} \blacktriangledown$	$4.1051 \times 10^{-1} \blacktriangledown$	$3.3396 \times 10^{-1} \blacktriangledown$	$4.0617 \times 10^{-1} \blacktriangledown$	$1.6683 \times 10^{-1} \blacktriangle$
$\kappa \approx 20$ - Newton-CG L_1	4.8802×10^{-1}	$7.6221 \times 10^{-1} \blacktriangledown$	$5.5687 \times 10^{-1} \blacktriangledown$	$6.2190 \times 10^{-1} \blacktriangledown$	$4.5512 \times 10^{-1} \blacktriangledown$	$4.3392 \times 10^{-1} \blacktriangledown$	$5.4573 \times 10^{-1} \blacktriangledown$
$\kappa \approx 100$ - Dynamic GD	4.6668×10^{-1}	$3.7060 \times 10^{-1} \blacktriangle$	$3.7060 \times 10^{-1} \blacktriangle$	$3.7060 \times 10^{-1} \blacktriangle$	$3.7060 \times 10^{-1} \blacktriangle$	$3.7060 \times 10^{-1} \blacktriangle$	$4.6668 \times 10^{-1} =$
$\kappa \approx 100$ - BB-CCV	1.0991×10^{-14}	$7.4538 \times 10^{-3} \blacktriangledown$	$7.4538 \times 10^{-3} \blacktriangledown$	$7.4538 \times 10^{-3} \blacktriangledown$	$7.4538 \times 10^{-3} \blacktriangledown$	$7.4538 \times 10^{-3} \blacktriangledown$	$1.0991 \times 10^{-14} =$
$\kappa \approx 100$ - Newton-CG	2.0969×10^{-1}	$1.2807 \times 10^0 \blacktriangledown$	$6.4441 \times 10^{-1} \blacktriangledown$	$3.3452 \times 10^{-1} \blacktriangledown$	$3.7338 \times 10^{-1} \blacktriangledown$	$4.4283 \times 10^{-1} \blacktriangledown$	$2.3041 \times 10^{-1} \blacktriangledown$
$\kappa \approx 100$ - Newton-CG L_1	9.6954×10^{-1}	$9.7065 \times 10^{-1} \blacktriangledown$	$8.6360 \times 10^{-1} \blacktriangledown$	$9.6997 \times 10^{-1} \blacktriangledown$	$8.7711 \times 10^{-1} \blacktriangledown$	$9.6944 \times 10^{-1} \blacktriangledown$	$8.6562 \times 10^{-1} \blacktriangle$
incrociato ($\kappa \approx 1.67$) - Dynamic GD	9.4161×10^{-3}	$5.5315 \times 10^{-3} \blacktriangle$	$9.9566 \times 10^{-3} \blacktriangledown$	$5.9490 \times 10^{-3} \blacktriangle$	$7.5801 \times 10^{-3} \blacktriangle$	$8.7213 \times 10^{-3} \blacktriangle$	$9.4161 \times 10^{-3} =$
incrociato ($\kappa \approx 1.67$) - BB-CCV	6.1644×10^{-4}	$6.1689 \times 10^{-4} \blacktriangle$	$6.1689 \times 10^{-4} \blacktriangle$	$6.1689 \times 10^{-4} \blacktriangle$	$6.1610 \times 10^{-4} \blacktriangle$	$6.1685 \times 10^{-4} \blacktriangle$	$6.1644 \times 10^{-4} =$
incrociato ($\kappa \approx 1.67$) - Newton-CG	3.5167×10^{-1}	$4.1026 \times 10^{-2} \blacktriangle$	$1.0511 \times 10^{-1} \blacktriangle$	$3.3540 \times 10^{-1} \blacktriangle$	$2.3364 \times 10^{-1} \blacktriangle$	$2.1820 \times 10^{-1} \blacktriangle$	$2.6381 \times 10^{-1} \blacktriangle$
incrociato ($\kappa \approx 1.67$) - Newton-CG L_1	2.0877×10^{-2}	$3.8938 \times 10^{-2} \blacktriangle$	$3.9410 \times 10^{-2} \blacktriangle$	$2.9304 \times 10^{-2} \blacktriangle$	$2.3645 \times 10^{-2} \blacktriangle$	$3.8543 \times 10^{-2} \blacktriangle$	$2.5154 \times 10^{-2} \blacktriangledown$
Funzione di Rosenbrock ($c=100$) - Dynamic GD	6.1354×10^{-4}	$2.5435 \times 10^0 \blacktriangledown$	$2.5435 \times 10^0 \blacktriangledown$	$2.5435 \times 10^0 \blacktriangledown$	$2.0803 \times 10^0 \blacktriangledown$	$1.4213 \times 10^0 \blacktriangledown$	$6.1354 \times 10^{-4} =$
Funzione di Rosenbrock ($c=100$) - BB-CCV	1.0645×10^{-1}	$1.6648 \times 10^{-1} \blacktriangledown$	$1.6648 \times 10^{-1} \blacktriangledown$	$1.6648 \times 10^{-1} \blacktriangledown$	$1.6648 \times 10^{-1} \blacktriangledown$	$3.6984 \times 10^{-1} \blacktriangledown$	$1.0645 \times 10^{-1} =$
Funzione di Rosenbrock ($c=100$) - Newton-CG	2.0625×10^{-1}	$1.0605 \times 10^0 \blacktriangledown$	$1.1367 \times 10^0 \blacktriangledown$	$1.2475 \times 10^0 \blacktriangledown$	$1.1893 \times 10^0 \blacktriangledown$	$1.2292 \times 10^0 \blacktriangledown$	$9.3953 \times 10^{-1} \blacktriangledown$
Funzione di Rosenbrock ($c=100$) - Newton-CG L_1	1.2525×10^{-1}	$3.8199 \times 10^{-1} \blacktriangledown$	$2.4883 \times 10^{-1} \blacktriangledown$	$3.0766 \times 10^{-1} \blacktriangledown$	$3.1242 \times 10^{-1} \blacktriangledown$	$2.7111 \times 10^{-1} \blacktriangledown$	$2.0207 \times 10^{-1} \blacktriangledown$

Lettura. Tabella di sintesi dell'esperimento di riuso: errore finale e_{30} (seed 42) per tutti i valori di $M \in \{\infty, 10, 5, 3, 2, 1\}$ su tutte le coppie problema $\times$ algoritmo. Si legge per individuare dove il riuso aiuta e dove peggiora: in generale aiuta su ben condizionato e termine incrociato e per i metodi del primo ordine dove c'è margine (BB-CCV su $\kappa \approx 20$), mentre peggiora per Dynamic GD e Newton-CG sui mal condizionati con $M=\infty$ e per BB-CCV su $\kappa \approx 100$, dove la base è già alla precisione macchina.

Tabella 6.2: Robustezza del riuso del mini-batch su 5 seed indipendenti ($\{42, 7, 123, 2024, 999\}$): per ogni coppia problema–algoritmo e per ciascuna politica di riuso ($M=\infty$ e $M=10$), numero di seed su 5 in cui e_{30} rispetto alla *base* è minore (*Migl.*), maggiore (*Pegg.*) o identico (*Uguale*).

Problema	Algoritmo	$M=\infty$			$M=10$		
		<i>Migl.</i>	<i>Pegg.</i>	<i>Uguale</i>	<i>Migl.</i>	<i>Pegg.</i>	<i>Uguale</i>
$\kappa \approx 1.1$	Dynamic GD	5	0	0	5	0	0
	BB-CCV	5	0	0	5	0	0
	Newton-CG	4	1	0	3	2	0
	Newton-CG L_1	4	1	0	5	0	0
$\kappa \approx 20$	Dynamic GD	2	3	0	1	4	0
	BB-CCV	3	2	0	3	2	0
	Newton-CG	0	5	0	0	5	0
	Newton-CG L_1	1	4	0	2	3	0
$\kappa \approx 100$	Dynamic GD	3	2	0	3	2	0
	BB-CCV	1	3	1	1	3	1
	Newton-CG	0	5	0	0	5	0
	Newton-CG L_1	3	2	0	4	1	0
incrociato ($\kappa \approx 1.67$)	Dynamic GD	4	1	0	3	2	0
	BB-CCV	2	3	0	2	3	0
	Newton-CG	4	1	0	3	2	0
	Newton-CG L_1	2	3	0	1	4	0
Funzione di Rosenbrock ($c=100$)	Dynamic GD	2	3	0	2	3	0
	BB-CCV	1	4	0	1	4	0
	Newton-CG	1	4	0	2	3	0
	Newton-CG L_1	1	4	0	2	3	0

Lettura. Verifica se il vantaggio del riuso regge al variare del seed: per ogni coppia problema–algoritmo conta su quanti seed (su 5) il riuso migliora, peggiora o lascia invariata la base. Conferma il quadro: quasi tutti i metodi migliorano su $\kappa \approx 1.1$, mentre sui mal condizionati il segno dell’effetto dipende dal metodo e dal problema (per esempio BB-CCV migliora su $\kappa \approx 20$ ma peggiora su $\kappa \approx 100$, dove è già alla precisione macchina) e Newton-CG non migliora mai su $\kappa \approx 20$ e $\kappa \approx 100$ per la Hessiana obsoleta.

Questa tabella conferma, come già osservato, che il riuso porta miglioramenti sui problemi ben condizionati ($\kappa \approx 1.1$: quasi tutti i seed migliorano, con 5/5 per Dynamic GD e BB-CCV). Sui mal condizionati il quadro dipende dal metodo: su $\kappa \approx 20$ la maggior parte dei seed peggiora per Dynamic GD e Newton-CG (rispettivamente 2/5 e 0/5 migliorano, a causa della deriva verso il minimo campionario e dell’Hessiana obsoleta), mentre BB-CCV, che parte già da 9.72×10^{-5} , trae ancora beneficio dal riuso (3/5); Newton-CG L_1 migliora solo su 1–2 seed su 5. Su $\kappa \approx 100$ Dynamic GD migliora su 3 seed su 5 e Newton-CG L_1 su 3 su 5 con $M=\infty$ (4/5 con $M=10$): con una curvatura così estrema l’errore è dominato dal rimbalzo dell’iterato nella direzione piatta, che il riuso attenua fissando il campione; BB-CCV invece peggiora (1/5), perché la base è già alla precisione macchina; Newton-CG resta sempre peggiorativo (0/5), perché il danno dell’Hessiana obsoleta prevale su ogni beneficio. Sul termine incrociato ($\kappa \approx 1.67$) il riuso aiuta Dynamic GD e Newton-CG (4/5 con $M=\infty$) ma non BB-CCV e Newton-CG L_1 (2/5), meno robusti quando al riuso di

batch e Hessiana si sommano la proiezione ortante e il subgradiente del termine L_1 (per L_1) o la sensibilità del passo di Barzilai–Borwein al campione fissato (per BB-CCV). Sulla Funzione di Rosenbrock il riuso è invece sempre peggiorativo: migliora in 2 seed su 5 al massimo (Dynamic GD, sia con $M = \infty$ sia con $M = 10$) e per gli altri tre metodi in 1–2 seed su 5 (Tabella 6.2).

6.5.6 Stop adattivo con validation set

Le Tabelle 6.1 e 6.2 mostrano che il numero massimo M di iterazioni sullo stesso mini-batch va scelto con cura: il valore migliore cambia con problema e algoritmo, e per i metodi di Newton un valore troppo alto ($M = \infty$) può far collassare la convergenza (errore finale e_{30} fino a 1.28 sui problemi mal condizionati). Lo *stop adattivo con validation set* automatizza questa scelta: il momento in cui ricampionare il batch (e, per i metodi di Newton, l’Hessiana) è deciso dalla loss media su un validation set, senza fissare M a priori.

Il meccanismo è il seguente. Il dataset è diviso in training e validation (p è la percentuale in validation); il mini-batch è campionato dal solo training set, con la CCV che ne aumenta la dimensione con tetto $|\mathcal{T}|$ invece di N . Dopo ogni aggiornamento w_{k+1} (anche a passo nullo) la loss media J_{val} è valutata ogni f iterazioni; se per P valutazioni consecutive non risulta $J_{\text{val}} \leq J_{\text{val}}^{\text{best}}(1 - \tau) - \epsilon_{\text{abs}}$, il batch viene ricampionato all’iterazione successiva. La strategia di split è *fissa* (una volta all’inizio) o *dinamica* (a ogni cambio di batch); per i metodi di Newton l’Hessiana segue il batch in modalità legata (Sezione 6.5.1).

Setup come nella Sezione 6.5.3 (l’intera batteria di cinque problemi: i quattro quadratici e la Funzione di Rosenbrock; $N = 200$, $w_0 = (2, -3)$, $\alpha = 0.1$, $\theta = 0.5$, $n_0 = 5$, 30 iterazioni, seed 42), con gli algoritmi esatti generati dall’applicazione (varianti con validation set dei codici Python dell’Appendice B). I riferimenti *base* e $M = \infty$ sono ricalcolati sul solo training set e non vanno confrontati con le colonne della Tabella 6.1, che usano tutti gli $N = 200$ esempi.

Iperparametri testati. L’applicazione espone sei iperparametri:

- la pazienza P (default 3): valutazioni senza miglioramento prima di ricampionare;
- la tolleranza relativa τ (default 10^{-4}) e la soglia assoluta ϵ_{abs} (default 0): definiscono il criterio di miglioramento $J_{\text{val}} \leq J_{\text{val}}^{\text{best}}(1 - \tau) - \epsilon_{\text{abs}}$ che azzerà il contatore di pazienza;
- la percentuale di validation p (default 20%);
- la frequenza di valutazione f (default 1): una valutazione ogni f iterazioni;
- la strategia di split: *fissa* o *dinamica* (default *fissa*).

Confronto con i riferimenti. La Tabella 6.3 confronta lo stop adattivo con la *base* e con $M = \infty$ (seed 42). Con i valori di default lo stop adattivo è peggiore della *base* in media (2.34×10^{-1} contro 1.96×10^{-1} sulle 20 combinazioni) ma con molti meno ricampionamenti e, per i metodi di Newton, evita il collasso di $M = \infty$: su Newton-CG con $\kappa \approx 1.1$ l’errore finale passa da 1.41 (riuso illimitato) a 2.98×10^{-1}

con i default e a 1.78×10^{-1} con la calibrazione $P=1, p=0.1, \text{dyn}$, migliore persino della *base* (3.73×10^{-1}). Su 5 seed (Tabella 6.4) la calibrazione ($P=1, p=10\%$, strategia dinamica) porta l'errore medio a 2.04×10^{-1} , inferiore a quello della *base* (2.16×10^{-1}) e di $M = \infty$ (3.84×10^{-1}), vincendo in 12 delle 20 combinazioni problema $\times$ algoritmo.

In sintesi, lo stop adattivo rende il riuso del mini-batch una scelta sicura per i metodi del secondo ordine, dove $M = \infty$ è pericoloso, ma i valori di default sono peggiori della *base* (2.67×10^{-1} contro 2.16×10^{-1} su 5 seed) e vanno calibrati: la calibrazione ($P=1, p=10\%$, strategia dinamica) porta l'errore medio sotto la *base* (2.04×10^{-1} , 12/20). Gli iperparametri che contano sono la pazienza (bassa) e la percentuale di validation (bassa); la strategia di split e la tolleranza relativa hanno effetti marginali. Il costo aggiuntivo è trascurabile: una valutazione di J_{val} ogni f iterazioni su circa pN esempi.

Tabella 6.3: Stop adattivo con validation set: errore finale $e_{30} = \|w_{30} - w_*\|_2$ (seed 42). Colonne: *base* = ricampionamento a ogni iterazione (training set); $M=\infty$ = riuso illimitato (training set); *def.* = valori di default ($p=0.2, \tau=10^{-4}, P=3, f=1$, split fisso); $P=1, p=0.1, \text{dyn}$ e $P=3, p=0.1, \text{dyn}$. Tra parentesi il numero di ricampionamenti.

Metodo	<i>base</i>	$M=\infty$	<i>def.</i>	$P=1, p=0.1, \text{dyn}$	$P=3, p=0.1, \text{dyn}$
$\kappa \approx 1.1$ - Dynamic GD	1.2412×10^{-1} (29)	$1.2347 \times 10^{-1} \blacktriangle$ (19)	$1.2347 \times 10^{-1} \blacktriangle$ (19)	$1.1704 \times 10^{-1} \blacktriangle$ (19)	$1.1441 \times 10^{-1} \blacktriangle$ (18)
$\kappa \approx 1.1$ - BB-CCV	1.2268×10^{-1} (29)	$1.2268 \times 10^{-1} \blacktriangledown$ (8)	$1.2268 \times 10^{-1} \blacktriangledown$ (8)	$1.1629 \times 10^{-1} \blacktriangle$ (26)	$1.1629 \times 10^{-1} \blacktriangle$ (26)
$\kappa \approx 1.1$ - Newton-CG	3.7346×10^{-1} (29)	$1.4142 \times 10^{-1} \blacktriangledown$ (10)	$2.9780 \times 10^{-1} \blacktriangle$ (3)	$1.7763 \times 10^{-1} \blacktriangle$ (5)	$1.6879 \times 10^{-1} \blacktriangle$ (6)
$\kappa \approx 1.1$ - Newton-CG L_1	1.1114×10^{-1} (29)	$7.7838 \times 10^{-2} \blacktriangle$ (6)	$7.7838 \times 10^{-2} \blacktriangle$ (6)	$8.7102 \times 10^{-2} \blacktriangle$ (13)	$8.7102 \times 10^{-2} \blacktriangle$ (13)
$\kappa \approx 20$ - Dynamic GD	5.6422×10^{-2} (29)	$6.1835 \times 10^{-2} \blacktriangledown$ (1)	$6.1835 \times 10^{-2} \blacktriangledown$ (1)	$1.5675 \times 10^{-1} \blacktriangledown$ (27)	$1.2093 \times 10^{-2} \blacktriangle$ (8)
$\kappa \approx 20$ - BB-CCV	1.7173×10^{-3} (29)	$1.7173 \times 10^{-3} \blacktriangle$ (10)	$1.7173 \times 10^{-3} \blacktriangle$ (13)	$3.7758 \times 10^{-2} \blacktriangledown$ (26)	$1.6199 \times 10^{-2} \blacktriangledown$ (20)
$\kappa \approx 20$ - Newton-CG	1.7217×10^{-1} (29)	$6.4637 \times 10^{-1} \blacktriangledown$ (0)	$3.6965 \times 10^{-1} \blacktriangledown$ (6)	$1.8698 \times 10^{-1} \blacktriangledown$ (11)	$4.0726 \times 10^{-1} \blacktriangledown$ (5)
$\kappa \approx 20$ - Newton-CG L_1	4.8708×10^{-1} (29)	$5.9759 \times 10^{-1} \blacktriangledown$ (4)	$5.9759 \times 10^{-1} \blacktriangledown$ (4)	$6.6464 \times 10^{-1} \blacktriangledown$ (7)	$6.7171 \times 10^{-1} \blacktriangledown$ (5)
$\kappa \approx 100$ - Dynamic GD	4.5401×10^{-1} (29)	$4.7131 \times 10^{-1} \blacktriangledown$ (26)	$4.7131 \times 10^{-1} \blacktriangledown$ (26)	$5.4144 \times 10^{-1} \blacktriangledown$ (27)	$4.0066 \times 10^{-1} \blacktriangle$ (26)
$\kappa \approx 100$ - BB-CCV	1.7173×10^{-3} (29)	$1.4573 \times 10^{-3} \blacktriangle$ (26)	$1.4573 \times 10^{-3} \blacktriangle$ (26)	$3.4910 \times 10^{-3} \blacktriangledown$ (27)	$2.2569 \times 10^{-1} \blacktriangledown$ (25)
$\kappa \approx 100$ - Newton-CG	1.8251×10^{-1} (29)	$1.4142 \times 10^{-1} \blacktriangledown$ (10)	$8.2559 \times 10^{-1} \blacktriangledown$ (8)	$1.9718 \times 10^{-1} \blacktriangledown$ (12)	$3.9508 \times 10^{-1} \blacktriangledown$ (5)
$\kappa \approx 100$ - Newton-CG L_1	8.6698×10^{-1} (29)	$9.7009 \times 10^{-1} \blacktriangledown$ (3)	$9.6923 \times 10^{-1} \blacktriangledown$ (4)	$9.6870 \times 10^{-1} \blacktriangledown$ (9)	$9.6870 \times 10^{-1} \blacktriangledown$ (4)
incrociato ($\kappa \approx 1.67$) - Dynamic GD	1.8709×10^{-2} (29)	$1.7261 \times 10^{-2} \blacktriangle$ (16)	$1.7261 \times 10^{-2} \blacktriangle$ (16)	$6.1465 \times 10^{-3} \blacktriangle$ (16)	$6.2449 \times 10^{-3} \blacktriangle$ (15)
incrociato ($\kappa \approx 1.67$) - BB-CCV	9.5580×10^{-3} (29)	$9.5580 \times 10^{-3} \blacktriangle$ (19)	$9.5580 \times 10^{-3} \blacktriangle$ (21)	$5.3768 \times 10^{-4} \blacktriangle$ (27)	$5.3768 \times 10^{-4} \blacktriangle$ (27)
incrociato ($\kappa \approx 1.67$) - Newton-CG	2.8717×10^{-1} (29)	$1.4142 \times 10^{-1} \blacktriangledown$ (10)	$7.8791 \times 10^{-2} \blacktriangle$ (5)	$9.2824 \times 10^{-2} \blacktriangle$ (11)	$1.7781 \times 10^{-1} \blacktriangle$ (8)
incrociato ($\kappa \approx 1.67$) - Newton-CG L_1	1.0628×10^{-2} (29)	$2.2289 \times 10^{-2} \blacktriangledown$ (11)	$2.2289 \times 10^{-2} \blacktriangledown$ (11)	$2.7610 \times 10^{-2} \blacktriangledown$ (17)	$2.7754 \times 10^{-2} \blacktriangledown$ (14)
Funzione di Rosenbrock ($c=100$) - Dynamic GD	5.3698×10^{-3} (29)	$5.3845 \times 10^{-3} \blacktriangledown$ (22)	$5.3845 \times 10^{-3} \blacktriangledown$ (22)	$1.4065 \times 10^{-2} \blacktriangledown$ (24)	$4.7963 \times 10^{-3} \blacktriangle$ (23)
Funzione di Rosenbrock ($c=100$) - BB-CCV	5.3653×10^{-3} (29)	$5.3653 \times 10^{-3} \blacktriangledown$ (26)	$5.3653 \times 10^{-3} \blacktriangledown$ (26)	$5.0034 \times 10^{-3} \blacktriangle$ (27)	$5.0034 \times 10^{-3} \blacktriangle$ (27)
Funzione di Rosenbrock ($c=100$) - Newton-CG	4.2039×10^{-1} (29)	$5.6994 \times 10^{-1} \blacktriangledown$ (2)	$4.8797 \times 10^{-1} \blacktriangledown$ (3)	$7.2464 \times 10^{-2} \blacktriangle$ (10)	$9.7980 \times 10^{-2} \blacktriangle$ (7)
Funzione di Rosenbrock ($c=100$) - Newton-CG L_1	2.0116×10^{-1} (29)	$1.2973 \times 10^{-1} \blacktriangle$ (2)	$1.2973 \times 10^{-1} \blacktriangle$ (2)	$1.1021 \times 10^{-1} \blacktriangle$ (3)	$1.0884 \times 10^{-1} \blacktriangle$ (3)
Media (20 casi)	1.9562×10^{-1}	$4.0383 \times 10^{-1} \blacktriangledown$	$2.3383 \times 10^{-1} \blacktriangledown$	$1.7919 \times 10^{-1} \blacktriangle$	$2.0065 \times 10^{-1} \blacktriangledown$

Lettura. Confronta lo stop adattivo con validation set con la base e con $M=\infty$ (seed 42), riportando tra parentesi il numero di ricampionamenti: con i valori di default si evita il collasso di $M=\infty$ per i metodi di Newton, e la calibrazione $P=1, p=0.1, \text{dyn}$ migliora o eguaglia la base nella maggior parte delle combinazioni.

Tabella 6.4: Robustezza su 5 seed indipendenti: $\bar{e}_{30}$ = media di e_{30} su 20 caselle $\times$ 5 seed; *vitt.* = caselle (su 20) in cui la media su 5 seed è minore di quella di *base*; le ultime cinque colonne riportano la media su 5 seed per problema.

Configurazione	$\bar{e}_{30}$	<i>vitt.</i>	$\kappa \approx 1.1$	$\kappa \approx 20$	$\kappa \approx 100$	incr. ($\kappa \approx 1.67$)	Funzione di Rosenbrock ($c=100$)
<i>base</i>	2.1608×10^{-1}	0/20	1.8850×10^{-1}	1.9229×10^{-1}	4.0422×10^{-1}	8.4365×10^{-2}	2.1102×10^{-1}
$M=\infty$	3.8354×10^{-1}	5/20	2.4978×10^{-1}	4.5080×10^{-1}	7.1556×10^{-1}	1.6970×10^{-1}	3.3186×10^{-1}
<i>def.</i>	2.6706×10^{-1}	7/20	1.3485×10^{-1}	3.1368×10^{-1}	5.7133×10^{-1}	3.8100×10^{-2}	2.7736×10^{-1}
$P=1, p=0.1, \text{dyn}$	2.0375×10^{-1}	12/20	1.4045×10^{-1}	2.1065×10^{-1}	4.5437×10^{-1}	3.9223×10^{-2}	1.7407×10^{-1}
$P=3, p=0.1, \text{dyn}$	2.2931×10^{-1}	11/20	1.3955×10^{-1}	2.4684×10^{-1}	5.2925×10^{-1}	4.3722×10^{-2}	1.8717×10^{-1}

Lettura. Robustezza su 5 seed: la calibrazione $P=1, p=0.1, \text{dyn}$ porta l'errore medio a 2.04×10^{-1} , inferiore a quello della base (2.16×10^{-1}) e di $M=\infty$ (3.84×10^{-1}), vincendo in 12 combinazioni su 20; il default (2.67×10^{-1} , $7/20$) resta sopra la *base*.

6.5.7 Riuso per discesa della loss sul batch

Lo stop adattivo con validation set (Sezione 6.5.6) tiene fuori dal campionamento una frazione p degli esempi, riducendo il training set disponibile. Il *riuso per discesa della loss sul batch* persegue lo stesso obiettivo (decidere automaticamente quando ricampionare il mini-batch), senza riservare alcun dato: la decisione è presa osservando esclusivamente l'andamento di J_{batch} sul mini-batch corrente.

Il meccanismo è il seguente. Dopo ogni aggiornamento w_{k+1} la loss media $J_{\text{batch}}(w_k)$ è valutata sul batch corrente ogni f iterazioni e confrontata con il valore dell'iterazione precedente *sullo stesso batch* (il confronto riparte da zero dopo ogni ricampionamento). La versione firmata del criterio considera un miglioramento solo se

$$J_{\text{batch}}(w_{k-1}) - J_{\text{batch}}(w_k) \geq \tau |J_{\text{batch}}(w_{k-1})| + \epsilon_{\text{abs}},$$

con tolleranza relativa τ e soglia assoluta ϵ_{abs} ; se per P valutazioni consecutive non si registra un miglioramento, il batch viene ricampionato all'iterazione successiva. Non essendoci split, il mini-batch è campionato dall'intero dataset e la CCV ha tetto N ; per i metodi di Newton l'Hessiana segue il batch in modalità legata e M_H segue lo stesso criterio (per Newton-CG L_1 si monitora la funzione completa $F_{\text{batch}} = J_{\text{batch}} + \nu \|w\|_1$).

Una differenza qualitativa rispetto al criterio di validazione è importante. Le ricerche lineari (Wolfe per Dynamic GD e Newton-CG, Armijo per BB-CCV) garantiscono già che J_{batch} decresca a ogni passo accettato: il criterio di discesa non scatta quando la loss *cresce* (non può, a meno di passo nullo), ma quando *decresce troppo poco*, cioè quando la riduzione relativa è sotto soglia. Questo accade tipicamente in prossimità del minimo campionario del batch, dove il batch è “esaurito” nel senso della CCV; la tolleranza τ funziona quindi come soglia di sensibilità: valori più alti (per esempio 10^{-3}) dichiarano il batch esaurito prima e generano più ricampionamenti.

Setup come nella Sezione 6.5.3 (l'intera batteria di cinque problemi: i quattro quadratici e la Funzione di Rosenbrock; $N = 200$, $w_0 = (2, -3)$, $\alpha = 0.1$, $\theta = 0.5$, $n_0 = 5$, 30 iterazioni, seed 42), con gli algoritmi esatti generati dall'applicazione (varianti con criterio di discesa dei codici Python dell'Appendice B). I riferimenti *base* e $M = \infty$ sono ricalcolati sull'intero dataset con lo stesso codice: la *base* ricampiona il mini-batch a ogni iterazione, $M = \infty$ corrisponde a pazienza infinita (si ricampiona solo quando la CCV aumenta il batch). Non essendoci split, queste colonne non vanno confrontate con quelle della Tabella 6.3, che campionano dal solo training set.

Iperparametri testati. L'applicazione espone quattro iperparametri:

- la pazienza P (default 1): valutazioni senza miglioramento prima di ricampionare;
- la tolleranza relativa τ (default 10^{-4}) e la soglia assoluta ϵ_{abs} (default 0): definiscono il criterio di miglioramento qui sopra;

- la frequenza di valutazione f (default 1): una valutazione ogni f iterazioni.

Tabella 6.5: Riuso per discesa della loss sul batch: errore finale e_{30} (seed 42). Colonne: *base* = ricampionamento a ogni iterazione; $M=\infty$ = riuso illimitato; *def.* = valori di default ($\tau = 10^{-4}$, $P = 1$, $f = 1$); $P=1, \tau=10^{-3}, f=1$ e $P=1, \tau=10^{-5}, f=1$. Tra parentesi il numero di ricampionamenti.

Metodo	<i>base</i>	$M=\infty$	<i>def.</i>	$P=1, \tau=10^{-3}, f=1$	$P=1, \tau=10^{-5}, f=1$
$\kappa \approx 1.1$ - Dynamic GD	1.1895×10^{-1} (29)	$1.1739 \times 10^{-1} \blacktriangle$ (18)	$1.1739 \times 10^{-1} \blacktriangle$ (18)	$1.1739 \times 10^{-1} \blacktriangle$ (18)	$1.1739 \times 10^{-1} \blacktriangle$ (18)
$\kappa \approx 1.1$ - BB-CCV	1.1662×10^{-1} (11)	$1.1662 \times 10^{-1} \blacktriangle$ (5)	$1.1662 \times 10^{-1} \blacktriangle$ (5)	$1.1662 \times 10^{-1} \blacktriangle$ (5)	$1.1662 \times 10^{-1} \blacktriangle$ (5)
$\kappa \approx 1.1$ - Newton-CG	3.0560×10^{-1} (29)	$2.2230 \times 10^{-1} \blacktriangle$ (2)	$1.6534 \times 10^{-1} \blacktriangle$ (4)	$1.6534 \times 10^{-1} \blacktriangle$ (4)	$1.6534 \times 10^{-1} \blacktriangle$ (4)
$\kappa \approx 1.1$ - Newton-CG L_1	1.0028×10^{-1} (29)	$8.1750 \times 10^{-2} \blacktriangle$ (8)	$8.1750 \times 10^{-2} \blacktriangle$ (8)	$8.1750 \times 10^{-2} \blacktriangle$ (8)	$8.1750 \times 10^{-2} \blacktriangle$ (8)
$\kappa \approx 20$ - Dynamic GD	4.9050×10^{-2} (29)	$1.0103 \times 10^{-1} \blacktriangledown$ (1)	$1.0103 \times 10^{-1} \blacktriangledown$ (1)	$4.8866 \times 10^{-2} \blacktriangle$ (14)	$1.0103 \times 10^{-1} \blacktriangledown$ (1)
$\kappa \approx 20$ - BB-CCV	9.7195×10^{-5} (29)	$9.5364 \times 10^{-10} \blacktriangle$ (14)	$9.5364 \times 10^{-10} \blacktriangle$ (14)	$9.5364 \times 10^{-10} \blacktriangle$ (14)	$9.5364 \times 10^{-10} \blacktriangle$ (14)
$\kappa \approx 20$ - Newton-CG	1.6683×10^{-1} (29)	$1.2807 \times 10^0 \blacktriangledown$ (0)	$2.4844 \times 10^{-1} \blacktriangledown$ (8)	$2.4844 \times 10^{-1} \blacktriangledown$ (8)	$2.4844 \times 10^{-1} \blacktriangledown$ (8)
$\kappa \approx 20$ - Newton-CG L_1	5.4573×10^{-1} (29)	$7.6221 \times 10^{-1} \blacktriangledown$ (5)	$7.6221 \times 10^{-1} \blacktriangledown$ (5)	$7.6221 \times 10^{-1} \blacktriangledown$ (5)	$7.6221 \times 10^{-1} \blacktriangledown$ (5)
$\kappa \approx 100$ - Dynamic GD	4.6668×10^{-1} (29)	$3.7060 \times 10^{-1} \blacktriangle$ (27)	$3.7060 \times 10^{-1} \blacktriangle$ (27)	$3.7060 \times 10^{-1} \blacktriangle$ (27)	$3.7060 \times 10^{-1} \blacktriangle$ (27)
$\kappa \approx 100$ - BB-CCV	1.0991×10^{-14} (10)	$7.4538 \times 10^{-3} \blacktriangledown$ (24)	$7.4538 \times 10^{-3} \blacktriangledown$ (24)	$7.4538 \times 10^{-3} \blacktriangledown$ (24)	$7.4538 \times 10^{-3} \blacktriangledown$ (24)
$\kappa \approx 100$ - Newton-CG	2.3041×10^{-1} (29)	$1.2807 \times 10^0 \blacktriangledown$ (0)	$4.2582 \times 10^{-1} \blacktriangledown$ (11)	$4.2582 \times 10^{-1} \blacktriangledown$ (11)	$4.2582 \times 10^{-1} \blacktriangledown$ (11)
$\kappa \approx 100$ - Newton-CG L_1	8.6562×10^{-1} (29)	$9.7065 \times 10^{-1} \blacktriangledown$ (5)	$9.7065 \times 10^{-1} \blacktriangledown$ (5)	$9.7065 \times 10^{-1} \blacktriangledown$ (5)	$9.7065 \times 10^{-1} \blacktriangledown$ (5)
incrociato ($\kappa \approx 1.67$) - Dynamic GD	9.4161×10^{-3} (29)	$5.5315 \times 10^{-3} \blacktriangle$ (16)	$5.5315 \times 10^{-3} \blacktriangle$ (16)	$5.5315 \times 10^{-3} \blacktriangle$ (16)	$5.5315 \times 10^{-3} \blacktriangle$ (16)
incrociato ($\kappa \approx 1.67$) - BB-CCV	6.1644×10^{-4} (15)	$6.1689 \times 10^{-4} \blacktriangledown$ (9)	$6.1689 \times 10^{-4} \blacktriangledown$ (9)	$6.1689 \times 10^{-4} \blacktriangledown$ (9)	$6.1689 \times 10^{-4} \blacktriangledown$ (9)
incrociato ($\kappa \approx 1.67$) - Newton-CG	2.6381×10^{-1} (29)	$4.1026 \times 10^{-2} \blacktriangle$ (5)	$4.1026 \times 10^{-2} \blacktriangle$ (5)	$4.1026 \times 10^{-2} \blacktriangle$ (5)	$4.1026 \times 10^{-2} \blacktriangle$ (5)
incrociato ($\kappa \approx 1.67$) - Newton-CG L_1	2.5154×10^{-2} (29)	$3.8938 \times 10^{-2} \blacktriangledown$ (10)	$3.8938 \times 10^{-2} \blacktriangledown$ (10)	$3.8938 \times 10^{-2} \blacktriangledown$ (10)	$3.8938 \times 10^{-2} \blacktriangledown$ (10)
Funzione di Rosenbrock ($c=100$) - Dynamic GD	6.1354×10^{-4} (29)	$2.5435 \times 10^0 \blacktriangledown$ (25)	$2.5435 \times 10^0 \blacktriangledown$ (25)	$2.5435 \times 10^0 \blacktriangledown$ (25)	$2.5435 \times 10^0 \blacktriangledown$ (25)
Funzione di Rosenbrock ($c=100$) - BB-CCV	1.0645×10^{-1} (29)	$1.6648 \times 10^{-1} \blacktriangledown$ (10)	$1.6648 \times 10^{-1} \blacktriangledown$ (10)	$1.6648 \times 10^{-1} \blacktriangledown$ (10)	$1.6648 \times 10^{-1} \blacktriangledown$ (10)
Funzione di Rosenbrock ($c=100$) - Newton-CG	9.3953×10^{-1} (29)	$1.0605 \times 10^0 \blacktriangledown$ (0)	$1.0247 \times 10^0 \blacktriangledown$ (4)	$1.0247 \times 10^0 \blacktriangledown$ (4)	$1.0247 \times 10^0 \blacktriangledown$ (4)
Funzione di Rosenbrock ($c=100$) - Newton-CG L_1	2.0207×10^{-1} (29)	$3.8199 \times 10^{-1} \blacktriangledown$ (0)	$3.8199 \times 10^{-1} \blacktriangledown$ (0)	$3.8199 \times 10^{-1} \blacktriangledown$ (0)	$3.8199 \times 10^{-1} \blacktriangledown$ (0)

Lettura. Confronta il criterio di discesa (che non riserva dati) con la base e con $M=\infty$: per Dynamic GD e BB-CCV si comporta quasi come $M=\infty$ (la line search tiene il batch “in discesa”), per i metodi di Newton evita il collasso di $M=\infty$ (su $\kappa \approx 20$: da 1.28 a 2.48×10^{-1}).

Tabella 6.6: Robustezza su 5 seed indipendenti del riuso per discesa: $\bar{e}_{30}$ = media di e_{30} su 20 caselle $\times$ 5 seed; *vitt.* = caselle (su 20) in cui la media su 5 seed è minore di quella di *base*; le ultime cinque colonne riportano la media su 5 seed per problema.

Configurazione	$\bar{e}_{30}$	<i>vitt.</i>	$\kappa \approx 1.1$	$\kappa \approx 20$	$\kappa \approx 100$	incr. ($\kappa \approx 1.67$)	Funzione di Rosenbrock ($c=100$)
<i>base</i>	2.0909×10^{-1}	0/20	1.7930×10^{-1}	1.7595×10^{-1}	4.1162×10^{-1}	8.1419×10^{-2}	1.9719×10^{-1}
$M=\infty$	3.7299×10^{-1}	8/20	1.9159×10^{-1}	5.0123×10^{-1}	6.6432×10^{-1}	9.8773×10^{-2}	4.0901×10^{-1}
<i>def.</i>	2.3947×10^{-1}	10/20	1.1855×10^{-1}	2.4065×10^{-1}	4.2013×10^{-1}	3.4413×10^{-2}	3.8362×10^{-1}
$P=1, \tau=10^{-3}, f=1$	2.3817×10^{-1}	11/20	1.1855×10^{-1}	2.3416×10^{-1}	4.2013×10^{-1}	3.4413×10^{-2}	3.8362×10^{-1}
$P=1, \tau=10^{-5}, f=1$	2.3947×10^{-1}	10/20	1.1855×10^{-1}	2.4065×10^{-1}	4.2013×10^{-1}	3.4413×10^{-2}	3.8362×10^{-1}

Lettura. Robustezza su 5 seed: la configurazione consigliata ($\tau=10^{-3}$, $P=1$, $f=1$) vince in 11 delle 20 combinazioni problema $\times$ algoritmo ma porta l'errore medio a 2.38×10^{-1} , superiore alla media della *base* (2.09×10^{-1}): sulla Funzione di Rosenbrock il criterio peggiora su tutti i metodi (3.84×10^{-1} contro 1.97×10^{-1} , ultima colonna), mentre sui problemi quadratici resta vicina o migliore della *base*. Rispetto a $M=\infty$ (3.73×10^{-1} , 8/20) la discesa evita comunque i collassi dei metodi di Newton.

Confronto con i riferimenti. La Tabella 6.5 confronta il criterio di discesa con la *base* e con $M = \infty$ (seed 42). Per Dynamic GD e BB-CCV il criterio si comporta quasi come $M = \infty$ per i metodi del primo ordine: la monotonia della ricerca lineare mantiene il batch “in discesa” e i ricampionamenti aggiuntivi sono rari (per esempio su $\kappa \approx 20$ il default ricampiona una sola volta, come $M = \infty$, peggiorando

la *base*: 1.01×10^{-1} contro 4.91×10^{-2} ; la calibrazione $\tau = 10^{-3}$, $P = 1$, $f = 1$ riconosce prima il batch “esaurito” e riporta Dynamic GD a 4.89×10^{-2} con 14 ricampionamenti). BB-CCV, la cui base su $\kappa \approx 20$ è già 9.72×10^{-5} , migliora fino a 9.54×10^{-10} . Per i metodi di Newton il criterio limita il riuso ed evita il collasso di $M = \infty$: su Newton-CG con $\kappa \approx 20$ l’errore finale passa da 1.28 (riuso illimitato) a 2.48×10^{-1} . Sulla Funzione di Rosenbrock, al contrario, il criterio è controproducente rispetto alla *base*: l’errore medio per problema su 5 seed sale da 1.97×10^{-1} a 3.84×10^{-1} (Tabella 6.6), perché i metodi che su questo problema beneficiano dei ricampionamenti frequenti vengono trattenuti troppo a lungo sullo stesso batch.

Robustezza. La Tabella 6.6 riporta la robustezza su 5 seed. (2.09×10^{-1}): le vittorie sono concentrate dove la base è già buona (ben condizionati, termine incrociato), mentre le sconfitte pesano di più sulla Funzione di Rosenbrock (3.84×10^{-1} contro 1.97×10^{-1}) e su $\kappa \approx 20$ (2.34×10^{-1} contro 1.76×10^{-1} , dove il criterio trattiene Dynamic GD sullo stesso batch). Il default ($\tau = 10^{-4}$, $P = 1$, $f = 1$) è pressoché equivalente (2.39×10^{-1} , 10/20): la tolleranza ha un effetto limitato perché la monotonia della ricerca lineare tiene comunque il batch “in discesa”.

Confronto tra i due criteri automatici. La Tabella 6.7 riassume il confronto su 5 seed tra la *base*, lo stop adattivo con validation set calibrato ($P = 1$, $p = 10\%$, split dinamico; Sezione 6.5.6) e il riuso per discesa calibrato ($\tau = 10^{-3}$, $P = 1$, $f = 1$). Con la Funzione di Rosenbrock nella batteria lo stop adattivo è la strategia migliore in media (2.04×10^{-1} , 12 vittorie su 20) e l’unica a migliorare la media della *base* (2.09×10^{-1}); il riuso per discesa vince in 11 casi su 20, ma la sua media sale a 2.38×10^{-1} perché sulla Funzione di Rosenbrock peggiora su tutti i metodi (3.84×10^{-1} contro 1.97×10^{-1} della *base*). Entrambi i criteri evitano il collasso di $M = \infty$ (3.73×10^{-1} , 8/20). Su $\kappa \approx 20$, il problema su cui $M = \infty$ è più pericoloso, la *base* resta la migliore in media (1.76×10^{-1}), con lo stop adattivo a 2.11×10^{-1} e la discesa a 2.34×10^{-1} : i criteri automatici proteggono dai collassi ma non aggiungono margine dove la base è già buona.

In sintesi, il riuso per discesa resta un’alternativa valida allo stop adattivo quando non si vuole (o non si può) riservare una frazione dei dati: molti meno ricampionamenti e protezione dal collasso di $M = \infty$ per i metodi del secondo ordine. Sulla batteria completa di cinque problemi, però, la sua media su 5 seed è peggiore di quella della *base* e dello stop adattivo, perché sulla Funzione di Rosenbrock (e in parte su $\kappa \approx 20$) trattiene i metodi troppo a lungo sullo stesso batch. La tolleranza ha un effetto limitato: $\tau = 10^{-3}$ è appena meglio del default 10^{-4} , perché la monotonia della ricerca lineare tiene comunque il batch “in discesa”.

Tabella 6.7: Confronto finale su 5 seed indipendenti (20 combinazioni problema $\times$ algoritmo) tra *base*, $M=\infty$, lo stop adattivo con validation set calibrato ($P=1$, $p=10\%$, split dinamico) e il riuso per discesa calibrato ($\tau=10^{-3}$, $P=1$, $f=1$). $\bar{e}_{30}$ = media su 20 caselle $\times$ 5 seed; *vitt.* = caselle (su 20) in cui la media su 5 seed è minore del proprio riferimento.

Strategia	$\bar{e}_{30}$	<i>vitt.</i>	$\kappa \approx 1.1$	$\kappa \approx 20$	$\kappa \approx 100$	incr. ($\kappa \approx 1.67$)	Funzione di Rosenbrock ($c=100$)
<i>base</i>	2.0909×10^{-1}	0/20	1.7930×10^{-1}	1.7595×10^{-1}	4.1162×10^{-1}	8.1419×10^{-2}	1.9719×10^{-1}
$M=\infty$	3.7299×10^{-1}	8/20	1.9159×10^{-1}	5.0123×10^{-1}	6.6432×10^{-1}	9.8773×10^{-2}	4.0901×10^{-1}
$P=1, p=0.1, \text{dyn}$	2.0375×10^{-1}	12/20	1.4045×10^{-1}	2.1065×10^{-1}	4.5437×10^{-1}	3.9223×10^{-2}	1.7407×10^{-1}
$\tau=10^{-3}, P=1, f=1$	2.3817×10^{-1}	11/20	1.1855×10^{-1}	2.3416×10^{-1}	4.2013×10^{-1}	3.4413×10^{-2}	3.8362×10^{-1}

Lettura. Chiude il confronto tra i due criteri automatici su 5 seed: la discesa calibrata è leggermente migliore in media (2.02×10^{-1} contro 2.11×10^{-1} della validation) e usa l'intero dataset, senza riservare dati; la validation tiene fuori il 10% dei dati.

6.5.8 Iperparametri consigliati per ciascun metodo

Le sottosezioni precedenti mostrano che il valore ottimo di M (riuso del mini-batch) e degli iperparametri dello stop adattivo cambia con il problema e con l'algoritmo. Lo *stop adattivo con validation set* (Sezione 6.5.6) offre una via per automatizzare la scelta del momento in cui ricampionare: una frazione p degli esempi è tenuta fuori dal campionamento del mini-batch e usata come *validation set*; il batch è estratto dal solo training set e, dopo ogni aggiornamento w_{k+1} , la loss media $J_{\text{val}}(w_{k+1})$ è valutata sul validation set con frequenza f . Se per P valutazioni consecutive non risulta $J_{\text{val}} \leq J_{\text{val}}^{\text{best}}(1 - \tau) - \epsilon_{\text{abs}}$, il batch viene ricampionato all'iterazione successiva. La strategia di split è *fissa* (train e validation estratti una sola volta) o *dinamica* (risplit a ogni cambio di batch); per i metodi di Newton l'Hessiana segue il batch in modalità legata. Restano quindi da scegliere i sei iperparametri P , f , p , τ , ϵ_{abs} e la strategia di split, oltre al limite M del riuso. Un'alternativa senza validation set è il *riuso per discesa della loss sul batch* (Sezione 6.5.7), che usa gli stessi iperparametri P , τ , ϵ_{abs} e f osservando la sola loss sul batch corrente; il confronto tra i due criteri è riportato nella Tabella 6.7.

Questa sottosezione riporta la scelta consigliata per ciascun metodo, ottenuta con una ricerca a griglia mirata sull'intera batteria di cinque problemi e con lo stesso setup della Sezione 6.3: i quattro preset quadratici ($\kappa \approx 1.1$, $\kappa \approx 20$, $\kappa \approx 100$ e termine incrociato) e la Funzione di Rosenbrock (non quadratica, $c=100$), $N = 200$ esempi sintetici, $w_0 = (2, -3)$, $\alpha = 0.1$, $\theta = 0.5$, $n_0 = 5$, 30 iterazioni, line search di Wolfe (Armijo per BB-CCV, come nella Sezione 6.1). La metrica è l'errore finale $e_{30} = \|w_{30} - w^*\|_2$. Le configurazioni candidate sono i valori $M \in \{\infty, 10, 5, 3, 2, 1\}$ della Tabella 6.1 e le varianti con validation set della Sezione 6.5.6 con $P \in \{1, 3\}$, $f = 1$, $p \in \{10\%, 20\%\}$ e strategia fissa o dinamica. Per ciascun metodo la configurazione consigliata è quella che migliora la *mediana* di e_{30} su tutti e cinque i problemi rispetto alla *base* (ricampionamento a ogni iterazione) e, tra quelle ammissibili, ha la migliore media geometrica del rapporto $e_{30}^{\text{cfg}}/e_{30}^{\text{base}}$ sulle 25 combinazioni (5 problemi $\times$ 5 seed indipendenti, $\{42, 7, 123, 2024, 999\}$). La scelta della mediana come filtro e della media geometrica come criterio finale ha due motivazioni. La mediana (valore centrale di e_{30} sui 5 seed) è robusta ai fallimenti catastrofici: un solo seed divergente non deve squalificare una configurazione il cui caso tipico è buono, mentre la semplice conta delle vittorie ignorerebbe l'entità del

miglioramento e potrebbe premiare un metodo che vince di poco su quasi tutti i seed ma fallisce male sul quinto. Si noti anche che il numero di seed vinti può essere basso (anche 1/5) pur con mediana migliore, perché la mediana confronta i valori centrali, non le coppie seme per seme.

Configurazioni consigliate. La Tabella 6.8 riporta, per ciascun problema e algoritmo, la configurazione consigliata, la mediana di e_{30} su cinque seed della *base* e della configurazione consigliata, e il numero di seed su 5 in cui la configurazione consigliata migliora la *base*. Includendo la Funzione di Rosenbrock nella ricerca, le uniche configurazioni ammissibili restano lo stop adattivo ($P=1$, $f=1$, $p=10\%$, split fissa) per Newton-CG e il riuso $M=3$ per Newton-CG L_1 ; per Dynamic GD e BB-CCV nessuna configurazione testata migliora la mediana della *base* su tutti e cinque i problemi (sulla Funzione di Rosenbrock la base di Dynamic GD è già $\approx 6.1 \times 10^{-4}$ e ogni variante la peggiora, mentre BB-CCV è già alla precisione macchina sui problemi molto mal condizionati e ha mediana 5.6×10^{-9} sulla Funzione di Rosenbrock) e quindi la *base* resta la configurazione consigliata. Il totale di vittorie su 25 combinazioni problema $\times$ seed è Newton-CG 16/25 e Newton-CG L_1 16/25.

Tabella 6.8: Sintesi degli iperparametri consigliati per ciascun metodo: configurazione consigliata, mediana di e_{30} su 5 seed della *base* e della configurazione consigliata, e numero di seed su 5 in cui la configurazione consigliata migliora la *base*.

Problema	Algoritmo	Configurazione consigliata	e_{30} base	e_{30} consigliato	vitt. (su 5)
$\kappa \approx 1.1$	Dynamic GD	<i>base</i>	1.1894×10^{-1}	1.1894×10^{-1}	—
$\kappa \approx 1.1$	BB-CCV	<i>base</i>	1.1662×10^{-1}	1.1662×10^{-1}	—
$\kappa \approx 1.1$	Newton-CG	stop adattivo: $P=1$, $f=1$, $p=10\%$, split fissa	4.0264×10^{-1}	1.9672×10^{-1}	4/5
$\kappa \approx 1.1$	Newton-CG L_1	riuso $M=3$	1.0167×10^{-1}	1.0120×10^{-1}	3/5
$\kappa \approx 20$	Dynamic GD	<i>base</i>	4.9162×10^{-2}	4.9162×10^{-2}	—
$\kappa \approx 20$	BB-CCV	<i>base</i>	4.7042×10^{-6}	4.7042×10^{-6}	—
$\kappa \approx 20$	Newton-CG	stop adattivo: $P=1$, $f=1$, $p=10\%$, split fissa	1.9843×10^{-1}	1.9055×10^{-1}	1/5
$\kappa \approx 20$	Newton-CG L_1	riuso $M=3$	3.9053×10^{-1}	3.5440×10^{-1}	4/5
$\kappa \approx 100$	Dynamic GD	<i>base</i>	4.4759×10^{-1}	4.4759×10^{-1}	—
$\kappa \approx 100$	BB-CCV	<i>base</i>	6.2835×10^{-14}	6.2835×10^{-14}	—
$\kappa \approx 100$	Newton-CG	stop adattivo: $P=1$, $f=1$, $p=10\%$, split fissa	3.1584×10^{-1}	2.8048×10^{-1}	3/5
$\kappa \approx 100$	Newton-CG L_1	riuso $M=3$	9.6942×10^{-1}	8.7375×10^{-1}	5/5
incrociato ($\kappa \approx 1.67$)	Dynamic GD	<i>base</i>	1.0172×10^{-2}	1.0172×10^{-2}	—
incrociato ($\kappa \approx 1.67$)	BB-CCV	<i>base</i>	2.7237×10^{-4}	2.7237×10^{-4}	—
incrociato ($\kappa \approx 1.67$)	Newton-CG	stop adattivo: $P=1$, $f=1$, $p=10\%$, split fissa	3.4458×10^{-1}	1.0227×10^{-1}	5/5
incrociato ($\kappa \approx 1.67$)	Newton-CG L_1	riuso $M=3$	2.6752×10^{-2}	2.3645×10^{-2}	2/5
Funzione di Rosenbrock ($c=100$)	Dynamic GD	<i>base</i>	6.1354×10^{-4}	6.1354×10^{-4}	—
Funzione di Rosenbrock ($c=100$)	BB-CCV	<i>base</i>	5.6060×10^{-9}	5.6060×10^{-9}	—
Funzione di Rosenbrock ($c=100$)	Newton-CG	stop adattivo: $P=1$, $f=1$, $p=10\%$, split fissa	6.8152×10^{-1}	6.6176×10^{-1}	3/5
Funzione di Rosenbrock ($c=100$)	Newton-CG L_1	riuso $M=3$	2.0488×10^{-1}	1.7321×10^{-1}	2/5

Lettura. È la tabella operativa della sezione: per ognuna delle 20 combinazioni problema×algoritmo indica la configurazione consigliata, la mediana di e_{30} su 5 seed della base e della configurazione consigliata, e su quanti seed (su 5) la configurazione consigliata batte la base. Regola d'insieme: *base* per Dynamic GD e BB-CCV (nessuna variante migliora la mediana su tutti i problemi, in particolare sulla Funzione di Rosenbrock), stop adattivo ($P=1$, $f=1$, $p=10\%$, split fissa) per Newton-CG e riuso $M=3$ per Newton-CG L_1 ; con queste scelte nessun metodo peggiora la mediana della base su nessuno dei cinque problemi.

7 Conclusioni e Lavoro Futuro

7.1 Riassunto dei risultati

In questo lavoro abbiamo studiato la selezione dinamica della dimensione del campione negli algoritmi di ottimizzazione per il machine learning su larga scala, seguendo l'approccio di Byrd, Chin, Nocedal e Wu [1]. I risultati principali sono i seguenti.

In primo luogo, abbiamo sviluppato un'analisi teorica completa del metodo del gradiente a campione dinamico. Abbiamo mostrato che, se la varianza stimata del gradiente stocastico è controllata dalla tolleranza θ (Condizione di Controllo della Varianza), la direzione di ricerca è una direzione di discesa e l'algoritmo converge linearmente, sia in forma deterministica sia in aspettativa. La complessità totale, il numero di valutazioni di gradienti individuali necessarie per ottenere un errore ε , è $O(mL/(\lambda\varepsilon))$, un bound competitivo con quelli noti per SGD e significativamente migliore su problemi mal condizionati, dove il termine κ^2 di SGD diventa κ .

In secondo luogo, abbiamo analizzato e implementato il metodo di Newton-CG con sottocampionamento dell'Hessiana, nel quale due campioni distinti vengono usati per il gradiente e per l'Hessiana. Il criterio di arresto del gradiente coniugato interno è adattivo: il CG viene fermato quando il suo residuo è dello stesso ordine di grandezza dell'errore di approssimazione dell'Hessiana, stimato dalla varianza campionaria dei prodotti Hessiana-vettore. Questo evita iterazioni interne inutili e rende il metodo particolarmente efficace su problemi mal condizionati, come confermato dagli esperimenti del Capitolo 6.

In terzo luogo, abbiamo studiato il campionamento dinamico per i problemi con regolarizzazione L_1 , utilizzando il gradiente generalizzato, l'identificazione dell'active set e la ricerca lineare proiettata. Abbiamo infine realizzato un'applicazione web interattiva che implementa i quattro algoritmi e ne permette la sperimentazione visuale su funzioni obiettivo modificabili dall'utente.

7.2 Limiti dello studio

Lo studio presenta alcuni limiti che è importante esplicitare.

1. Ipotesi di convessità forte. L'analisi di convergenza richiede che J sia λ -fortemente convessa, un'ipotesi non sempre verificata nei problemi reali. Come discusso nel Capitolo 3, l'ipotesi può essere aggirata aggiungendo una regolarizzazione $\frac{\gamma}{2}\|w\|^2$, che induce convessità forte con $\lambda = \gamma$, ma introduce un bias nel problema.

2. Limitazione della varianza. L'analisi di complessità si basa sull'ipotesi di limitatezza globale della varianza (Eq. (5.4) nel Capitolo 5), che può non valere in problemi con perdite non limitate o con code pesanti. In pratica questa ipotesi può essere rilassata richiedendo la limitatezza solo in un intorno del minimo, ma le garanzie teoriche in tal caso sono più deboli.
3. Dataset sintetico centrato. L'implementazione interattiva usa un dataset sintetico "centrato", in cui la media campionaria dei gradienti individuali coincide esattamente con il gradiente della funzione obiettivo teorica $J(w)$. Nei problemi reali questa coincidenza vale solo asintoticamente (nel limite $N \rightarrow \infty$), e la varianza dei gradienti individuali ha una struttura più ricca di quella dei dati sintetici.

7.3 Direzioni per lavoro futuro

Dai limiti appena discussi emergono naturalmente alcune direzioni di lavoro futuro.

1. Rilassamento dell'ipotesi di convessità forte. Nella nostra analisi la condizione di Polyak–Łojasiewicz (PL) interviene solo come conseguenza della convessità forte: l'ipotesi $\nabla^2 J(w) \succeq \lambda I$ implica $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$ (Appendice A.1) e da questa disuguaglianza si ricava la convergenza lineare del Teorema di Convergenza Deterministica. Un primo obiettivo è quindi invertire il ruolo delle due ipotesi: assumere direttamente la condizione PL, $\|\nabla J(w)\|^2 \geq 2\mu J(w)$ con $\mu > 0$ (forma forte, come in [7, 8]), eliminando la richiesta di convessità forte. Poiché la convessità forte è un caso particolare della PL (basta prendere $\mu = \lambda$), la generalizzazione non comporta alcuna perdita di risultati: le dimostrazioni restano valide sostituendo λ con μ e sopprimendo il passaggio in cui la PL è dedotta dall'Hessiana. Il vantaggio è duplice: l'analisi copre una classe più ampia di funzioni, per le quali la PL garantisce comunque la convergenza lineare del valore di funzione pur senza richiedere la convessità (forte); e le dimostrazioni risultano più semplici, perché la PL diventa un'ipotesi di partenza invece di essere derivata.
2. Rapporto di sottocampionamento dell'Hessiana dinamico. Nel metodo Newton-CG il rapporto $R = |\mathcal{H}_k|/|\mathcal{S}_k|$ tra la dimensione del campione per l'Hessiana e quella per il gradiente è attualmente fisso. Un'estensione naturale è rendere dinamico anche questo rapporto, ad esempio aumentandolo quando la curvatura del problema cambia rapidamente o quando il criterio di arresto del CG richiede troppe iterazioni interne, bilanciando il costo dei prodotti Hessiana-vettore con la qualità della direzione di Newton.
3. Confronto sistematico con GD, SGD, SVRG e SAGA. Gli esperimenti del Capitolo 6 confrontano i quattro metodi a campionamento dinamico tra loro e, sul piano teorico, con i bound di complessità di SGD, ma non includono un confronto empirico diretto con i metodi stocastici classici del Capitolo 4, in particolare GD, SGD e i metodi a varianza ridotta SVRG [9] e SAGA [10]. Una direzione naturale è implementarli nella stessa piattaforma (Pyodide/NumPy) dell'applicazione web di questa tesi, per misurarli nelle identiche condizioni sperimentali e confrontarli con il campionamento dinamico in termini di costo computazionale totale, numero di valutazioni di gradienti individuali $\nabla \ell(w; i)$ oppure tempo di esecuzione, anziché a parità di iterazioni, che non riflette il lavoro effettivo e favorirebbe i metodi dal costo per iterazione più basso.

A Dimostrazioni

A.1 Dimostrazione delle disuguaglianze di Polyak–Łojasiewicz

Sia w_* l'unico minimo di J e, per semplificare le notazioni, poniamo $J(w_*) = 0$. Allora con le ipotesi strutturali esplicitate sopra valgono le seguenti disuguaglianze:

$$\|\nabla J(w)\|_2^2 \geq 2\lambda J(w), \quad J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|_2^2.$$

Come prima cosa cerchiamo una rappresentazione integrale esatta di $J(w)$: per ottenere una formula che coinvolga esplicitamente l'Hessiana, applichiamo il Teorema Fondamentale del Calcolo due volte.

Prima applicazione: definiamo $\varphi(t) = J(w_* + t(w - w_*))$ per $t \in [0, 1]$. Allora $\varphi(0) = J(w_*) = 0$, $\varphi(1) = J(w)$, e $\varphi'(t) = \nabla J(w_* + t(w - w_*))^T(w - w_*)$. Per il TFC:

$$J(w) = \underbrace{J(w_*)}_{\varphi(0)=0} + \int_0^1 \nabla J(w_* + t(w - w_*))^T(w - w_*) dt. \quad (\text{A.1})$$

Seconda applicazione: applichiamo ora il TFC alla funzione $\psi(t) = \nabla J(w_* + t(w - w_*))$. Si ha $\psi(0) = \nabla J(w_*) = 0$, $\psi(1) = \nabla J(w)$, e $\psi'(t) = \nabla^2 J(w_* + t(w - w_*))(w - w_*)$. Quindi per ogni $t \in [0, 1]$:

$$\nabla J(w_* + t(w - w_*)) = \int_0^t \nabla^2 J(w_* + s(w - w_*))(w - w_*) ds. \quad (\text{A.2})$$

Sostituiamo (A.2) nella (A.1):

$$J(w) = \int_0^1 \left(\int_0^t \nabla^2 J(w_* + s(w - w_*))(w - w_*) ds \right)^T (w - w_*) dt.$$

Poiché $(w - w_*)$ è costante rispetto agli integrali, possiamo riscrivere:

$$J(w) = \int_0^1 \int_0^t (w - w_*)^T \nabla^2 J(w_* + s(w - w_*))(w - w_*) ds dt.$$

La regione di integrazione è $0 \leq s \leq t \leq 1$, che è equivalente a $0 \leq s \leq 1$, $s \leq t \leq 1$. Scambiando l'ordine di integrazione:

$$J(w) = \int_0^1 \int_s^1 (w - w_*)^T \nabla^2 J(w_* + s(w - w_*))(w - w_*) dt ds.$$

L'integrale interno in dt vale $\int_s^1 dt = 1 - s$. Quindi otteniamo la formula finale:

$$J(w) = \int_0^1 (1 - t)(w - w_*)^T \nabla^2 J(w_* + t(w - w_*))(w - w_*) dt. \quad (\text{A.3})$$

Si consideri ora la derivazione della disuguaglianza $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$. Scriviamo la rappresentazione integrale di $J(y)$ a partire da $J(w)$:

$$J(y) = J(w) + \int_0^1 \nabla J(w + t(y - w))^T(y - w) dt. \quad (\text{A.4})$$

Applicando nuovamente il TFC al gradiente:

$$\nabla J(w + t(y - w)) = \nabla J(w) + \int_0^t \nabla^2 J(w + s(y - w))(y - w) ds. \quad (\text{A.5})$$

Sostituendo (A.5) in (A.4):

$$J(y) = J(w) + \nabla J(w)^T(y - w) + \int_0^1 \int_0^t (y - w)^T \nabla^2 J(w + s(y - w))(y - w) ds dt.$$

Dalla convessità forte $\nabla^2 J \succeq \lambda I$, l'integrale doppio è maggiorato dal basso da:

$$\lambda \|y - w\|^2 \int_0^1 \int_0^t 1 ds dt = \frac{\lambda}{2} \|y - w\|^2.$$

Pertanto:

$$J(y) \geq J(w) + \nabla J(w)^T(y - w) + \frac{\lambda}{2} \|y - w\|^2. \quad (\text{A.6})$$

Minimizzando il membro destro rispetto a y si ottiene:

$$\min_y \left[J(w) + \nabla J(w)^T(y - w) + \frac{\lambda}{2} \|y - w\|^2 \right] = J(w) - \frac{1}{2\lambda} \|\nabla J(w)\|^2.$$

Dalla (A.6) segue che $J(y)$ è sempre maggiore o uguale al termine quadratico in y ; quindi il minimo di J sarà maggiore o uguale al minimo di tale termine. Poiché $y = w_*$ è il minimo di J e $J(w_*) = 0$, si ha:

$$0 = J(w_*) \geq J(w) - \frac{1}{2\lambda} \|\nabla J(w)\|^2,$$

da cui la tesi $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$.

Si consideri ora la derivazione della disuguaglianza $J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|^2$. Dalla rappresentazione integrale del gradiente che si ottiene valutando la (A.2) in $t = 1$:

$$\nabla J(w) = \int_0^1 \nabla^2 J(w_* + t(w - w_*))(w - w_*) dt. \quad (\text{A.7})$$

Passando alla norma:

$$\|\nabla J(w)\| = \left\| \int_0^1 \nabla^2 J(w_* + t(w - w_*))(w - w_*) dt \right\|.$$

Per la disuguaglianza triangolare in forma integrale:

$$\|\nabla J(w)\| \leq \int_0^1 \|\nabla^2 J(w_* + t(w - w_*))(w - w_*)\| dt.$$

Usando la limitatezza $\|\nabla^2 J\| \leq L$, si ha:

$$\|\nabla J(w)\| \leq \int_0^1 L \|w - w_*\| dt = L \|w - w_*\|. \quad (\text{A.8})$$

Da cui:

$$\|\nabla J(w)\| \leq L \|w - w_*\| \implies \|w - w_*\| \geq \frac{1}{L} \|\nabla J(w)\|. \quad (\text{A.9})$$

Elevando al quadrato (A.9):

$$\|w - w_*\|^2 \geq \frac{1}{L^2} \|\nabla J(w)\|^2. \quad (\text{A.10})$$

Dalla (A.3) invece:

$$J(w) = \int_0^1 (1-t) (w - w_*)^T \nabla^2 J(w_* + t(w - w_*)) (w - w_*) dt.$$

Usando la convessità forte $\nabla^2 J \succeq \lambda I$:

$$J(w) \geq \|w - w_*\|^2 \lambda \int_0^1 (1-t) dt.$$

L'integrale vale:

$$\int_0^1 (1-t) dt = \left[t - \frac{t^2}{2} \right]_0^1 = \frac{1}{2}.$$

Quindi:

$$J(w) \geq \frac{\lambda}{2} \|w - w_*\|^2. \quad (\text{A.11})$$

Combinando (A.10) e (A.11):

$$J(w) \geq \frac{\lambda}{2} \|w - w_*\|^2 \geq \frac{\lambda}{2} \cdot \frac{1}{L^2} \|\nabla J(w)\|^2 = \frac{\lambda}{2L^2} \|\nabla J(w)\|^2.$$

Questa è la seconda disuguaglianza cercata.

Con passaggi simili a quelli che sono stati fatti per dimostrare la (A.6) possiamo verificare che applicando il teorema di Taylor con resto integrale e usando $\nabla^2 J \preceq LI$ otteniamo

$$J(y) \leq J(w) + \nabla J(w)^T (y - w) + \frac{L}{2} \|y - w\|^2. \quad (\text{A.12})$$

A.2 Dimostrazione del fattore di correzione per popolazione finita

Il fattore $\frac{N-n_k}{N-1}$ è il Fattore di Correzione per Popolazione Finita. Per dimostrare formalmente il motivo per cui moltiplichiamo per questo fattore nel caso in cui accettassimo la possibilità di prendere più volte gli stessi dati nei batch possiamo prima dimostrare la necessità di questo fattore nel caso generale e poi applicarlo al nostro caso specifico: Consideriamo $\bar{X} = \frac{1}{n} \sum_{i \in \mathcal{S}} X_i = \frac{1}{n} \sum_{i=1}^N I_i X_i$ con

$$I_i = \begin{cases} 1 & \text{se } X_i \in \mathcal{S} \\ 0 & \text{se } X_i \notin \mathcal{S} \end{cases} \implies \begin{cases} \mathbb{E}[I_i] = \frac{n}{N}, & \mathbb{E}[I_i I_\ell] = \frac{n(n-1)}{N(N-1)} \\ \text{Var}(I_i) = \frac{n(N-n)}{N^2}, & \text{Cov}(I_i, I_\ell) = -\frac{n(N-n)}{N^2(N-1)} \end{cases}$$

$$\text{Var} \left(\sum_{i \in \mathcal{S}} X_i \right) = \sum_{i=1}^N X_i^2 \text{Var}(I_i) + \sum_{\substack{i, \ell \in \{1, \dots, N\} \\ i \neq \ell}} X_i X_\ell \text{Cov}(I_i, I_\ell)$$

Per verificarlo, basta espandere la definizione di varianza applicata alla combinazione lineare $\sum_{i=1}^N X_i I_i$: si scrive

$$\text{Var} \left(\sum_{i=1}^N X_i I_i \right) = \mathbb{E} \left[\left(\sum_{i=1}^N X_i (I_i - \mathbb{E}[I_i]) \right)^2 \right],$$

si sviluppa il quadrato della somma usando l'identità

$$\left(\sum_{i=1}^N a_i \right)^2 = \sum_{i=1}^N a_i^2 + \sum_{i \neq \ell} a_i a_\ell, \quad a_i = X_i (I_i - \mathbb{E}[I_i]),$$

che servirà anche in seguito. Essa è vera perché la doppia somma estesa a tutte le coppie, $\sum_i \sum_\ell a_i a_\ell$, coincide con il quadrato della somma $(\sum_i a_i)^2$, e quindi

$$\sum_i \sum_\ell a_i a_\ell = \sum_i a_i^2 + \sum_{i \neq \ell} a_i a_\ell \iff \sum_{i \neq \ell} a_i a_\ell = \left(\sum_i a_i \right)^2 - \sum_i a_i^2.$$

A questo punto si applica la linearità dell'aspettazione e si riconoscono le formule per la varianza e covarianza di I

$$\begin{aligned} &= \frac{n(N-n)}{N^2} \sum_{i=1}^N X_i^2 - \frac{n(N-n)}{N^2(N-1)} \sum_{i \neq \ell} X_i X_\ell \\ &= \frac{n(N-n)}{N^2} \left[\sum_{i=1}^N X_i^2 - \frac{1}{N-1} \sum_{i \neq \ell} X_i X_\ell \right] \\ &\quad \sum_{i=1}^N X_i = N\mu \\ &\quad \sum_{i=1}^N X_i^2 = N(\mu^2 + \sigma^2) \end{aligned}$$

Infatti $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2 \iff N\sigma^2 = \sum_{i=1}^N (X_i^2 - 2\mu X_i + \mu^2) \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - 2\mu \sum_{i=1}^N X_i + N\mu^2 \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - 2\mu(N\mu) + N\mu^2 \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - 2N\mu^2 + N\mu^2 \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - N\mu^2 \iff \sum_{i=1}^N X_i^2 = N\sigma^2 + N\mu^2 = N(\mu^2 + \sigma^2)$

$$\sum_{i \neq \ell} X_i X_\ell = \left(\sum_{i=1}^N X_i \right)^2 - \sum_{i=1}^N X_i^2 = N^2 \mu^2 - N(\mu^2 + \sigma^2)$$

$$\sum_{i=1}^N X_i^2 - \frac{1}{N-1} \sum_{i \neq \ell} X_i X_\ell = N(\mu^2 + \sigma^2) - \frac{1}{N-1} [N^2 \mu^2 - N(\mu^2 + \sigma^2)]$$

$$= N(\mu^2 + \sigma^2) - \frac{N^2 \mu^2}{N-1} + \frac{N(\mu^2 + \sigma^2)}{N-1}$$

$$= N(\mu^2 + \sigma^2) \left(1 + \frac{1}{N-1} \right) - \frac{N^2 \mu^2}{N-1} = N(\mu^2 + \sigma^2) \frac{N}{N-1} - \frac{N^2 \mu^2}{N-1}$$

$$= \frac{N^2(\mu^2 + \sigma^2)}{N-1} - \frac{N^2 \mu^2}{N-1} = \frac{N^2 \sigma^2}{N-1} = N\sigma^2 \frac{N}{N-1}$$

$$\text{Var} \left(\sum_{i \in \mathcal{S}} X_i \right) = \frac{n(N-n)}{N^2} \cdot N\sigma^2 \frac{N}{N-1} = \frac{n(N-n)}{N-1} \sigma^2$$

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \text{Var} \left(\sum_{i \in \mathcal{S}} X_i \right) = \frac{1}{n^2} \cdot \frac{n(N-n)}{N-1} \sigma^2 = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}$$

Nella dimostrazione generale con le variabili X_i , poniamo:

- $X_i \longleftrightarrow \nabla \ell(w_k; i)$ (gradiente della funzione di perdita sull'esempio i -esimo, valutato in w_k)
- $\mu \longleftrightarrow \nabla J(w_k) = \mathbb{E}_{i \sim \text{Unif}\{1, \dots, N\}} [\nabla \ell(w_k; i)] = \frac{1}{N} \sum_{i=1}^N \nabla \ell(w_k; i)$
- $\sigma^2 \longleftrightarrow \mathcal{V}_j(w_k)$ per ogni $j = 1, \dots, m$, dove

$$\mathcal{V}(w_k) := \frac{1}{N} \sum_{i=1}^N (\nabla \ell(w_k; i) - \nabla J(w_k))^2 \in \mathbb{R}^m$$

è la versione vettoriale di σ^2 nel caso multidimensionale.

Applicando la formula generale $\text{Var}(\bar{X}) = \frac{\mathcal{V}}{n_k} \cdot \frac{N-n_k}{N-1}$ a ogni componente $j = 1, \dots, m$:

$$\text{Var}(\nabla J_{\mathcal{S}_k}(w_k)) = \frac{\mathcal{V}(w_k)}{n_k} \cdot \frac{N-n_k}{N-1}$$

e quindi, in norma $\|\cdot\|_1$:

$$\|\text{Var}(\nabla J_{\mathcal{S}_k}(w_k))\|_1 = \frac{\|\mathcal{V}(w_k)\|_1}{n_k} \cdot \frac{N - n_k}{N - 1}.$$

Poiché $\mathcal{V}(w_k)$ è ignoto, lo stimiamo con la varianza campionaria

$$\widehat{\mathcal{V}}(w_k) := \frac{1}{n_k - 1} \sum_{i \in \mathcal{S}_k} (\nabla \ell(w_k; i) - \nabla J_{\mathcal{S}_k}(w_k))^2,$$

ottenendo la condizione di controllo della varianza:

$$\frac{\|\widehat{\mathcal{V}}\|_1}{n_k} \cdot \frac{N - n_k}{N - 1} \leq \theta^2 \|\nabla J_{\mathcal{S}_k}(w_k)\|^2.$$

A.3 Dimostrazione delle formule per α_k e β_k nel Metodo del Gradiente Coniugato

Consideriamo il funzionale quadratico

$$\phi(x) = \frac{1}{2}x^T A x - b^T x, \quad A = A^T > 0. \quad (\text{A.13})$$

Sia x^* il minimo, soluzione di $Ax^* = b$. Definiamo

$$\begin{cases} e^k = x^* - x^k, \\ r^k = b - Ax^k, \end{cases} \quad \xRightarrow{Ax^* = b} \quad r^k = Ae^k. \quad (\text{A.14})$$

L'aggiornamento del metodo è

$$\begin{cases} x^{k+1} = x^k + \alpha_k p^k, \\ p^k = r^k + \beta_k p^{k-1}, \quad p^0 = r^0 \end{cases} \quad (\text{A.15})$$

da cui, per la definizione di e^k ,

$$e^{k+1} = e^k - \alpha_k p^k. \quad (\text{A.16})$$

Il metodo minimizza $\|e^{k+1}\|_A^2$ nel piano $e^k + \text{span}(p^k, p^{k-1})$. Definiamo

$$F(\alpha, \gamma) = \|e^k + \alpha p^k + \gamma p^{k-1}\|_A^2. \quad (\text{A.17})$$

Poiché $\|z\|_A^2 = z^T A z$, con $z = e^k + \alpha p^k + \gamma p^{k-1}$:

$$\begin{aligned} F(\alpha, \gamma) &= (e^k + \alpha p^k + \gamma p^{k-1})^T A (e^k + \alpha p^k + \gamma p^{k-1}) \\ &= \|e^k\|_A^2 + 2\alpha(e^k)^T A p^k + 2\gamma(e^k)^T A p^{k-1} \\ &\quad + \alpha^2 \|p^k\|_A^2 + 2\alpha\gamma(p^k)^T A p^{k-1} + \gamma^2 \|p^{k-1}\|_A^2. \end{aligned} \quad (\text{A.18})$$

Annullando le derivate parziali:

$$\begin{cases} (e^k)^T A p^k + \alpha \|p^k\|_A^2 + \gamma (p^k)^T A p^{k-1} = 0, \\ (e^k)^T A p^{k-1} + \alpha (p^k)^T A p^{k-1} + \gamma \|p^{k-1}\|_A^2 = 0. \end{cases} \quad (\text{A.19})$$

Per la scelta di α_{k-1} (minimo lungo p^{k-1}):

$$\frac{d}{d\alpha} \phi(x^{k-1} + \alpha p^{k-1}) \Big|_{\alpha=\alpha_{k-1}} = 0 \implies \nabla \phi(x^k)^T p^{k-1} = 0 \implies (r^k)^T p^{k-1} = 0. \quad (\text{A.20})$$

Usando $r^k = Ae^k$ e la simmetria di A :

$$(e^k)^T A p^{k-1} = (Ae^k)^T p^{k-1} = (r^k)^T p^{k-1} = 0. \quad (\text{A.21})$$

Si noti l'ordine logico della deduzione: si applica prima la (A.21) alla seconda equazione del sistema (A.19) il termine $(e^k)^T A p^{k-1}$ si annulla e si ottiene $\gamma \|p^{k-1}\|_A^2 = 0$, da cui $\gamma = 0$; la proprietà (A.23), cioè $(p^k)^T A p^{k-1} = 0$, segue poi come conseguenza della prima equazione.

La minimizzazione nel piano implica le condizioni di ortogonalità

$$e^{k+1} \perp_A p^k \quad \text{e} \quad e^{k+1} \perp_A p^{k-1}. \quad (\text{A.22})$$

Dalla seconda, con $e^{k+1} = e^k - \alpha_k p^k$ e (A.21):

$$(e^k - \alpha_k p^k)^T A p^{k-1} = 0 \implies -\alpha_k (p^k)^T A p^{k-1} = 0 \xrightarrow{\alpha_k \neq 0} (p^k)^T A p^{k-1} = 0. \quad (\text{A.23})$$

Sfruttando (A.21) e (A.23) nel sistema (A.19):

$$\begin{cases} (e^k)^T A p^k + \alpha \|p^k\|_A^2 = 0, \\ \gamma \|p^{k-1}\|_A^2 = 0, \end{cases} \implies \gamma = 0, \quad \alpha = -\frac{(e^k)^T A p^k}{\|p^k\|_A^2}. \quad (\text{A.24})$$

Ora, $(e^k)^T A p^k = (r^k)^T p^k$ e da (A.20) $r^k \perp p^{k-1}$; quindi

$$(r^k)^T p^k = (r^k)^T (r^k + \beta_k p^{k-1}) = \|r^k\|^2. \quad (\text{A.25})$$

Pertanto

$$\alpha_k = \frac{\|r^k\|^2}{\|p^k\|_A^2} = \frac{(r^k)^T r^k}{(p^k)^T A p^k}. \quad (\text{A.26})$$

Per β_k , da (A.23) e $p^k = r^k + \beta_k p^{k-1}$:

$$(r^k + \beta_k p^{k-1})^T A p^{k-1} = 0 \implies \beta_k = -\frac{(r^k)^T A p^{k-1}}{(p^{k-1})^T A p^{k-1}}. \quad (\text{A.27})$$

Dall'aggiornamento del residuo:

$$r^k = r^{k-1} - \alpha_{k-1} A p^{k-1} \implies A p^{k-1} = \frac{r^{k-1} - r^k}{\alpha_{k-1}}. \quad (\text{A.28})$$

Al numeratore di (A.27):

$$(r^k)^T A p^{k-1} = \frac{(r^k)^T r^{k-1} - (r^k)^T r^k}{\alpha_{k-1}} \stackrel{(r^k)^T r^{k-1}=0}{=} -\frac{(r^k)^T r^k}{\alpha_{k-1}}. \quad (\text{A.29})$$

Dimostrazione di $(r^k)^T r^{k-1} = 0$: Mostriamo per induzione che $r^k \perp p^j$ per $j \leq k-1$.

- Base: $k=1$, (A.20) dà $r^1 \perp p^0$.
- Passo: supponiamo $r^{k-1} \perp p^j$ per $j \leq k-2$. Per $r^k = r^{k-1} - \alpha_{k-1} A p^{k-1}$ e $j \leq k-2$:

$$(r^k)^T p^j = (r^{k-1})^T p^j - \alpha_{k-1} (p^{k-1})^T A p^j = 0.$$

Inoltre (A.20) dà $(r^k)^T p^{k-1} = 0$. Quindi $r^k \perp p^j$ per $j \leq k-1$.

In particolare $r^k \perp p^{k-2}$. Da $p^{k-1} = r^{k-1} + \beta_{k-1} p^{k-2}$:

$$0 = (r^k)^T p^{k-1} = (r^k)^T r^{k-1} + \beta_{k-1} (r^k)^T p^{k-2} \implies (r^k)^T r^{k-1} = 0. \quad (\text{A.30})$$

Al denominatore di (A.27), usando (A.26) per $k-1$:

$$(p^{k-1})^T A p^{k-1} = \frac{(r^{k-1})^T r^{k-1}}{\alpha_{k-1}}. \quad (\text{A.31})$$

Sostituendo (A.29) e (A.31) in (A.27):

$$\beta_k = -\frac{-\frac{(r^k)^T r^k}{\alpha_{k-1}}}{\frac{(r^{k-1})^T r^{k-1}}{\alpha_{k-1}}} = \frac{(r^k)^T r^k}{(r^{k-1})^T r^{k-1}}. \quad (\text{A.32})$$

Abbiamo quindi dimostrato che le condizioni di ortogonalità (A.22) portano a:

$$\alpha_k = \frac{(r^k)^T r^k}{(p^k)^T A p^k}, \quad \beta_k = \frac{(r^k)^T r^k}{(r^{k-1})^T r^{k-1}} \quad (\text{A.33})$$

con

$$p^k = r^k + \beta_k p^{k-1}, \quad x^{k+1} = x^k + \alpha_k p^k. \quad (\text{A.34})$$

Equivalenza delle formule per α_k . Nel documento (Nota Tecnica) si afferma che le formule $\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}$ e $\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$ sono equivalenti. Dimostriamo questa equivalenza.

Prendendo la condizione di stazionarietà (A.20), ovvero $(r^k)^T p^{k-1} = 0$, e sostituendo l'aggiornamento del residuo (A.28), $r^k = r^{k-1} - \alpha_{k-1} A p^{k-1}$, si ottiene:

$$\begin{aligned} 0 &= (r^k)^T p^{k-1} = (r^{k-1} - \alpha_{k-1} A p^{k-1})^T p^{k-1} = (r^{k-1})^T p^{k-1} - \alpha_{k-1} (p^{k-1})^T A p^{k-1} \\ &\implies (r^{k-1})^T p^{k-1} - \alpha_{k-1} (p^{k-1})^T A p^{k-1} = 0. \end{aligned} \quad (\text{A.35})$$

Ora, l'aggiornamento del residuo nel metodo del gradiente coniugato è:

$$r_k = r_{k-1} - \alpha_{k-1} A p_{k-1}. \quad (\text{A.36})$$

Moltiplichiamo scalarmente la (A.36) per p_{k-1} :

$$r_k^T p_{k-1} = r_{k-1}^T p_{k-1} - \alpha_{k-1} p_{k-1}^T A p_{k-1}.$$

Ma il membro destro è esattamente zero per la (A.35). Quindi:

$$r_k^T p_{k-1} = 0. \quad (\text{A.37})$$

Questo risultato è valido per ogni $k \geq 1$ e deriva unicamente dalla line search esatta al passo precedente.

Ora, nella direzione di ricerca del gradiente coniugato si ha:

$$p_k = r_k + \beta_k p_{k-1}. \quad (\text{A.38})$$

Moltiplichiamo scalarmente la (A.38) per r_k :

$$r_k^T p_k = r_k^T r_k + \beta_k r_k^T p_{k-1}.$$

Usando la (A.37), il secondo termine si annulla:

$$r_k^T p_k = r_k^T r_k. \quad (\text{A.39})$$

Sostituendo la (A.39) nella formula $\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}$, otteniamo:

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}. \quad (\text{A.40})$$

Abbiamo quindi dimostrato che:

$$\frac{r_k^T p_k}{p_k^T A p_k} = \frac{r_k^T r_k}{p_k^T A p_k}.$$

Le due formule per α_k sono quindi equivalenti. La formula con $r_k^T r_k$ è preferita nelle implementazioni numeriche perché è numericamente più stabile, poiché non dipende dall'ortogonalità numerica di $r_k^T p_{k-1}$, che in presenza di errori di arrotondamento non è esattamente zero.

A.4 Spiegazione delle condizioni sul passo α_k

La condizione di Armijo introduce un limite superiore per il valore della funzione lungo la direzione di ricerca: il passo α è accettato se $f(x_k + \alpha p)$ si trova al di sotto della retta $f(x_k) + c_1 \alpha \nabla f(x_k)^T p$, e rifiutato altrimenti. La condizione di curvatura di Wolfe impone invece un limite inferiore per la derivata $f'(\alpha)$ lungo la direzione.

La condizione di Armijo richiede che

$$f(x_k + \alpha p) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p,$$

con $c_1 \in (0, 1)$ (tipicamente 10^{-4}). La retta al membro destro ha pendenza $c_1 \nabla f(x_k)^T p$, meno ripida della tangente in $\alpha = 0$, e funge da upper bound: passi che fanno superare questa retta vengono rifiutati e ridotti. Più c_1 è piccolo, più la condizione è debole e più passi grandi sono accettati.

La condizione di curvatura di Wolfe, con $g(\alpha) = f(x_k + \alpha p)$ e $g'(\alpha) = \nabla f(x_k + \alpha p)^T p$, richiede

$$g'(\alpha) \geq c_2 g'(0), \quad c_2 \in (c_1, 1),$$

dove $g'(0) = \nabla f(x_k)^T p < 0$. Poiché $c_2 < 1$, $c_2 g'(0)$ è meno negativo di $g'(0)$: la condizione è un lower bound sulla derivata, che scarta i passi troppo piccoli (per $\alpha \rightarrow 0^+$, $g'(\alpha) \rightarrow g'(0)$, che non soddisfa la disuguaglianza).

La condizione $0 < c_1 < c_2 < 1$ garantisce che le due disuguaglianze siano compatibili: Armijo (limite superiore su f) e Wolfe (limite inferiore su g') definiscono un intervallo non vuoto di α accettabili. Se $c_1 \geq c_2$, le due condizioni possono diventare contraddittorie. In sintesi, Armijo impedisce passi troppo grandi, Wolfe impedisce passi troppo piccoli.

B Codici Python completi

In questa appendice sono riportati i codici Python completi dei quattro algoritmi discussi nel Capitolo 5 e implementati nell'applicazione interattiva (Capitolo 6). I codici fanno riferimento alle seguenti funzioni ausiliarie, definite dall'utente e dipendenti dal dataset:

- `loss_i(w, i)`: perdita individuale $\ell(w; i)$,
- `grad_i(w, i)`: gradiente individuale $\nabla \ell(w; i)$,
- `hessvec_i(w, i, v)`: prodotto $\nabla^2 \ell(w; i) v$,
- `grad_full(w)`: gradiente esatto $\nabla J(w)$ (usato solo per il criterio di arresto),
- N : dimensione del dataset.

B.1 Metodo del gradiente a campione dinamico

Dynamic GD

```
import numpy as np

def dynamic_gd(w0, theta, max_iter, alpha, batch0):
    w = np.array(w0, dtype=float)
    n = max(batch0, 2)
    history = [w.copy().tolist()]
    batch_sizes = [n]
```

Definisce una funzione che prende in input w_0 , θ , $\max_iter$, α , batch0 , poi inizializza il vettore dei pesi w_0 (dove $w_0 \in \mathbb{R}^d$, con d pari al numero di parametri del modello), imposta la dimensione del batch iniziale $n = n_0 = \max(\text{batch0}, 2)$ in modo che non possa essere minore di 2, e inizializza la lista ‘history’ (che conterrà i pesi w_k a ogni iterazione k) e ‘batch_sizes’ (che conterrà le corrispondenti dimensioni n_k di ogni batch).

Dynamic GD

```
#
for k in range(max_iter):
    indices = np.random.choice(N, size=n, replace=False)
```

Per ogni iterazione $k \in \{0, \dots, \max_iter\}$ crea una lista indices ovvero un campione casuale $\mathcal{S}_k = \{i_1, \dots, i_n\}$ di n indici distinti da $\{1, \dots, N\}$, estratto senza reinserimento (ovvero uniforme tra tutti i $\binom{N}{n}$ possibili sottoinsiemi). N è definito come il numero di esempi totali, nel codice Python, per questioni di indicizzazione, l'insieme è $\{0, \dots, N-1\}$.

Dynamic GD

```
#
grads = np.array([grad_i(w, i) for i in indices])
g = np.mean(grads, axis=0)
```

grads colleziona un insieme di gradienti di loss su tanti esempi diversi (uno per ogni indice) quindi g è l'approssimazione che viene fatta del gradiente della loss usando il batch. Matematicamente grads è una lista di $\nabla \ell(w_k; i)$ per ogni indice i con cui si costruisce il batch mentre $g = g_k = \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i)$, dove $n_k = |\mathcal{S}_k|$ è la dimensione del batch corrente.

Dynamic GD

```
#
if n > 1:
    var_vec = np.var(grads, axis=0, ddof=1)
else:
    var_vec = np.zeros_like(g)
```

```

V_norm1 = np.sum(var_vec)

gg = np.dot(g, g)
if gg > 1e-16:
    if V_norm1 / n > theta**2 * gg:
        n_new = int(np.ceil(V_norm1 / (theta**2 * gg))) + 1
        n = min(n_new, N)

```

Matematicamente, `var_vec` è un vettore che calcola la varianza campionaria di ogni componente del gradiente sui dati del batch: $\hat{\mathcal{V}} := \text{Var}_{i \in \mathcal{S}_k}(\nabla \ell(w_k; i)) = \frac{1}{n_k - 1} \sum_{i \in \mathcal{S}_k} (\nabla \ell(w_k; i) - g_k)^2 \in \mathbb{R}^d$, dove $g_k = \nabla J_{\mathcal{S}_k}(w_k)$ come già definito. Poi `V_norm1` ne prende la norma L_1 : $\|\hat{\mathcal{V}}\|_1 = \sum_{j=1}^d [\hat{\mathcal{V}}]_j$. Questa quantità viene confrontata con $\theta^2 \|g_k\|_2^2$ per decidere se aumentare il batch, quindi se la CCV è soddisfatta allora la dimensione del batch viene aumentata come descritto dalla regola di aggiornamento del batch. Se $n = 1$ (mai vero, il controllo è superfluo) la varianza campionaria non è definita (divisione per 0), quindi si pone $\hat{\mathcal{V}} = 0$

Dynamic GD

```

#
def J_batch(w_curr):
    return np.mean([loss_i(w_curr, i) for i in indices])

c1 = 1e-4
step = alpha
J_curr = J_batch(w)
g_norm2 = np.dot(g, g)

```

Definisce la funzione di perdita sul batch corrente $J_batch = J_{\mathcal{S}_k}(w) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \ell(w; i)$, definisce lo `step` che viene inizializzato come `alpha`, definisce la variabile `J_curr` chiamando la funzione `J_batch` sui parametri `w` e definisce `g_norm2` come $g_k^T g_k = \|g_k\|_2^2$

Dynamic GD

```

#
def J_batch(w_curr):
    return np.mean([loss_i(w_curr, i) for i in indices])

# Line search Wolfe
c1, c2 = 1e-4, 0.9
step = alpha
J_curr = J_batch(w)
g_norm2 = np.dot(g, g)
d = -g
gd = -g_norm2
if g_norm2 > 1e-16:
    for _ in range(30):
        w_new = w + step * d

```

```

        if J_batch(w_new) <= J_curr + c1 * step * gd:
            g_new = np.mean([grad_i(w_new, i) for i in
                             indices], axis=0)
            if np.dot(g_new, d) >= c2 * gd:
                break
            step *= 0.5
        else:
            step = 0.0

    w = w + step * d

```

Si definisce la funzione di perdita sul batch corrente $J_{\mathcal{S}_k}(w)$. La direzione di ricerca è fissata come $d_k = -g_k$ e il prodotto scalare $g_k^\top d_k = -\|g_k\|_2^2$ misura la pendenza iniziale lungo tale direzione. Se il gradiente non è trascurabile ($\|g_k\|_2^2 > 10^{-16}$), si esegue una line search con backtracking che richiede le condizioni di Wolfe. $J_{\mathcal{S}_k}(w_k + \alpha_k d_k) \leq J_{\mathcal{S}_k}(w_k) + c_1 \alpha_k g_k^\top d_k$ con $c_1 = 10^{-4}$. Se questa è soddisfatta, si calcola il gradiente nel punto di prova sullo stesso batch e si verifica la seconda condizione (curvatura): il gradiente nel nuovo punto deve essere meno negativo lungo d_k , ovvero $\nabla J_{\mathcal{S}_k}(w_k + \alpha_k d_k)^\top d_k \geq c_2 g_k^\top d_k$ con $c_2 = 0.9$. Se una delle due condizioni fallisce, il passo viene dimezzato. Dopo al più 30 tentativi, se nessuno step è accettabile si pone $\alpha_k = 0$. Infine si aggiorna $w_{k+1} = w_k + \alpha_k d_k$.

Dynamic GD

```

if np.linalg.norm(grad_full(w)) < 1e-6:
    history.append(w.copy().tolist())
    batch_sizes.append(n)
    break

history.append(w.copy().tolist())
batch_sizes.append(n)

return history, batch_sizes

history, batch_sizes = dynamic_gd(w0, theta, max_iter, alpha, batch0)

```

Infine, si controlla la norma del gradiente esatto (calcolato su tutti i dati) tramite `grad_full(w)`: se $\|\nabla J(w_k)\|_2 < 10^{-6}$, si considera raggiunta la convergenza e si interrompe il ciclo, registrando l'ultimo punto. Altrimenti, si continua registrando la storia dei pesi e delle dimensioni del batch. Al termine, la funzione restituisce le liste `history` (contenente i pesi w_k a ogni iterazione) e `batch_sizes` (contenente le corrispondenti dimensioni n_k del batch).

B.2 Newton-CG con campionamento dinamico

Newton-CG

```
import numpy as np

def cg(A, b, gamma, maxcg):
    x = np.zeros_like(b)
    r = b - A(x)
    p = r.copy()
    rr = np.dot(r, r)
    for _ in range(maxcg):
        Ap = A(p)
        pHp = np.dot(p, Ap)
        if pHp <= 1e-14:
            break
        alpha = rr / pHp
        x = x + alpha * p
        r_new = r - alpha * Ap
        rr_new = np.dot(r_new, r_new)
        if rr_new <= gamma * np.dot(x, x) + 1e-16:
            return x
        beta = rr_new / rr
        p = r_new + beta * p
        r = r_new
        rr = rr_new
    return x
```

La funzione `cg` risolve $Ax = b$ con il metodo del gradiente coniugato, dove A è l'operatore Hessiana-vettore. Parte da $x_0 = 0$, residuo $r_0 = b$ e direzione $p_0 = r_0$. Ad ogni iterazione calcola Ap , la curvatura $pHp = p^T Ap$ (se troppo piccola, si ferma), aggiorna con $\alpha = rr/pHp$ e il residuo. Il test di arresto

$$\|r_{\text{new}}\|^2 \leq \gamma \|x\|^2 + 10^{-16}$$

è descritto nel paragrafo “Criterio di terminazione del gradiente coniugato” la soglia γ (calcolata dall'algoritmo esterno) bilancia l'errore di troncamento del CG con il rumore statistico del sottocampionamento dell'Hessiana. Se il test è soddisfatto, restituisce x ; altrimenti aggiorna $\beta = rr_{\text{new}}/rr$ e la direzione $p = r_{\text{new}} + \beta p$. Il ciclo termina al massimo dopo `maxcg` iterazioni.

Newton-CG

```
def newton_cg(w0, theta, max_iter, alpha, batch0, R, maxcg):
    w = np.array(w0, dtype=float)
    n = max(batch0, 2)
    history, batch_sizes = [w.copy().tolist()], [n]
```

La funzione principale `newton_cg` riceve il punto iniziale w_0 , la tolleranza θ per il controllo della varianza, il numero massimo di iterazioni esterne `max_iter`, il passo iniziale `alpha` per la line search, la dimensione del batch iniziale `batch0`, il rapporto R tra la dimensione del campione per l'Hessiana e quello per il gradiente, e il numero

massimo di iterazioni del CG `maxcg`. Il vettore dei pesi w viene convertito in array NumPy in doppia precisione, la dimensione del batch è forzata ad almeno 2 (per garantire che la varianza campionaria sia definita) e si inizializzano le liste `history` e `batch_sizes` che registreranno la traiettoria dei pesi e le dimensioni del batch a ogni iterazione.

Newton-CG

```
#
for k in range(max_iter):
    indices_S = np.random.choice(N, size=n, replace=False)
    g = np.mean([grad_i(w, i) for i in indices_S], axis=0)
```

Ad ogni iterazione esterna k , si estrae un campione casuale $\mathcal{S}_k$ di $n_k = n$ indici distinti (senza reinserimento) da $\{0, \dots, N-1\}$. Su questo campione si calcola il gradiente approssimato

$$g_k = \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i),$$

che costituisce la stima stocastica del gradiente esatto $\nabla J(w_k)$.

Newton-CG

```
#
n_h = min(max(1, int(round(R * n))), N)
indices_H = np.random.choice(indices_S, size=n_h,
    replace=False)
Hv = lambda v: np.mean([hessvec_i(w, i, v) for i in
    indices_H], axis=0)
```

Si determina la dimensione del campione per l'Hessiana come $n_h = \lceil R n_k \rceil$, vincolata tra 1 e N . Viene quindi estratto un sottocampione $\mathcal{H}_k \subseteq \mathcal{S}_k$ (senza reinserimento) di dimensione n_h . L'operatore `Hv` definisce il prodotto Hessiana-vettore come

$$H_v(v) = \nabla^2 J_{\mathcal{H}_k}(w_k) v = \frac{1}{n_h} \sum_{i \in \mathcal{H}_k} \nabla^2 \ell(w_k; i) v.$$

Questo operatore viene passato al risolutore CG, che lo utilizzerà per calcolare i prodotti Ap senza mai costruire esplicitamente la matrice Hessiana.

Newton-CG

```
#
p0 = -g
p0_norm2 = np.dot(p0, p0)
gamma = 0.0
if p0_norm2 > 1e-16 and n_h > 1:
    Hp0 = np.array([hessvec_i(w, i, p0) for i in indices_H])
    gamma = np.sum(np.var(Hp0, axis=0, ddof=1)) / (n_h *
        p0_norm2)
```

Prima di chiamare il CG, si calcola il coefficiente γ che quantifica l'errore di approssimazione dell'Hessiana lungo la direzione iniziale $p_0 = -g_k$. Si valutano i prodotti Hessiana-vettore individuali $\nabla^2 \ell(w_k; i) p_0$ per ogni $i \in \mathcal{H}_k$; la loro varianza campionaria (componente per componente) viene aggregata in norma L_1 e normalizzata:

$$\gamma = \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{n_h \|p_0\|_2^2}.$$

Se il gradiente è nullo (o quasi) o $n_h = 1$ (varianza non definita), si pone $\gamma = 0$, il che corrisponde a richiedere convergenza completa del CG. Questo parametro sarà utilizzato nel test di arresto del CG per fermarsi quando il residuo è confrontabile con il rumore statistico dell'Hessiana.

Newton-CG

```
#
d = cg(Hv, -g, gamma, maxcg)
```

Si risolve il sistema lineare di Newton approssimato

$$\nabla^2 J_{\mathcal{H}_k}(w_k) d = -g_k$$

chiamando la funzione `cg` con l'operatore `Hv`, il termine noto $-g_k$, il coefficiente γ e il limite di iterazioni `maxcg`. La soluzione d è la direzione di ricerca di Newton-CG, calcolata senza costruire l'Hessiana e con un criterio di arresto che bilancia l'accuratezza interna con l'incertezza statistica del campionamento.

Newton-CG

```
#
J_batch = lambda wc: np.mean([loss_i(wc, i) for i in
    indices_S])

c1, c2 = 1e-4, 0.9
step, J_w = alpha, J_batch(w)
gd = np.dot(g, d)
if gd >= 0:
    d = -g
    gd = -np.dot(g, g)
```

Si definisce la funzione obiettivo sul batch del gradiente, $J_{\mathcal{S}_k}(w)$, e si inizializza la ricerca lineare con passo `step = alpha`. Si calcola la derivata direzionale $\text{gd} = g_k^T d$. Se $\text{gd} \geq 0$, la direzione d non è di discesa; in tal caso si forza il fallback $d = -g_k$, che è sempre di discesa (a meno di gradiente nullo), e si ricalcola $\text{gd} = -\|g_k\|^2$.

Newton-CG

```
#
for _ in range(30):
    w_new = w + step * d
    if J_batch(w_new) <= J_w + c1 * step * gd:
```

```

g_new = np.mean([grad_i(w_new, i) for i in
                  indices_S], axis=0)
if np.dot(g_new, d) >= c2 * gd:
    break
step *= 0.5
else:
    step = 0.0
w = w + step * d

```

La line search con backtracking cerca un passo α_k che soddisfi le condizioni di Wolfe. $J_{S_k}(w_k + \alpha_k d_k) \leq J_{S_k}(w_k) + c_1 \alpha_k g_k^T d_k$ con $c_1 = 10^{-4}$ e $\nabla J_{S_k}(w_k + \alpha_k d_k)^T d_k \geq c_2 g_k^T d_k$ con $c_2 = 0.9$ (Spiegazione nell'appendice). Se entrambe sono soddisfatte, il passo è accettato. In caso contrario, il passo viene dimezzato e si riprova, per al più 30 tentativi; se nessuno è accettabile, si pone $\alpha_k = 0$. L'aggiornamento dei pesi è quindi $w_{k+1} = w_k + \alpha_k d_k$.

Newton-CG

```

#
history.append(w.copy().tolist())
batch_sizes.append(n)

```

Si registrano il nuovo punto w_{k+1} e la dimensione corrente del batch n .

Newton-CG

```

#
indices_new = np.random.choice(N, size=n, replace=False)
g_new = np.mean([grad_i(w, i) for i in indices_new], axis=0)
var_vec = np.var([grad_i(w, i) for i in indices_new], axis=0,
                  ddof=1) if n > 1 else np.zeros_like(g_new)
V_norm1, gg_new = np.sum(var_vec), np.dot(g_new, g_new)
if gg_new > 1e-16 and V_norm1 / n > theta**2 * gg_new:
    n = min(int(np.ceil(V_norm1 / (theta**2 * gg_new))) + 1,
            N)

```

Dopo l'aggiornamento dei pesi, si verifica la Condizione di Controllo della Varianza (CCV) su un nuovo campione $\mathcal{S}_{k+1}$ di dimensione n (quella corrente) per decidere se aumentare il batch per l'iterazione successiva. Si calcolano i gradienti individuali sul nuovo campione, la loro varianza campionaria $\hat{\mathcal{V}}$ e la norma L_1 $V_{\text{norm1}} = \|\hat{\mathcal{V}}\|_1$. La CCV richiede

$$\frac{\|\hat{\mathcal{V}}\|_1}{n} \leq \theta^2 \|g_{\text{new}}\|_2^2.$$

Se non è soddisfatta, la nuova dimensione del batch viene stimata come

$$n \leftarrow \min \left\{ N, \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|g_{\text{new}}\|_2^2} \right\rceil + 1 \right\},$$

in modo che il batch cresca automaticamente quando la varianza dello stimatore è troppo alta rispetto alla norma del gradiente, ovvero quando ci si avvicina alla soluzione e serve maggiore precisione.

Newton-CG

```
#
    if np.linalg.norm(grad_full(w)) < 1e-6:
        break
    return history, batch_sizes

history, batch_sizes = newton_cg(w0, theta, max_iter, alpha, batch0,
    R, maxcg)
```

Infine, si controlla la norma del gradiente esatto (calcolato su tutto il dataset) tramite `grad_full`; se $\|\nabla J(w_{k+1})\|_2 < 10^{-6}$, si considera raggiunta la convergenza e si interrompe il ciclo. Al termine delle iterazioni, la funzione restituisce le liste `history` e `batch_sizes`, che contengono rispettivamente la traiettoria dei pesi w_k e le dimensioni del batch n_k a ogni iterazione. L'ultima riga mostra la chiamata tipica alla funzione, che produce le due liste per l'analisi successiva. Dunque l'algoritmo Newton-CG condivide con il Dynamic GD la strategia di campionamento dinamico del gradiente (regolazione della dimensione del batch tramite la CCV); la differenza è nella direzione di ricerca, che non è l'antigradiente, bensì la direzione di Newton approssimata, ottenuta risolvendo il sistema (5.31) con il gradiente coniugato Hessian free.

B.3 Newton-CG per problemi L_1 -regolarizzati

In questa sezione illustriamo il funzionamento del codice dell'algoritmo Newton-CG per problemi con regolarizzazione L_1 . Per facilitare la comprensione, supponiamo che il vettore dei parametri abbia dimensione m : $w \in \mathbb{R}^m$.

Newton-L1

```
import numpy as np

def newton_l1(w0, theta, max_iter, alpha, batch0, nu, sigma, maxcg,
    eta=0.5):
    w = np.array(w0, dtype=float)
    n = max(batch0, 2)
    history = [w.copy().tolist()]
    batch_sizes = [n]
```

La funzione principale `newton_l1` implementa il metodo Newton-CG con campionamento dinamico per problemi con regolarizzazione L_1 . Riceve il punto iniziale w_0 , la tolleranza θ per il controllo della varianza, il numero massimo di iterazioni esterne `max_iter`, il passo iniziale `alpha` per la ricerca lineare, la dimensione del batch iniziale `batch0`, il parametro di penalità $\nu > 0$, la costante $\sigma \in (0, 1)$ per la condizione di Armijo, il numero massimo di iterazioni del gradiente coniugato `maxcg` e il fattore di tolleranza $\eta \in (0, 1)$ per il criterio di arresto del CG. Il vettore dei pesi w viene convertito in array NumPy in doppia precisione, la dimensione del batch è forzata ad almeno 2 (per garantire che la varianza campionaria sia definita) e si inizializzano le liste `history` e `batch_sizes` che registreranno la traiettoria dei pesi e le dimensioni del batch a ogni iterazione.

Newton-L1

```
#
def F_batch(v, indices):
    Jb = np.mean([loss_i(v, i) for i in indices])
    return Jb + nu * np.sum(np.abs(v))
def subgrad_batch(v, indices):
    grads = np.array([grad_i(v, i) for i in indices])
    gJ = np.mean(grads, axis=0)
    g = np.zeros_like(v)
    for i in range(len(v)):
        if v[i] > 0:
            g[i] = gJ[i] + nu
        elif v[i] < 0:
            g[i] = gJ[i] - nu
        else:
            if gJ[i] < -nu:
                g[i] = gJ[i] + nu
            elif gJ[i] > nu:
                g[i] = gJ[i] - nu
            else:
                g[i] = 0.0
    return g
def project_orthant(v, z):
    res = v.copy()
    for i in range(len(v)):
        if z[i] != 0 and np.sign(res[i]) != z[i]:
            res[i] = 0.0
    return res
```

Vengono definite tre funzioni ausiliarie interne. `F_batch` calcola la funzione obiettivo regolarizzata sul batch $\mathcal{S}$:

$$F_{\mathcal{S}}(v) = J_{\mathcal{S}}(v) + \nu \|v\|_1 = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} \ell(v; i) + \nu \sum_{j=1}^m |v_j|,$$

in accordo con la formulazione (5.42). `subgrad_batch` implementa il gradiente generalizzato $\tilde{\nabla} F_{\mathcal{S}}(v)$ componente per componente, seguendo la regola (5.43): se $v_i \neq 0$ si somma $\nu \operatorname{sign}(v_i)$; se invece $v_i = 0$, si sceglie il subgradiente in $[-\nu, +\nu]$ che rende nullo (quando possibile) la componente del gradiente generalizzato, realizzando la proiezione $g_i = \arg \min_{g \in [-\nu, \nu]} |(\nabla J_{\mathcal{S}})_i + g|$. `project_orthant` implementa la proiezione $P(\cdot)$ sulla faccia ortante Ω_k definita in (5.45): azzera ogni componente il cui segno non coincide con quello prescritto dal vettore z .

Newton-L1

```
#
for k in range(max_iter):
    indices_S = np.random.choice(N, size=n, replace=False)
    grads = np.array([grad_i(w, i) for i in indices_S])
    g_batch = np.mean(grads, axis=0)
    z = np.where(w > 0, 1,
```

```
np.where(w < 0, -1,
        np.where(g_batch < -nu, 1,
                 np.where(g_batch > nu, -1, 0))))
```

Ad ogni iterazione esterna k , si estrae un campione casuale $\mathcal{S}_k$ di $n_k = n$ indici distinti (senza reinserimento) da $\{0, \dots, N-1\}$. Su questo campione si calcola il gradiente della parte liscia

$$g_k = \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i),$$

che costituisce la stima stocastica del gradiente esatto $\nabla J(w_k)$. Quindi si determina il vettore $z_k \in \{-1, 0, +1\}^m$ che caratterizza la faccia ortante secondo la (5.44): $z_k^i = \text{sign}(w_k^i)$ se $w_k^i \neq 0$; se invece $w_k^i = 0$, la componente viene posta a ± 1 quando il gradiente della parte liscia supera in valore assoluto la soglia ν (indicando che conviene “liberare” la variabile), e a 0 altrimenti (la variabile resta bloccata nell’active set).

Newton-L1

```
#
sg = subgrad_batch(w, indices_S)
sgn = np.linalg.norm(sg)
if sgn < 1e-10:
    history.append(w.copy().tolist())
    batch_sizes.append(n)
    break
n_h = max(1, int(round(R * n)))
n_h = min(n_h, N)
indices_H = np.random.choice(indices_S, size=n_h,
                              replace=False)
free = (z != 0)
d = np.zeros_like(w)
if np.any(free):
    g_free = sg[free]
    # Hessian free: prodotto H.v senza costruire H
    def Hv(v_full):
        return np.mean([hessvec_i(w, i, v_full) for i in
                        indices_H], axis=0)
    def Hv_free(v_free):
        v_full = np.zeros_like(w)
        v_full[free] = v_free
        Hv_full = Hv(v_full)
        return Hv_full[free]
    tol_cg = eta * np.linalg.norm(g_free)
    d_free = np.zeros(np.sum(free))
    r = -g_free.copy()
    p = r.copy()
    rr = np.dot(r, r)
    for _ in range(maxcg):
        Hp = Hv_free(p)
```

```

pHp = np.dot(p, Hp)
if pHp <= 1e-14:
    if np.linalg.norm(d_free) < 1e-14:
        d_free = -g_free.copy()
    break
alpha_cg = rr / pHp
d_free = d_free + alpha_cg * p
r_new = r - alpha_cg * Hp
rr_new = np.dot(r_new, r_new)
if np.sqrt(rr_new) <= tol_cg:
    r = r_new
    rr = rr_new
    break
beta = rr_new / rr
p = r_new + beta * p
r = r_new
rr = rr_new
d[free] = d_free

```

Si calcola il subgradiente $\tilde{\nabla} F_{S_k}(w_k)$ tramite `subgrad_batch` e la sua norma euclidea; se questa è trascurabile ($< 10^{-10}$) si considera raggiunta la convergenza e si interrompe il ciclo, registrando l'ultimo punto. Altrimenti si determina la dimensione del campione per l'Hessiana come $n_h = \lceil R n_k \rceil$, vincolata tra 1 e N , e si estrae il sottocampione $\mathcal{H}_k \subseteq \mathcal{S}_k$ (senza reinserimento) di dimensione n_h . Il vettore booleano `free` individua le variabili libere (quelle con $z_k^i \neq 0$), mentre le rimanenti appartengono all'active set $\mathcal{A}_k$ definito in (5.46). Sul sottospazio delle variabili libere si risolve il sistema lineare di Newton ridotto

$$[Y_k^T \nabla^2 J_{\mathcal{H}_k}(w_k) Y_k] d^Y = -Y_k^T \tilde{\nabla} F_{S_k}(w_k),$$

dove Y_k è la matrice dei versori delle coordinate libere, mediante il metodo del gradiente coniugato Hessian free. Gli operatori `Hv` e `Hv_free` calcolano il prodotto $\nabla^2 J_{\mathcal{H}_k}(w_k) v$ senza costruire esplicitamente la matrice Hessiana. Il CG viene arrestato quando il residuo soddisfa il criterio (5.51),

$$\|r_j\|_2 \leq \eta \|g_{\text{free}}\|_2.$$

o quando incontra curvatura non positiva ($\text{pHp} \leq 10^{-14}$), nel qual caso si effettua il fallback sulla direzione dell'antigradiente ridotto $-g_{\text{free}}$.

Newton-L1

```

#
step = alpha
F_w = F_batch(w, indices_S)
sg_d = np.dot(sg, d)
if sg_d >= 0:
    d = -sg
    sg_d = -np.dot(sg, sg)
w_new = w.copy()
for _ in range(20):

```

```

w_trial = project_orthant(w + step * d, z)
if F_batch(w_trial, indices_S) <= F_w + sigma * step *
    sg_d:
    w_new = w_trial
    break
step *= 0.5
if step < 1e-12:
    w_new = w.copy()
    break
w = w_new

```

Si inizializza la ricerca lineare proiettata con passo `step = alpha`. Si calcola il valore dell'obiettivo $F_{S_k}(w_k)$ e la derivata direzionale $\text{sg_d} = \tilde{\nabla} F_{S_k}(w_k)^T d$. Se questa non è negativa, la direzione d non è di discesa e si forza il fallback $d = -\tilde{\nabla} F_{S_k}(w_k)$, che è sempre di discesa (a meno di subgradiente nullo). La line search cerca il più grande passo α_k nella sequenza $1, \frac{1}{2}, \frac{1}{4}, \dots$ tale che

$$F_{S_k}(P[w_k + \alpha_k d]) \leq F_{S_k}(w_k) + \sigma \alpha_k \tilde{\nabla} F_{S_k}(w_k)^T (P[w_k + \alpha_k d] - w_k),$$

dove P è la proiezione `project_orthant`. Questo corrisponde alla condizione (5.50). Se lo step diventa troppo piccolo ($< 10^{-12}$) si rifiuta l'aggiornamento e si mantiene il punto corrente.

Se la direzione d avesse portato a un valore con segno diverso da z , la proiezione avrebbe azzerato il valore a 0, impedendo alla variabile di attraversare lo zero. Ad esempio, se x fosse negativo con $z = -1$ e la direzione d positiva, $x + \alpha d$ diventerebbe positivo, e la proiezione lo azzererebbe, mantenendo la coerenza con la faccia ortante.

Newton-L1

```

#
indices_new = np.random.choice(N, size=n, replace=False)
grads_new = np.array([grad_i(w, i) for i in indices_new])
g_new = np.mean(grads_new, axis=0)
if n > 1:
    var_vec = np.var(grads_new, axis=0, ddof=1)
else:
    var_vec = np.zeros_like(g_new)
V_norm1 = np.sum(var_vec)
gg_new = np.dot(g_new, g_new)
if gg_new > 1e-16:
    if V_norm1 / n > theta**2 * gg_new:
        n_new = int(np.ceil(V_norm1 / (theta**2 * gg_new))) +
        1
        n = min(n_new, N)
history.append(w.copy().tolist())
batch_sizes.append(n)
if np.linalg.norm(grad_full(w)) < 1e-6:
    break
return history, batch_sizes

```

```
history, batch_sizes = newton_ll(w0, theta, max_iter, alpha, batch0,
                                nu, sigma, maxcg, eta)
```

Dopo l'aggiornamento dei pesi, si verifica la Condizione di Controllo della Varianza (CCV) su un nuovo campione $\mathcal{S}_{k+1}$ della stessa dimensione n_k corrente per decidere se aumentare il batch per l'iterazione successiva. Si calcolano i gradienti individuali della parte liscia sul nuovo campione, la loro varianza campionaria $\hat{\mathcal{V}}$ e la norma L_1 $V_{\text{norm1}} = \|\hat{\mathcal{V}}\|_1$. La CCV richiede

$$\frac{\|\hat{\mathcal{V}}\|_1}{n} \leq \theta^2 \|g_{k+1}\|_2^2,$$

dove g_{k+1} è il gradiente della parte liscia sul nuovo campione. Se la condizione non è soddisfatta, la nuova dimensione del batch viene stimata come

$$n \leftarrow \min \left\{ N, \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|g_{k+1}\|_2^2} \right\rceil + 1 \right\}.$$

Questa è un'estensione dinamica rispetto al paper originale, dove il campione per il caso L_1 era mantenuto fisso. Si registrano il nuovo punto w_{k+1} e la dimensione del batch, quindi si controlla la norma del gradiente esatto (calcolato su tutto il dataset) tramite `grad_full`; se $\|\nabla J(w_{k+1})\|_2 < 10^{-6}$ si interrompe il ciclo. Al termine delle iterazioni, la funzione restituisce le liste `history` e `batch_sizes`. L'ultima riga mostra la chiamata tipica alla funzione, che produce le due liste per l'analisi successiva.

B.4 Barzilai–Borwein con campionamento dinamico

Il metodo BB-CCV sostituisce il passo fisso del Dynamic GD con un passo adattivo di Barzilai–Borwein, che stima la curvatura di J usando solo i gradienti già calcolati, mantenendo la Condizione di Controllo della Varianza per il campionamento dinamico del batch (Sezione 5.4).

BB-CCV

```
def bb_dynamic_gd(w0, theta, max_iter, alpha, batch0):
    w = np.array(w0, dtype=float)
    n = max(batch0, 2)
    history = [w.copy().tolist()]
    batch_sizes = [n]

    w_prev = w.copy()
    g_prev = None
```

La funzione riceve gli stessi argomenti del Dynamic GD (Sezione B.1): il punto iniziale $w_0 \in \mathbb{R}^d$, la tolleranza θ della CCV, il numero massimo di iterazioni, il passo base α e la dimensione iniziale del batch $n_0 = \max(\text{batch0}, 2)$. Oltre alle liste `history` (pesi w_k) e `batch_sizes` (dimensioni n_k), si inizializza lo stato del passo di Barzilai–Borwein: w_{prev} e g_{prev} , cioè il punto e il gradiente dell'iterazione precedente,

usati per costruire le differenze s_k e y_k . Alla prima iterazione $g_{\text{prev}} = \text{None}$ e il passo sarà semplicemente α .

BB-CCV

```
for k in range(max_iter):
    indices = np.random.choice(N, size=n, replace=False)
    grads = np.array([grad_i(w, i) for i in indices])
    g = np.mean(grads, axis=0)
```

Come nel Dynamic GD (Sezione B.1) si estrae il batch $\mathcal{S}_k = \{i_1, \dots, i_n\}$ senza reinserimento e si calcola il gradiente campionato $g_k = \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i)$.

BB-CCV

```
if k > 0 and g_prev is not None:
    s = w - w_prev
    y = g - g_prev
    sy = np.dot(s, y)
    if abs(sy) > 1e-14:
        step_bb = np.dot(s, s) / sy
        step = np.clip(step_bb, alpha / 20.0, alpha * 5.0)
    else:
        step = alpha
else:
    step = alpha

w_prev = w.copy()
g_prev = g.copy()
```

Il passo di Barzilai–Borwein stima la curvatura di J lungo la direzione percorsa usando le differenze tra iterazioni consecutive:

$$s_k = w_k - w_{k-1}, \quad y_k = g_k - g_{k-1}, \quad \alpha_k^{\text{BB}} = \frac{s_k^\top s_k}{s_k^\top y_k}.$$

Per una quadratica vale $y_k = \nabla^2 J s_k$, come dedotto in Sezione 5.4.1 (relazione fondamentale, Eq. (5.54)); quindi $\alpha_k^{\text{BB}} = \frac{s_k^\top s_k}{s_k^\top \nabla^2 J s_k}$ coincide con l'inverso della curvatura media di $\nabla^2 J$ lungo la direzione s_k , il rapporto $\frac{s_k^\top \nabla^2 J s_k}{s_k^\top s_k}$ è una media pesata delle curvature della Hessiana (per una matrice simmetrica il rapporto sta tra $\lambda_{\min}$ e $\lambda_{\max}$; si può dimostrare), cioè un passo di Newton scalare a costo nullo, poiché s_k e y_k sono quantità già disponibili. Per robustezza sui problemi non quadratici il passo è salvaguardato nell'intervallo $[\alpha/20, 5\alpha]$ tramite `np.clip`; se $s_k^\top y_k$ è numericamente nullo si torna al passo base α . Alla prima iterazione ($k = 0$) la coppia (s, y) non esiste ancora e si usa $\alpha_0 = \alpha$. Infine si aggiorna lo stato precedente $w_{\text{prev}} \leftarrow w_k$, $g_{\text{prev}} \leftarrow g_k$.

BB-CCV

```
def J_batch(w_curr):
    return np.mean([loss_i(w_curr, i) for i in indices])
```

```

c1 = 1e-4
J_curr = J_batch(w)
g_norm2 = np.dot(g, g)

if g_norm2 > 1e-16:
    for _ in range(30):
        w_new = w - step * g
        if J_batch(w_new) <= J_curr - c1 * step * g_norm2:
            break
        step *= 0.5
    else:
        step = 0.0

w = w - step * g

```

Il candidato è $w_k - \alpha_k g_k$: il passo di Barzilai–Borwein viene rifinito da una line search di Armijo con backtracking sulla loss del batch, come nel Dynamic GD. La condizione di sufficiente decremento, con $c_1 = 10^{-4}$, è

$$J_{S_k}(w_k - \alpha_k g_k) \leq J_{S_k}(w_k) - c_1 \alpha_k \|g_k\|_2^2,$$

che è la condizione di Armijo della Sezione 5.1.5 con direzione $d_k = -g_k$. Se dopo 30 dimezzamenti la condizione non è soddisfatta si pone $\alpha_k = 0$. L'aggiornamento è quindi $w_{k+1} = w_k - \alpha_k g_k$.

BB-CCV

```

if n > 1:
    var_vec = np.var(grads, axis=0, ddof=1)
else:
    var_vec = np.zeros_like(g)
V_norm1 = np.sum(var_vec)

gg = np.dot(g, g)
if gg > 1e-16:
    if V_norm1 / n > theta**2 * gg:
        n_new = int(np.ceil(V_norm1 / (theta**2 * gg))) + 1
        n = min(n_new, N)

```

La gestione del batch è identica al Dynamic GD (Sezione B.1): si calcola la varianza campionaria dei gradienti individuali sul batch $\hat{\mathcal{V}} = \text{Var}_{i \in S_k}(\nabla \ell(w_k; i))$, la sua norma $V_{\text{norm1}} = \|\hat{\mathcal{V}}\|_1$ e si verifica la CCV $\|\hat{\mathcal{V}}\|_1/n_k \leq \theta^2 \|g_k\|_2^2$. Se violata, il batch viene aumentato a $n \leftarrow \min\{N, \lceil \|\hat{\mathcal{V}}\|_1/(\theta^2 \|g_k\|_2^2) \rceil + 1\}$.

BB-CCV

```

history.append(w.copy().tolist())
batch_sizes.append(n)

if np.linalg.norm(grad_full(w)) < 1e-6:

```



```

        break

    return history, batch_sizes

history, batch_sizes = bb_dynamic_gd(w0, theta, max_iter, alpha,
    batch0)

```

Si registrano il nuovo punto w_{k+1} e la dimensione del batch e si verifica la convergenza sulla norma del gradiente esatto $\|\nabla J(w_{k+1})\|_2 < 10^{-6}$. Al termine la funzione restituisce le liste `history` e `batch_sizes`; l'ultima riga mostra la chiamata tipica.

C Istruzioni per l'esecuzione

In questa appendice sono raccolte le istruzioni per eseguire il codice Python presentato nell'Appendice B e per avviare l'applicazione web interattiva descritta nella Sezione 6.2.

C.1 Dipendenze

Il codice richiede Python 3.9 o successivo e le seguenti librerie:

- `numpy` (versione ≥ 1.21) – calcolo numerico vettoriale;
- `matplotlib` (versione ≥ 3.5) – generazione dei grafici di convergenza e dei percorsi di ottimizzazione;
- `plotly` (versione ≥ 5.0) – visualizzazioni interattive nell'applicazione web;
- `pyodide` – runtime Python nel browser per l'esecuzione del codice degli algoritmi (usato dall'applicazione web).

C.2 Installazione

Si consiglia di creare un ambiente virtuale dedicato e installare le dipendenze con `pip`:

```

python3 -m venv .venv
source .venv/bin/activate          # su Windows: .venv\Scripts\activate
pip install --upgrade pip
pip install numpy matplotlib plotly

```

C.3 Esecuzione degli esperimenti numerici

Gli esperimenti del Capitolo 6 sono stati eseguiti sul computer dell'autore con le implementazioni Python dell'Appendice B e con il generatore di numeri casuali inizializzato con seme fisso (seed 42): i valori riportati nel capitolo (tabelle e figure) sono quelli ottenuti da questa esecuzione locale (Sezione 6.1). L'applicazione web interattiva (Sezione 6.4) permette di ripetere gli esperimenti nel browser selezionando il preset, l'algoritmo e i parametri indicati: i risultati coincidono con quelli qui

riportati a meno di differenze dell'ordine di qualche punto percentuale, che possono comparire sui problemi mal condizionati, perché il runtime Pyodide (build WASM) usa un'aritmetica in virgola mobile leggermente diversa dal NumPy di sistema con cui sono state generate le tabelle (Sezione 6.1).

C.4 Esecuzione dei singoli algoritmi

I codici dell'Appendice B possono essere eseguiti anche in modo isolato, previa definizione delle funzioni ausiliarie `loss_i`, `grad_i`, `hessvec_i`, `grad_full` e della costante N , che dipendono dal dataset.

C.5 Avvio dell'applicazione web

L'applicazione web interattiva è un'applicazione a pagina singola (HTML + JavaScript) che esegue il codice Python nel browser tramite Pyodide: non è necessario un server dedicato. È sufficiente aprire il file HTML in un browser moderno (Chrome, Firefox, Safari, Edge).

C.6 Requisiti di sistema

Gli esperimenti riportati in questo elaborato sono stati eseguiti su un computer portatile con processore Apple Silicon (8 core) e 16 GB di RAM, in ambiente macOS, utilizzando Python 3.14, NumPy 2.4 e Matplotlib 3.11. Il costo complessivo della simulazione (tre problemi test, tre valori di θ e quattro algoritmi) è inferiore a due minuti; nessun acceleratore GPU è richiesto, poiché tutti i calcoli sono operazioni vettoriali su array NumPy di dimensione al più $N \times m$. Per la riproducibilità esatta dei risultati, il generatore di numeri casuali è stato inizializzato con seme fisso (seed 42); a parità di codice e versioni delle librerie, i valori riportati sono riproducibili.

D Schemi dei metodi a varianza ridotta

I metodi a varianza ridotta SVRG e SAGA, discussi nella Sezione 4, combinano la stima stocastica del gradiente con una correzione basata su quantità globali: lo stimatore g_k resta non distorto, $\mathbb{E}_{i_k}[g_k] = \nabla J(w_k)$, e la sua varianza è ridotta rispetto al gradiente stocastico puro $\nabla \ell(w_k; i_k)$. Nella notazione del documento, $J(w) = \frac{1}{N} \sum_{i=1}^N \ell(w; i)$ è la perdita media empirica, $\nabla \ell(w; i)$ il gradiente sull'esempio i -esimo, i_k l'indice estratto uniformemente a caso da $\{1, \dots, N\}$ all'iterazione k e α_k il passo.




Figura D.1: Schema del metodo SVRG di Johnson e Zhang [9]: il punto di ancoraggio $\bar{w}$ viene aggiornato ogni t iterazioni con il gradiente esatto $\nabla J(\bar{w})$, e lo stimatore corregge il gradiente stocastico corrente con la differenza $\nabla \ell(w_k; i_k) - \nabla \ell(\bar{w}; i_k)$. Lo stimatore è non distorto, $\mathbb{E}_{i_k}[g_k] = \nabla J(w_k)$, e quando w_k è vicino a $\bar{w}$ i due termini stocastici si elidono quasi del tutto, riducendo la varianza.




Figura D.2: Schema del metodo SAGA di Defazio, Bach e Lacoste-Julien [10]: la tavola dei gradienti $g^{(i)}$ memorizza l'ultimo gradiente calcolato per ogni esempio ed è aggiornata a ogni iterazione; lo stimatore usa la media $\bar{g}$ della tavola come correzione. Anche in questo caso $\mathbb{E}_{i_k}[g_k] = \nabla J(w_k)$ e la varianza è ridotta rispetto al gradiente stocastico puro.

Riferimenti bibliografici

- [1] R. H. Byrd, G. M. Chin, J. Nocedal, and Y. Wu, “Sample size selection in optimization methods for machine learning,” *Mathematical Programming, Series A*, vol. 134, no. 1, pp. 127–155, 2012.
- [2] L. Bottou and O. Bousquet, “The tradeoffs of large scale learning,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 20, 2008, pp. 161–168.
- [3] J. Nocedal and S. J. Wright, *Numerical Optimization*, 2nd ed., Springer Series in Operations Research and Financial Engineering, New York: Springer, 2006.
- [4] R. H. Byrd, G. M. Chin, W. Neveitt, and J. Nocedal, “On the use of stochastic Hessian information in optimization methods for machine learning,” *SIAM Journal on Optimization*, vol. 21, no. 3, pp. 894–1009, 2011.
- [5] L. Bottou, F. E. Curtis, and J. Nocedal, “Optimization methods for large-scale machine learning,” *SIAM Review*, vol. 60, no. 2, pp. 223–311, 2018.
- [6] H. Robbins and S. Monro, “A stochastic approximation method,” *The Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, 1951.

- [7] B. T. Polyak, “Gradient methods for the minimization of functionals,” *USSR Computational Mathematics and Mathematical Physics*, vol. 3, no. 4, pp. 864–878, 1963 (traduzione inglese, 1964).
- [8] H. Karimi, J. Nutini, and M. Schmidt, “Linear convergence of gradient and proximal-gradient methods under the Polyak–Łojasiewicz condition,” in *European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases (ECML PKDD)*, 2016, pp. 795–811.
- [9] R. Johnson and T. Zhang, “Accelerating stochastic gradient descent using predictive variance reduction,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 26, 2013, pp. 315–323.
- [10] A. Defazio, F. Bach, and S. Lacoste-Julien, “SAGA: A fast incremental gradient method with support for non-strongly convex composite objectives,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 1646–1654.
- [11] R. S. Dembo and T. Steihaug, “Truncated-Newton algorithms for large-scale unconstrained optimization,” *Mathematical Programming*, vol. 26, no. 2, pp. 190–212, 1983.
- [12] J. R. Shewchuk, “An introduction to the conjugate gradient method without the agonizing pain,” Technical Report CMU-CS-94-125, Carnegie Mellon University, 1994.
- [13] J. Barzilai and J. M. Borwein, “Two-point step size gradient methods,” *IMA Journal of Numerical Analysis*, vol. 8, no. 1, pp. 141–148, 1988.