



SAPIENZA
UNIVERSITÀ DI ROMA

Selezione Dinamica della Dimensione del Campione in Algoritmi di Ottimizzazione per il Machine Learning su Larga Scala

Metodi adattivi con campionamento dinamico dell'Hessiana
per problemi di ottimizzazione convessa

Facoltà di Scienze Matematiche Fisiche e Naturali
Scienze Matematiche per l'Intelligenza Artificiale

Alessandro Lo Curcio

Matricola 2107367

Relatore

Prof. Marco Sciandrone

Anno Accademico 2025/2026

Tesi non ancora discussa

Selezione Dinamica della Dimensione del Campione in Algoritmi di Ottimizzazione per il Machine Learning su Larga Scala

Tesi di Laurea Triennale. Sapienza Università di Roma

© 2026 Alessandro Lo Curcio. Tutti i diritti riservati

Questa tesi è stata composta con $\text{\LaTeX}$ e la classe Sapthesis.

Email dell'autore: alessandro.locurcio@uniroma1.it

Ringraziamenti

placeholder

Abstract

Questa tesi presenta, in forma rigorosa ma accessibile, la metodologia per la selezione dinamica della dimensione del campione negli algoritmi di ottimizzazione per il machine learning su larga scala, basandosi sul lavoro seminale di Byrd, Chin, Nocedal e Wu [1]. L'idea centrale è la seguente: anziché scegliere a priori una dimensione fissa del batch (il sottoinsieme di dati usato ad ogni iterazione), è possibile decidere durante l'algoritmo se e quando aumentarla, guidandosi da stime statistiche della varianza del gradiente stocastico. Vengono trattati tre contributi principali: (i) un metodo del gradiente a campione dinamico con analisi di convergenza lineare e stima di complessità; (ii) un metodo di Newton con gradiente coniugato e Hessiana sottocampionata, con un criterio di arresto adattivo per il risolutore interno; (iii) un'estensione ai problemi con regolarizzazione L_1 per la produzione di soluzioni sparse. Il documento è organizzato (placeholder) in sette capitoli: dopo l'introduzione e il background necessario, si formula il problema di ottimizzazione, si passano in rassegna i lavori correlati, si descrivono gli algoritmi proposti, se ne discute l'implementazione interattiva con i risultati sperimentali e si traggono le conclusioni con le prospettive di lavoro futuro. I dettagli dimostrativi e i listati Python completi sono raccolti in appendice.

Indice

1	Introduzione	5
1.1	Contesto	5
1.2	Il problema: la dimensione del mini-batch	5
1.3	La soluzione proposta: il campionamento dinamico	5
1.4	Contributi del lavoro	6
1.5	Struttura della tesi	6
2	Background e Notazione	6
2.1	Glossario dei simboli ricorrenti	6
2.2	Prerequisiti matematici essenziali	7
2.3	Collegamento con la formulazione del problema	9
3	Formulazione del Problema	10
3.1	Apprendimento supervisionato su larga scala	10
3.2	La sfida computazionale	10
3.3	Il trade-off	11
3.4	Formulazione del problema	11
3.5	Ipotesi su J	11
4	Lavori Correlati	13
4.1	Metodi di ottimizzazione stocastica	13
4.2	Campionamento dinamico	13
4.3	Metodi di secondo ordine stocastici	13
4.4	Regolarizzazione L_1 in ottimizzazione	14
5	Algoritmi Proposti	15
5.1	Metodo del Gradiente a Campione Dinamico	15
5.1.1	Formulazione della dinamica del batch	15
5.1.2	Formulazione matematica della condizione di accettazione	16
5.1.3	Regola di aggiornamento del batch	19
5.1.4	Pseudocodice (Algoritmo)	20
5.1.5	Convergenza deterministica	21
5.1.6	Analisi Stocastica e Complessità del Metodo	25
5.2	Metodo di Newton-CG con Campionamento Dinamico	33
5.2.1	Struttura del metodo	33
5.2.2	Criterio di terminazione del gradiente coniugato	34
5.2.3	Pseudocodice (Algoritmo Newton-CG)	37
5.3	Metodo Newton-CG per Modelli con Regolarizzazione L_1	41
5.3.1	Formulazione del Problema	41
5.3.2	Il gradiente generalizzato	41
5.3.3	Identificazione dell'Active Set e della Faccia Ortante	43
5.3.4	Fase di Minimizzazione nel Sottospazio	44
5.3.5	Ricerca Lineare Proiettata	44
5.3.6	Algoritmo Completo	45

6	Esperimenti e Visualizzazione Interattiva	45
6.1	Setup Sperimentale	46
6.2	Architettura Software	47
6.3	Risultati Numerici	48
6.4	Visualizzazione Interattiva	49
7	Conclusioni e Lavoro Futuro	50
7.1	Riassunto dei risultati	50
7.2	Limiti dello studio	51
7.3	Direzioni per lavoro futuro	51
A	Dimostrazioni	52
A.1	Dimostrazione delle disuguaglianze di Polyak–Łojasiewicz	52
A.2	Dimostrazione del fattore di correzione per popolazione finita	55
A.3	Dimostrazione delle formule per α_k e β_k nel Metodo del Gradiente Coniugato	57
A.4	Spiegazione delle condizioni sul passo α_k	60
B	Listati Python completi	60
B.1	Listato B.1: metodo del gradiente a campione dinamico	61
B.2	Listato B.2: Newton-CG con campionamento dinamico	62
B.3	Listato B.3: Newton-CG per problemi L_1 -regolarizzati	64
C	Istruzioni per l'esecuzione	67
C.1	Dipendenze	67
C.2	Installazione	67
C.3	Esecuzione degli esperimenti numerici	67
C.4	Esecuzione dei singoli algoritmi	68
C.5	Avvio dell'applicazione web	68
C.6	Requisiti di sistema	68

1 Introduzione

1.1 Contesto

Negli ultimi anni il *machine learning* ha assunto un ruolo centrale in numerosi ambiti applicativi, dalla visione artificiale all'elaborazione del linguaggio naturale, e la disponibilità di dataset sempre più grandi ha reso l'*ottimizzazione su larga scala* uno dei problemi computazionali più rilevanti. In un tipico problema di apprendimento supervisionato si dispone di un insieme di N esempi etichettati e si cerca il vettore di parametri w che minimizza la perdita media $J(w)$ sul dataset. Quando N è dell'ordine di 10^6 – 10^9 esempi, come accade nelle applicazioni reali, il calcolo del gradiente completo $\nabla J(w)$ che richiede di valutare la perdita su tutti gli esempi, ha costo $O(Nm)$ ed è computazionalmente proibitivo se ripetuto ad ogni iterazione.

Per questo motivo gli algoritmi di ottimizzazione stocastica, che usano ad ogni passo soltanto un sottoinsieme dei dati (batch), sono diventati lo standard. La letteratura offre un ampio spettro di metodi: dal gradiente stocastico classico (SGD) [4, 2] ai metodi a varianza ridotta [6, 5].

1.2 Il problema: la dimensione del mini-batch

La scelta della dimensione del mini-batch è un compromesso fondamentale. Un batch piccolo rende ogni iterazione economica ma il gradiente stimato è *rumoroso*, e il rumore limita la precisione raggiungibile. Un batch grande fornisce una stima più accurata, ma il costo per iterazione cresce proporzionalmente alla sua dimensione. Nei metodi classici la dimensione del batch è **fissa** e scelta *euristicamente* all'inizio dell'ottimizzazione, senza alcun adattamento alla difficoltà del problema: se il batch è troppo piccolo si rischia di non convergere alla precisione desiderata; se è troppo grande si spreca risorse computazionali nelle prime iterazioni, dove una stima grossolana sarebbe più che sufficiente.

1.3 La soluzione proposta: il campionamento dinamico

La soluzione studiata in questa tesi consiste nel rendere *dinamica* la dimensione del batch: si parte da un campione piccolo per fare progressi rapidi ed economici e lo si aumenta progressivamente quando serve precisione. La decisione su *quando* e *di quanto* aumentare il batch è guidata da una **condizione di controllo della varianza** (CCV): finché la varianza campionaria del gradiente stocastico è piccola rispetto alla norma del gradiente corrente, il batch corrente è adeguato; quando il gradiente si avvicina a zero, il rumore relativo cresce e la CCV impone un batch più grande. In questo modo la risorsa computazionale viene concentrata dove è realmente necessaria, con un adattamento automatico alla difficoltà del problema.

Questa idea, introdotta da Byrd, Chin, Nocedal e Wu [1], viene qui sviluppata in tre direzioni: un'analisi teorica completa del metodo del gradiente a campione dinamico, l'estensione a un metodo di Newton-CG con Hessiana sottocampionata, e un'estensione ai problemi con regolarizzazione L_1 , accompagnate da un'applicazione web interattiva che ne permette la sperimentazione diretta.

1.4 Contributi del lavoro

I contributi principali di questo lavoro sono i seguenti:

1. **Analisi teorica del metodo del gradiente a campione dinamico.** Trattamento completa della dinamica del batch basata sul controllo della varianza, con convergenza lineare in aspettativa e stima di complessità totale competitiva con quella di SGD per problemi mal condizionati.
2. **Estensione al metodo Newton-CG con sottocampionamento dell'Hessiana.** Metodo di secondo ordine che usa due campioni distinti per gradiente e Hessiana, con un criterio di arresto adattivo per il gradiente coniugato interno basato sulla varianza campionaria dei prodotti Hessiana-vettore.
3. **Estensione ai problemi con regolarizzazione L_1 e applicazione interattiva.** Il campionamento dinamico viene esteso al caso non liscio mediante gradiente generalizzato, active set e ricerca lineare proiettata; gli algoritmi sono inoltre implementati in un'applicazione web interattiva per la visualizzazione e la sperimentazione.

1.5 Struttura della tesi

Il resto del lavoro è organizzato come segue. Il Capitolo 2 richiama prerequisiti e notazione; il Capitolo 3 formalizza il problema dell'ottimizzazione empirica su larga scala e le ipotesi strutturali su J ; il Capitolo 4 passa in rassegna i lavori correlati; il Capitolo 5 descrive gli algoritmi proposti con i risultati di convergenza e complessità; il Capitolo 6 illustra l'implementazione e i risultati numerici; il Capitolo 7 riassume i risultati e delinea le direzioni di lavoro futuro. Le dimostrazioni, i listati Python e le istruzioni di esecuzione sono raccolti nelle Appendici A, B e C.

2 Background e Notazione

Questo capitolo richiama la notazione e i prerequisiti matematici usati nel resto del lavoro: convessità, gradiente, norme di matrice e numero di condizionamento. Le nozioni probabilistiche di base (valore atteso, varianza) sono date per note.

2.1 Glossario dei simboli ricorrenti

Per facilitare la lettura, raccogliamo qui i simboli matematici che appariranno più frequentemente.

Simbolo	Significato
$w \in \mathbb{R}^m$	Vettore dei parametri del modello (ciò che si vuole trovare)
N	Numero totale di esempi nel dataset di training
n_k	Dimensione del batch all'iterazione k (variabile con k)
$\mathcal{S}_k \subseteq \{1, \dots, N\}$	Sottoinsieme di indici selezionati all'iterazione k
$\ell(w; i)$	Perdita (errore) del modello w sull'esempio i
$J(w)$	Perdita media su tutto il dataset
$J_{\mathcal{S}}(w)$	Perdita media sul sottoinsieme $\mathcal{S}$
$\nabla J(w)$	Gradiente di J : vettore che indica la direzione di massima crescita
$\nabla^2 J(w)$	Hessiana di J : matrice che descrive la curvatura locale
λ, L	Costanti di convessità forte e di Lipschitz del gradiente
$\kappa = L/\lambda$	Numero di condizionamento: misura la "difficoltà" dell'ottimizzazione
$\theta \in (0, 1)$	Parametro di tolleranza per il controllo della varianza
α_k	Passo (learning rate) all'iterazione k

2.2 Prerequisiti matematici essenziali

Definizione

Funzione convessa. Una funzione $f : \mathbb{R}^m \rightarrow \mathbb{R}$ si dice *convessa* se, preso qualunque segmento tra due punti del suo dominio, il grafico della funzione sta *sotto* (o al più su) quel segmento. Formalmente, per ogni $x, y \in \mathbb{R}^m$ e $t \in [0, 1]$:

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y).$$

L'utilità delle funzioni convesse in ottimizzazione è fondamentale: **ogni minimo locale è anche globale.**

Definizione

Gradiente. Il gradiente $\nabla f(w) \in \mathbb{R}^m$ di una funzione differenziabile $f : \mathbb{R}^m \rightarrow \mathbb{R}$ nel punto w è il vettore delle derivate parziali:

$$\nabla f(w) = \left(\frac{\partial f}{\partial w_1}, \frac{\partial f}{\partial w_2}, \dots, \frac{\partial f}{\partial w_m} \right)^T.$$

Punta nella direzione di massima crescita di f ; pertanto $-\nabla f(w)$ è la direzione di *massima discesa*, usata negli algoritmi di ottimizzazione.

Definizione

Norma di una matrice. Data una matrice $A \in \mathbb{R}^{n \times n}$, la **norma indotta** (o norma operatoriale) è definita come:

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \sqrt{\lambda_{\max}(A^T A)}.$$

Per una matrice simmetrica definita positiva, $\|A\|_2 = \lambda_{\max}(A)$.

Nota Tecnica

Numero di condizionamento e convergenza. Le norme di matrice sono fondamentali per analizzare la stabilità e la convergenza degli algoritmi. Per una matrice A simmetrica definita positiva, il **numero di condizionamento** è definito come

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$

Questo numero misura la **sensibilità** del problema alla propagazione degli errori: più $\kappa(A)$ è grande, più piccole perturbazioni nei dati o negli arrotondamenti possono amplificarsi nella soluzione. Un problema con $\kappa(A)$ grande si dice **mal condizionato**, perché la soluzione è numericamente instabile e gli algoritmi iterativi (come il gradiente) convergono lentamente. Per una funzione quadratica $f(w) = \frac{1}{2}w^T A w$, nel metodo del gradiente con passo ottimale l'errore in valore di funzione decresce come

$$f(w_k) - f(w_*) \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2k} (f(w_0) - f(w_*)).$$

Nel nostro contesto, la matrice Hessiana $\nabla^2 J(w)$ ha autovalori compresi tra λ e L (per le ipotesi di convessità forte e Lipschitzianità), quindi il suo numero di condizionamento è $\kappa = L/\lambda$: nel Machine Learning κ può essere enorme, da qui la necessità di metodi più avanzati come Newton o il gradiente coniugato (Sezione 5).

Nota

Il significato di $\mathcal{V}$ (varianza della popolazione). Al passo k , con pesi correnti w_k , il vettore $\mathcal{V}$ misura quanto i singoli gradienti $\nabla \ell(w_k; i)$ differiscono dalla loro media $\nabla J(w_k)$:

$$\mathcal{V} := \frac{1}{N} \sum_{i=1}^N (\nabla \ell(w_k; i) - \nabla J(w_k))^2 \in \mathbb{R}^m,$$

dove il quadrato è inteso *componente per componente*. Se i gradienti individuali sono tra loro coerenti (bassa varianza), la media campionaria è un buon stimatore di $\nabla J(w_k)$; se invece sono molto dispersi, il batch deve essere grande

perché la stima sia affidabile. Questa osservazione è il punto di partenza della *Condizione di Controllo della Varianza* (CCV) introdotta nella Sezione 5.

2.3 Collegamento con la formulazione del problema

I concetti introdotti in questo capitolo – convessità, gradiente, norme, condizionamento e varianza – sono gli strumenti con cui il prossimo capitolo formalizza il problema di ottimizzazione empirica su larga scala. In particolare, la varianza della popolazione $\mathcal{V}$ e la sua stima campionaria forniranno il criterio per decidere, dinamicamente, quanti dati usare a ogni iterazione.

3 Formulazione del Problema

3.1 Apprendimento supervisionato su larga scala

Nell'apprendimento supervisionato, si dispone di un insieme di esempi etichettati $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, dove:

- $x_i \in \mathbb{R}^m$ è il vettore delle *feature* (caratteristiche) dell' i -esimo esempio,
- $y_i \in \mathcal{Y}$ è la corrispondente *etichetta* (valore da predire),
- $N \in \mathbb{N}$ è il numero totale di esempi, potenzialmente dell'ordine di 10^6 – 10^9 .

Si assume che le coppie (x_i, y_i) siano realizzazioni i.i.d. di una variabile casuale con distribuzione di probabilità congiunta P su $\mathcal{X} \times \mathcal{Y}$. L'obiettivo ideale è minimizzare il rischio ovvero l'attesa della loss sullo spazio $\mathcal{X} \times \mathcal{Y}$:

$$\min_{w \in \mathbb{R}^m} R(w) = \mathbb{E}_{(x,y) \sim P} \ell(f(w, x), y) = \int_{\mathcal{X} \times \mathcal{Y}} \ell(f(w; x), y) dP(x, y)$$

dove:

- $f(w; x) = w^T x$ è il *predittore lineare* parametrizzato da w ,
- $\ell : \mathbb{R} \times \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}$ è la *funzione di perdita* convessa.

Poiché P è ignota, si minimizza invece il **rischio empirico**:

Definizione

Funzione Obiettivo Empirica.

$$\min_{w \in \mathbb{R}^m} J(w) = \min_{w \in \mathbb{R}^m} \frac{1}{N} \sum_{i=1}^N \ell(w; i), \quad (3.1)$$

dove abbiamo usato la notazione abbreviata $\ell(w; i) \triangleq \ell(f(w; x_i), y_i)$

- $w \in \mathbb{R}^m$: parametri del modello (variabile di ottimizzazione),
- N : dimensione del dataset,
- $\ell(w; i)$: perdita del modello w sull'esempio i -esimo.

3.2 La sfida computazionale

Il gradiente esatto di J richiede la somma su tutti gli N esempi:

$$\nabla J(w) = \frac{1}{N} \sum_{i=1}^N \nabla \ell(w; i).$$

Il costo di ogni $\nabla \ell(w; i)$ è $O(m)$, siccome deve essere valutato N volte, ogni valutazione del gradiente di J in un punto w costa $O(Nm)$ operazioni. Per $N = 10^8$ e $m = 10^4$ si tratta di 10^{12} operazioni *per singola iterazione* ovvero un costo che non è praticabile.

3.3 Il trade-off

Il problema è che per minimizzare J dobbiamo calcolare $\nabla J(w)$ in tanti punti w , una volta per ogni iterazione, finché non troviamo il minimo; in particolare un singolo gradiente di J costa $O(Nm)$. Se N è enorme, una iterazione è già costosissima, e di iterazioni ne servono tante. Le strade possibili sono le seguenti: il metodo stocastico (SGD) usa un solo esempio per iterazione: il costo è basso, ma il gradiente è rumoroso, quindi servono tante iterazioni e la convergenza è lenta. Il batch completo usa tutti i dati: il gradiente è esatto, quindi servono poche iterazioni, ma ogni iterazione costa $O(Nm)$ ed è impraticabile. Il mini-batch fisso è un compromesso: usa un numero intermedio di esempi, bilanciando costo e accuratezza, ma la dimensione del batch è arbitraria e fissa.

La soluzione proposta è il metodo del gradiente a campione dinamico: si parte con un batch piccolo per fare progressi veloci, e lo si aumenta gradualmente quando serve precisione, in questo modo il costo computazionale si concentra solo dove serve.

3.4 Formulazione del problema

Definizione

Ottimizzazione batch dinamica: ad ogni iterazione k si seleziona un sottoinsieme $\mathcal{S}_k \subseteq \{1, \dots, N\}$ di dimensione $n_k = |\mathcal{S}_k|$ e si definisce la funzione

$$J_{\mathcal{S}_k}(w) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \ell(w; i).$$

- $\mathcal{S}_k$: campione casuale di indici all'iterazione k ,
- $n_k = |\mathcal{S}_k|$: dimensione del batch, *variabile* con k ,
- $J_{\mathcal{S}_k}(w)$: approssimazione stocastica dell'obiettivo reale $J(w)$.

L'algoritmo definisce una regola per aggiornare w_k e per scegliere n_{k+1} in funzione delle informazioni disponibili all'iterazione k .

3.5 Ipotesi su J

Per garantire le proprietà teoriche degli algoritmi, si assumono le seguenti condizioni.

Definizione

Convessità forte e liscezza: la funzione $J : \mathbb{R}^m \rightarrow \mathbb{R}$ è *uniformemente convessa* e ha gradiente *Lipschitz continuo*: esistono costanti $0 < \lambda \leq L$ tali che, per ogni $w, d \in \mathbb{R}^m$,

$$\lambda \|d\|_2^2 \leq d^T \nabla^2 J(w) d \leq L \|d\|_2^2.$$

- $\lambda > 0$: costante di convessità forte. Impone che $\nabla^2 J(w) \succeq \lambda I$ per ogni w , il che garantisce che J abbia un unico minimizzatore w^* .
- L : costante di Lipschitz del gradiente. Impone che $\|\nabla J(x) - \nabla J(y)\|_2 \leq L \|x - y\|_2$ per ogni x, y , il che equivale a $\nabla^2 J(w) \preceq LI$ per ogni w .

- $\kappa = L/\lambda$: numero di condizionamento (stima superiore). Per una data Hessiana $\nabla^2 J(w)$, il numero di condizionamento in norma 2 sarebbe $\lambda_{\max}(\nabla^2 J(w))/\lambda_{\min}(\nabla^2 J(w))$. Dato che gli autovalori sono ovunque compresi tra λ e L , si ha $\kappa \leq L/\lambda$, $\kappa = L/\lambda$ viene usato come stima superiore uniforme. Se $\kappa \gg 1$, il problema è mal condizionato e più difficile da ottimizzare.

Nota

In pratica, la convessità forte non è sempre verificata (ad esempio, la perdita logistica non è fortemente convessa). Tuttavia, è sufficiente aggiungere un termine di regolarizzazione $\frac{\gamma}{2} \|w\|^2$ alla funzione obiettivo J se è convessa, per indurre convessità forte con $\lambda = \gamma$.

Nota

Disuguaglianze fondamentali (si veda l'Appendice A.1 per la dimostrazione completa). Sia w_* l'unico minimo di J e, per semplificare le notazioni, poniamo $J(w_*) = 0$. Allora con le ipotesi strutturali esplicitate sopra valgono le seguenti disuguaglianze:

$$\|\nabla J(w)\|_2^2 \geq 2\lambda J(w), \quad J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|_2^2.$$

4 Lavori Correlati

Questo capitolo passa in rassegna la letteratura pertinente, organizzata per temi: metodi di ottimizzazione stocastica, metodi con campionamento dinamico, metodi di secondo ordine stocastici e regolarizzazione L_1 .

4.1 Metodi di ottimizzazione stocastica

Il punto di partenza di tutti i metodi stocastici è il lavoro pionieristico di Robbins e Monro [4], che ha introdotto il metodo del gradiente stocastico (SGD): ad ogni iterazione si stima il gradiente su un singolo esempio (o un piccolo batch) e si aggiorna w con un passo decrescente. Il costo per iterazione è indipendente da N , ma la varianza dello stimatore limita la velocità di convergenza e la precisione raggiungibile, come analizzato in dettaglio da Bottou e Bousquet [2] e nella rassegna più recente di Bottou, Curtis e Nocedal [3], che hanno formalizzato il compromesso tra costo per iterazione e velocità di convergenza su larga scala.

Per ridurre la varianza dello stimatore sono state proposte diverse famiglie di metodi. I metodi *a varianza ridotta* combinano la stima stocastica con una correzione periodica basata su un gradiente (quasi) esatto: SVRG di Johnson e Zhang [5] mantiene una copia dei parametri su cui ricalcola un gradiente completo a intervalli regolari, mentre SAGA di Defazio et al. [6] mantiene una tavola dei gradienti individuali e corregge la stima a ogni iterazione. Questi metodi ottengono una convergenza lineare per problemi fortemente convessi, ma richiedono di memorizzare o ricalcolare quantità globali e la dimensione del batch rimane comunque fissata a priori.

Tutti questi metodi condividono una caratteristica: la dimensione del batch è **fissa** o comunque determinata da una regola prestabilita, non da una condizione di accuratezza verificata durante l'esecuzione. È proprio questo il punto che il campionamento dinamico intende superare.

4.2 Campionamento dinamico

L'idea di far crescere la dimensione del batch *durante* l'ottimizzazione non è nuova, ma è stata formalizzata in modo sistematico da Byrd, Chin, Nocedal e Wu [1], il lavoro di riferimento di questa tesi. Gli autori

Approcci correlati adottano regole di crescita della dimensione del batch basate su criteri diversi. Ad esempio, una strategia semplice e diffusa è la *crescita geometrica* $n_k = \lceil a^k \rceil$, che però richiede la conoscenza (o una stima) del numero di condizionamento κ . Alcuni metodi propongono invece di adattare la dimensione del batch in modo euristico in base all'andamento della funzione obiettivo o della perdita di validazione, senza una garanzia teorica. Il vantaggio dell'approccio basato sulla varianza è duplice: da un lato fornisce una *giustificazione statistica* alla regola di aggiornamento, dall'altro si adatta automaticamente alla difficoltà locale del problema, senza richiedere la stima di κ .

4.3 Metodi di secondo ordine stocastici

I metodi del primo ordine convergono lentamente su problemi mal condizionati, poiché il numero di condizionamento κ del problema entra nel tasso di convergenza. I

metodi di Newton incorporano l'informazione di curvatura dell'Hessiana e raggiungono un tasso di convergenza locale quadratico (o superlineare), a costo di risolvere ad ogni iterazione un sistema lineare $H_k d = -g_k$; si veda il testo di Nocedal e Wright [7] per una trattazione completa.

Su larga scala la costruzione esplicita dell'Hessiana è impraticabile, e sono stati sviluppati metodi che ne usano soltanto *approssimazioni*. I metodi *inexact Newton* [12] risolvono il sistema di Newton in modo approssimato, controllando il residuo del risolutore interno tramite un parametro di forcing; il metodo del gradiente coniugato (CG) applicato al sistema di Newton, in forma *Hessian-free*, permette di calcolare i prodotti Hessiana-vettore senza costruire la matrice [13, 7]. In ambito stocastico, Byrd et al. [14] hanno proposto un metodo che sottocampiona sia il gradiente sia l'Hessiana, mostrando che un numero di iterazioni del CG che cresce con la precisione desiderata mantiene la convergenza. Il metodo Newton-CG presentato in questa tesi si colloca in questa linea di ricerca, con due innovazioni rispetto ai lavori precedenti: la dimensione del campione per il gradiente è regolata dinamicamente dalla CCV, e il criterio di arresto del CG interno è *adattivo*, basato sulla varianza campionaria dei prodotti Hessiana-vettore, in modo da non sprecare iterazioni interne quando l'approssimazione dell'Hessiana è limitata dal sottocampionamento.

4.4 Regularizzazione L_1 in ottimizzazione

La regolarizzazione L_1 produce soluzioni *sparse* ed è uno strumento fondamentale per l'interpretabilità dei modelli ad alta dimensionalità, a partire dal LASSO di Tibshirani [10]. Il termine di penalità $\nu \|w\|_1$ rende la funzione obiettivo non differenziabile, e i metodi classici del primo ordine devono essere adattati. Una tecnica basilare è il *soft-thresholding*, usato nei metodi proximali (ad esempio ISTA e FISTA di Beck e Teboulle [11]), che applica alla soluzione l'operatore di soglia $S_\nu(w_i) = \text{sign}(w_i) \max\{|w_i| - \nu, 0\}$.

Per i problemi che coinvolgono anche un termine liscio $J(w)$, un'alternativa efficace è rappresentata dai metodi a *active set* e dalle strategie di *ottimizzazione su facce ortanti*: si identifica l'insieme delle variabili che all'ottimo saranno nulle e si minimizza la funzione su tale faccia, dove il termine L_1 è differenziabile. Questa è la strategia seguita, ad esempio, da Byrd et al. [14] per problemi regolarizzati e adottata anche nel metodo Newton-CG- L_1 descritto in questa tesi, che combina l'identificazione dell'active set con l'Hessiana sottocampionata e la ricerca lineare proiettata.

osservano che, per garantire che la direzione di ricerca sia una direzione di discesa, è sufficiente che l'errore di approssimazione del gradiente sia controllato in norma relativa dalla tolleranza θ . Poiché l'errore non è osservabile direttamente, essi lo stimano tramite la *varianza campionaria* dei gradienti individuali sul batch, ottenendo una condizione di controllo della varianza (CCV): se la varianza stimata è troppo alta rispetto alla norma del gradiente, la dimensione del batch viene aumentata secondo una formula esplicita. L'analisi mostra che il numero totale di valutazioni di gradienti per raggiungere una precisione ε è $O(L/(\lambda\varepsilon))$, indipendente da N e competitivo con i migliori bound noti per SGD.

5 Algoritmi Proposti

5.1 Metodo del Gradiente a Campione Dinamico




Figura 5.1: Schema dell'algoritmo con controllo della varianza campionaria (CCV): il flusso principale segue inizializzazione $\rightarrow$ estrazione batch $\rightarrow$ calcolo di gradiente e varianza $\rightarrow$ verifica della CCV $\rightarrow$ line search $\rightarrow$ aggiornamento; quando la CCV è violata la dimensione del batch viene aumentata e si ripete l'estrazione.

5.1.1 Formulazione della dinamica del batch

Il metodo del gradiente (o *steepest descent*) è l'algoritmo di ottimizzazione più semplice: a ogni passo, si scende nella direzione opposta al gradiente. La variante proposta non usa il gradiente esatto $\nabla J(w_k)$ (troppo costoso), ma un'approssimazione

basata su un campione:

$$g_k = \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i).$$

Vogliamo sapere quando il campione $\mathcal{S}_k$ è abbastanza grande da garantire che $-g_k$ sia davvero una direzione di discesa per J .

La direzione $-g_k$ è di discesa per J se l'errore del gradiente $\|g_k - \nabla J(w_k)\|$ è piccolo rispetto a $\|g_k\|$ (dimostrazione sotto). Questo errore non è calcolabile esattamente, ma può essere *stimato* dalla varianza campionaria di $\{\nabla \ell(w_k; i)\}_{i \in \mathcal{S}_k}$: se i gradienti dei singoli esempi nel batch sono coerenti tra loro (bassa varianza), allora la loro media è un buon estimatore di $\nabla J(w_k)$.

Nel metodo del gradiente classico, si richiede che la direzione di discesa d_k soddisfi $\nabla J(w_k)^T d_k < 0$. Qui, poiché g_k è la direzione di discesa, che approssima $\nabla J(w_k)$, abbiamo $\nabla J(w_k)^T (-g_k) = -\nabla J(w_k)^T g_k$. Se g_k è sufficientemente vicino a $\nabla J(w_k)$ in norma relativa, allora $-g_k$ è effettivamente una direzione di discesa.

5.1.2 Formulazione matematica della condizione di accettazione

La direzione $d_k = -g_k$ è di discesa per J se l'errore del gradiente stimato rispetto a quello reale è sufficientemente piccolo in norma relativa:

$$\|g_k - \nabla J(w_k)\|_2 \leq \theta \|g_k\|_2, \quad \theta \in [0, 1).$$

Per capire perché questo garantisce la discesa, poniamo $e_k = g_k - \nabla J(w_k)$, cioè $g_k = \nabla J(w_k) + e_k$. Allora

$$\nabla J(w_k)^T g_k = \nabla J(w_k)^T (\nabla J(w_k) + e_k) = \|\nabla J(w_k)\|^2 + \nabla J(w_k)^T e_k.$$

Poiché $\nabla J(w_k) = g_k - e_k$, si ha anche

$$\nabla J(w_k)^T g_k = (g_k - e_k)^T g_k = \|g_k\|^2 - e_k^T g_k.$$

Per ogni numero reale x vale $x \geq -|x|$; quindi $e_k^T g_k \geq -|e_k^T g_k|$. Usando Cauchy-Schwarz, $|e_k^T g_k| \leq \|e_k\| \|g_k\|$, da cui $e_k^T g_k \geq -\|e_k\| \|g_k\|$. Sostituendo,

$$\nabla J(w_k)^T g_k \geq \|g_k\|^2 - \|e_k\| \|g_k\| = \|g_k\| (\|g_k\| - \|e_k\|).$$

Affinché $\nabla J(w_k)^T g_k > 0$ (cioè $-g_k$ sia di discesa) è sufficiente che $\|g_k\| - \|e_k\| > 0$, ovvero $\|e_k\| < \|g_k\|$. La condizione $\|e_k\| \leq \theta \|g_k\|$ con $\theta < 1$ implica $\|e_k\| < \|g_k\|$, dunque garantisce la discesa.




Figura 5.2: Rappresentazione geometrica della condizione di discesa: se il gradiente stimato g_k giace nel cono di tolleranza attorno al gradiente esatto $\nabla J(w_k)$, con errore $\|e_k\| = \|g_k - \nabla J(w_k)\| \leq \theta \|g_k\|$, allora $-g_k$ è una direzione di discesa per J .

Dimostrazione: Per dimostrare il fatto che g_k debba essere in norma vicino al gradiente, possiamo semplicemente prendere le disuguaglianze del Lemma 1 (dimoststrate nella Sezione 5.1.5); poi, per trovare l'angolo, prendiamo la disuguaglianza che abbiamo ottenuto per il doppio prodotto scalare tra il gradiente di $J(w_k)$ e g_k durante la dimostrazione del Lemma 1. Da lì sostituiamo la definizione di prodotto scalare e isoliamo il coseno, ottenendo un quoziente con una somma di quadrati al numeratore. Da quella somma di quadrati possiamo indebolire il termine, minorando tale somma con $2AB$ (grazie a $A^2 + B^2 \geq 2AB$), e poi da lì scriviamo il seno in funzione del coseno. Poiché il gradiente della popolazione totale $\nabla J(w_k)$ è ignoto, non è possibile valutare questa condizione in modo deterministico a ogni iterazione. È importante distinguere due livelli: la condizione puntuale $\|g_k - \nabla J(w_k)\| \leq \theta \|g_k\|$ è quella usata nel Teorema deterministico per garantire la discesa a ogni passo; la Condizione di Controllo della Varianza (CCV) che introdurremo tra poco è invece una condizione *in aspettativa*, sufficiente per l'analisi di convergenza in media ma non una garanzia puntuale. Il mini-batch $\mathcal{S}_k$ viene estratto casualmente dal dataset, rendendo g_k una variabile aleatoria con $\mathbb{E}_{\mathcal{S}_k}[g_k] = \nabla J(w_k)$. Passare dal controllo dell'errore puntuale $\|g_k - \nabla J(w_k)\|$ al controllo del suo valore atteso permette di aggirare l'ignoranza su $\nabla J(w_k)$:

$$\begin{aligned} \mathbb{E}_{\mathcal{S}_k} [\|g_k - \mathbb{E}_{\mathcal{S}_k}[g_k]\|_2^2] &= \mathbb{E}_{\mathcal{S}_k} \left[\sum_{j=1}^m \left(g_k^{(j)} - \mathbb{E}_{\mathcal{S}_k}[g_k^{(j)}] \right)^2 \right] \\ &= \sum_{j=1}^m \mathbb{E}_{\mathcal{S}_k} \left[\left(g_k^{(j)} - \mathbb{E}_{\mathcal{S}_k}[g_k^{(j)}] \right)^2 \right] \\ &= \sum_{j=1}^m \text{Var}_{\mathcal{S}_k} \left(g_k^{(j)} \right) = \|\text{Var}_{\mathcal{S}_k}(g_k)\|_1. \end{aligned}$$

Decomposizione della varianza dello stimatore. Definiamo la varianza della popolazione (vettore):

$$\mathcal{V} := \mathbb{E}_I [(\nabla \ell(w_k; I) - \mathbb{E}_I[\nabla \ell(w_k; I)])^2]$$

$$= \text{Var}_I(\nabla \ell(w_k; I)) = \frac{1}{N} \sum_{i=1}^N (\nabla \ell(w_k; i) - \nabla J(w_k))^2 \in \mathbb{R}^m,$$

dove il quadrato è inteso componente per componente, e distinguiamo I variabile aleatoria distribuita uniformemente in $\{1, \dots, N\}$ con i realizzazione di tale variabile.

Caso con reinserimento (indipendenza):

$$\begin{aligned} \text{Var}(g_k) &= \text{Var}\left(\frac{1}{n_k} \sum_{i \in S_k} \nabla \ell(w_k; i)\right) = \frac{1}{n_k^2} \sum_{i \in S_k} \text{Var}(\nabla \ell(w_k; i)) \\ &= \frac{1}{n_k^2} \underbrace{\text{Var}(\nabla \ell(w_k; i)) + \dots + \text{Var}(\nabla \ell(w_k; i))}_{n_k \text{ volte}} = \frac{\mathcal{V}}{n_k}. \end{aligned}$$

Anche qui la divisione va fatta componente per componente, siccome $\mathcal{V}$ è un vettore.

Caso senza reinserimento (dipendenza):

$$\text{Var}(\nabla J_{S_k}(w_k)) = \frac{\mathcal{V}}{n_k} \cdot \frac{N - n_k}{N - 1}.$$

La dimostrazione del fattore che si aggiunge qui è riportata nell'appendice. Per $N \gg n_k$ (condizione tipica nel Machine Learning), il fattore di correzione $\frac{N-n_k}{N-1}$ è circa 1, quindi $\text{Var}(g_k) \approx \mathcal{V}/n_k$: la condizione esatta si semplifica nella forma pratica riportata sotto.

Poiché $\mathcal{V}$ è ignoto, lo sostituiamo con la sua stima campionaria sul batch corrente:

$$\hat{\mathcal{V}} := \text{Var}_{i \in S_k}(\nabla \ell(w_k; i)) = \frac{1}{n_k - 1} \sum_{i \in S_k} (\nabla \ell(w_k; i) - \nabla J_{S_k}(w_k))^2.$$

Otteniamo così la Condizione di Controllo della Varianza (CCV):

Teorema

$$\frac{\|\hat{\mathcal{V}}\|_1}{n_k} \leq \theta^2 \|\nabla J_{S_k}(w_k)\|_2^2,$$

dove:

- $\|\cdot\|_1$ somma le varianze componente per componente,
- $\theta \in (0, 1)$ è la tolleranza impostata dall'utente,
- n_k è la dimensione del batch corrente.

Questa è la forma pratica per $N \gg n_k$ (corrispondente al limite $N \rightarrow \infty$ della condizione esatta che include il fattore $\frac{N-n_k}{N-1}$ derivata sopra). La condizione verifica che la varianza stimata dello stimatore sia sufficientemente piccola rispetto al gradiente corrente. Se non è soddisfatta, si aumenta n_k .

Nota

Dalla condizione di discesa (5.1.5) sappiamo che, per garantire che $-g_k$ sia una direzione di discesa, dobbiamo avere:

$$\|e_k\|_2 \leq \theta \|g_k\|_2, \quad e_k := g_k - \nabla J(w_k).$$

Elevando al quadrato entrambi i membri:

$$\|e_k\|_2^2 \leq \theta^2 \|g_k\|_2^2.$$

Poiché $\nabla J(w_k)$ è ignoto, non possiamo calcolare $\|e_k\|_2^2$ esattamente. Tuttavia, poiché $\mathbb{E}[g_k] = \nabla J(w_k)$, si ha:

$$\mathbb{E}[\|e_k\|_2^2] = \mathbb{E}[\|g_k - \mathbb{E}[g_k]\|_2^2] = \|\text{Var}(g_k)\|_1.$$

Stimando $\|\text{Var}(g_k)\|_1 \approx \frac{\|\hat{\mathcal{V}}\|_1}{n_k}$, la disuguaglianza in valore atteso diventa esattamente la CCV:

$$\frac{\|\hat{\mathcal{V}}\|_1}{n_k} \leq \theta^2 \|g_k\|_2^2.$$

Il parametro θ controlla la tolleranza sull'errore relativo $\|e_k\|/\|g_k\|$; elevandolo al quadrato si preserva la coerenza dimensionale con la varianza (che è un errore quadratico medio).

5.1.3 Regola di aggiornamento del batch

Se la condizione CCV non è soddisfatta, si stima la nuova dimensione minima del batch. Supponendo che, per aumenti gradualmente, la varianza campionaria e la norma del gradiente non cambino significativamente (la stima della varianza per predire la dimensione del batch k viene fatta con la varianza del batch $k-1$) si ottiene:¹

Definizione**Regola di Aggiornamento del Batch.**

$$n_k^{\text{new}} = \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|\nabla J_{\mathcal{S}_k}(w_k)\|_2^2} \right\rceil$$

dove $\hat{\mathcal{V}} := \text{Var}_{i \in \mathcal{S}_k}(\nabla \ell(w_k; i))$ è la varianza campionaria.

Nota

Quando siamo lontani dal minimo, $\|\nabla J_{\mathcal{S}_k}(w_k)\|_2^2$ è grande: la formula di aggiornamento del batch dà un n piccolo, quindi il batch resta piccolo. Avvicinandoci al minimo, il gradiente si azzerizza e il denominatore diventa piccolo: la formula impone un batch grande.

¹Nell'implementazione si aggiunge 1 per evitare che, quando il rapporto è esattamente intero, il batch non cresca, causando ripetute violazioni della CCV per fluttuazioni numeriche.

Il batch cresce automaticamente dove serve precisione.




Figura 5.3: Andamento qualitativo della dimensione del batch n_k in funzione dell'iterazione k per il metodo a campione dinamico (linea blu, con gradini in corrispondenza delle violazioni della CCV) confrontato con un batch fisso $n_k = 16$ (linea rossa tratteggiata). La strategia dinamica concentra la risorsa computazionale nelle iterazioni finali, dove il gradiente è piccolo e serve precisione.

5.1.4 Pseudocodice (Algoritmo)

Algoritmo

Gradiente a Campione Dinamico

Input: w_0 (punto iniziale), $\mathcal{S}_0$ (batch iniziale), $\theta \in (0, 1)$ (tolleranza).

Ripeti per ogni $k \in \mathbb{N}$ fino a convergenza:

1. $g_k = \nabla J_{\mathcal{S}_k}(w_k)$.
2. $\hat{\mathcal{V}} = \text{Var}_{i \in \mathcal{S}_k}(\nabla \ell(w_k; i)) = \frac{1}{n_k - 1} \sum_{i \in \mathcal{S}_k} (\nabla \ell_i(w_k) - g_k)^2$.
3. Se $\frac{\|\hat{\mathcal{V}}\|_1}{n_k} > \theta^2 \|g_k\|_2^2$ aumenta il batch: $n_k \leftarrow \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|g_k\|_2^2} \right\rceil$.
4. Esegui una line search: trova $\alpha_k > 0$ tale che $J_{\mathcal{S}_k}(w_k - \alpha_k g_k) < J_{\mathcal{S}_k}(w_k)$.
5. Aggiorna: $w_{k+1} = w_k - \alpha_k g_k$.
6. Seleziona un nuovo campione $\mathcal{S}_{k+1}$ di dimensione n_k (la nuova dimensione, eventualmente aumentata).

5.1.5 Convergenza deterministica

Consideriamo l'iterazione a passo fisso

$$w_{k+1} = w_k - \alpha g_k, \quad \alpha = \frac{1 - \theta}{L},$$

dove g_k è un'approssimazione di $\nabla J(w_k)$ che soddisfa la condizione di accuratezza

$$\|g_k - \nabla J(w_k)\|_2 \leq \theta \|g_k\|_2, \quad \theta \in [0, 1).$$

Lemma 1. *Sotto la condizione di accuratezza si hanno le seguenti disuguaglianze:*

$$\|\nabla J(w_k)\| \leq (1 + \theta)\|g_k\|, \quad \|\nabla J(w_k)\| \geq (1 - \theta)\|g_k\|.$$

Inoltre,

$$\nabla J(w_k)^T g_k \geq (1 - \theta)\|g_k\|^2.$$

Dimostrazione. Poniamo $e_k = g_k - \nabla J(w_k)$. Allora per definizione $\nabla J(w_k) = g_k - e_k$.

Prima dimostrazione: $\|\nabla J(w_k)\| \leq (1 + \theta)\|g_k\|$. Applicando la disuguaglianza triangolare $\|x + y\| \leq \|x\| + \|y\|$ con $x = g_k$ e $y = -e_k$:

$$\|\nabla J(w_k)\| = \|g_k + (-e_k)\| \leq \|g_k\| + \|-e_k\| = \|g_k\| + \|e_k\|.$$

Dalla condizione di accuratezza, $\|e_k\| \leq \theta\|g_k\|$. Sostituendo:

$$\|\nabla J(w_k)\| \leq \|g_k\| + \theta\|g_k\| = (1 + \theta)\|g_k\|.$$

Seconda dimostrazione: $\|\nabla J(w_k)\| \geq (1 - \theta)\|g_k\|$. Partiamo dalla disuguaglianza triangolare standard $\|a\| = \|a - b + b\| \leq \|a - b\| + \|b\|$, valida per ogni a, b . Ponendo $a = g_k$ e $b = e_k$:

$$\|g_k\| \leq \|g_k - e_k\| + \|e_k\| = \|\nabla J(w_k)\| + \|e_k\|.$$

Quindi $\|\nabla J(w_k)\| \geq \|g_k\| - \|e_k\|$. Sostituendo $\|e_k\| \leq \theta\|g_k\|$:

$$\|\nabla J(w_k)\| \geq \|g_k\| - \theta\|g_k\| = (1 - \theta)\|g_k\|.$$

Dimostrazione di $\nabla J(w_k)^T g_k \geq (1 - \theta)\|g_k\|^2$. Eleviamo al quadrato la condizione di accuratezza:

$$\|g_k - \nabla J(w_k)\|^2 \leq \theta^2 \|g_k\|^2.$$

Sviluppando il quadrato del binomio:

$$\|g_k\|^2 - 2\nabla J(w_k)^T g_k + \|\nabla J(w_k)\|^2 \leq \theta^2 \|g_k\|^2.$$

Isoliamo il termine con il prodotto scalare portando gli altri termini a destra:

$$-2\nabla J(w_k)^T g_k \leq \theta^2 \|g_k\|^2 - \|g_k\|^2 - \|\nabla J(w_k)\|^2 = (\theta^2 - 1)\|g_k\|^2 - \|\nabla J(w_k)\|^2.$$

Moltiplichiamo entrambi i membri per -1 :

$$2\nabla J(w_k)^T g_k \geq (1 - \theta^2)\|g_k\|^2 + \|\nabla J(w_k)\|^2.$$

Utilizziamo ora la disuguaglianza $\|\nabla J(w_k)\| \geq (1-\theta)\|g_k\|$ dimostrata in precedenza, elevandola al quadrato:

$$\|\nabla J(w_k)\|^2 \geq (1-\theta)^2\|g_k\|^2.$$

Sostituiamo questa stima nella disuguaglianza del Lemma:

$$2\nabla J(w_k)^T g_k \geq (1-\theta^2)\|g_k\|^2 + (1-\theta)^2\|g_k\|^2.$$

Raccogliamo $\|g_k\|^2$ e semplifichiamo i coefficienti:

$$\begin{aligned} 2\nabla J(w_k)^T g_k &\geq [(1-\theta^2) + (1-2\theta+\theta^2)]\|g_k\|^2 \\ &= [1-\theta^2 + 1-2\theta+\theta^2]\|g_k\|^2 = 2(1-\theta)\|g_k\|^2. \end{aligned}$$

Dividendo entrambi i membri per 2 si ottiene la tesi:

$$\nabla J(w_k)^T g_k \geq (1-\theta)\|g_k\|^2.$$

□

Teorema

Teorema di Convergenza Deterministica. Sia $J : \mathbb{R}^m \rightarrow \mathbb{R}$ una funzione λ -fortemente convessa ($\nabla^2 J(w) \succeq \lambda I$ per ogni w) e con gradiente L -Lipschitz ($\nabla^2 J(w) \preceq LI$ per ogni w). Si assuma che a ogni iterazione valga la condizione di accuratezza e si scelga il passo $\alpha = \frac{1-\theta}{L}$. Allora

$$\underbrace{J(w_{k+1}) - J(w^*)}_{=:\varepsilon_{k+1}} \leq \left(1 - \frac{(1-\theta)\lambda}{L}\right) \underbrace{(J(w_k) - J(w^*))}_{=:\varepsilon_k}.$$

Di conseguenza:

- Il fattore di riduzione per iterazione è $\rho = 1 - \frac{(1-\theta)\lambda}{L} \in (0, 1)$;
- Il numero di iterazioni per ottenere $J(w_k) - J(w^*) \leq \varepsilon$ è al più

$$k \geq \frac{L}{(1-\theta)\lambda} \log\left(\frac{J(w_0) - J(w^*)}{\varepsilon}\right) = O\left(\frac{L}{\lambda} \log \frac{1}{\varepsilon}\right).$$

Nota

Confronto con il risultato di Nocedal e Wright [7]. Il fattore di contrazione qui ottenuto è $1 - \frac{(1-\theta)\lambda}{L}$, mentre Nocedal e Wright [7] dimostrano $1 - \frac{(1-\theta)\lambda}{2L}$ (eq. 4.9). Ora $1 - \frac{(1-\theta)\lambda}{L} < 1 - \frac{(1-\theta)\lambda}{2L}$, cioè abbiamo un fattore di contrazione più piccolo (convergenza più rapida). Esso è dovuto all'uso della disuguaglianza di Polyak–Łojasiewicz nella forma forte $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$ (dimostrata nell'appendice A.1), invece della forma più debole $\|\nabla J(w)\|^2 \geq \lambda(J(w) - J(w_*))$ (eq. 4.4–4.5) utilizzata da Nocedal e Wright [7]. La forma più forte è resa possibile dall'ipotesi di convessità forte ($\nabla^2 J \succeq \lambda I$), che implica direttamente $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$ quando $J(w_*) = 0$.

Dimostrazione. Per semplificare poniamo $J(w^*) = 0$ (altrimenti si definisce $\tilde{J}(w) = J(w) - J(w^*)$, che soddisfa le stesse ipotesi di convessità e ha minimo nullo).

Per la L -lipschitzianità del gradiente, vale la seguente maggiorazione (conseguenza del teorema di Taylor con resto di Lagrange):

$$J(w_{k+1}) \leq J(w_k) + \nabla J(w_k)^T (w_{k+1} - w_k) + \frac{L}{2} \|w_{k+1} - w_k\|^2.$$

Sostituendo $\alpha = \frac{1-\theta}{L}$ e $w_{k+1} = w_k - \alpha g_k \Rightarrow w_{k+1} - w_k = -\alpha g_k$:

$$J(w_{k+1}) \leq J(w_k) - \frac{1-\theta}{L} \nabla J(w_k)^T g_k + \frac{L}{2} \left(\frac{1-\theta}{L}\right)^2 \|g_k\|^2.$$

Semplifichiamo il coefficiente del termine quadratico:

$$\frac{L}{2} \left(\frac{1-\theta}{L}\right)^2 = \frac{L}{2} \cdot \frac{(1-\theta)^2}{L^2} = \frac{(1-\theta)^2}{2L}.$$

Quindi:

$$J(w_{k+1}) \leq J(w_k) - \underbrace{\frac{1-\theta}{L} \nabla J(w_k)^T g_k + \frac{(1-\theta)^2}{2L} \|g_k\|^2}_{:=S}.$$

Moltiplichiamo la disuguaglianza del Lemma per $\frac{1-\theta}{2L}$:

$$\frac{1-\theta}{2L} \cdot 2 \nabla J(w_k)^T g_k \geq \frac{1-\theta}{2L} \left[(1-\theta^2) \|g_k\|^2 + \|\nabla J(w_k)\|^2 \right].$$

Semplificando il membro sinistro:

$$\frac{1-\theta}{L} \nabla J(w_k)^T g_k \geq \frac{(1-\theta)(1-\theta^2)}{2L} \|g_k\|^2 + \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Riorganizziamo la disuguaglianza appena scritta per isolare $-\frac{1-\theta}{L} \nabla J(w_k)^T g_k$, che compare nella definizione di S :

$$-\frac{1-\theta}{L} \nabla J(w_k)^T g_k \leq -\frac{(1-\theta)(1-\theta^2)}{2L} \|g_k\|^2 - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Inseriamo questa disuguaglianza nella definizione di S :

$$J(w_{k+1}) \leq J(w_k) - \frac{(1-\theta)(1-\theta^2)}{2L} \|g_k\|^2 - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2 + \frac{(1-\theta)^2}{2L} \|g_k\|^2.$$

Raccogliamo i coefficienti di $\|g_k\|^2$:

$$-\frac{(1-\theta)(1-\theta^2)}{2L} + \frac{(1-\theta)^2}{2L} = -\frac{1-\theta}{2L} \left[(1-\theta^2) - (1-\theta) \right].$$

Calcoliamo la differenza tra parentesi:

$$(1-\theta^2) - (1-\theta) = 1-\theta^2-1+\theta = \theta-\theta^2 = \theta(1-\theta).$$

Quindi:

$$-\frac{1-\theta}{2L} \cdot \theta(1-\theta) = -\frac{\theta(1-\theta)^2}{2L}.$$

La disuguaglianza diventa:

$$J(w_{k+1}) \leq J(w_k) - \frac{\theta(1-\theta)^2}{2L} \|g_k\|^2 - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Poiché $\frac{\theta(1-\theta)^2}{2L} \|g_k\|^2 \geq 0$, il termine $-\frac{\theta(1-\theta)^2}{2L} \|g_k\|^2$ è minore o uguale a zero, trascurarlo può solo aumentare il membro destro e la disuguaglianza rimane valida:

$$J(w_{k+1}) \leq J(w_k) - \frac{1-\theta}{2L} \|\nabla J(w_k)\|^2.$$

Infine, dalla disuguaglianza di convessità forte dimostrata nell'Appendice A.1,

$$\|\nabla J(w_k)\|^2 \geq 2\lambda J(w_k) \quad (\text{valida con } J(w_*) = 0),$$

si ottiene:

$$S \leq -\frac{1-\theta}{2L} \cdot 2\lambda J(w_k) = -\frac{\lambda(1-\theta)}{L} J(w_k).$$

Sostituendo nella disuguaglianza che definisce S :

$$J(w_{k+1}) \leq J(w_k) - \frac{\lambda(1-\theta)}{L} J(w_k) = \left(1 - \frac{\lambda(1-\theta)}{L}\right) J(w_k).$$

Applicando la disuguaglianza appena dimostrata ricorsivamente:

$$J(w_k) \leq \rho^k J(w_0), \quad \text{dove } \rho = 1 - \frac{\lambda(1-\theta)}{L}.$$

Poiché $\theta \in [0, 1)$, $\lambda > 0$ e $L > 0$, si ha $\rho \in (0, 1)$.

Imponiamo $J(w_k) \leq \varepsilon$:

$$\rho^k J(w_0) \leq \varepsilon \implies k \geq \frac{\log(J(w_0)/\varepsilon)}{\log(1/\rho)}.$$

Usando $\log(1/\rho) \geq 1 - \rho$:

$$1 - \rho = \frac{\lambda(1-\theta)}{L},$$

quindi:

$$k \geq \frac{L}{\lambda(1-\theta)} \log\left(\frac{J(w_0)}{\varepsilon}\right).$$

Questa è la stima del numero di iterazioni necessarie per ridurre l'errore al di sotto di ε . $\square$

5.1.6 Analisi Stocastica e Complessità del Metodo

Nell'analisi deterministica abbiamo assunto la condizione di accuratezza

$$\|g_k - \nabla J(w_k)\|_2 \leq \theta \|g_k\|_2, \quad \theta \in [0, 1), \quad (5.1)$$

garantendo che $-g_k$ sia una direzione di discesa per J e stabilendo la convergenza lineare (Teorema di Convergenza Deterministica).

Nel caso stocastico, $g_k = \nabla J_{\mathcal{S}_k}(w_k)$ è calcolato su un campione casuale $\mathcal{S}_k$ di dimensione n_k , rendendo g_k una variabile aleatoria. La condizione (5.1) non può essere garantita con probabilità 1 per ogni iterazione. Dobbiamo quindi sviluppare un'analisi in aspettativa, tenendo conto che n_k può variare nel corso delle iterazioni.

Impostazione del problema stocastico Definiamo

$$g_k := \nabla J_{\mathcal{S}_k}(w_k) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i), \quad n_k := |\mathcal{S}_k|. \quad (5.2)$$

Per ogni w_k fissato, g_k è uno stimatore non distorto:

$$\mathbb{E}[g_k \mid w_k] = \nabla J(w_k). \quad (5.3)$$

Introduciamo l'ipotesi fondamentale di limitatezza della varianza dei gradienti individuali. Si noti che questa è un'ipotesi forte, necessaria per l'analisi di complessità teorica; in pratica può essere rilassata, ad esempio richiedendo la limitatezza solo in un intorno del minimo o utilizzando stime locali della varianza.

Nota

Ipotesi di limitatezza della varianza. $\exists \omega \in \mathbb{R}, \omega > 0$ tale che $\forall w_k$,

$$\|\text{Var}(\nabla \ell(w_k; I))\|_1 \leq \omega, \quad (5.4)$$

dove $\text{Var}(\nabla \ell(w_k; I)) := \mathbb{E}_I[(\nabla \ell(w_k; I) - \nabla J(w_k))^2]$ è inteso componente per componente.

Dal Lemma 1 abbiamo $\|\nabla J(w_k)\| \geq (1 - \theta)\|g_k\|$, da cui

$$\|g_k\|^2 \leq \frac{1}{(1 - \theta)^2} \|\nabla J(w_k)\|^2.$$

Dall'Appendice A.1 (disuguaglianza $J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|^2$) otteniamo $\|\nabla J(w_k)\|^2 \leq \frac{2L^2}{\lambda} J(w_k)$. Combinando con la convergenza lineare del Teorema di Convergenza Deterministica, $J(w_k) \leq (1 - \frac{(1-\theta)\lambda}{L})^k J(w_0)$, segue

$$\|g_k\|^2 \leq \frac{1}{(1 - \theta)^2} \frac{2L^2}{\lambda} J(w_k) \leq \frac{1}{(1 - \theta)^2} \frac{2L^2 J(w_0)}{\lambda} \left(1 - \frac{(1 - \theta)\lambda}{L}\right)^k. \quad (5.5)$$

Va osservato che questo bound ha natura circolare: la convergenza lineare del Teorema di Convergenza Deterministica, usata nella (5.5), richiede a sua volta che la CCV sia soddisfatta a ogni iterazione, ed è proprio questo che si intende garantire con la scelta di n_k . La (5.5) va quindi intesa come una stima guida/euristica per la scelta di n_k , non come una derivazione rigorosa, in analogia con quanto fatto nel lavoro originale [1]. Questo bound adotta il tasso deterministico $\rho = 1 - \frac{(1-\theta)\lambda}{L}$ usato nel teorema precedente. Si noti che questo tasso è più favorevole (più rapido) rispetto a quello ottenuto da Byrd et al. [1], che presentano un fattore $1/2$ aggiuntivo a denominatore a causa dell'uso di una disuguaglianza più debole. Dalla Condizione di Controllo della Varianza (CCV):

$$\frac{\|\overbrace{\text{Var}_{i \in \mathcal{S}_k}(\nabla \ell(w_k; i))}^{\hat{v}}\|_1}{n_k} \leq \theta^2 \|g_k\|^2. \quad (5.6)$$

Per garantire la (5.6) in media, dobbiamo scegliere n_k sufficientemente grande. Usando l'ipotesi (5.4), la condizione (5.6) è sicuramente soddisfatta se

$$\frac{\omega}{n_k} \leq \theta^2 \|g_k\|^2,$$

ovvero se

$$n_k \geq \frac{\omega}{\theta^2 \|g_k\|^2}. \quad (5.7)$$

Osserviamo che la (5.5) fornisce un *bound superiore* su $\|g_k\|^2$ che decresce geometricamente con tasso $\rho = 1 - (1 - \theta)\lambda/L$. Poiché nella (5.7) la dimensione del batch è inversamente proporzionale a $\|g_k\|^2$, al restringersi del gradiente n_k deve crescere per evitare che il rumore domini la discesa. Per stimare la velocità di crescita necessaria, usiamo il bound (5.5) per valutare il *tasso massimo* con cui il denominatore di (5.7)

può restringersi: sostituendo la (5.5) nella (5.7) si ottiene una condizione guida sulla crescita di n_k ,

$$n_k \geq \frac{\omega}{\theta^2 \cdot \frac{1}{(1-\theta)^2} \frac{2L^2 J(w_0)}{\lambda} \left(1 - \frac{(1-\theta)\lambda}{L}\right)^k} = \frac{\omega(1-\theta)^2 \lambda}{\theta^2 2L^2 J(w_0)} \left(1 - \frac{(1-\theta)\lambda}{L}\right)^{-k}. \quad (5.8)$$

Pertanto, per far decadere il rumore almeno alla stessa velocità con cui l'errore deterministico si riduce, n_k deve crescere geometricamente come

$$n_k \geq O\left(\left(1 - \frac{(1-\theta)\lambda}{L}\right)^{-k}\right).$$

Nell'analisi stocastica imponiamo quindi:

$$n_k = \lceil a^k \rceil, \quad a > 1. \quad (5.9)$$

Le ipotesi si dividono in due categorie complementari:

- **Ipotesi strutturali su J** ($\lambda I \preceq \nabla^2 J(w) \preceq LI$): garantiscono la convergenza lineare se la direzione di discesa è accurata (Teorema di Convergenza Deterministica), e forniscono la maggiorazione di Taylor (A.12), che sarà usata per derivare la disuguaglianza di convergenza in aspettativa.
- **Ipotesi stocastica** (5.4): garantisce che la varianza dello stimatore g_k decada come $\|\text{Var}(g_k)\|_1 \leq \omega/n_k$, rendendo il rumore controllabile aumentando il batch.

Iterazione stocastica a passo fisso Consideriamo l'iterazione

$$w_{k+1} = w_k - \frac{1}{L} g_k. \quad (5.10)$$

Nell'analisi stocastica si adotta il passo $1/L$, più lungo del passo deterministico $(1-\theta)/L$ poiché il fattore $(1-\theta)$ non è necessario quando il controllo dell'errore è affidato alla crescita del batch. Questo produce un tasso di contrazione deterministico $\alpha = 1 - \lambda/L$ più piccolo rispetto a $1 - (1-\theta)\lambda/L$, e quindi un reciproco $(1 - \lambda/L)^{-1}$ più grande: il vincolo su a ammette un bound superiore più alto.

Usando la (A.12) con $y = w_{k+1}$ e $w = w_k$:

$$J(w_{k+1}) \leq J(w_k) + \nabla J(w_k)^T (w_{k+1} - w_k) + \frac{L}{2} \|w_{k+1} - w_k\|^2. \quad (5.11)$$

Sostituendo $w_{k+1} - w_k = -\frac{1}{L} g_k$:

$$J(w_{k+1}) \leq J(w_k) - \frac{1}{L} \nabla J(w_k)^T g_k + \frac{1}{2L} \|g_k\|^2. \quad (5.12)$$

Passando al valore atteso condizionato a w_k :

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{L} \nabla J(w_k)^T \mathbb{E}[g_k \mid w_k] + \frac{1}{2L} \mathbb{E}[\|g_k\|^2 \mid w_k].$$

Usando (5.3):

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{L} \|\nabla J(w_k)\|^2 + \frac{1}{2L} \mathbb{E}[\|g_k\|^2 \mid w_k]. \quad (5.13)$$

Per esprimere $\mathbb{E}[\|g_k\|^2 \mid w_k]$, utilizziamo l'identità $\mathbb{E}[\|X\|^2] = \|\text{Var}(X)\|_1 + \|\mathbb{E}[X]\|^2$ (valida componente per componente). Applicandola a $X = g_k$:

$$\mathbb{E}[\|g_k\|^2 \mid w_k] = \|\text{Var}(g_k)\|_1 + \|\nabla J(w_k)\|^2. \quad (5.14)$$

Sostituendo in (5.13):

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{2L} \|\nabla J(w_k)\|^2 + \frac{1}{2L} \|\text{Var}(g_k)\|_1. \quad (5.15)$$

Dalla formula per la varianza di una media campionaria (derivata in precedenza) e dall'ipotesi (5.4):

$$\|\text{Var}(g_k)\|_1 \leq \frac{\|\text{Var}(\nabla \ell(w_k; i))\|_1}{n_k} \leq \frac{\omega}{n_k}. \quad (5.16)$$

Sostituendo in (5.15):

$$\mathbb{E}[J(w_{k+1}) \mid w_k] \leq J(w_k) - \frac{1}{2L} \|\nabla J(w_k)\|^2 + \frac{\omega}{2Ln_k}. \quad (5.17)$$

Dalla λ -convessità forte di J (disuguaglianza di PL dimostrata nell'Appendice A.1):

$$\|\nabla J(w_k)\|^2 \geq 2\lambda(J(w_k) - J(w_*)). \quad (5.18)$$

Sostituendo in (5.17):

$$\mathbb{E}[J(w_{k+1}) - J(w_*) \mid w_k] \leq \left(1 - \frac{\lambda}{L}\right) (J(w_k) - J(w_*)) + \frac{\omega}{2Ln_k}. \quad (5.19)$$

Prendendo il valore atteso totale e ponendo $\varepsilon_k := \mathbb{E}[J(w_k) - J(w_*)]$:

$$\varepsilon_{k+1} \leq \left(1 - \frac{\lambda}{L}\right) \varepsilon_k + \frac{\omega}{2Ln_k}. \quad (5.20)$$

Questa è l'equazione fondamentale che governa la convergenza in aspettativa.

Possiamo ora enunciare il teorema di convergenza in aspettativa.

Teorema

Teorema 5.1 (Convergenza in aspettativa). Posto $\alpha := 1 - \frac{\lambda}{L}$ e $\beta := \frac{\omega}{2L}$, per ogni $k \geq 0$ vale

$$\mathbb{E}[J(w_k) - J(w_*)] \leq \alpha^k \varepsilon_0 + \beta a \frac{\alpha^k - a^{-k}}{\alpha a - 1}, \quad (5.21)$$

dove il rapporto va inteso nel senso dei limiti se $\alpha a = 1$. Di conseguenza, posto $\rho := \max\{\alpha, 1/a\}$, se $a > 1$ si ha $\rho < 1$ e esiste una costante $C =$

$C(\varepsilon_0, \omega, \lambda, L, a)$ tale che

$$\mathbb{E}[J(w_k) - J(w_*)] \leq C\rho^k \quad \forall k \geq 0.$$

Nota

Differenza rispetto al lavoro originale [1] (Teorema 4.2). Il paper ottiene $\rho = \max\{1 - \lambda/(4L), 1/a\}$ e $C = \max\{J(w_0) - J(w_*), 2\omega/\lambda\}$ tramite un argomento induttivo che introduce un fattore $\frac{1}{2}$ aggiuntivo. La dimostrazione qui presentata ottiene invece $\rho = \max\{1 - \lambda/L, 1/a\}$ risolvendo esplicitamente la ricorrenza, il che dà un tasso deterministico $\alpha = 1 - \lambda/L$ più conservativo. Di conseguenza, l'intervallo ammissibile per a nel Corollario 5.2 è $(1, (1 - \lambda/L)^{-1}]$ anziché $(1, (1 - \lambda/(4L))^{-1}]$ come nel paper.

Dimostrazione. Iterazione della ricorrenza e forma chiusa

Dalla (5.20) possiamo esplicitare l'andamento di ε_k . Scriviamo i primi passi:

$$\begin{aligned} \varepsilon_1 &\leq \alpha\varepsilon_0 + \beta, \\ \varepsilon_2 &\leq \alpha\varepsilon_1 + \beta a^{-1} \leq \alpha(\alpha\varepsilon_0 + \beta) + \beta a^{-1} = \alpha^2\varepsilon_0 + \alpha\beta + \beta a^{-1}, \\ \varepsilon_3 &\leq \alpha\varepsilon_2 + \beta a^{-2} \leq \alpha(\alpha^2\varepsilon_0 + \alpha\beta + \beta a^{-1}) + \beta a^{-2} \\ &= \alpha^3\varepsilon_0 + \alpha^2\beta + \alpha\beta a^{-1} + \beta a^{-2}. \end{aligned}$$

Il pattern generale è

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \beta \sum_{j=0}^{k-1} \alpha^{k-1-j} a^{-j}. \quad (5.22)$$

Calcoliamo la somma geometrica finita:

$$S_k := \sum_{j=0}^{k-1} \alpha^{k-1-j} a^{-j}.$$

Ponendo $i = k - 1 - j$, si ha:

$$S_k = \sum_{i=0}^{k-1} \alpha^i a^{-(k-1-i)} = a^{-(k-1)} \sum_{i=0}^{k-1} (\alpha a)^i.$$

Se $\alpha a \neq 1$, la progressione geometrica dà:

$$S_k = a^{-(k-1)} \frac{1 - (\alpha a)^k}{1 - \alpha a} = \frac{a(\alpha^k - a^{-k})}{\alpha a - 1}. \quad (5.23)$$

Sostituendo (5.23) in (5.22) si ottiene la forma chiusa:

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \beta a \frac{\alpha^k - a^{-k}}{\alpha a - 1}, \quad (5.24)$$

che è la (5.24), cioè la (5.21) del teorema. Questa espressione è valida per $\alpha a \neq 1$; nel caso $\alpha a = 1$ si intende per limite e si ottiene $\varepsilon_k \leq (\varepsilon_0 + \beta k/\alpha) \rho^k$ (con $\rho = \alpha$), che porta allo stesso tasso esponenziale a meno di un fattore polinomiale.

Deduzione del tasso di convergenza Dalla (5.21) possiamo ricavare il tasso di convergenza studiando il comportamento asintotico. Si presentano tre casi.

- **Caso $\alpha a > 1$:** allora $\alpha > 1/a$, quindi α^k decresce più lentamente di a^{-k} ; il termine α^k domina. Trascurando a^{-k} rispetto a α^k :

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \frac{\beta a}{\alpha a - 1} \alpha^k = \left(\varepsilon_0 + \frac{\beta a}{\alpha a - 1} \right) \alpha^k.$$

Quindi $\rho = \alpha = 1 - \lambda/L$. Possiamo trascurare il fattore a^{-k} perché è un o -piccolo rispetto ad α^k : infatti $\lim_{k \rightarrow \infty} \frac{a^{-k}}{\alpha^k} = \lim_{k \rightarrow \infty} \left(\frac{1/a}{\alpha} \right)^k = \lim_{k \rightarrow \infty} \left(\frac{1}{\alpha a} \right)^k$ poiché $\alpha a > 1$, si ha $0 < \frac{1}{\alpha a} < 1 \implies \lim_{k \rightarrow \infty} \left(\frac{1}{\alpha a} \right)^k = 0 \implies \frac{a^{-k}}{\alpha^k} \rightarrow 0$

- **Caso $\alpha a < 1$:** allora $\alpha < 1/a$, quindi a^{-k} decresce più lentamente di α^k ; il termine a^{-k} domina. Trascurando α^k rispetto a a^{-k} :

$$\varepsilon_k \leq \frac{\beta a}{1 - \alpha a} a^{-k} = \frac{\beta a}{1 - \alpha a} \left(\frac{1}{a} \right)^k.$$

Quindi $\rho = 1/a$. Possiamo trascurare il fattore α^k perché è un o -piccolo rispetto a a^{-k} : infatti $\lim_{k \rightarrow \infty} \frac{\alpha^k}{a^{-k}} = \lim_{k \rightarrow \infty} \frac{\alpha^k}{(1/a)^k} = \lim_{k \rightarrow \infty} (\alpha a)^k$ poiché $0 < \alpha a < 1$, si ha $0 < \alpha a < 1 \implies \lim_{k \rightarrow \infty} (\alpha a)^k = 0 \implies \frac{\alpha^k}{a^{-k}} \rightarrow 0$.

- **Caso $\alpha a = 1$:** allora $\alpha = 1/a$. La somma geometrica si riduce a $S_k = k a^{-(k-1)}$, da cui:

$$\varepsilon_k \leq \alpha^k \varepsilon_0 + \beta k a^{-(k-1)} = (\varepsilon_0 + \beta k / \alpha) \rho^k, \quad \rho := \alpha = 1/a.$$

Poiché per ogni $\rho' \in (\rho, 1)$ esiste una costante C (indipendente da k) tale che $k \rho^k \leq C(\rho')^k$, la tesi vale con tasso ρ' .

Quindi per $\alpha a > 1$ si ottiene $\rho = \alpha$ e $C = \varepsilon_0 + \frac{\beta a}{\alpha a - 1}$; se $\alpha a < 1$ si ottiene $\rho = 1/a$ e $C = \varepsilon_0 + \frac{\beta a}{1 - \alpha a}$ (o, più strettamente, $C = \max\{\varepsilon_0, \frac{\beta a}{1 - \alpha a}\}$).

In tutti i casi si ha:

$$\varepsilon_k \leq C \rho^k, \quad \rho := \max\{\alpha, 1/a\}, \quad (5.25)$$

per una opportuna costante $C = C(\varepsilon_0, \omega, \lambda, L, a)$.

□

Corollario sulla complessità totale

Corollario

Corollario 5.2 (Complessità totale). Supponiamo $n_k = \lceil a^k \rceil$ con

$$a \in \left(1, \underbrace{\left(1 - \frac{\lambda}{L} \right)^{-1}}_{1/\alpha} \right],$$

e che (5.4) valga per tutti i w_k . Allora il numero totale di valutazioni dei

gradienti $\nabla \ell(w; i)$ necessarie per ottenere $\mathbb{E}[J(w_k) - J(w_*)] \leq \varepsilon$ è

$$O\left(\frac{L}{\lambda \varepsilon}\right), \quad (5.26)$$

e il lavoro totale dell'algoritmo (5.10) con campionamento dinamico (5.9) è

$$\mathcal{T}_{\text{tot}} = O\left(\frac{Lm}{\lambda \varepsilon} \max\left\{J(w_0) - J(w_*), \frac{\omega}{\lambda}\right\}\right), \quad (5.27)$$

dove m è il numero di variabili.

Dimostrazione. Con la scelta $a \leq \alpha^{-1}$, si ha $\rho = 1/a$. Dalla (5.21), il numero di iterazioni k necessario per ottenere $\mathbb{E}[J(w_k) - J(w_*)] \leq \varepsilon$ soddisfa $a^k \geq C/\varepsilon$. Poiché $\rho = 1/a$, la condizione $C\rho^k \leq \varepsilon$ equivale a $a^k \geq C/\varepsilon$. Il numero di iterazioni necessario soddisfa quindi $a^k = \Theta(C/\varepsilon)$. Il costo in valutazioni del gradiente è:

$$\sum_{j=0}^{k-1} n_j \leq 2 \sum_{j=0}^{k-1} a^j = 2 \cdot \frac{a^k - 1}{a - 1} \leq \frac{2}{a - 1} a^k = O\left(\frac{1}{\varepsilon}\right).$$

Moltiplicando per il costo $O(m)$ di ogni gradiente si ottiene (5.27). $\square$

Scelta di a e confronto Il risultato (5.27) vale se a è scelto nell'intervallo

$$a \in \left(1, \left(1 - \frac{\lambda}{L}\right)^{-1}\right].$$

Non è necessario conoscere il numero di condizionamento $\kappa = L/\lambda$ esattamente; qualsiasi sovrastima va bene:

$$a = \left(1 - \frac{1}{\kappa'}\right)^{-1}, \quad \kappa' \geq \kappa. \quad (5.28)$$

Dalla (5.27) ignorando la dipendenza dal punto iniziale (come in [2]) e assumendo il regime $\omega/\lambda \geq J(w_0) - J(w_*)$, si ottiene $\mathcal{T}_{\text{tot}} = O(m\kappa\omega/\lambda\varepsilon)$, che è il bound riportato in tabella sotto.

Confrontiamo questo risultato con i bound di complessità noti per il metodo a gradiente a campione fisso e il metodo del gradiente stocastico (SGD), calcolati da Bottou e Bousquet [2]: nella tabella, lo scalare $\bar{\alpha} \in [1/2, 1]$ è il *tasso di stima* del metodo a campione fisso, come definito in [2].

Nome algoritmo	Bound
Metodo a gradiente dinamico (questo lavoro)	$O(m\kappa\omega/\lambda\varepsilon)$
Metodo a gradiente a campione fisso	$O(m^2\kappa\varepsilon^{-1/\bar{\alpha}} \log^2(1/\varepsilon))$
Metodo del gradiente stocastico	$O(m\bar{\nu}\kappa^2/\varepsilon)$

Tabella 5.1: Bound di complessità per tre metodi. Qui m è il numero di variabili, $\kappa = L/\lambda$, ω e $\bar{\nu}$ sono definiti in (5.4) e (5.29), e $\bar{\alpha} \in [1/2, 1]$.

I metodi a campione fisso e stocastico sono definiti come:

- Metodo a campione fisso: $w_{k+1} = w_k - \frac{1}{L} \frac{\sum_{i=1}^{N_\varepsilon} \nabla \ell(w_k; i)}{N_\varepsilon},$
- Metodo del gradiente stocastico: $w_{k+1} = w_k - \frac{1}{\lambda k} \nabla \ell(w_k; i_k),$

dove N_ε specifica una dimensione del campione tale che $\mathbb{E}[|J(w_*) - J_S(w_*)|] < \varepsilon$ vale in aspettativa. I bound di complessità presentati in [2] ignorano l'effetto del punto iniziale w_0 .

Lo scalare $\bar{\alpha} \in [1/2, 1]$, chiamato *tasso di stima* [2], dipende dalle proprietà della funzione di perdita; la costante $\bar{\nu}$ è definita come

$$\bar{\nu} = \text{trace}(H^{-1}G), \quad H = \nabla^2 J(w_*), \quad G = \mathbb{E}[\nabla \ell(w_*; i) \nabla \ell(w_*; i)^T]. \quad (5.29)$$

Poiché $H \succeq \lambda I$ e ω è un bound per $\|\text{Var}(\nabla \ell(w_k; I))\|_1$, si ha $\bar{\nu} \approx \omega/\lambda$. Sostituendo nel bound per SGD:

$$O(m\bar{\nu}\kappa^2/\varepsilon) = O\left(\frac{m\omega\kappa^2}{\lambda\varepsilon}\right). \quad (5.30)$$

Il bound per il metodo dinamico (5.27) è invece $O(m\kappa\omega/(\lambda\varepsilon))$. La differenza principale è il termine κ^2 in SGD contro κ nel metodo dinamico. Concludiamo che **il metodo a gradiente dinamico gode di un bound di complessità competitivo con quello del metodo del gradiente stocastico**, risultando particolarmente vantaggioso per problemi mal condizionati (grande κ).

La strategia dinamica $n_k = \lceil a^k \rceil$ con a scelto in base a una stima (bound superiore) di κ garantisce un compromesso ottimale tra costo per iterazione e velocità di convergenza. In pratica, la stima di κ può essere sostituita da una regola euristica semplice (ad esempio, $a = 1.1$), e l'algoritmo si adatta automaticamente.

5.2 Metodo di Newton-CG con Campionamento Dinamico

Il metodo del gradiente (steepest descent) può convergere lentamente, specialmente su problemi mal condizionati; gli algoritmi che incorporano informazione di curvatura (secondo ordine) sulla funzione obiettivo possono essere molto più efficienti. In questa sezione descriviamo un metodo di Newton-CG (gradiente coniugato) *Hessian-free* (non costruiamo e non memorizziamo esplicitamente la matrice Hessiana di $J(w)$, ma ne usiamo solo i prodotti per un vettore), che impiega tecniche di campionamento dinamico sia per il calcolo della funzione e del gradiente, sia per i prodotti Hessiana-vettore.

5.2.1 Struttura del metodo

Il metodo estende l'algoritmo del gradiente a campione dinamico (quello pratico, non la sua variante idealizzata con $n_k = \lceil a^k \rceil$). Rispetto ai metodi che utilizzano un campione fisso per il gradiente e un numero fisso di iterazioni del CG, questo metodo presenta due innovazioni principali:

1. Il campione $\mathcal{S}_k$ per il gradiente non è più fisso; qui si incorporano le tecniche di campionamento dinamico dell'algoritmo visto precedentemente.
2. Il numero di iterazioni del gradiente coniugato non è più fisso; si propone un criterio di terminazione automatico per il CG, che si adatta alla dimensione del campione e all'accuratezza dell'approssimazione dell'Hessiana.

Ad ogni iterazione, il metodo sceglie due campioni $\mathcal{S}_k$ e $\mathcal{H}_k$ tali che

$$|\mathcal{H}_k| \ll |\mathcal{S}_k|,$$

e definisce la direzione di ricerca d_k come soluzione approssimata del sistema lineare

$$\underbrace{\nabla^2 J_{\mathcal{H}_k}(w_k) d = -\nabla J_{\mathcal{S}_k}(w_k)}_{\text{(metodo di Newton classico)}}. \quad (5.31)$$

L'uso di due campioni distinti è cruciale:

- $\mathcal{S}_k$ per il gradiente $\nabla J_{\mathcal{S}_k}(w_k)$, per garantire una direzione di discesa affidabile.
- $\mathcal{H}_k$ per l'Hessiana $\nabla^2 J_{\mathcal{H}_k}(w_k)$, per mantenere il costo dei prodotti Hessiana-vettore sufficientemente basso.

Il sistema (5.31) viene risolto con il **metodo del gradiente coniugato (CG)** **Hessian-free**: la matrice $\nabla^2 J_{\mathcal{H}_k}(w_k)$ non viene mai costruita esplicitamente; invece, si calcola direttamente il prodotto di questa Hessiana per un vettore.

Il rapporto

$$R = \frac{|\mathcal{H}_k|}{|\mathcal{S}_k|} < 1 \quad (5.32)$$

viene fissato a priori ed è mantenuto costante durante tutto l'algoritmo. Quando il campione per il gradiente $\mathcal{S}_k$ cresce (dinamicamente), la dimensione di $\mathcal{H}_k$ viene aggiornata come $|\mathcal{H}_k| = \lceil R \cdot |\mathcal{S}_k| \rceil$, in modo che $\mathcal{H}_k$ cresca proporzionalmente a $\mathcal{S}_k$. Una linea guida pratica è che il costo totale dei prodotti Hessiana-vettore nel CG non superi il costo di una valutazione del gradiente $\nabla J_{\mathcal{S}_k}$.

5.2.2 Criterio di terminazione del gradiente coniugato

Proponiamo un criterio automatico per decidere con quale accuratezza risolvere il sistema (5.31). L'idea chiave è che il *residuo* del CG,

$$r_k \stackrel{\text{def}}{=} \nabla^2 J_{\mathcal{H}_k}(w_k)d + \nabla J_{\mathcal{S}_k}(w_k), \quad (5.33)$$

non deve essere più piccolo dell'*errore di approssimazione dell'Hessiana*.

Per comprendere questo punto, scriviamo il residuo del sistema di Newton che userebbe il campione grande $\mathcal{S}_k$ sia per il gradiente che per l'Hessiana:

$$\underbrace{\nabla^2 J_{\mathcal{S}_k}(w_k)d + \nabla J_{\mathcal{S}_k}(w_k)}_{\text{Residuo del sistema}} = \underbrace{r_k}_{\text{Residuo del CG}} + \underbrace{[\nabla^2 J_{\mathcal{S}_k}(w_k) - \nabla^2 J_{\mathcal{H}_k}(w_k)] d}_{\text{Errore di Hessiana } = \Delta_{\mathcal{H}_k}(w_k; d)}. \quad (5.34)$$

Il termine $\Delta_{\mathcal{H}_k}(w_k; d)$ misura l'errore nell'approssimazione dell'Hessiana lungo la direzione d , dovuto all'uso del campione più piccolo $\mathcal{H}_k$ e questo è costante durante l'algoritmo. È chiaro dall'equazione sopra che se l'errore di Hessiana $\Delta_{\mathcal{H}_k}$ non si può eliminare, non serve ridurre r_k fino a zero. Basta ridurlo fino a quando è comparabile a $\Delta_{\mathcal{H}_k}$. Oltre quel punto, il tempo speso è sprecato.

Il nostro obiettivo è quindi bilanciare i due termini al membro destro di (5.34), terminando il CG quando il residuo r_k è dello stesso ordine dell'errore dell'hessiana.

Tuttavia, $\Delta_{\mathcal{H}_k}(w; d)$, analogamente all'errore di approssimazione del gradiente discusso precedentemente, non è direttamente calcolabile, perché richiederebbe di calcolare $\nabla^2 J_{\mathcal{S}_k}(w_k)d$ (cioè il prodotto Hessiana-vettore sul campione grande), il che vanificherebbe il vantaggio del sottocampionamento dell'Hessiana.

Seguendo la stessa strategia implementata precedentemente per il gradiente, usiamo la varianza campionaria del prodotto Hessiana-vettore per stimare l'errore.

Errore del gradiente (sez. 5.1.2)	Errore dell'Hessiana (sez. 5.2.2)
$e_k = g_k - \nabla J(w_k)$	$\Delta_{\mathcal{H}_k}(w_k; d) = [\nabla^2 J_{\mathcal{S}_k}(w_k) - \nabla^2 J_{\mathcal{H}_k}(w_k)] d$
Non calcolabile perché richiederebbe $\nabla J(w_k)$ su tutti i dati	Non calcolabile perché richiederebbe $\nabla^2 J_{\mathcal{S}_k}(w_k)d$ su tutto il campione grande
Si aggira il problema stimando $\mathbb{E}[\ e_k\ ^2]$ con la varianza campionaria dei gradienti individuali $\nabla \ell(w_k; i)$ sul batch	Si aggira il problema stimando $\mathbb{E}[\ \Delta\ ^2]$ con la varianza campionaria dei prodotti Hessiana-vettore individuali $\nabla^2 \ell(w_k; i)d$ sul sottocampione $\mathcal{H}_k$

Per comprendere la derivazione, partiamo dalla definizione di $\Delta_{\mathcal{H}_k}$.

Precedentemente avevamo definito

$$\Delta_{\mathcal{H}_k}(w_k; d) \stackrel{\text{def}}{=} [\nabla^2 J_{\mathcal{S}_k}(w_k) - \nabla^2 J_{\mathcal{H}_k}(w_k)] d.$$

Sviluppando le medie campionarie e ponendo $X_i = \nabla^2 \ell(w_k; i)d$, abbiamo

$$\nabla^2 J_{\mathcal{S}_k}(w_k)d = \frac{1}{|\mathcal{S}_k|} \sum_{i \in \mathcal{S}_k} X_i := \mu_{\mathcal{S}} \quad \text{e} \quad \nabla^2 J_{\mathcal{H}_k}(w_k)d = \frac{1}{|\mathcal{H}_k|} \sum_{i \in \mathcal{H}_k} X_i := \mu_{\mathcal{H}}.$$

Indichiamo $\Delta_{\mathcal{H}_k}(w_k; d)$ con Δ , poiché $\mathcal{H}_k$ è un sottocampione casuale estratto senza reinserimento dall'insieme $\mathcal{S}_k$, la quantità $\mu_{\mathcal{H}}$ è uno stimatore della media

della popolazione finita $\mu_{\mathcal{S}}$. L'errore di stima è $\mu_{\mathcal{H}} - \mu_{\mathcal{S}}$, il cui quadrato atteso è la varianza dello stimatore $\mu_{\mathcal{H}}$. Osserviamo che

$$\|\Delta\|^2 = \|\mu_{\mathcal{S}} - \mu_{\mathcal{H}}\|^2 = \|\mu_{\mathcal{H}} - \mu_{\mathcal{S}}\|^2 \implies \mathbb{E}[\|\Delta\|^2] = \mathbb{E}[\|\mu_{\mathcal{H}} - \mu_{\mathcal{S}}\|^2] = \text{Var}(\mu_{\mathcal{H}}).$$

A questo punto, usiamo la formula per la varianza di una media campionaria in un campionamento senza reinserimento che avevamo derivato precedentemente. Consideriamo una popolazione finita di dimensione $N = |\mathcal{S}_k|$ con elementi $X_1, \dots, X_N$, e un campione senza reinserimento di dimensione $n = |\mathcal{H}_k|$.

$$\text{Var}(\mu_{\mathcal{H}}) = \frac{\sigma^2}{n} \cdot \frac{N - n}{N - 1}.$$

Questa è la formula classica per la varianza di una media campionaria in un campionamento senza reinserimento, che include il fattore di correzione per popolazione finita $\frac{N-n}{N-1}$. Sostituendo $n = |\mathcal{H}_k|$, $N = |\mathcal{S}_k|$ e prendendo la norma $\|\cdot\|_1$ componente per componente (poiché gli X_i sono vettori), otteniamo:

$$\mathbb{E}[\|\Delta\|^2] = \frac{\overbrace{\left\| \frac{1}{|\mathcal{S}_k|} \sum_{i \in \mathcal{S}_k} (X_i - \mu_{\mathcal{S}})^2 \right\|_1}^{\sigma^2}}{|\mathcal{H}_k|} \cdot \frac{|\mathcal{S}_k| - |\mathcal{H}_k|}{|\mathcal{S}_k| - 1}.$$

Ritornando alla notazione originale, $X_i = \nabla^2 \ell(w_k; i) d$, e ricordando che σ^2 denota la varianza della popolazione $\mathcal{S}_k$ che approssimiamo con la varianza campionaria calcolata su $\mathcal{H}_k$, otteniamo la prima approssimazione:

$$\mathbb{E}[\|\Delta_{\mathcal{H}_k}(w_k; d)\|_2^2] \approx \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d)\|_1}{|\mathcal{H}_k|} \frac{(|\mathcal{S}_k| - |\mathcal{H}_k|)}{|\mathcal{S}_k| - 1}. \quad (5.35a)$$

Questo viene fatto siccome l'uso di σ^2 richiederebbe di calcolare il prodotto Hessiana-vettore su tutto il campione grande $\mathcal{S}_k$, il che vanificherebbe il vantaggio del sotto-campionamento dell'Hessiana.

Poiché nel paper si assume $|\mathcal{H}_k| \ll |\mathcal{S}_k|$ (il campione per l'Hessiana è molto più piccolo di quello per il gradiente), il rapporto $\frac{|\mathcal{S}_k| - |\mathcal{H}_k|}{|\mathcal{S}_k| - 1}$ è circa uguale a 1. Si ottiene quindi la semplificazione finale:

$$\mathbb{E}[\Delta_{\mathcal{H}_k}(w_k; d)^2] \approx \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d)\|_1}{|\mathcal{H}_k|}. \quad (5.35b)$$

Questa equazione fornisce una stima dell'errore di approssimazione dell'Hessiana per un generico vettore d . Osserviamo che la mappa $d \mapsto \nabla^2 \ell(w_k; i) d$ è *lineare* in d . Di conseguenza, la sua varianza (calcolata su un campione fissato) è una *forma quadratica* in d : esiste una matrice di covarianza campionaria $\Sigma_{\mathcal{H}_k} \in \mathbb{R}^{m \times m}$, simmetrica semidefinita positiva, tale che

$$\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d) = d^T \Sigma_{\mathcal{H}_k} d \in \mathbb{R}^m,$$

dove il membro sinistro è inteso componente per componente e la relazione vale per ogni componente $j = 1, \dots, m$ con la corrispondente matrice $\Sigma_{\mathcal{H}_k}^{(j)}$. Questa forma quadratica gode della proprietà di omogeneità

$$\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i)(\lambda d)) = \lambda^2 \text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d).$$

All'inizio dell'algoritmo, la soluzione candidata è $d_0 = 0$ e il residuo iniziale è $r_0 = \nabla J_{\mathcal{S}_k}(w_k)$. La prima direzione di ricerca del CG è quindi $p_0 = -r_0$. Per evitare di ricalcolare la varianza a ogni iterazione del CG (operazione costosa), il lavoro originale [1] propone di calcolarla *una sola volta* per $d = p_0$. Sfruttando l'omogeneità della forma quadratica, si definisce

$$\alpha := \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{\|p_0\|_2^2} = \frac{\|p_0^T \Sigma_{\mathcal{H}_k} p_0\|_1}{\|p_0\|_2^2}. \quad (5.36)$$

Poiché la varianza effettiva per una generica direzione d_j è $\|d_j^T \Sigma_{\mathcal{H}_k} d_j\|_1$, e non $\alpha \|d_j\|^2$, l'uso di α per tutte le direzioni costituisce un'approssimazione, α misura l'influenza media della matrice di covarianza campionaria dei prodotti Hessiana-vettore su un vettore generico, è una media pesata degli autovalori di $\Sigma_{\mathcal{H}_k}$ ed è sempre compreso tra $\lambda_{\min}(\Sigma_{\mathcal{H}_k})$ e $\lambda_{\max}(\Sigma_{\mathcal{H}_k})$. Il metodo assume che la forma quadratica sia sufficientemente ben condizionata perché la dipendenza angolare sia trascurabile ai fini del test di arresto; ciò giustifica la stima

$$\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) d_j)\|_1 \approx \alpha \|d_j\|_2^2 = \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{\|p_0\|_2^2} \|d_j\|_2^2. \quad (5.37)$$

Ora, dalla (5.35b), sostituendo la varianza stimata tramite la (5.37), definiamo

$$\gamma := \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{|\mathcal{H}_k| \|p_0\|_2^2}, \quad \Psi(d) := \gamma \|d\|_2^2. \quad (5.38)$$

Test di arresto del CG. La soglia $\Psi(d_j)$ definita in (5.38) viene utilizzata per decidere quando fermare il metodo del gradiente coniugato. Ad ogni iterazione j del CG, si controlla se il residuo r_{j+1} soddisfa

$$\|r_{j+1}\|_2^2 \leq \Psi(d_j) = \gamma \|d_j\|_2^2. \quad (5.39)$$

Se la condizione è verificata, il CG termina e la soluzione corrente d_{j+1} viene accettata come direzione di Newton approssimata. In caso contrario, si prosegue con la successiva iterazione del CG. Questo criterio di arresto è particolarmente efficace perché evita calcoli inutili quando l'approssimazione dell'Hessiana è limitata dal campione $\mathcal{H}_k$; si adatta alla distanza dal minimo poiché $\Psi \propto \|r_0\|^2$; previene instabilità numeriche perché Ψ cresce con $\|d_j\|^2$, fermando il CG prima che la direzione diventi eccessivamente grande.

L'algoritmo quindi calcola γ una volta sola all'inizio del CG, e poi ad ogni iterazione aggiorna $\Psi(d_j) = \gamma \|d_j\|^2$ e verifica la condizione (5.39).

5.2.3 Pseudocodice (Algoritmo Newton-CG)

Algoritmo

Newton-CG con Campionamento Dinamico

Input: w_0 (punto iniziale), $\mathcal{S}_0$ (batch iniziale per gradiente), $\mathcal{H}_0 \subset \mathcal{S}_0$ (batch iniziale per Hessiana), $R = |\mathcal{H}_0|/|\mathcal{S}_0|$ (rapporto costante), $\theta \in (0, 1)$ (tolleranza per varianza del gradiente), $c_1, c_2 \in (0, 1)$ con $c_1 < c_2$ (parametri Wolfe).

Inizializzazione: poni $k = 0$.

Ripeti per ogni iterazione k fino a convergenza:

1. **Calcola la direzione di Newton approssimata d_k mediante gradiente coniugato (CG):**

- (a) $d_0 = 0, r_0 = \nabla J_{\mathcal{S}_k}(w_k), p_0 = -r_0, j = 0, \Psi = 0.$

- (b) $\gamma = \frac{\|\text{Var}_{i \in \mathcal{H}_k}(\nabla^2 \ell(w_k; i) p_0)\|_1}{|\mathcal{H}_k| \|p_0\|_2^2}.$

- (c) Finchè $\|r_j\|_2^2 > \Psi$:

- i. $s_j = \nabla^2 J_{\mathcal{H}_k}(w_k) p_j$

- ii. $\alpha_j = \frac{r_j^T r_j}{p_j^T s_j}.$

- iii. $d_{j+1} = d_j + \alpha_j p_j, r_{j+1} = r_j + \alpha_j s_j.$

- iv. $\beta_{j+1} = \frac{r_{j+1}^T r_{j+1}}{r_j^T r_j}.$

- v. $p_{j+1} = -r_{j+1} + \beta_{j+1} p_j.$

- vi. $j = j + 1, \Psi = \gamma \|d_j\|_2^2.$

- (d) $d_k = d_j$

2. **Line search con condizioni di Wolfe:** Trova $\alpha_k > 0$ tale che:

$$J_{\mathcal{S}_k}(w_k + \alpha_k d_k) \leq J_{\mathcal{S}_k}(w_k) + c_1 \alpha_k \nabla J_{\mathcal{S}_k}(w_k)^T d_k,$$

$$\nabla J_{\mathcal{S}_k}(w_k + \alpha_k d_k)^T d_k \geq c_2 \nabla J_{\mathcal{S}_k}(w_k)^T d_k.$$

3. Aggiorna il punto: $w_{k+1} = w_k + \alpha_k d_k.$

4. **Aggiornamento dinamico del batch per il gradiente:**

- (a) Seleziona un nuovo campione $\mathcal{S}_{k+1}$ della stessa dimensione di $\mathcal{S}_k.$

- (b) Calcola la varianza campionaria $\hat{\mathcal{V}} = \text{Var}_{i \in \mathcal{S}_{k+1}}(\nabla \ell(w_{k+1}; i)).$

- (c) Se $\frac{\|\hat{\mathcal{V}}\|_1}{|\mathcal{S}_{k+1}|} > \theta^2 \|\nabla J_{\mathcal{S}_{k+1}}(w_{k+1})\|_2^2$, aumenta il batch:

$$|\mathcal{S}_{k+1}| \leftarrow \left\lceil \frac{\|\hat{\mathcal{V}}\|_1}{\theta^2 \|\nabla J_{\mathcal{S}_{k+1}}(w_{k+1})\|_2^2} \right\rceil.$$

5. Seleziona $\mathcal{H}_{k+1} \subseteq \mathcal{S}_{k+1}$ tale che $|\mathcal{H}_{k+1}| = R \cdot |\mathcal{S}_{k+1}|.$

6. Incrementa $k \leftarrow k + 1.$




Figura 5.4: Schema del metodo Newton-CG con campionamento dinamico: ad ogni iterazione il gradiente coniugato risolve (in modo Hessian-free) il sistema di Newton con un criterio di arresto adattivo; dopo l'aggiornamento e il re-campionamento, la CCV decide se aumentare la dimensione del batch.

Nota Tecnica

L'algoritmo del gradiente coniugato serve a minimizzare l'errore di $x \approx \bar{x}$ t.c. $A\bar{x} = b$. Nel contesto del metodo di Newton, i suoi elementi vengono reinterpretati come segue:

- $A = H_k = \nabla^2 J(w_k)$ (Hessiana della funzione obiettivo, calcolata sul campione $\mathcal{H}_k$);
- $b = -g_k = -\nabla J(w_k)$ (gradiente negativo, calcolato sul campione $\mathcal{S}_k$);

- $x = d_k$ (direzione di Newton, che risolve $H_k d_k = -g_k$).

Il CG, quindi, viene usato internamente per approssimare la direzione di Newton senza costruire esplicitamente l'Hessiana.

INPUT: $A \in \mathbb{R}^{n \times n}$ (simmetrica def. pos.), $b \in \mathbb{R}^n$, $x_0 = \mathbf{1}$, $\text{tol} = 10^{-10} \|b\|_2$, $it_{\max} = 1000$

- Calcola $r = b - Ax_0$, $p = r$, residui = $\|r\|_2$
- Per $k = 1$ a $it_{\max}$:
 - $Ap = A \cdot p$
 - $\alpha = \frac{r^T p}{p^T Ap}$ (Passo ottimale)
 - $x = x + \alpha p$
 - $r' = r - \alpha Ap$
 - $\beta = \frac{r'^T r'}{r'^T r}$
 - $p = r' + \beta p$
 - $r = r'$
 - residui = $\|r\|_2$
 - Se $\|r\|_2 \leq \text{tol}$: termina

OUTPUT: x , residui

Questo metodo usa un passo α_k che si ottiene minimizzando il funzionale

$$\phi(x) = \frac{1}{2} x^T A x - b^T x$$

per $x = x_k + \alpha p_k$, annullando la derivata di tale funzionale rispetto ad α :

$$\left. \frac{d}{d\alpha} \phi(x_k + \alpha p_k) \right|_{\alpha=\alpha_k} = (Ax_k - b)^T p_k + \alpha_k p_k^T A p_k = 0.$$

Poiché $Ax_k - b = -r_k$, dove $r_k = b - Ax_k$ è il residuo, si ha:

$$-r_k^T p_k + \alpha_k p_k^T A p_k = 0 \implies \alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}. \quad (5.40)$$

Ora però si può dimostrare che la formula usata in questo metodo è equivalente a questa. La dimostrazione completa è riportata nell'Appendice A.3. In sintesi, dalla condizione di stazionarietà al passo precedente e dall'aggiornamento del residuo si ottiene $r_k^T p_{k-1} = 0$, da cui segue $r_k^T p_k = r_k^T r_k$ e quindi l'equivalenza delle due formule. La formula con $r_k^T r_k$ è preferita nelle implementazioni numeriche perché è più stabile, poiché non dipende dall'ortogonalità numerica di $r_k^T p_{k-1}$, che in presenza di errori di arrotondamento non è esattamente zero.

In sostanza l'algoritmo a ogni iterazione k estrae due campioni distinti dal dataset. Un campione S_k grande per calcolare il gradiente $g_k = \nabla J_{S_k}(w_k)$, perché deve essere una stima accurata della direzione di discesa, e un sottocampione H_k con $|H_k| = R \cdot |S_k|$ e $R \ll 1$ per calcolare l'Hessiana $H_k = \nabla^2 J_{H_k}(w_k)$, poiché i prodotti Hessiana-vettore sono costosi e una stima della curvatura basta. Per aggiornare i pesi usa la direzione di Newton che si ottiene minimizzando l'espansione di Taylor per $J(w)$ al secondo ordine attorno a w_k : $J(w_k + d) \approx \tilde{J}(d) = J(w_k) + \nabla J(w_k)^T d + \frac{1}{2} d^T \nabla^2 J(w_k) d$, dove w_k è il punto corrente e d è la direzione. Troviamo la d che minimizza questo modello quadratico annullandone il gradiente rispetto a d , ottenendo il sistema lineare $\nabla^2 J(w_k) d = -\nabla J(w_k)$, che è praticamente del tipo $Ax = b$ con $A = \nabla^2 J(w_k)$ e $b = -\nabla J(w_k)$. Per risolvere questo sistema non si inverte mai la matrice (troppo costoso), ma si usa il metodo del gradiente coniugato Hessian-free, facendo solo prodotti $H_k \cdot v$ senza costruire H_k .

Ora poiché l'Hessiana è calcolata su un campione piccolo H_k e quindi è approssimata, non ha senso risolvere il sistema con precisione assoluta. Il CG si ferma quando il suo residuo è confrontabile con l'errore di approssimazione dell'Hessiana, stimato dalla varianza campionaria dei prodotti $\nabla^2 \ell(w_k; i) \cdot p_0$ su H_k . In questo modo non si spreca iterazioni del CG a ridurre un errore che è già dominato dal rumore del campionamento.

Infine si esegue una line search di Armijo lungo la direzione d_k trovata, si aggiorna $w_{k+1} = w_k + \alpha_k d_k$, e come nell'algoritmo visto precedentemente si verifica la condizione di controllo della varianza (CCV) sul gradiente: se la varianza campionaria di g_k è troppo alta rispetto a $\|g_k\|^2$, si aumenta la dimensione del batch n_k per l'iterazione successiva, in modo da avere più precisione man mano che ci si avvicina al minimo.

Ora il metodo del gradiente coniugato è un metodo numerico per trovare x che approssimi la soluzione di $Ax = b$, ovvero minimizzi il funzionale $\phi(x) = \frac{1}{2} x^T A x - b^T x$ e per farlo cerca di minimizzare $\|e^{k+1}\|_A^2$ cercando in $e^k + \text{span}(p^k, p^{k-1})$; equivalentemente pone $e^{k+1} \perp_A p^k$ ed $e^{k+1} \perp_A p^{k-1}$, dalla prima condizione troviamo α_k e dalla seconda β_k (Dimostrazione nell'appendice).

5.3 Metodo Newton-CG per Modelli con Regularizzazione L_1

5.3.1 Formulazione del Problema

Nei modelli di apprendimento statistico con un numero molto elevato di parametri, l'aggiunta di un termine di regularizzazione L_1 è particolarmente vantaggiosa perché produce soluzioni *sparse*: molti coefficienti vengono automaticamente portati a zero, semplificando il modello e migliorandone l'interpretabilità.

La funzione obiettivo (3.1) viene quindi modificata aggiungendo un termine di penalità sulla norma L_1 dei parametri:

$$F(w) = \frac{1}{N} \sum_{i=1}^N \ell(f(w; x_i), y_i) + \nu \|w\|_1 = J(w) + \nu \|w\|_1, \quad (5.41)$$

dove:

- $\nu > 0$ è un parametro di penalità (fisso);
- $\|w\|_1 = \sum_{j=1}^m |w_j|$ è la norma L_1 del vettore dei parametri;
- $J(w)$ è la funzione di perdita empirica definita in (3.1).

Nel contesto mini-batch, si sceglie un sottoinsieme $\mathcal{S} \subseteq \{1, \dots, N\}$ del training set e si risolve il problema approssimato:

$$\min_{w \in \mathbb{R}^m} F_{\mathcal{S}}(w) = J_{\mathcal{S}}(w) + \nu \|w\|_1, \quad (5.42)$$

dove $J_{\mathcal{S}}$ è definita come in (5.1).

5.3.2 Il gradiente generalizzato

Per comprendere come si costruisce il gradiente generalizzato di una funzione contenente un termine L_1 , è utile partire dal caso più semplice in una variabile.

Caso 1D: la funzione $\nu|x|$. Consideriamo la funzione $\phi(x) = \nu|x|$, con $x \in \mathbb{R}$, $\nu \in \mathbb{R}$, $\nu > 0$. Questa funzione presenta un punto di non derivabilità in $x = 0$:

- se $x > 0$, la derivata è $\phi'(x) = +\nu$;
- se $x < 0$, la derivata è $\phi'(x) = -\nu$;
- se $x = 0$, la derivata classica non esiste.

Siccome la derivata classica non esiste, si utilizza il concetto di *subgradiente* (o gradiente generalizzato). Per $\phi(x) = \nu|x|$, il subgradiente in $x = 0$ è l'intervallo:

$$\partial\phi(0) = [-\nu, +\nu].$$

Questo significa che in $x = 0$ possiamo scegliere qualsiasi valore di pendenza compreso tra $-\nu$ e $+\nu$, a seconda della direzione di discesa che vogliamo seguire.

Estensione al caso multidimensionale. Consideriamo ora:

$$F(w) = \underbrace{J(w)}_{\text{parte liscia}} + \underbrace{\nu \sum_{i=1}^m |w_i|}_{\text{parte non liscia}}.$$

La parte non liscia è una somma di termini $\nu|w_i|$, uno per ogni componente di w . Poiché la somma si decompone componente per componente, possiamo calcolare il gradiente generalizzato di F separatamente per ogni coordinata.

Per la i -esima componente, abbiamo due contributi:

1. la derivata parziale della parte liscia: $\frac{\partial J(w)}{\partial w_i}$;
2. il subgradiente di $\nu|w_i|$:

$$\partial(\nu|w_i|) = \begin{cases} +\nu & \text{se } w_i > 0, \\ -\nu & \text{se } w_i < 0, \\ [-\nu, +\nu] & \text{se } w_i = 0. \end{cases}$$

Pertanto, per ogni componente i , il gradiente generalizzato $\tilde{\nabla}F(w)$ è dato da:

$$[\tilde{\nabla}F(w)]_i = \underbrace{\frac{\partial J(w)}{\partial w_i}}_{\text{gradiente di } J} + \underbrace{g_i}_{\text{subgradiente di } \nu|w_i|} \quad g_i \in \begin{cases} \{+\nu\} & \text{se } w_i > 0, \\ \{-\nu\} & \text{se } w_i < 0, \\ [-\nu, +\nu] & \text{se } w_i = 0. \end{cases}$$

Quando $w_i = 0$, abbiamo libertà di scegliere g_i in $[-\nu, +\nu]$. La scelta viene effettuata in modo che in w^* si abbia $\tilde{\nabla}F(w^*) = 0$. Per ogni coordinata i , definiamo:

$$\begin{cases} d_i := \frac{\partial J}{\partial w_i} \\ g_i \in [-\nu, +\nu] \end{cases} \implies [\tilde{\nabla}F]_i = d_i + g_i.$$

La scelta di g_i viene effettuata risolvendo il problema di proiezione:

$$g_i = \arg \min_{g \in [-\nu, \nu]} |d_i + g|,$$

cioè si sceglie il subgradiente che rende il gradiente generalizzato $d_i + g_i$ il più vicino possibile a zero. Ne derivano i tre casi seguenti:

Condizione su $d_i = \partial J / \partial w_i$	Scelta di g_i	Risultato $[\tilde{\nabla}F]_i$	Effetto
$d_i < -\nu$	$g_i = +\nu$	$d_i + \nu < 0$	$\tilde{\nabla}F < 0$: la discesa spinge w_i verso destra (aumenta)
$d_i > +\nu$	$g_i = -\nu$	$d_i - \nu > 0$	$\tilde{\nabla}F > 0$: la discesa spinge w_i verso sinistra (diminuisce)
$-\nu \leq d_i \leq +\nu$	$g_i = -d_i$	$d_i + g_i = 0$	$\tilde{\nabla}F = 0$: $w_i = 0$ è punto stazionario (minimo)

In sintesi, la regola di proiezione $g_i = \arg \min_{g \in [-\nu, \nu]} |d_i + g|$ garantisce che, nel punto di minimo w^* , si abbia esattamente $\tilde{\nabla} F(w^*) = 0$ per tutte le coordinate in cui $|d_i| \leq \nu$, mentre per le altre coordinate il gradiente viene reso il più piccolo possibile in valore assoluto.

Mettendo insieme tutti i casi, si ottiene la seguente espressione per il gradiente generalizzato:

$$[\tilde{\nabla} F_S(w)]^i = \begin{cases} \frac{\partial J_S(w)}{\partial w_i} + \nu & \text{se } w_i > 0 \text{ oppure } \left(w_i = 0 \text{ e } \frac{\partial J_S(w)}{\partial w_i} < -\nu \right), \\ \frac{\partial J_S(w)}{\partial w_i} - \nu & \text{se } w_i < 0 \text{ oppure } \left(w_i = 0 \text{ e } \frac{\partial J_S(w)}{\partial w_i} > \nu \right), \\ 0 & \text{se } w_i = 0 \text{ e } -\nu \leq \frac{\partial J_S(w)}{\partial w_i} \leq \nu. \end{cases} \quad (5.43)$$

Nota

La formula (5.43) è la versione multidimensionale del subgradiente di $F_S(w) = J_S(w) + \nu \|w\|_1$. Essa generalizza il caso 1D: quando $w_i \neq 0$, il gradiente è semplicemente la somma del gradiente di J_S e del segno di w_i moltiplicato per ν ; quando $w_i = 0$, si sceglie il subgradiente che punta nella direzione di massima discesa.

5.3.3 Identificazione dell'Active Set e della Faccia Ortante

Poiché la funzione $\nu|w_i|$ ha un angolo (una non-derivabilità) proprio in $w_i = 0$, l'algoritmo non può usare la solita regola della derivata zero per decidere se quel punto è il minimo. Deve quindi fare una scelta esplicita: se la pendenza della parte liscia J è più forte del costo ν , allora conviene 'liberare' w_i (spostarla da zero); altrimenti, conviene 'attivarla' (tenerla bloccata a zero per ottenere una soluzione sparsa).

L'obiettivo della fase di predizione è determinare quali variabili sono nulle alla soluzione e identificare la *faccia ortante* (parte dell'iperpiano) su cui eseguire la minimizzazione. L'idea è quella di compiere un passo infinitesimo lungo la direzione di massima discesa $-\tilde{\nabla} F_{S_k}(w_k)$ e osservare il segno di ogni componente.

Definiamo il vettore $z_k \in \{-1, 0, +1\}^m$ che caratterizza la faccia ortante:

$$z_k^i = \begin{cases} +1 & \text{se } w_k^i > 0 \text{ oppure } \left(w_k^i = 0 \text{ e } \frac{\partial J_{S_k}(w_k)}{\partial w_i} < -\nu \right), \\ -1 & \text{se } w_k^i < 0 \text{ oppure } \left(w_k^i = 0 \text{ e } \frac{\partial J_{S_k}(w_k)}{\partial w_i} > \nu \right), \\ 0 & \text{altrimenti.} \end{cases} \quad (5.44)$$

Il vettore z_k definisce l'ortante

$$\Omega_k = \{d \in \mathbb{R}^m : \text{sign}(d^i) = \text{sign}(z_k^i)\}, \quad (5.45)$$

all'interno del quale la funzione $\|w\|_1$ è differenziabile e il suo gradiente è esattamente z_k . Le variabili con $z_k^i = 0$ costituiscono l'**active set**:

$$\mathcal{A}_k \triangleq \{i \mid z_k^i = 0\}. \quad (5.46)$$

Tali variabili verranno mantenute a zero durante la fase di minimizzazione nel sottospazio; le rimanenti sono dette *libere*.

5.3.4 Fase di Minimizzazione nel Sottospazio

Una volta identificata la faccia ortante, si costruisce un modello quadratico della funzione obiettivo ristretto alle variabili libere. Il modello è:

$$\begin{aligned} \min_{d \in \mathbb{R}^m} m_k(d) &\stackrel{\text{def}}{=} F_{\mathcal{S}_k}(w_k) + \tilde{\nabla} F_{\mathcal{S}_k}(w_k)^T d + \frac{1}{2} d^T \nabla^2 J_{\mathcal{H}_k}(w_k) d \\ \text{s.t. } d^i &= 0, \quad i \in \mathcal{A}_k. \end{aligned} \quad (5.47)$$

La minimizzazione viene effettuata con il metodo del gradiente coniugato Hessian-free applicato al sistema lineare ridotto. Sia Y_k la matrice $n \times (n - |\mathcal{A}_k|)$ le cui colonne sono i versori delle coordinate libere; allora il sistema da risolvere è:

$$[Y_k^T \nabla^2 J_{\mathcal{H}_k}(w_k) Y_k] d^Y = -Y_k^T \tilde{\nabla} F_{\mathcal{S}_k}(w_k), \quad (5.48)$$

dove $d^Y \in \mathbb{R}^{n-|\mathcal{A}_k|}$ è il vettore delle componenti libere. La direzione di ricerca dell'algoritmo è quindi $d_k = Y_k d^Y$.

5.3.5 Ricerca Lineare Proiettata

Per garantire che il nuovo iterato rimanga all'interno della stessa faccia ortante Ω_k , si utilizza una *proiezione ortogonale* $P(\cdot)$ su Ω_k :

$$P(w_i) = \begin{cases} w_i & \text{se } \text{sign}(w_i) = \text{sign}(z_k^i), \\ 0 & \text{altrimenti.} \end{cases} \quad (5.49)$$

La ricerca lineare determina il passo α_k come il più grande valore nella sequenza $1, \frac{1}{2}, \frac{1}{4}, \dots$ tale che:

$$F_{\mathcal{S}_k}(P[w_k + \alpha_k d_k]) \leq F_{\mathcal{S}_k}(w_k) + \sigma \tilde{\nabla} F_{\mathcal{S}_k}(w_k)^T (P[w_k + \alpha_k d_k] - w_k) \quad (5.50)$$

(Armijo) dove $\sigma \in (0, 1)$ è una costante prefissata. Il nuovo iterato è $w_{k+1} = P[w_k + \alpha_k d_k]$.

5.3.6 Algoritmo Completo

Algoritmo

Newton-CG per Problemi L_1 -Regolarizzati

Input: w_0 (punto iniziale, tipicamente $w_0 = 0$), $\mathcal{H}_0, \mathcal{S}_0$ con $|\mathcal{H}_0| < |\mathcal{S}_0|$, $\nu > 0$ (parametro di regolarizzazione), $\eta, \sigma \in (0, 1)$, $\max_{cg}$ (limite iterazioni CG).

Per ogni iterazione $k = 0, 1, \dots$ fino a convergenza:

1. Calcola $\tilde{\nabla} F_{\mathcal{S}_k}(w_k)$ tramite (5.43) e determina z_k con (5.44). Definisci l'active set $\mathcal{A}_k$ con (5.46).
2. Minimizzazione nel sottospazio
 - (a) Calcola $\tilde{\nabla} F_{\mathcal{S}_k}(w_k) = \nabla J_{\mathcal{S}_k}(w_k) + \nu z_k$.
 - (b) Applica il gradiente coniugato al sistema (5.48). Termina quando il residuo r_k soddisfa

$$\|r_k\| \leq \eta \|Y_k^T \tilde{\nabla} F_{\mathcal{S}_k}(w_k)\|, \quad (5.51)$$

oppure dopo $\max_{cg}$ iterazioni.

- (c) Poni $d_k = Y_k d^Y$.

3. Ricerca lineare proiettata. Determina il più grande $\alpha_k \in \{1, \frac{1}{2}, \frac{1}{4}, \dots\}$ che soddisfi (5.50). Aggiorna

$$w_{k+1} = P[w_k + \alpha_k d_k].$$

4. Re-campionamento. Scegli $\mathcal{H}_{k+1}, \mathcal{S}_{k+1}$ con $|\mathcal{H}_{k+1}| = |\mathcal{H}_0|$ e $|\mathcal{S}_{k+1}| = |\mathcal{S}_0|$.

Nota

L'algoritmo appena descritto è particolarmente efficace nella produzione di soluzioni sparse: la fase di predizione identifica rapidamente le variabili nulle, mentre la fase di sottospazio accelera la convergenza sulle variabili libere sfruttando l'informazione di curvatura dell'Hessiana sottocampionata.

6 Esperimenti e Visualizzazione Interattiva

In questo capitolo descriviamo l'ambiente sperimentale utilizzato per validare gli algoritmi del Capitolo 5, l'architettura software dell'applicazione web interattiva e i risultati numerici ottenuti, confrontando il metodo del gradiente a campione dinamico con SGD e batch gradient descent, e Newton-CG con il gradiente dinamico. I listati Python completi sono riportati nell'Appendice B.

Metodo	Costo per iterazione	Memoria	Ipotesi aggiuntive	Complessità totale
Gradiente a campione dinamico	$O(m n_k)$	$O(m)$	CCV soddisfatta a ogni iterazione; varianza limitata (5.4)	$O\left(\frac{mL}{\lambda\varepsilon}\right)$
Newton-CG con campionamento dinamico	$O(m n_k + m n_h j_k)$			
(j_k : iterazioni CG)	$O(m n_h)$ (sotto-campione Hessiana)	Hessiana sul sottospazio; criterio di arresto (5.35)–(5.36)	sdp esterne iter.	$O\left(\frac{mL}{\lambda\varepsilon}\right)$
Newton-CG con regolarizzazione L_1	come Newton-CG + costo active set	$O(m)$	identificazione corretta faccia ortante (5.41)–(5.46)	come Newton-CG

Tabella 5.2: Confronto dei tre metodi proposti nel Capitolo 5. n_k è la dimensione del batch corrente, $n_h = R n_k$ quella del sottocampione per l'Hessiana, j_k il numero di iterazioni interne del gradiente coniugato, m il numero di variabili.

6.1 Setup Sperimentale

Gli esperimenti sono condotti in un ambiente di *simulazione*: le funzioni obiettivo e i dataset sono generati sinteticamente, seguendo la costruzione del “dataset centrato” descritta nella Sezione 6.2. In questo modo si può controllare esattamente la soluzione w^* e la struttura del problema, e misurare l'errore finale $\|w_k - w^*\|$ senza ambiguità.

Le funzioni test utilizzate sono le seguenti.

- **Quadratica (regressione lineare).** La perdita è $J(w) = \frac{1}{2N} \sum_{i=1}^N (x_i^T w - y_i)^2$, con $N = 1000$ esempi, $m = 10$ variabili, dati x_i generati da una gaussiana standard e $y_i = x_i^T w_{\text{true}} + \varepsilon_i$ con rumore gaussiano. Il numero di condizionamento misurato è $\kappa \approx 1.4$.
- **Quadratica mal condizionata.** Come sopra, ma con feature correlate tra loro, in modo da ottenere $\kappa \approx 107$. Questo problema è rappresentativo dei dataset reali, dove le caratteristiche sono spesso ridondanti.
- **Rosenbrock.** La funzione di Rosenbrock $J(w) = \sum_{j=1}^{m-1} [100(w_{j+1} - w_j^2)^2 + (1 - w_j)^2]$, con minimo $w^* = (1, \dots, 1)$, è usata come esempio di funzione non quadratica con valle stretta e curvatura fortemente variabile. Come discusso nella Sezione 6.3, i metodi del primo ordine falliscono su questo problema, mentre Newton-CG converge rapidamente.

Per ogni problema test, la dimensione del dataset è $N = 1000$ e la dimensionalità è $m = 10$. Il punto iniziale è $w_0 = (2, \dots, 2)$ e la tolleranza per il criterio di arresto $\|\nabla J(w_k)\|_2 < 10^{-6}$. Per il metodo dinamico sono stati testati i valori $\theta \in \{0.1, 0.5, 0.9\}$ della tolleranza nella Condizione di Controllo della Varianza, con dimensione iniziale del batch $n_0 = 16$; per Newton-CG il rapporto di sottocampionamento dell'Hessiana è $R = 0.1$. Il confronto include il gradiente stocastico (SGD) con batch unitario e passo $1/(\lambda k)$, e il gradiente batch completo con passo $1/L$.

Tutti gli esperimenti sono stati eseguiti su un computer portatile con processore Apple Silicon (8 core) e 16 GB di RAM, in ambiente macOS, con Python 3.14, NumPy 2.4 e Matplotlib 3.11. Non è richiesto alcun acceleratore GPU. I tempi riportati sono tempi di esecuzione misurati su una singola esecuzione per ogni configurazione.

6.2 Architettura Software

Per rendere concreti i concetti teorici esposti nel Capitolo 5, è stata realizzata un'**applicazione web interattiva** che implementa i tre algoritmi in un ambiente visivo e modificabile dall'utente. Il codice sorgente è disponibile al seguente repository GitHub:

<https://github.com/alessandrolocurcio/selezione-dinamica-batch>

L'applicazione esegue il codice Python (funzione obiettivo, gradiente, algoritmo) *direttamente nel browser* tramite il runtime Python Pyodide, consentendo all'utente di modificare loss e algoritmo e vedere immediatamente il risultato. La visualizzazione delle superfici e dei percorsi di ottimizzazione è affidata a Plotly (libreria JavaScript). L'interfaccia permette di:

- selezionare o scrivere una funzione obiettivo $J(w)$ con gradiente $\nabla J(w)$ e Hessiana $\nabla^2 J(w)$, scegliendo tra preset predefiniti o codice personalizzato;
- scegliere tra i tre algoritmi discussi (gradiente dinamico, Newton-CG con campionamento dinamico, Newton-CG con regolarizzazione L_1), il cui codice Python è visibile e modificabile;
- variare i parametri dell'algoritmo in tempo reale;
- visualizzare il percorso di ottimizzazione sulla superficie di $J(w)$ (in 3D per funzioni 2D, in 2D per funzioni 1D), con possibilità di scorrere le iterazioni, avviare una riproduzione automatica e ruotare la visualizzazione;
- monitorare metriche in tempo reale (valore di $J(w_k)$, norma del gradiente, dimensione del batch);
- eseguire un'analisi di convergenza che mostra l'errore e $J(w_k)$ per ogni iterazione.

Costruzione del dataset sintetico centrato. Nel codice dell'applicazione, la superficie plottata è la funzione obiettivo teorica $J(w)$, definita dall'utente nel preset della loss. Questa è la funzione che si vorrebbe minimizzare: viene usata per disegnare il grafico, per calcolare i valori del percorso e per mostrare le metriche come $J(w_k)$

e $\|\nabla J(w_k)\|$. L'algoritmo però non minimizza direttamente $J(w)$, ma utilizza un dataset sintetico di N funzioni di perdita individuali $\ell(w; i)$, con $i = 1, \dots, N$, costruito a partire da $J(w)$ perturbando i suoi coefficienti; ogni funzione $\ell(w; i)$ rappresenta il contributo del singolo esempio i . A ogni iterazione l'algoritmo seleziona un batch $\mathcal{S}_k$ di dimensione n_k e calcola il gradiente del batch come $g_k = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \nabla \ell(w_k; i)$; la line search di Armijo usa la loss del batch $J_{\mathcal{S}_k}(w) = \frac{1}{n_k} \sum_{i \in \mathcal{S}_k} \ell(w; i)$. La media su tutti gli N dati è $\hat{J}_N(w) = \frac{1}{N} \sum_{i=1}^N \ell(w; i)$.

Il dataset è costruito in modo che le medie campionarie dei coefficienti delle perturbazioni coincidano *esattamente* con i coefficienti di $J(w)$; pertanto $\hat{J}_N(w) = J(w)$ per ogni w e $\nabla \hat{J}_N(w) = \nabla J(w)$ per ogni w , indipendentemente da N . Questa proprietà è ottenuta sottraendo a ogni perturbazione la propria media campionaria. Quindi $J(w)$ è la funzione plottata, mentre l'algoritmo minimizza $\hat{J}_N(w)$ (o sue approssimazioni su batch). Nel codice $\hat{J}_N(w)$ coincide esattamente con $J(w)$ per ogni N , a differenza di un problema reale dove la coincidenza si ha solo nel limite $N \rightarrow \infty$. In sintesi, la loss teorica $J(w)$ è usata per il plot e le metriche, la loss campionaria totale $\hat{J}_N(w)$ per la condizione di arresto, la loss del batch $J_{\mathcal{S}_k}(w)$ per la line search, e il gradiente del batch g_k per l'aggiornamento dei pesi.

L'implementazione segue la struttura algoritmica del Capitolo 5, con due estensioni rispetto alla formulazione originale [1]: la CCV estesa al subgradiente per L_1 (nel paper il sample size per il caso L_1 è assunto fisso, e gli autori lasciano l'estensione al caso dinamico come lavoro futuro) e il dataset sintetico centrato descritto sopra. Per il resto, l'implementazione è fedele al paper: l'Hessiana nel Newton-CG è calcolata su un sottocampione di dimensione $|\mathcal{H}_k| = R \cdot |\mathcal{S}_k|$; il CG per il caso L_1 usa la tolleranza fissa η della (5.51); la line search di Wolfe è quella degli algoritmi pratici del paper, mentre i passi fissi compaiono solo nell'analisi teorica di complessità.

6.3 Risultati Numerici

Presentiamo i risultati numerici ottenuti nel setup descritto nella Sezione 6.1. La Tabella 6.1 confronta il metodo del gradiente a campione dinamico (Dynamic GD) con SGD e batch gradient descent (Batch GD) sui due problemi quadratici. La Tabella 6.2 confronta Newton-CG con Dynamic GD.

Le figure seguenti illustrano il comportamento qualitativo del metodo. La Figura 6.1 mostra la convergenza del gradiente a campione dinamico sul problema quadratico ben condizionato per i tre valori di θ : come previsto dalla teoria, l'errore $J(w_k) - J(w_*)$ decresce linearmente (scala logaritmica), con una pendenza che dipende da θ . La Figura 6.2 mostra l'evoluzione della dimensione del batch n_k : il batch cresce a scalini quando la CCV viene violata, e rimane invece costante nel caso di batch fisso. La Figura 6.3 confronta il costo totale in valutazioni di gradienti individuali entro un budget di 300 iterazioni: Dynamic GD usa molte meno valutazioni di Batch GD (che valuta l'intero dataset a ogni iterazione) e, a differenza di SGD, raggiunge la precisione richiesta.

Dalla Tabella 6.1 emergono tre osservazioni. In primo luogo, sul problema ben condizionato il metodo dinamico converge in poche iterazioni (14–45) con un errore dell'ordine di 10^{-6} – 10^{-7} , a fronte di un costo per iterazione che cresce progressivamente: la CCV aumenta il batch fino alla dimensione massima N proprio quando il gradiente si avvicina a zero, concentrando la risorsa computazionale dove serve precisione. In secondo luogo, SGD con passo $1/(\lambda k)$ non riesce a scendere al di

Metodo	Parametro	Iterazioni	Tempo (s)	Errore	Max batch
Quadratica ($\kappa \approx 1.4$)					
Dynamic GD	$\theta = 0.1$	14	0.03	6.47×10^{-7}	1000
Dynamic GD	$\theta = 0.5$	18	0.02	6.34×10^{-7}	1000
Dynamic GD	$\theta = 0.9$	45	0.03	1.13×10^{-6}	1000
SGD	$n = 1$	300	< 0.01	4.45×10^{-1}	1
Batch GD	$n = N$	14	< 0.01	1.46×10^{-7}	1000
Quadratica mal condizionata ($\kappa \approx 107$)					
Dynamic GD	$\theta = 0.1$	300	12.82	2.66×10^0	1000
Dynamic GD	$\theta = 0.5$	300	7.33	3.09×10^{-1}	1000
Dynamic GD	$\theta = 0.9$	300	3.21	2.03×10^{-1}	992
SGD	$n = 1$	300	< 0.01	4.11×10^{-1}	1
Batch GD	$n = N$	300	< 0.01	4.99×10^{-2}	1000

Tabella 6.1: Confronto tra Dynamic GD, SGD e Batch GD sui problemi quadratici. Per ogni configurazione sono riportate le iterazioni totali, il tempo di esecuzione, l'errore finale $\|w_k - w^*\|$ e la dimensione massima del batch raggiunta dal metodo dinamico. SGD non raggiunge la tolleranza $\|\nabla J\| < 10^{-6}$ entro il budget di 300 iterazioni.

sotto di un errore dell'ordine di 10^{-1} : il rumore stocastico limita la precisione, come previsto dalla teoria. In terzo luogo, sul problema mal condizionato tutti i metodi del primo ordine degradano sensibilmente: Dynamic GD e Batch GD richiedono le 300 iterazioni del budget senza raggiungere la tolleranza, a causa del numero di condizionamento elevato.

La Tabella 6.2 mostra il vantaggio dell'informazione di curvatura: sul problema mal condizionato Newton-CG converge in 66 iterazioni esterne (con in media meno di 2 iterazioni del CG interno per iterazione) e raggiunge un errore di 1.95×10^{-5} , mentre Dynamic GD non converge nel budget disponibile. Il criterio di arresto adattivo del CG evita iterazioni interne inutili: le iterazioni medie del CG sono molto basse, poiché il CG viene fermato quando il residuo è confrontabile con l'errore di approssimazione dell'Hessiana.

Infine, il problema di Rosenbrock (non quadratico, con valle stretta) conferma qualitativamente le conclusioni: i metodi del primo ordine, incluso Dynamic GD con la strategia dinamica, restano intrappolati nella valle e non raggiungono il minimo in 300 iterazioni, mentre Newton-CG sfrutta la curvatura dell'Hessiana (esatta, in questo caso) e scende rapidamente lungo la valle. Questi risultati motivano l'uso di metodi di secondo ordine per problemi difficili, in accordo con l'analisi teorica del Capitolo 5.

6.4 Visualizzazione Interattiva

L'applicazione web descritta nella Sezione 6.2 consente di osservare direttamente i concetti teorici discussi in questa tesi. L'utente può:

Metodo	Parametro	Iter. est.	Iter. medie CG	Tempo (s)	Errore
Quadratica ($\kappa \approx 1.4$)					
Newton-CG	$R = 0.1$	18	1.1	0.03	5.53×10^{-7}
Dynamic GD	$\theta = 0.5$	18	—	0.02	6.34×10^{-7}
Quadratica mal condizionata ($\kappa \approx 107$)					
Newton-CG	$R = 0.1$	66	1.9	0.24	1.95×10^{-5}
Dynamic GD	$\theta = 0.5$	300	—	7.33	3.09×10^{-1}

Tabella 6.2: Confronto tra Newton-CG e gradiente a campione dinamico. Sono riportate le iterazioni esterne, le iterazioni medie del gradiente coniugato interno e l'errore finale. Newton-CG riduce drasticamente il numero di iterazioni sul problema mal condizionato.

- **sperimentare l'effetto di θ** : selezionando un valore piccolo di θ , la CCV diventa stringente e il batch cresce presto; con θ grande, il batch resta piccolo più a lungo e l'algoritmo procede più rapidamente, ma con un errore finale più alto;
- **osservare la dinamica del batch**: il grafico della dimensione del batch in funzione dell'iterazione mostra i “gradini” di crescita, che si verificano esattamente quando la varianza stimata supera la soglia;
- **confrontare i tre algoritmi** sulla stessa funzione obiettivo, variando in tempo reale i parametri (batch iniziale, rapporto R , passo, regolarizzazione ν), e visualizzando i percorsi sovrapposti sulla superficie di $J(w)$;
- **studiare la convergenza**: la tabella delle iterazioni riporta $J(w_k)$ e l'errore, permettendo di verificare empiricamente il tasso di convergenza lineare del metodo dinamico;
- **modificare il codice**: il codice Python di ogni algoritmo è visibile e modificabile nel browser, consentendo di introdurre varianti e di verificarne l'effetto senza installare nulla.

Il codice completo degli algoritmi eseguiti nell'applicazione è riportato nell'Appendice B; le istruzioni per l'esecuzione e per l'avvio dell'applicazione sono nell'Appendice C.

7 Conclusioni e Lavoro Futuro

7.1 Riassunto dei risultati

In questo lavoro abbiamo studiato la *selezione dinamica della dimensione del campione* negli algoritmi di ottimizzazione per il machine learning su larga scala, seguendo l'approccio di Byrd, Chin, Nocedal e Wu [1]. I risultati principali sono i seguenti.

In primo luogo, abbiamo sviluppato un’analisi teorica completa del metodo del gradiente a campione dinamico. Abbiamo mostrato che, se la varianza stimata del gradiente stocastico è controllata dalla tolleranza θ (Condizione di Controllo della Varianza), la direzione di ricerca è una direzione di discesa e l’algoritmo converge *linearmente*, sia in forma deterministica sia in aspettativa. La complessità totale – il numero di valutazioni di gradienti individuali necessarie per ottenere un errore ε – è $O(mL/(\lambda\varepsilon))$, un bound competitivo con quelli noti per SGD e significativamente migliore su problemi mal condizionati, dove il termine κ^2 di SGD diventa κ .

In secondo luogo, abbiamo esteso la strategia dinamica a un metodo di Newton-CG con sottocampionamento dell’Hessiana, nel quale due campioni distinti vengono usati per il gradiente e per l’Hessiana. Il criterio di arresto del gradiente coniugato interno è adattivo: il CG viene fermato quando il suo residuo è dello stesso ordine di grandezza dell’errore di approssimazione dell’Hessiana, stimato dalla varianza campionaria dei prodotti Hessiana-vettore. Questo evita iterazioni interne inutili e rende il metodo particolarmente efficace su problemi mal condizionati, come confermato dagli esperimenti del Capitolo 6.

In terzo luogo, abbiamo esteso il campionamento dinamico ai problemi con regolarizzazione L_1 , utilizzando il gradiente generalizzato, l’identificazione dell’active set e la ricerca lineare proiettata. Abbiamo infine realizzato un’applicazione web interattiva che implementa i tre algoritmi e ne permette la sperimentazione visuale su funzioni obiettivo modificabili dall’utente.

7.2 Limiti dello studio

Lo studio presenta alcuni limiti che è importante esplicitare.

1. **Ipotesi di convessità forte.** L’analisi di convergenza richiede che J sia λ -fortemente convessa, un’ipotesi non sempre verificata nei problemi reali (ad esempio la perdita logistica non lo è). Come discusso nel Capitolo 3, l’ipotesi può essere aggirata aggiungendo una regolarizzazione $\frac{\gamma}{2}\|w\|^2$, che induce convessità forte con $\lambda = \gamma$, ma introduce un bias nel problema.
2. **Limitazione della varianza.** L’analisi di complessità si basa sull’ipotesi di *limitatezza globale* della varianza (Eq. (5.4) nel Capitolo 5), che può non valere in problemi con perdite non limitate o con code pesanti. In pratica questa ipotesi può essere rilassata richiedendo la limitatezza solo in un intorno del minimo, ma le garanzie teoriche in tal caso sono più deboli.
3. **Dataset sintetico centrato.** L’implementazione interattiva usa un dataset sintetico “centrato”, in cui la media campionaria dei gradienti individuali coincide *esattamente* con il gradiente della funzione obiettivo teorica $J(w)$. Nei problemi reali questa coincidenza vale solo asintoticamente (nel limite $N \rightarrow \infty$), e la varianza dei gradienti individuali ha una struttura più ricca di quella dei dati sintetici.

7.3 Direzioni per lavoro futuro

Dai limiti appena discussi emergono naturalmente alcune direzioni di lavoro futuro.

1. **Rilassamento dell'ipotesi di convessità forte.** Un primo obiettivo è estendere l'analisi alla condizione di *Polyak–Lojasiewicz* [8, 9] (Appendice A.1), che non richiede convessità forte ma conserva la convergenza lineare del valore di funzione. Questa estensione consentirebbe di trattare problemi come la regressione logistica regolarizzata in modo diretto, senza introdurre un bias di regolarizzazione.
2. **Validazione su benchmark reali.** Gli esperimenti presentati in questa tesi usano funzioni sintetiche con un dataset generato artificialmente. Una direzione naturale è la validazione su dataset standard (ad esempio i benchmark LIBSVM o MNIST), confrontando Dynamic GD, Newton-CG e Newton- L_1 con SGD standard in termini di tempo a convergenza, precisione finale e costo totale. Su tali problemi si potrebbero anche misurare gli effetti della struttura di covarianza dei gradienti reali sulla dinamica del batch.
3. **Rapporto di sottocampionamento dell'Hessiana dinamico.** Nel metodo Newton-CG il rapporto $R = |\mathcal{H}_k|/|\mathcal{S}_k|$ tra la dimensione del campione per l'Hessiana e quella per il gradiente è attualmente *fisso*. Un'estensione naturale è rendere dinamico anche questo rapporto, ad esempio aumentandolo quando la curvatura del problema cambia rapidamente o quando il criterio di arresto del CG richiede troppe iterazioni interne, bilanciando il costo dei prodotti Hessiana-vettore con la qualità della direzione di Newton.

A Dimostrazioni

A.1 Dimostrazione delle disuguaglianze di Polyak–Lojasiewicz

Sia w_* l'unico minimo di J e, per semplificare le notazioni, poniamo $J(w_*) = 0$. Allora con le ipotesi strutturali esplicitate sopra valgono le seguenti disuguaglianze:

$$\|\nabla J(w)\|_2^2 \geq 2\lambda J(w), \quad J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|_2^2.$$

Come prima cosa cerchiamo una rappresentazione integrale esatta di $J(w)$: per ottenere una formula che coinvolga esplicitamente l'Hessiana, applichiamo il Teorema Fondamentale del Calcolo due volte.

Prima applicazione: definiamo $\varphi(t) = J(w_* + t(w - w_*))$ per $t \in [0, 1]$. Allora $\varphi(0) = J(w_*) = 0$, $\varphi(1) = J(w)$, e $\varphi'(t) = \nabla J(w_* + t(w - w_*))^T(w - w_*)$. Per il TFC:

$$J(w) = \underbrace{J(w_*)}_{\varphi(0)=0} + \int_0^1 \nabla J(w_* + t(w - w_*))^T(w - w_*) dt. \quad (\text{A.1})$$

Seconda applicazione: applichiamo ora il TFC alla funzione $\psi(t) = \nabla J(w_* + t(w - w_*))$. Si ha $\psi(0) = \nabla J(w_*) = 0$, $\psi(1) = \nabla J(w)$, e $\psi'(t) = \nabla^2 J(w_* + t(w - w_*))(w - w_*)$. Quindi per ogni $t \in [0, 1]$:

$$\nabla J(w_* + t(w - w_*)) = \int_0^t \nabla^2 J(w_* + s(w - w_*))(w - w_*) ds. \quad (\text{A.2})$$

Sostituiamo (A.2) nella (A.1):

$$J(w) = \int_0^1 \left(\int_0^t \nabla^2 J(w_* + s(w - w_*))(w - w_*) ds \right)^T (w - w_*) dt.$$

Poiché $(w - w_*)$ è costante rispetto agli integrali, possiamo riscrivere:

$$J(w) = \int_0^1 \int_0^t (w - w_*)^T \nabla^2 J(w_* + s(w - w_*))(w - w_*) ds dt.$$

La regione di integrazione è $0 \leq s \leq t \leq 1$, che è equivalente a $0 \leq s \leq 1$, $s \leq t \leq 1$. Scambiando l'ordine di integrazione:

$$J(w) = \int_0^1 \int_s^1 (w - w_*)^T \nabla^2 J(w_* + s(w - w_*))(w - w_*) dt ds.$$

L'integrale interno in dt vale $\int_s^1 dt = 1 - s$. Quindi otteniamo la formula finale:

$$J(w) = \int_0^1 (1 - t)(w - w_*)^T \nabla^2 J(w_* + t(w - w_*))(w - w_*) dt. \quad (\text{A.3})$$

Si consideri ora la derivazione della disuguaglianza $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$. Scriviamo la rappresentazione integrale di $J(y)$ a partire da $J(w)$:

$$J(y) = J(w) + \int_0^1 \nabla J(w + t(y - w))^T (y - w) dt. \quad (\text{A.4})$$

Applicando nuovamente il TFC al gradiente:

$$\nabla J(w + t(y - w)) = \nabla J(w) + \int_0^t \nabla^2 J(w + s(y - w))(y - w) ds. \quad (\text{A.5})$$

Sostituendo (A.5) in (A.4):

$$J(y) = J(w) + \nabla J(w)^T (y - w) + \int_0^1 \int_0^t (y - w)^T \nabla^2 J(w + s(y - w))(y - w) ds dt.$$

Dalla convessità forte $\nabla^2 J \succeq \lambda I$, l'integrale doppio è maggiorato dal basso da:

$$\lambda \|y - w\|^2 \int_0^1 \int_0^t 1 ds dt = \frac{\lambda}{2} \|y - w\|^2.$$

Pertanto:

$$J(y) \geq J(w) + \nabla J(w)^T (y - w) + \frac{\lambda}{2} \|y - w\|^2. \quad (\text{A.6})$$

Minimizzando il membro destro rispetto a y si ottiene:

$$\min_y \left[J(w) + \nabla J(w)^T (y - w) + \frac{\lambda}{2} \|y - w\|^2 \right] = J(w) - \frac{1}{2\lambda} \|\nabla J(w)\|^2.$$

Dalla (A.6) segue che $J(y)$ è sempre maggiore o uguale al termine quadratico in y ; quindi il minimo di J sarà maggiore o uguale al minimo di tale termine. Poiché $y = w_*$ è il minimo di J e $J(w_*) = 0$, si ha:

$$0 = J(w_*) \geq J(w) - \frac{1}{2\lambda} \|\nabla J(w)\|^2,$$

da cui la tesi $\|\nabla J(w)\|^2 \geq 2\lambda J(w)$.

Si consideri ora la derivazione della disuguaglianza $J(w) \geq \frac{\lambda}{2L^2} \|\nabla J(w)\|^2$. Dalla rappresentazione integrale del gradiente che si ottiene valutando la (A.2) in $t = 1$:

$$\nabla J(w) = \int_0^1 \nabla^2 J(w_* + t(w - w_*))(w - w_*) dt. \quad (\text{A.7})$$

Passando alla norma:

$$\|\nabla J(w)\| = \left\| \int_0^1 \nabla^2 J(w_* + t(w - w_*))(w - w_*) dt \right\|.$$

Per la disuguaglianza triangolare in forma integrale:

$$\|\nabla J(w)\| \leq \int_0^1 \|\nabla^2 J(w_* + t(w - w_*))(w - w_*)\| dt.$$

Usando la limitatezza $\|\nabla^2 J\| \leq L$, si ha:

$$\|\nabla J(w)\| \leq \int_0^1 L \|w - w_*\| dt = L \|w - w_*\|. \quad (\text{A.8})$$

Da cui:

$$\|\nabla J(w)\| \leq L \|w - w_*\| \implies \|w - w_*\| \geq \frac{1}{L} \|\nabla J(w)\|. \quad (\text{A.9})$$

Elevando al quadrato (A.9):

$$\|w - w_*\|^2 \geq \frac{1}{L^2} \|\nabla J(w)\|^2. \quad (\text{A.10})$$

Dalla (A.3) invece:

$$J(w) = \int_0^1 (1-t) (w - w_*)^T \nabla^2 J(w_* + t(w - w_*)) (w - w_*) dt.$$

Usando la convessità forte $\nabla^2 J \succeq \lambda I$:

$$J(w) \geq \|w - w_*\|^2 \lambda \int_0^1 (1-t) dt.$$

L'integrale vale:

$$\int_0^1 (1-t) dt = \left[t - \frac{t^2}{2} \right]_0^1 = \frac{1}{2}.$$

Quindi:

$$J(w) \geq \frac{\lambda}{2} \|w - w_*\|^2. \quad (\text{A.11})$$

Combinando (A.10) e (A.11):

$$J(w) \geq \frac{\lambda}{2} \|w - w_*\|^2 \geq \frac{\lambda}{2} \cdot \frac{1}{L^2} \|\nabla J(w)\|^2 = \frac{\lambda}{2L^2} \|\nabla J(w)\|^2.$$

Questa è la seconda disuguaglianza cercata.

Con passaggi simili a quelli che sono stati fatti per dimostrare la (A.6) possiamo verificare che applicando il teorema di Taylor con resto integrale e usando $\nabla^2 J \preceq LI$ otteniamo

$$J(y) \leq J(w) + \nabla J(w)^T (y - w) + \frac{L}{2} \|y - w\|^2. \quad (\text{A.12})$$

A.2 Dimostrazione del fattore di correzione per popolazione finita

Il fattore $\frac{N-n_k}{N-1}$ è il **Fattore di Correzione per Popolazione Finita**. Per dimostrare formalmente il motivo per cui moltiplichiamo per questo fattore nel caso in cui accettassimo la possibilità di prendere più volte gli stessi dati nei batch possiamo prima dimostrare la necessità di questo fattore nel caso generale e poi applicarlo al nostro caso specifico: Consideriamo $\bar{X} = \frac{1}{n} \sum_{i \in \mathcal{S}} X_i = \frac{1}{n} \sum_{i=1}^N I_i X_i$ con

$$I_i = \begin{cases} 1 & \text{se } X_i \in \mathcal{S} \\ 0 & \text{se } X_i \notin \mathcal{S} \end{cases} \implies \begin{cases} \mathbb{E}[I_i] = \frac{n}{N}, & \mathbb{E}[I_i I_\ell] = \frac{n(n-1)}{N(N-1)} \\ \text{Var}(I_i) = \frac{n(N-n)}{N^2}, & \text{Cov}(I_i, I_\ell) = -\frac{n(N-n)}{N^2(N-1)} \end{cases}$$

$$\text{Var} \left(\sum_{i \in \mathcal{S}} X_i \right) = \sum_{i=1}^N X_i^2 \text{Var}(I_i) + \sum_{\substack{i, \ell \in \{1, \dots, N\} \\ i \neq \ell}} X_i X_\ell \text{Cov}(I_i, I_\ell)$$

Per verificarlo, basta espandere la definizione di varianza applicata alla combinazione lineare $\sum_{i=1}^N X_i I_i$: si scrive

$$\text{Var} \left(\sum_{i=1}^N X_i I_i \right) = \mathbb{E} \left[\left(\sum_{i=1}^N X_i (I_i - \mathbb{E}[I_i]) \right)^2 \right],$$

si sviluppa il quadrato della somma usando $\left(\sum_{i=1}^N a_i \right)^2 = \sum_{i=1}^N a_i^2 + \sum_{i \neq \ell} a_i a_\ell$ con $a_i = X_i (I_i - \mathbb{E}[I_i])$ (e questa servirà anche dopo, vera perché: $\underbrace{\sum_i \sum_\ell a_i a_\ell}_{(\sum_i a_i)^2} =$

$\sum_i a_i^2 + \sum_{i \neq \ell} a_i a_\ell \iff \sum_{i \neq \ell} a_i a_\ell = (\sum_i a_i)^2 - \sum_i a_i^2$), si applica la linearità dell'aspettazione e si riconoscono le formule per la varianza e covarianza di I

$$\begin{aligned} &= \frac{n(N-n)}{N^2} \sum_{i=1}^N X_i^2 - \frac{n(N-n)}{N^2(N-1)} \sum_{i \neq \ell} X_i X_\ell \\ &= \frac{n(N-n)}{N^2} \left[\sum_{i=1}^N X_i^2 - \frac{1}{N-1} \sum_{i \neq \ell} X_i X_\ell \right] \\ &\quad \sum_{i=1}^N X_i = N\mu \\ &\quad \sum_{i=1}^N X_i^2 = N(\mu^2 + \sigma^2) \end{aligned}$$

Infatti $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2 \iff N\sigma^2 = \sum_{i=1}^N (X_i^2 - 2\mu X_i + \mu^2) \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - 2\mu \sum_{i=1}^N X_i + N\mu^2 \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - 2\mu(N\mu) + N\mu^2 \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - 2N\mu^2 + N\mu^2 \iff N\sigma^2 = \sum_{i=1}^N X_i^2 - N\mu^2 \iff \sum_{i=1}^N X_i^2 = N\sigma^2 + N\mu^2 = N(\mu^2 + \sigma^2)$

$$\sum_{i \neq \ell} X_i X_\ell = \left(\sum_{i=1}^N X_i \right)^2 - \sum_{i=1}^N X_i^2 = N^2 \mu^2 - N(\mu^2 + \sigma^2)$$

$$\begin{aligned}
\sum_{i=1}^N X_i^2 - \frac{1}{N-1} \sum_{i \neq \ell} X_i X_\ell &= N(\mu^2 + \sigma^2) - \frac{1}{N-1} [N^2 \mu^2 - N(\mu^2 + \sigma^2)] \\
&= N(\mu^2 + \sigma^2) - \frac{N^2 \mu^2}{N-1} + \frac{N(\mu^2 + \sigma^2)}{N-1} \\
&= N(\mu^2 + \sigma^2) \left(1 + \frac{1}{N-1}\right) - \frac{N^2 \mu^2}{N-1} = N(\mu^2 + \sigma^2) \frac{N}{N-1} - \frac{N^2 \mu^2}{N-1} \\
&= \frac{N^2(\mu^2 + \sigma^2)}{N-1} - \frac{N^2 \mu^2}{N-1} = \frac{N^2 \sigma^2}{N-1} = N \sigma^2 \frac{N}{N-1} \\
\text{Var} \left(\sum_{i \in \mathcal{S}} X_i \right) &= \frac{n(N-n)}{N^2} \cdot N \sigma^2 \frac{N}{N-1} = \frac{n(N-n)}{N-1} \sigma^2 \\
\text{Var}(\bar{X}) &= \frac{1}{n^2} \text{Var} \left(\sum_{i \in \mathcal{S}} X_i \right) = \frac{1}{n^2} \cdot \frac{n(N-n)}{N-1} \sigma^2 = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}
\end{aligned}$$

Nella dimostrazione generale con le variabili X_i , poniamo:

- $X_i \longleftrightarrow \nabla \ell(w_k; i)$ (gradiente della funzione di perdita sull'esempio i -esimo, valutato in w_k)
- $\mu \longleftrightarrow \nabla J(w_k) = \mathbb{E}_{i \sim \text{Unif}\{1, \dots, N\}} [\nabla \ell(w_k; i)] = \frac{1}{N} \sum_{i=1}^N \nabla \ell(w_k; i)$
- $\sigma^2 \longleftrightarrow \mathcal{V}_j(w_k)$ per ogni $j = 1, \dots, m$, dove

$$\mathcal{V}(w_k) := \frac{1}{N} \sum_{i=1}^N (\nabla \ell(w_k; i) - \nabla J(w_k))^2 \in \mathbb{R}^m$$

è la versione vettoriale di σ^2 nel caso multidimensionale.

Applicando la formula generale $\text{Var}(\bar{X}) = \frac{\mathcal{V}}{n_k} \cdot \frac{N-n_k}{N-1}$ a ogni componente $j = 1, \dots, m$:

$$\text{Var}(\nabla J_{\mathcal{S}_k}(w_k)) = \frac{\mathcal{V}(w_k)}{n_k} \cdot \frac{N-n_k}{N-1}$$

e quindi, in norma $\|\cdot\|_1$:

$$\|\text{Var}(\nabla J_{\mathcal{S}_k}(w_k))\|_1 = \frac{\|\mathcal{V}(w_k)\|_1}{n_k} \cdot \frac{N-n_k}{N-1}.$$

Poiché $\mathcal{V}(w_k)$ è ignoto, lo stimiamo con la varianza campionaria

$$\hat{\mathcal{V}}(w_k) := \frac{1}{n_k - 1} \sum_{i \in \mathcal{S}_k} (\nabla \ell(w_k; i) - \nabla J_{\mathcal{S}_k}(w_k))^2,$$

ottenendo la condizione di controllo della varianza:

$$\frac{\|\hat{\mathcal{V}}\|_1}{n_k} \cdot \frac{N-n_k}{N-1} \leq \theta^2 \|\nabla J_{\mathcal{S}_k}(w_k)\|^2.$$

A.3 Dimostrazione delle formule per α_k e β_k nel Metodo del Gradiente Coniugato

Consideriamo il funzionale quadratico

$$\phi(x) = \frac{1}{2}x^T A x - b^T x, \quad A = A^T > 0. \quad (\text{A.13})$$

Sia x^* il minimo, soluzione di $Ax^* = b$. Definiamo

$$\begin{cases} e^k = x^* - x^k, \\ r^k = b - Ax^k, \end{cases} \quad \xRightarrow{Ax^* = b} \quad r^k = Ae^k. \quad (\text{A.14})$$

L'aggiornamento del metodo è

$$\begin{cases} x^{k+1} = x^k + \alpha_k p^k, \\ p^k = r^k + \beta_k p^{k-1}, \quad p^0 = r^0 \end{cases} \quad (\text{A.15})$$

da cui, per la definizione di e^k ,

$$e^{k+1} = e^k - \alpha_k p^k. \quad (\text{A.16})$$

Il metodo minimizza $\|e^{k+1}\|_A^2$ nel piano $e^k + \text{span}(p^k, p^{k-1})$. Definiamo

$$F(\alpha, \gamma) = \|e^k + \alpha p^k + \gamma p^{k-1}\|_A^2. \quad (\text{A.17})$$

Poiché $\|z\|_A^2 = z^T A z$, con $z = e^k + \alpha p^k + \gamma p^{k-1}$:

$$\begin{aligned} F(\alpha, \gamma) &= (e^k + \alpha p^k + \gamma p^{k-1})^T A (e^k + \alpha p^k + \gamma p^{k-1}) \\ &= \|e^k\|_A^2 + 2\alpha(e^k)^T A p^k + 2\gamma(e^k)^T A p^{k-1} \\ &\quad + \alpha^2 \|p^k\|_A^2 + 2\alpha\gamma(p^k)^T A p^{k-1} + \gamma^2 \|p^{k-1}\|_A^2. \end{aligned} \quad (\text{A.18})$$

Annullando le derivate parziali:

$$\begin{cases} (e^k)^T A p^k + \alpha \|p^k\|_A^2 + \gamma (p^k)^T A p^{k-1} = 0, \\ (e^k)^T A p^{k-1} + \alpha (p^k)^T A p^{k-1} + \gamma \|p^{k-1}\|_A^2 = 0. \end{cases} \quad (\text{A.19})$$

Per la scelta di α_{k-1} (minimo lungo p^{k-1}):

$$\frac{d}{d\alpha} \phi(x^{k-1} + \alpha p^{k-1}) \Big|_{\alpha=\alpha_{k-1}} = 0 \implies \nabla \phi(x^k)^T p^{k-1} = 0 \implies (r^k)^T p^{k-1} = 0. \quad (\text{A.20})$$

Usando $r^k = Ae^k$ e la simmetria di A :

$$(e^k)^T A p^{k-1} = (Ae^k)^T p^{k-1} = (r^k)^T p^{k-1} = 0. \quad (\text{A.21})$$

Si noti l'ordine logico della deduzione: si applica prima la (A.21) alla seconda equazione del sistema (A.19) il termine $(e^k)^T A p^{k-1}$ si annulla e si ottiene $\gamma \|p^{k-1}\|_A^2 = 0$, da cui $\gamma = 0$; la proprietà (A.23), cioè $(p^k)^T A p^{k-1} = 0$, segue poi come conseguenza della prima equazione.

La minimizzazione nel piano implica le condizioni di ortogonalità

$$e^{k+1} \perp_A p^k \quad \text{e} \quad e^{k+1} \perp_A p^{k-1}. \quad (\text{A.22})$$

Dalla seconda, con $e^{k+1} = e^k - \alpha_k p^k$ e (A.21):

$$(e^k - \alpha_k p^k)^T A p^{k-1} = 0 \implies -\alpha_k (p^k)^T A p^{k-1} = 0 \xrightarrow{\alpha_k \neq 0} (p^k)^T A p^{k-1} = 0. \quad (\text{A.23})$$

Sfruttando (A.21) e (A.23) nel sistema (A.19):

$$\begin{cases} (e^k)^T A p^k + \alpha \|p^k\|_A^2 = 0, \\ \gamma \|p^{k-1}\|_A^2 = 0, \end{cases} \implies \gamma = 0, \quad \alpha = -\frac{(e^k)^T A p^k}{\|p^k\|_A^2}. \quad (\text{A.24})$$

Ora, $(e^k)^T A p^k = (r^k)^T p^k$ e da (A.20) $r^k \perp p^{k-1}$; quindi

$$(r^k)^T p^k = (r^k)^T (r^k + \beta_k p^{k-1}) = \|r^k\|^2. \quad (\text{A.25})$$

Pertanto

$$\alpha_k = \frac{\|r^k\|^2}{\|p^k\|_A^2} = \frac{(r^k)^T r^k}{(p^k)^T A p^k}. \quad (\text{A.26})$$

Per β_k , da (A.23) e $p^k = r^k + \beta_k p^{k-1}$:

$$(r^k + \beta_k p^{k-1})^T A p^{k-1} = 0 \implies \beta_k = -\frac{(r^k)^T A p^{k-1}}{(p^{k-1})^T A p^{k-1}}. \quad (\text{A.27})$$

Dall'aggiornamento del residuo:

$$r^k = r^{k-1} - \alpha_{k-1} A p^{k-1} \implies A p^{k-1} = \frac{r^{k-1} - r^k}{\alpha_{k-1}}. \quad (\text{A.28})$$

Al numeratore di (A.27):

$$(r^k)^T A p^{k-1} = \frac{(r^k)^T r^{k-1} - (r^k)^T r^k}{\alpha_{k-1}} \stackrel{(r^k)^T r^{k-1}=0}{=} -\frac{(r^k)^T r^k}{\alpha_{k-1}}. \quad (\text{A.29})$$

Dimostrazione di $(r^k)^T r^{k-1} = 0$: Mostriamo per induzione che $r^k \perp p^j$ per $j \leq k-1$.

- Base: $k=1$, (A.20) dà $r^1 \perp p^0$.
- Passo: supponiamo $r^{k-1} \perp p^j$ per $j \leq k-2$. Per $r^k = r^{k-1} - \alpha_{k-1} A p^{k-1}$ e $j \leq k-2$:

$$(r^k)^T p^j = (r^{k-1})^T p^j - \alpha_{k-1} (p^{k-1})^T A p^j = 0.$$

Inoltre (A.20) dà $(r^k)^T p^{k-1} = 0$. Quindi $r^k \perp p^j$ per $j \leq k-1$.

In particolare $r^k \perp p^{k-2}$. Da $p^{k-1} = r^{k-1} + \beta_{k-1} p^{k-2}$:

$$0 = (r^k)^T p^{k-1} = (r^k)^T r^{k-1} + \beta_{k-1} (r^k)^T p^{k-2} \implies (r^k)^T r^{k-1} = 0. \quad (\text{A.30})$$

Al denominatore di (A.27), usando (A.26) per $k-1$:

$$(p^{k-1})^T A p^{k-1} = \frac{(r^{k-1})^T r^{k-1}}{\alpha_{k-1}}. \quad (\text{A.31})$$

Sostituendo (A.29) e (A.31) in (A.27):

$$\beta_k = -\frac{-\frac{(r^k)^T r^k}{\alpha_{k-1}}}{\frac{(r^{k-1})^T r^{k-1}}{\alpha_{k-1}}} = \frac{(r^k)^T r^k}{(r^{k-1})^T r^{k-1}}. \quad (\text{A.32})$$

Abbiamo quindi dimostrato che le condizioni di ortogonalità (A.22) portano a:

$$\alpha_k = \frac{(r^k)^T r^k}{(p^k)^T A p^k}, \quad \beta_k = \frac{(r^k)^T r^k}{(r^{k-1})^T r^{k-1}} \quad (\text{A.33})$$

con

$$p^k = r^k + \beta_k p^{k-1}, \quad x^{k+1} = x^k + \alpha_k p^k. \quad (\text{A.34})$$

Equivalenza delle formule per α_k . Nel documento (Nota Tecnica) si afferma che le formule $\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}$ e $\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$ sono equivalenti. Dimostriamo questa equivalenza.

Prendendo la condizione di stazionarietà (A.20), ovvero $(r^k)^T p^{k-1} = 0$, e sostituendo l'aggiornamento del residuo (A.28), $r^k = r^{k-1} - \alpha_{k-1} A p^{k-1}$, si ottiene:

$$\begin{aligned} 0 &= (r^k)^T p^{k-1} = (r^{k-1} - \alpha_{k-1} A p^{k-1})^T p^{k-1} = (r^{k-1})^T p^{k-1} - \alpha_{k-1} (p^{k-1})^T A p^{k-1} \\ &\implies (r^{k-1})^T p^{k-1} - \alpha_{k-1} (p^{k-1})^T A p^{k-1} = 0. \end{aligned} \quad (\text{A.35})$$

Ora, l'aggiornamento del residuo nel metodo del gradiente coniugato è:

$$r_k = r_{k-1} - \alpha_{k-1} A p_{k-1}. \quad (\text{A.36})$$

Moltiplichiamo scalarmente la (A.36) per p_{k-1} :

$$r_k^T p_{k-1} = r_{k-1}^T p_{k-1} - \alpha_{k-1} p_{k-1}^T A p_{k-1}.$$

Ma il membro destro è esattamente zero per la (A.35). Quindi:

$$r_k^T p_{k-1} = 0. \quad (\text{A.37})$$

Questo risultato è valido per ogni $k \geq 1$ e deriva unicamente dalla line search esatta al passo precedente.

Ora, nella direzione di ricerca del gradiente coniugato si ha:

$$p_k = r_k + \beta_k p_{k-1}. \quad (\text{A.38})$$

Moltiplichiamo scalarmente la (A.38) per r_k :

$$r_k^T p_k = r_k^T r_k + \beta_k r_k^T p_{k-1}.$$

Usando la (A.37), il secondo termine si annulla:

$$r_k^T p_k = r_k^T r_k. \quad (\text{A.39})$$

Sostituendo la (A.39) nella formula $\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}$, otteniamo:

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}. \quad (\text{A.40})$$

Abbiamo quindi dimostrato che:

$$\frac{r_k^T p_k}{p_k^T A p_k} = \frac{r_k^T r_k}{p_k^T A p_k}.$$

Le due formule per α_k sono quindi equivalenti. La formula con $r_k^T r_k$ è preferita nelle implementazioni numeriche perché è numericamente più stabile, poiché non dipende dall'ortogonalità numerica di $r_k^T p_{k-1}$, che in presenza di errori di arrotondamento non è esattamente zero.

A.4 Spiegazione delle condizioni sul passo α_k

La condizione di Armijo introduce un limite superiore per il valore della funzione lungo la direzione di ricerca: il passo α è accettato se $f(x_k + \alpha p)$ si trova al di sotto della retta $f(x_k) + c_1 \alpha \nabla f(x_k)^T p$, e rifiutato altrimenti. La condizione di curvatura di Wolfe impone invece un limite inferiore per la derivata $f'(\alpha)$ lungo la direzione.

La condizione di Armijo richiede che

$$f(x_k + \alpha p) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p,$$

con $c_1 \in (0, 1)$ (tipicamente 10^{-4}). La retta al membro destro ha pendenza $c_1 \nabla f(x_k)^T p$, meno ripida della tangente in $\alpha = 0$, e funge da *upper bound*: passi che fanno superare questa retta vengono rifiutati e ridotti. Più c_1 è piccolo, più la condizione è debole e più passi grandi sono accettati.

La condizione di curvatura di Wolfe, con $g(\alpha) = f(x_k + \alpha p)$ e $g'(\alpha) = \nabla f(x_k + \alpha p)^T p$, richiede

$$g'(\alpha) \geq c_2 g'(0), \quad c_2 \in (c_1, 1),$$

dove $g'(0) = \nabla f(x_k)^T p < 0$. Poiché $c_2 < 1$, $c_2 g'(0)$ è meno negativo di $g'(0)$: la condizione è un *lower bound* sulla derivata, che scarta i passi troppo piccoli (per $\alpha \rightarrow 0^+$, $g'(\alpha) \rightarrow g'(0)$, che non soddisfa la disuguaglianza).

La condizione $0 < c_1 < c_2 < 1$ garantisce che le due disuguaglianze siano compatibili: Armijo (limite superiore su f) e Wolfe (limite inferiore su g') definiscono un intervallo non vuoto di α accettabili. Se $c_1 \geq c_2$, le due condizioni possono diventare contraddittorie. In sintesi, Armijo impedisce passi troppo grandi, Wolfe impedisce passi troppo piccoli.

B Listati Python completi

In questa appendice sono riportati i listati Python completi dei tre algoritmi discussi nel Capitolo 5 e implementati nell'applicazione interattiva (Capitolo 6). I listati fanno riferimento alle seguenti funzioni ausiliarie, definite dall'utente e dipendenti dal dataset:

- `loss_i(w, i)`: perdita individuale $\ell(w; i)$,
- `grad_i(w, i)`: gradiente individuale $\nabla \ell(w; i)$,
- `hessvec_i(w, i, v)`: prodotto $\nabla^2 \ell(w; i) v$,
- `grad_full(w)`: gradiente esatto $\nabla J(w)$ (usato solo per il criterio di arresto),
- N : dimensione del dataset.

B.1 Listato B.1: metodo del gradiente a campione dinamico

Dynamic GD

```
import numpy as np

def dynamic_gd(w0, theta, max_iter, alpha, batch0):
    w = np.array(w0, dtype=float)
    n = max(batch0, 2)
    history = [w.copy().tolist()]
    batch_sizes = [n]

    for k in range(max_iter):
        indices = np.random.choice(N, size=n, replace=False)
        grads = np.array([grad_i(w, i) for i in indices])
        g = np.mean(grads, axis=0)

        # Condizione di Controllo della Varianza (CCV)
        if n > 1:
            var_vec = np.var(grads, axis=0, ddof=1)
        else:
            var_vec = np.zeros_like(g)
        V_norm1 = np.sum(var_vec)

        gg = np.dot(g, g)
        if gg > 1e-16:
            if V_norm1 / n > theta**2 * gg:
                n_new = int(np.ceil(V_norm1 / (theta**2 * gg))) + 1
                n = min(n_new, N)

        # Line search di Wolfe sul batch corrente
        def J_batch(w_curr):
            return np.mean([loss_i(w_curr, i) for i in indices])

        c1, c2 = 1e-4, 0.9
        step = alpha
        J_curr = J_batch(w)
        g_norm2 = np.dot(g, g)
        d = -g
        gd = -g_norm2
        if g_norm2 > 1e-16:
            for _ in range(30):
                w_new = w + step * d
                if J_batch(w_new) <= J_curr + c1 * step * gd:
                    g_new = np.mean([grad_i(w_new, i) for i in
                                     indices], axis=0)
                    if np.dot(g_new, d) >= c2 * gd:
                        break
                step *= 0.5
            else:
                step = 0.0
```

```

        w = w + step * d

    if np.linalg.norm(grad_full(w)) < 1e-6:
        history.append(w.copy().tolist())
        batch_sizes.append(n)
        break

    history.append(w.copy().tolist())
    batch_sizes.append(n)

    return history, batch_sizes

history, batch_sizes = dynamic_gd(w0, theta, max_iter, alpha, batch0)

```

B.2 Listato B.2: Newton-CG con campionamento dinamico

Newton-CG

```

import numpy as np

def cg(A, b, gamma, maxcg):
    """Gradiente coniugato per risolvere A x = b (A operatore
    Hessiana-vettore)."""
    x = np.zeros_like(b)
    r = b - A(x)
    p = r.copy()
    rr = np.dot(r, r)
    for _ in range(maxcg):
        Ap = A(p)
        pHp = np.dot(p, Ap)
        if pHp <= 1e-14:
            break
        alpha = rr / pHp
        x = x + alpha * p
        r_new = r - alpha * Ap
        rr_new = np.dot(r_new, r_new)
        # Test di arresto adattivo: residuo confrontabile con la
        # soglia
        if rr_new <= gamma * np.dot(x, x) + 1e-16:
            return x
        beta = rr_new / rr
        p = r_new + beta * p
        r = r_new
        rr = rr_new
    return x

def newton_cg(w0, theta, max_iter, alpha, batch0, R, maxcg):
    w = np.array(w0, dtype=float)
    n = max(batch0, 2)
    history, batch_sizes = [w.copy().tolist()], [n]

```



```

for k in range(max_iter):
    indices_S = np.random.choice(N, size=n, replace=False)
    g = np.mean([grad_i(w, i) for i in indices_S], axis=0)

    # Sottocampione per l'Hessiana
    n_h = min(max(1, int(round(R * n))), N)
    indices_H = np.random.choice(indices_S, size=n_h,
    → replace=False)
    Hv = lambda v: np.mean([hessvec_i(w, i, v) for i in
    → indices_H], axis=0)

    # Coefficiente gamma: varianza dei prodotti Hessiana-vettore
    → lungo p0
    p0 = -g
    p0_norm2 = np.dot(p0, p0)
    gamma = 0.0
    if p0_norm2 > 1e-16 and n_h > 1:
        Hp0 = np.array([hessvec_i(w, i, p0) for i in indices_H])
        gamma = np.sum(np.var(Hp0, axis=0, ddof=1)) / (n_h *
        → p0_norm2)

    d = cg(Hv, -g, gamma, maxcg)

    # Line search di Wolfe lungo d
    J_batch = lambda wc: np.mean([loss_i(wc, i) for i in
    → indices_S])
    c1, c2 = 1e-4, 0.9
    step, J_w = alpha, J_batch(w)
    gd = np.dot(g, d)
    if gd >= 0:
        d = -g
        gd = -np.dot(g, g)
    for _ in range(30):
        w_new = w + step * d
        if J_batch(w_new) <= J_w + c1 * step * gd:
            g_new = np.mean([grad_i(w_new, i) for i in
            → indices_S], axis=0)
            if np.dot(g_new, d) >= c2 * gd:
                break
            step *= 0.5
    else:
        step = 0.0
    w = w + step * d

    history.append(w.copy().tolist())
    batch_sizes.append(n)

    # CCV sul nuovo campione
    indices_new = np.random.choice(N, size=n, replace=False)
    g_new = np.mean([grad_i(w, i) for i in indices_new], axis=0)

```

```

var_vec = (np.var([grad_i(w, i) for i in indices_new],
                 axis=0, ddof=1)
            if n > 1 else np.zeros_like(g_new))
V_norm1, gg_new = np.sum(var_vec), np.dot(g_new, g_new)
if gg_new > 1e-16 and V_norm1 / n > theta**2 * gg_new:
    n = min(int(np.ceil(V_norm1 / (theta**2 * gg_new))) + 1,
            N)

if np.linalg.norm(grad_full(w)) < 1e-6:
    break
return history, batch_sizes

history, batch_sizes = newton_cg(w0, theta, max_iter, alpha, batch0,
                                R, maxcg)

```

B.3 Listato B.3: Newton-CG per problemi L_1 -regolarizzati

Newton-L1

```

import numpy as np

def newton_l1(w0, theta, max_iter, alpha, batch0, nu, sigma, maxcg,
             eta=0.5, R=0.1):
    w = np.array(w0, dtype=float)
    n = max(batch0, 2)
    history = [w.copy().tolist()]
    batch_sizes = [n]

    # F_batch: obiettivo regolarizzato sul batch
    def F_batch(v, indices):
        Jb = np.mean([loss_i(v, i) for i in indices])
        return Jb + nu * np.sum(np.abs(v))

    # subgrad_batch: gradiente generalizzato (6.3)
    def subgrad_batch(v, indices):
        grads = np.array([grad_i(v, i) for i in indices])
        gJ = np.mean(grads, axis=0)
        g = np.zeros_like(v)
        for i in range(len(v)):
            if v[i] > 0:
                g[i] = gJ[i] + nu
            elif v[i] < 0:
                g[i] = gJ[i] - nu
            else:
                if gJ[i] < -nu:
                    g[i] = gJ[i] + nu
                elif gJ[i] > nu:
                    g[i] = gJ[i] - nu
                else:
                    g[i] = 0.0

```

```

    return g

# project_orthant: proiezione sulla faccia ortante Omega_k (6.5)
def project_orthant(v, z):
    res = v.copy()
    for i in range(len(v)):
        if z[i] != 0 and np.sign(res[i]) != z[i]:
            res[i] = 0.0
    return res

for k in range(max_iter):
    indices_S = np.random.choice(N, size=n, replace=False)
    grads = np.array([grad_i(w, i) for i in indices_S])
    g_batch = np.mean(grads, axis=0)

    # vettore z_k che caratterizza la faccia ortante (6.4)
    z = np.where(w > 0, 1,
                np.where(w < 0, -1,
                        np.where(g_batch < -nu, 1,
                                np.where(g_batch > nu, -1, 0))))

    sg = subgrad_batch(w, indices_S)
    sgn = np.linalg.norm(sg)
    if sgn < 1e-10:
        history.append(w.copy().tolist())
        batch_sizes.append(n)
        break

    # Hessiana sottocampionata sulle variabili libere
    n_h = min(max(1, int(round(R * n))), N)
    indices_H = np.random.choice(indices_S, size=n_h,
                                  replace=False)
    free = (z != 0)
    d = np.zeros_like(w)
    if np.any(free):
        g_free = sg[free]

    def Hv(v_full):
        return np.mean([hessvec_i(w, i, v_full) for i in
                        indices_H],
                        axis=0)

    def Hv_free(v_free):
        v_full = np.zeros_like(w)
        v_full[free] = v_free
        return Hv(v_full)[free]

    # CG Hessian-free sul sottospazio libero
    tol_cg = eta * np.linalg.norm(g_free)
    d_free = np.zeros(np.sum(free))
    r = -g_free.copy()

```

```

    p = r.copy()
    rr = np.dot(r, r)
    for _ in range(maxcg):
        Hp = Hv_free(p)
        pHp = np.dot(p, Hp)
        if pHp <= 1e-14:
            if np.linalg.norm(d_free) < 1e-14:
                d_free = -g_free.copy()
            break
        alpha_cg = rr / pHp
        d_free = d_free + alpha_cg * p
        r_new = r - alpha_cg * Hp
        rr_new = np.dot(r_new, r_new)
        if np.sqrt(rr_new) <= tol_cg:
            break
        beta = rr_new / rr
        p = r_new + beta * p
        r = r_new
        rr = rr_new
    d[free] = d_free

# Ricerca lineare proiettata (Armijo con backtracking)
step = alpha
F_w = F_batch(w, indices_S)
sg_d = np.dot(sg, d)
if sg_d >= 0:
    d = -sg
    sg_d = -np.dot(sg, sg)
w_new = w.copy()
for _ in range(20):
    w_trial = project_orthant(w + step * d, z)
    if F_batch(w_trial, indices_S) <= F_w + sigma * step *
        sg_d:
        w_new = w_trial
        break
    step *= 0.5
    if step < 1e-12:
        w_new = w.copy()
        break
w = w_new

# CCV estesa al gradiente della parte liscia
indices_new = np.random.choice(N, size=n, replace=False)
grads_new = np.array([grad_i(w, i) for i in indices_new])
g_new = np.mean(grads_new, axis=0)
if n > 1:
    var_vec = np.var(grads_new, axis=0, ddof=1)
else:
    var_vec = np.zeros_like(g_new)
V_norm1 = np.sum(var_vec)
gg_new = np.dot(g_new, g_new)

```

```

    if gg_new > 1e-16 and V_norm1 / n > theta**2 * gg_new:
        n_new = int(np.ceil(V_norm1 / (theta**2 * gg_new))) + 1
        n = min(n_new, N)

    history.append(w.copy().tolist())
    batch_sizes.append(n)
    if np.linalg.norm(grad_full(w)) < 1e-6:
        break
    return history, batch_sizes

history, batch_sizes = newton_l1(w0, theta, max_iter, alpha, batch0,
                                nu, sigma, maxcg, eta)

```

C Istruzioni per l'esecuzione

In questa appendice sono raccolte le istruzioni per eseguire il codice Python presentato nell'Appendice B e per avviare l'applicazione web interattiva descritta nella Sezione 6.2.

C.1 Dipendenze

Il codice richiede Python 3.9 o successivo e le seguenti librerie:

- **numpy** (versione ≥ 1.21) – calcolo numerico vettoriale;
- **matplotlib** (versione ≥ 3.5) – generazione dei grafici di convergenza e dei percorsi di ottimizzazione;
- **plotly** (versione ≥ 5.0) – visualizzazioni interattive nell'applicazione web;
- **pyodide** – runtime Python nel browser per l'esecuzione del codice degli algoritmi (usato dall'applicazione web).

C.2 Installazione

Si consiglia di creare un ambiente virtuale dedicato e installare le dipendenze con `pip`:

```

python3 -m venv .venv
source .venv/bin/activate          # su Windows: .venv\Scripts\activate
pip install --upgrade pip
pip install numpy matplotlib plotly

```

C.3 Esecuzione degli esperimenti numerici

Gli esperimenti del Capitolo 6 (convergenza, dinamica del batch e confronto tra metodi) possono essere riprodotti eseguendo lo script `sim_exp.py`, che genera automaticamente le figure in formato PDF/PNG e le tabelle dei risultati in formato LaTeX:

```
python3 sim_exp.py
```

Lo script accetta i parametri descritti nel Capitolo 6 (numero di esempi N , dimensionalità m , tolleranza θ , rapporto R) e stampa a video, per ogni funzione test, il numero di iterazioni, il tempo di esecuzione, l'errore finale $\|w_k - w^*\|$ e la dimensione massima del batch raggiunta.

C.4 Esecuzione dei singoli algoritmi

I listati dell'Appendice B possono essere eseguiti anche in modo isolato, previa definizione delle funzioni ausiliarie `loss_i`, `grad_i`, `hessvec_i`, `grad_full` e della costante N , che dipendono dal dataset. Un esempio completo per la regressione lineare è incluso nello script `sim_exp.py`.

C.5 Avvio dell'applicazione web

L'applicazione web interattiva è un'applicazione a pagina singola (HTML + JavaScript) che esegue il codice Python nel browser tramite Pyodide: non è necessario un server dedicato. È sufficiente aprire il file HTML in un browser moderno (Chrome, Firefox, Safari, Edge). Per lo sviluppo locale si può utilizzare un semplice server HTTP statico:

```
python3 -m http.server 8000
```

e quindi visitare `http://localhost:8000`.

C.6 Requisiti di sistema

Gli esperimenti riportati in questo elaborato sono stati eseguiti su un computer portatile con processore Apple Silicon (8 core) e 16 GB di RAM, in ambiente macOS, utilizzando Python 3.14, NumPy 2.4 e Matplotlib 3.11. Il costo complessivo della simulazione (tre problemi test, tre valori di θ e quattro algoritmi) è inferiore a due minuti; nessun acceleratore GPU è richiesto, poiché tutti i calcoli sono operazioni vettoriali su array NumPy di dimensione al più $N \times m$.

Riferimenti bibliografici

- [1] R. H. Byrd, G. M. Chin, J. Nocedal, and Y. Wu, "Sample size selection in optimization methods for machine learning," *Mathematical Programming, Series A*, vol. 134, no. 1, pp. 127–155, 2012.
- [2] L. Bottou and O. Bousquet, "The tradeoffs of large scale learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 20, 2008, pp. 161–168.
- [3] L. Bottou, F. E. Curtis, and J. Nocedal, "Optimization methods for large-scale machine learning," *SIAM Review*, vol. 60, no. 2, pp. 223–311, 2018.
- [4] H. Robbins and S. Monro, "A stochastic approximation method," *The Annals of Mathematical Statistics*, vol. 22, no. 3, pp. 400–407, 1951.

- [5] R. Johnson and T. Zhang, “Accelerating stochastic gradient descent using predictive variance reduction,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 26, 2013, pp. 315–323.
- [6] A. Defazio, F. Bach, and S. Lacoste-Julien, “SAGA: A fast incremental gradient method with support for non-strongly convex composite objectives,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 1646–1654.
- [7] J. Nocedal and S. J. Wright, *Numerical Optimization*, 2nd ed., Springer Series in Operations Research and Financial Engineering, New York: Springer, 2006.
- [8] B. T. Polyak, “Gradient methods for the minimization of functionals,” *USSR Computational Mathematics and Mathematical Physics*, vol. 3, no. 4, pp. 864–878, 1963 (traduzione inglese, 1964).
- [9] H. Karimi, J. Nutini, and M. Schmidt, “Linear convergence of gradient and proximal-gradient methods under the Polyak–Łojasiewicz condition,” in *European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases (ECML PKDD)*, 2016, pp. 795–811.
- [10] R. Tibshirani, “Regression shrinkage and selection via the lasso,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 58, no. 1, pp. 267–288, 1996.
- [11] A. Beck and M. Teboulle, “A fast iterative shrinkage-thresholding algorithm for linear inverse problems,” *SIAM Journal on Imaging Sciences*, vol. 2, no. 1, pp. 183–202, 2009.
- [12] R. S. Dembo and T. Steihaug, “Truncated-Newton algorithms for large-scale unconstrained optimization,” *Mathematical Programming*, vol. 26, no. 2, pp. 190–212, 1983.
- [13] J. R. Shewchuk, “An introduction to the conjugate gradient method without the agonizing pain,” Technical Report CMU-CS-94-125, Carnegie Mellon University, 1994.
- [14] R. H. Byrd, G. M. Chin, W. Neveitt, and J. Nocedal, “On the use of stochastic Hessian information in optimization methods for machine learning,” *SIAM Journal on Optimization*, vol. 21, no. 3, pp. 894–1009, 2011.




Figura 5.5: Schema del metodo Newton-CG per problemi con regolarizzazione L_1 : il gradiente generalizzato determina l'active set e la faccia ortante, il CG risolve il sistema ridotto sulle variabili libere e la ricerca lineare proiettata mantiene le variabili dell'active set a zero.




Figura 6.1: Convergenza $J(w_k) - J(w_*)$ in scala logaritmica del metodo del gradiente a campione dinamico sul problema quadratico ($\kappa \approx 1.4$) per $\theta \in \{0.1, 0.5, 0.9\}$.




Figura 6.2: Evoluzione della dimensione del batch n_k con la strategia dinamica (CCV) rispetto a un batch fisso. Il batch cresce automaticamente quando ci si avvicina al minimo.




Figura 6.3: Numero totale di valutazioni di gradienti individuali entro un budget di 300 iterazioni sul problema quadratico ben condizionato. SGD non raggiunge la tolleranza $\|\nabla J\| < 10^{-6}$ entro il budget.